

个性化推荐系统研究方法综述

余江龙¹, 宋腾飞^{2*}, 汪德超¹, 李海龙¹, 马正忠¹

(1. 云南电网有限责任公司丽江供电局, 云南 丽江 674100; 2. 昆明理工大学 交通工程学院, 云南 昆明 650500)

摘要: 文章首先介绍了推荐系统的基本概念, 其次详细探讨了包括基于内容的、基于协同过滤的(用户和物品)、基于矩阵分解以及基于深度学习来处理大数据的几种主要推荐算法。然后还讨论了推荐系统面临的主要挑战, 如冷启动问题、数据稀疏性、多样性与新颖性, 以及隐私和安全性; 在评估推荐系统方面, 介绍了各种评估指标。最后, 总结推荐系统的未来趋势, 如跨模态推荐、强化学习应用, 以及社交网络数据的整合, 这些趋势预示着未来的推荐系统将更加智能、多样化和高效。

关键词: 推荐系统; 个性化推荐; 面临挑战; 评价指标; 未来发展趋势; 应用研究

中图分类号: TP301 文献标识码: A

文章编号: 1009-3044(2024)10-0046-04

DOI:10.14004/j.cnki.ckt.2024.0483

开放科学(资源服务)标识码(OSID):



0 引言

随着互联网技术的发展, 每个人每天都会接触大量的信息。面对如此巨大的信息流, 如何帮助用户找到他们真正需要的内容变得尤为重要。因此, 个性化推荐系统应运而生, 其目的是为用户提供他们可能感兴趣的内容或产品, 提高用户满意度和留存率。

尽管有多种对推荐系统的定义, 但广泛认可的定义可以追溯到1997年, 由Resnick和Varian^[1]提出: “它是利用电子商务网站向客户提供商品信息和建议, 帮助用户决定应该购买什么产品, 模拟销售人员帮助客户完成购买过程”。一个完整的推荐系统通常包括3个主要组成部分: 行为数据收集模块、用户兴趣分析模块以及推荐算法模块, 如图1所示^[2]。




图1 推荐系统通用模型

在行为数据收集模块中, 系统负责记录用户的各种行为, 如问答、评分、购买、下载、浏览等。尽管一些用户可能不愿意主动提供评分或问答信息, 但通过分析其他行为数据, 如购买历史、下载记录和浏览行为等, 系统仍然能够洞察用户的潜在兴趣和喜好。用户兴趣分析模块的任务是根据用户的行为数据, 建立合适的模型来描述他们的兴趣和喜好。这一过程需要

分析用户行为记录以了解他们的行为模式和偏好。用户兴趣模型的建立使系统能够更好地理解用户, 并预测他们可能感兴趣的产品或内容。最后, 推荐算法模块扮演着推荐系统中的核心角色。该模块利用用户兴趣模型以及后台的推荐算法, 从产品或内容库中实时筛选出与用户兴趣高度匹配的项目, 从而提供个性化的推荐。这一过程确保用户在系统中获得与其兴趣相关的内容, 增强其满意度和参与度^[3]。

本文将概述在文献和实践中所使用的推荐算法, 按照推荐算法的差异, 推荐系统可细分为以下几种: 内容为基础的推荐、协同过滤方法、基于矩阵分解技术, 以及深度学习在推荐系统中的应用。此外, 文章还会讨论这些系统的不足之处、评估准则以及未来的研究趋势。

1 主要的推荐算法

1.1 基于内容的推荐

基于内容的推荐^[4]是一种广泛用于推荐系统的方法, 它依赖于分析项目(如文章、产品、音乐或视频)的内容, 以便向用户推荐具有相似内容的项目。基于内容的推荐的主要步骤如下。

1) 内容表示: 需要将项目的内容进行表示, 这可以包括文本、图像、音频或视频数据的特征提取。对于文本内容, 通常使用自然语言处理技术来提取关键词、主题、情感等信息。对于图像、音频或视频内容, 可以使用计算机视觉和音频处理技术提取特征。

2) 用户表示: 包括用户的历史行为、兴趣、个人信

收稿日期: 2023-11-16

作者简介: 余江龙(1986—), 男, 云南丽江人, 工程师, 主要研究方向为电网变电智能运维; 宋腾飞(2000—), 男, 通信作者, 研究生, 主要研究方向为人工智能。

息等,其中历史行为包括点击、购买、评分等。

3) 相似性度量:一旦有了内容和用户的表示,可以计算项目之间的相似性,通常涉及使用合适的相似性度量方法,如余弦相似度或欧氏距离,来度量项目内容之间的相似性。

4) 候选项目生成:根据用户的表示和相似性度量,可以生成一组候选项目,这些项目与用户的兴趣或历史行为相似。

5) 排序和推荐:从候选项目中选择最相关的项目,以构建最终的推荐列表。这可以根据相似性得分进行排序或者结合其他因素,如项目的热门程度或用户的个性化权重。




图2 基于内容的推荐

1.2 协同过滤算法

协同过滤算法^[5]是一种广泛应用于推荐系统和个性化推荐领域的算法。其基本思想是通过分析用户的历史行为和偏好,找到与目标用户具有相似兴趣或相似行为模式的其他用户或物品,然后利用这些相似用户或物品的信息来进行个性化推荐。协同过滤算法通常分为两种主要类型:

1) 用户协同过滤(User-based Collaborative Filtering):这种方法基于用户之间的相似性来进行推荐。它的核心思想是找到与目标用户兴趣相似的其他用户,并将这些用户喜欢的物品推荐给目标用户。用户协同过滤的缺点是可能受到稀疏性和冷启动问题的影响,即当用户和物品的数量庞大时,很难找到足够相似的用户。




图3 用户协同过滤示例

2) 物品协同过滤(Item-based Collaborative Filtering):这种方法基于物品之间的相似性来进行推荐。它的核心思想是找到目标用户喜欢的物品,然后推荐

与这些物品相似的其他物品给目标用户。物品协同过滤通常比用户协同过滤更稳定,因为物品的数量通常比用户少,相似性计算更容易实现。




图4 物品协同过滤示例

协同过滤算法的实现通常依赖于用户-物品交互矩阵,该矩阵记录了用户与物品之间的交互历史,如用户对物品的评分或点击行为。基于这个矩阵,可以计算用户之间的相似性或物品之间的相似性,并据此进行推荐。

1.3 基于矩阵分解的方法

矩阵分解^[6]是线性代数中的一种基本技术,经常被用于数据分析、推荐系统、机器学习等领域。它的主要目标是将一个大的和复杂的矩阵分解为几个小的、更简单的矩阵,这些小矩阵的组合或乘积可以近似地重构原始矩阵。以下是一些矩阵分解算法。

1) 奇异值分解(SVD):这是最广泛使用的矩阵分解技术之一。对于一个给定的矩阵A,SVD可以将其分解为3个矩阵U、Σ和V^T的乘积,即

$$A = U \Sigma V^T$$
 (1)

其中U和V是正交矩阵,Σ是对角矩阵。SVD在推荐系统中尤为受欢迎,因为它可以识别和提取出数据中的主要特征。

2) 非负矩阵分解(NMF):这种分解方法要求分解后的矩阵都是非负的。给定一个非负矩阵A,NMF旨在找到两个非负矩阵W和H,使得A近似等于W和H的乘积,NMF常用于图像处理和文本挖掘。

3) 主成分分析(PCA):虽然PCA经常被看作一种降维技术,但其背后的数学实际上涉及了矩阵分解。PCA旨在找到一组正交向量,这些向量可以最好地表示原始数据的变化。这些向量构成了所谓的“主成分”,它们可以通过分解数据的协方差矩阵得到。

4) QR分解:对于一个给定的矩阵A,QR分解将其分解为一个正交矩阵Q和一个上三角矩阵R的乘积,即

$$A = QR$$
 (2)

5) LU分解:这是另一种常见的矩阵分解方法,它将一个矩阵分解为一个下三角矩阵L和一个上三角矩阵U的乘积,LU分解常用于解线性方程组。

矩阵分解的核心优点:通过将复杂的矩阵简化为几个小的、具有特定结构或性质的矩阵,可以更轻松地理解、解释和操作这些矩阵。此外,矩阵分解为众多数学、科学和工程问题提供了强大的数值解决方

案。在实际应用中,选择哪种矩阵分解方法取决于特定的问题和所需的性质。例如,如果数据有非负约束,NMF可能是一个好选择,而在推荐系统中,SVD可能更受欢迎。总之,矩阵分解是一种强大的工具,能够深入理解和操作大型数据集。

1.4 深度学习与推荐系统

深度学习在推荐系统中发挥了重要作用^[7],它为推荐算法提供了更强大的建模能力,克服了传统方法的一些限制。以下是深度学习与推荐系统之间的关系以及深度学习在推荐系统中的应用。

1) 特征学习:深度学习可以用于学习用户和项目的高阶特征表示。传统的协同过滤方法和基于矩阵分解的方法通常依赖于手工设计的特征,而深度学习可以自动从原始数据中学习特征,例如用户的点击历史、项目的内容描述等,这使得模型能够更好地捕捉用户兴趣和项目特性。




图5 特征学习

2) 多模态数据处理:深度学习可以有效地处理多模态数据,如图像、文本和音频,这对于各种推荐任务非常有用,例如推荐电影、音乐、商品或文章。深度学习模型可以将不同类型的数据整合在一起,提高推荐的多样性和精确度。

3) 序列建模:对于涉及用户行为序列的推荐,如推荐新闻文章、社交媒体帖子或视频,深度学习的序列建模能力非常有用。循环神经网络(RNN)和长短时记忆网络(LSTM)等深度学习架构可以捕获用户行为的时间依赖性,提高对用户兴趣变化的建模。

4) 嵌入学习:嵌入学习是深度学习在推荐系统中的重要应用,通过将用户和项目映射到低维嵌入空间,可以更好地捕捉它们之间的关系。例如,矩阵分解神经网络(Matrix Factorization Neural Networks)结合了传统矩阵分解方法和深度学习技术,通过嵌入学习来提高推荐性能。

5) 推荐系统模型:深度学习推荐模型,如卷积神经网络(CNN)和推荐系统的深度神经网络(DNN),已经在工业界和学术界取得了成功。它们能够处理大规模数据、生成更准确的推荐,并适应不同类型的推荐任务。

2 推荐系统中的挑战

推荐系统面临许多挑战,这些挑战对于提供准确、有效的个性化建议和提高用户满意度至关重要,主要包括:冷启动问题、数据稀疏性与扩展性问题、多

样性与新颖性和隐私和安全性问题^[8]。

2.1 冷启动问题

冷启动问题(Cold-start Problem)是指在推荐系统中如何有效地处理新用户或新项目的问题。这种情况下,系统缺乏足够的历史数据来做出个性化的推荐,因为没有关于这些新用户或项目的足够信息。冷启动问题通常可以分为以下两个方面。

1) 新用户冷启动:当新用户注册或加入推荐系统时,系统不了解新用户的偏好和兴趣。因此,很难基于用户的历史行为为他们提供准确的个性化推荐。

2) 新项目冷启动:在推荐系统中引入新项目时,这些项目缺乏与用户的交互历史。因此,系统无法根据用户的过去行为来评估这些项目的相关性,从而难以为用户生成个性化的推荐。

2.2 数据稀疏性与扩展性问题

数据稀疏性与扩展性问题是推荐系统领域的两个关键挑战,特别是在应对大规模数据集时。

1) 数据稀疏性是指用户-项目互动矩阵中包含大量的缺失值,即用户与项目之间的交互数据非常有限。这会导致传统的协同过滤方法在推荐过程中表现不佳,需要足够的用户项目交互信息来生成有意义的推荐。

2) 扩展性问题涉及推荐系统如何有效地处理大规模数据集,尤其是在具有数百万用户和项目的环境下。传统的推荐算法可能在大规模数据集上表现不佳,可能需要计算庞大的用户-项目相似性矩阵或需要大量的计算资源。

2.3 多样性与新颖性

多样性与新颖性是推荐系统中非常重要的目标,它们有助于提供更富有吸引力和有趣的推荐,从而改善用户体验。

1) 多样性是指推荐系统生成的推荐列表中包含多种不同类型的项目,以满足用户的多样化兴趣。如果一个推荐系统只推荐相似的项目,用户可能会感到推荐列表缺乏多样性,从而降低了用户的满意度。

2) 新颖性是指推荐系统生成的推荐列表中包含用户以前没有接触过或了解的项目,新颖的推荐可以激发用户的兴趣,带来新的体验,而不仅仅是推荐用户已经知道的项目。

2.4 隐私和安全性问题

推荐系统需要处理用户的个人数据,包括用户历史行为和偏好。因此,隐私和安全性是一个非常重要的问题,用户不希望自己的个人信息被滥用或泄露。

3 评估推荐系统的指标与方法

评估指标在推荐系统中用于测量和评估推荐算法的性能。不同的指标关注不同方面的性能,下面是一些常见的推荐系统评估指标。

3.1 均方根误差 (Root Mean Square Error, RMSE)

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2} \quad (4)$$

m 表示样本数量, y_i 表示真实值, $\hat{y}_i$ 表示预测值。适用于连续型推荐问题, 如评分预测。值越低表示模型性能越好, 0 表示完美预测。

3.2 平均绝对误差 (Mean Absolute Error, MAE)

$$MAE = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i| \quad (5)$$

m 表示样本数量, y_i 表示真实值, $\hat{y}_i$ 表示预测值。适用于连续型推荐问题, 如评分预测。值越低表示模型性能越好, 0 表示完美预测。

3.3 精确度 (Precision)

$$Precision = \frac{TP}{TP + FP} \quad (6)$$

TP 指正类判定为正类, FP 指负类判定为正类。用于度量在前 k 个推荐项目中有多少个项目是用户真正感兴趣的, 适用于排名问题, 如 Top-N 推荐, 值越高表示模型能够更好地准确推荐用户感兴趣的项目。

3.4 召回率 (Recall)

$$Recall = \frac{TP}{TP + FN} \quad (7)$$

TP 指正类判定为正类, FN 指正类判定为负类。用于度量模型成功推荐的项目数量与用户真正感兴趣的项目总数之间的比率, 适用于排名问题, 如 Top-N 推荐, 值越高表示模型能够更好地覆盖用户感兴趣的项目。

4 未来发展趋势

推荐系统领域的未来发展趋势涵盖了多个方面, 反映了技术、用户需求和市场动态的演变, 以下是一些可能的未来发展趋势。

1) 跨模态推荐: 跨模态推荐是推荐系统的一项重要技术, 综合了用户的历史行为和多种数据模态 (如文本、图像、音频等), 以提供更准确的推荐和提高用户体验。关键因素和方法包括模态融合, 有效地整合不同数据模态; 特征提取, 从各模态数据中提取有用的信息; 跨模态相似性度量, 用于评估不同模态之间的关联, 以及深度学习和神经网络。它们在处理跨模态数据时表现出色, 有助于学习高级特征表示。跨模态推荐的应用领域广泛, 包括电子商务、社交媒体推荐、音乐和视频推荐等, 为用户提供更全面和个性化的推荐服务, 这种方法的综合性有助于提升用户满意度和推荐系统性能。

2) 强化学习在推荐系统中的应用: 强化学习在推荐系统中的应用是一个充满潜力的领域, 旨在通过优化决策策略来最大化用户的长期满意度。其中一些关键的应用和方法包括使用 Bandit 算法, 如多臂赌博

机问题, 以进行在线实验, 平衡探索和利用, 同时也借助深度强化学习来培训推荐系统, 考虑用户的长期反馈和影响。此外, 强化学习还可以支持在线学习, 使推荐系统能够不断改进以适应不断变化的用户兴趣, 并创建更个性化的推荐, 以满足每位用户的独特需求。然而, 这一领域面临的挑战包括需要平衡探索以及确保在线学习的稳定性, 这些挑战需要创新性的方法和算法来实现更强大的推荐系统。

3) 社交网络与推荐系统的结合: 将社交网络与推荐系统结合, 为个性化推荐提供更多信息和上下文, 以提高准确性和用户满意度。这包括获取社交媒体数据, 如用户的点赞、分享和评论, 以改进推荐系统; 构建社交图谱, 以了解用户之间的社交关系, 并利用这些关系来增强推荐; 考虑社交影响因素, 例如朋友的偏好, 以实现个性化推荐, 以及向用户推荐其喜欢的项目。社交网络与推荐系统的整合在社交媒体、电子商务、新闻推荐等多个领域都具有广泛应用, 有望提高推荐的社交互动性和社交影响, 从而更好地满足用户需求。

5 结论与建议

在信息爆炸时代, 个性化推荐系统的重要性日益凸显, 有效筛选相关和有价值的信息, 成为广大研究者需要考虑的问题。本文深入研究了推荐系统的核心算法、实施挑战和评估方法。面对冷启动、数据稀疏性和隐私保护等挑战, 建议采取综合策略: 在算法设计时考虑数据多样性; 对新用户和产品, 引入混合模型和利用用户反馈; 加强数据的加密和匿名化处理。未来研究需注重实验设计的严谨性, 并探索跨模态推荐和数据整合。推动跨领域合作, 尤其是社交网络和人工智能的整合, 以推动推荐系统研究的创新和应用扩展。在不断的探索和创新中, 实现推荐系统在多个领域中的广泛应用和技术提升。

参考文献:

- [1] RESNICK P, VARIAN H R. Recommender systems[J]. Communications of the ACM, 1997, 40(3): 56-58.
- [2] 许海玲, 吴潇, 李晓东, 等. 互联网推荐系统比较研究[J]. 软件学报, 2009, 20(2): 350-362.
- [3] 刘建国, 周涛, 汪秉宏. 个性化推荐系统的研究进展[J]. 自然科学进展, 2009, 19(1): 1-15.
- [4] 曾春, 邢春晓, 周立柱. 基于内容过滤的个性化搜索算法[J]. 软件学报, 2003, 14(5): 999-1004.
- [5] 甄珠米, 王莲芝, 张彦娥. 基于 Web 日志和协同过滤算法的水产养殖信息推荐[J]. 农业工程学报, 2017, 33(S1): 260-265.
- [6] 李旭, 李景文, 姜建武, 等. 基于矩阵分解的上下文感知兴趣点推荐方法[J]. 计算机工程与设计, 2022, 43(11): 3108-3115.
- [7] 黄振. 基于深度学习的个性化新闻推荐系统设计与实现[D]. 成都: 电子科技大学, 2021.
- [8] 杨博, 赵鹏飞. 推荐算法综述[J]. 山西大学学报 (自然科学版), 2011, 34(3): 337-350.

【通联编辑: 王力】