

分类号： TP399 学校代号： 10150
UDC： 004.8 密级： 公开 学 号： 20214056

大连交通大学

专业硕士学位论文

基于协同过滤算法的书籍推荐系统的
研究与实现

**Research and Implementation of Book
Recommendation System Based on
Collaborative Filtering Algorithm**

学 生 姓 名：	刘珣
校 内 导 师 及 职 称：	殷丽凤 副教授
行 业 产 业 导 师 及 职 称：	牛铁 高级工程师
专 业 名 称：	计算机技术
研 究 方 向：	数据挖掘
论 文 类 型：	应用研究
培 养 类 型：	非全日制专业学位硕士
论 文 答 辩 日 期：	2024 年 6 月 4 日
学 位 授 予 单 位：	大连交通大学

摘 要

随着互联网和信息技术的发展，数字阅读不断普及，用户可以轻松地获取大量的图书资源，但也带来了选择困难。为解决这一问题，基于协同过滤算法的书籍推荐系统应运而生。然而，传统算法在处理大规模数据时效率低下且推荐准确度不高。因此，本研究旨在通过改进协同过滤算法，设计实现一个准确、高效的个性化书籍推荐系统，以满足用户在数字阅读时的需求。

随着书籍数量的增加、用户需求的扩大，一般的协同过滤推荐算法推荐结果准确率较低，面临新用户还会产生冷启动等问题。针对这些挑战，本研究提出了一种基于 K-Means++ 聚类改进的协同过滤算法（记作 KM++-CF）。首先，本文使用开源数据集，通过程序进行数据预处理和清洗工作。其次，引入用户个人特征相似度矩阵和职业相似度矩阵，利用皮尔逊系数计算出用户的综合特征相似度，并采用 K-Means++ 聚类算法对综合特征相似的用户进行聚类，通过迭代计算更新质心以获得最佳的聚类效果。最后，结合用户特征和职业标签生成推荐书籍，如果用户无特征和行为数据或者推荐书籍过少，则通过借阅量最大堆技术，计算借阅量 Top-N 的书籍补充推荐结果，以降低数据稀疏性对推荐结果的影响。

为了评测本文算法改进的真实有效性，通过实验得到 KM++-CF 算法聚类效果最优的轮廓系数后，从平均绝对误差和准确率的不同角度与其他算法进行数据分析和实验对比。结果显示，本文提出的 KM++-CF 推荐算法无论在大数据处理速度还是推荐结果的准确度上表现效果都是最佳的。最后，将 KM++-CF 算法应用于个性化书籍推荐系统，此算法的应用极大地提升了系统的推荐准确性和个性化程度，进一步丰富了用户的阅读体验。

关键词：推荐系统；协同过滤算法；K-Means++聚类；用户综合相似度；书籍推荐

Abstract

With the development of the Internet and information technology, digital reading has become increasingly popular. Users can easily access a large number of book resources, but it also brings difficulties in choosing. To solve this problem, book recommendation systems based on collaborative filtering algorithms have emerged. However, traditional algorithms are inefficient in processing large-scale data and have low recommendation accuracy. Therefore, this study aims to design and implement an accurate and efficient personalized book recommendation system by improving collaborative filtering algorithms to meet the needs of users during digital reading.

With the increase of the number of books and the expansion of user needs, the general collaborative filtering recommendation algorithm has a low recommendation accuracy, and it also faces problems such as cold start for new users. To address these challenges, this study proposes an improved collaborative filtering algorithm based on K-Means++ clustering (KM++-CF). First of all, this paper uses open source data set to preprocess and clean the data through the program. Secondly, the user's personal feature similarity matrix and occupational similarity matrix are introduced to calculate the user's comprehensive feature similarity by using Pearson coefficient, and the K-Means++ clustering algorithm is used to cluster the users with similar comprehensive features, and the centroid is updated by iterative calculation to obtain the best clustering effect. Finally, recommended books are generated by combining user characteristics and professional labels. If the user has no feature and behavior data or has too few recommended books, Top-N books with borrowed books are calculated through the maximum pile technology to supplement the recommendation results, so as to reduce the impact of data sparsity on the recommendation results.

In order to evaluate the authenticity and effectiveness of the algorithm improvement in this article, the optimal contour coefficients for KM++-CF algorithm clustering were obtained through experiments. Data analysis and experimental comparison were conducted with other algorithms from different perspectives of average absolute error and accuracy. The results show that the KM++-CF recommendation algorithm proposed in this thesis performs the best in both big data processing speed and accuracy of recommendation results. Finally, the KM++-CF algorithm was applied to a personalized book recommendation system, which greatly improved the accuracy and personalization of the system's recommendations, further enriching the user's reading experience.

Key Words: Recommendation system; Collaborative filtering algorithm; K-Means++ clustering; User comprehensive similarity; Book recommendations

目 录

第一章 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	2
1.3 论文研究内容及论文结构	4
1.3.1 研究内容	4
1.3.2 研究结构	5
本章小结	6
第二章 相关理论和技术介绍	7
2.1 推荐系统.....	7
2.2 推荐算法.....	10
2.2.1 基于内容的推荐算法.....	10
2.2.2 协同过滤推荐算法.....	11
2.2.3 矩阵分解推荐算法.....	14
2.3 聚类算法.....	15
2.3.1 K-Means 聚类算法	15
2.3.2 K-Means++聚类算法	17
2.4 加权的用户个人特征相似度	19
2.5 借阅量最大堆.....	20
本章小结	21
第三章 基于 K-Means++聚类改进的协同过滤算法.....	22
3.1 算法问题的分析.....	22
3.1.1 协同过滤算法优劣分析.....	22
3.1.2 用户特征与书籍评分分析.....	23
3.2 KM++-CF 推荐算法的改进思想	24
3.2.1 用户综合特征性相似度.....	25
3.2.2 利用 K-Means++聚类算法	29
3.2.3 利用借阅量最大堆.....	31
3.3 KM++-CF 推荐算法流程	32
3.3.1 算法步骤.....	32
3.3.2 算法伪代码.....	34
本章小结	35
第四章 实验结果与分析	36
4.1 实验环境.....	36
4.2 算法的评估指标.....	36

4.3 数据集.....	39
4.3.1 数据来源.....	39
4.3.2 数据预处理.....	40
4.4 KM++-CF 的参数寻优	41
4.5 数据稀疏性影响对比实验	42
4.6 算法推荐效果对比实验.....	44
4.6.1 不同邻居数下推荐的平均绝对误差的角度	44
4.6.2 不同邻居数下推荐的准确率的角度.....	45
4.6.3 不同训练集下推荐的平均绝对误差的角度	46
本章小结.....	48
第五章 基于 KM++-CF 的推荐系统的实现	49
5.1 系统需求分析.....	49
5.2 系统设计.....	50
5.3 系统实现.....	50
5.4 系统页面展示.....	52
本章小结.....	55
结论.....	56
参考文献.....	58

第一章 绪论

本章将会重点介绍推荐系统的相关应用技术理论背景与发展现状，最后以论文概要的形式阐述本篇论文的整体框架和主要学术研究课题内容。

1.1 研究背景和意义

随着互联网技术的迅猛进步，网络信息资源日益丰富，在传统的搜索引擎下人们很难获取到他们所感兴趣的资源。并且消费者在选择和购买商品时也面临巨大的选择困难和信息过载的问题。这尤其体现在图书领域，书籍的种类是繁多的并且涵盖在各种领域，因此消费者很难直接在众多的选择中找到最适合自己的书籍。针对这些挑战挑，书籍的个性化推荐系统应运而生，旨在应对上述问题下的书籍推荐。比如可以通过改进用户评价矩阵等手段，有效地解决在当前这个信息大爆炸时代中信息负载过大的问题，借助个性化的推荐起到过滤相关信息的目标。

本文研究的背景和意义在于当用户在面对众多书籍出现选择困难时，通过对相关推荐算法的改进，实现一个个性化的书籍推荐系统，此系统能够根据用户的兴趣和喜好向推荐相关的书籍，节省用户寻找合适书籍的时间和精力，提高用户的满意度和阅读体验。并且个性化的书籍推荐系统还能够促进图书销售和电子商务的发展。对于电子书店来说，通过个性化的推荐能够使书店更好地满足用户需求、提升销售额和转化率的潜力。个性化的推荐不仅可以帮助电子书店发现和推广长尾图书，还能扩大产品的曝光度和销售范围，从而带动整个图书销售行业的发展。这就需要深入对书籍推荐系统的算法进行研究，探索和改进各种个性化推荐技术，推动推荐系统领域的研究和创新。比如个性化推荐系统就可以借助协同过滤、内容推荐以及深度学习等技术进行研究改进。同样在大数据领域提高数据处理能力上，姜宇^[1]等学者研究表明由于大数据处理需要大量的计算能力和数据存储能力，计算机软件技术可以通过优化算法、提高计算效率和数据压缩等方式提高数据处理能力。所以说本文的研究能够为推荐系统及其相关领域提供宝贵的经验和巨大的启示，从而来推动各个领域的进步和创新。

那么通过改进协同过滤算法实现书籍推荐系统可以提高推荐准确性，传统的协同过滤算法主要依赖于用户行为数据进行推荐，这种方法可能无法准确反映用户的真实兴趣和偏好。通过改进算法，引入用户的综合特征相似度矩阵，可以更全面地考虑用户的个人特征和阅读偏好，从而提高推荐准确性。准确的推荐可以提高用户的满意度，增加用户对推荐系统的信任度。对于新用户或新书籍，传统的协同过滤算法可能面临冷启动问题，即缺乏足够的行为数据来进行推荐。通过引入用户的综合特征相似度，可以将新用

户与具有相似特征的用户进行关联，并基于这些用户的行为数据进行推荐。这样可以解决冷启动问题，提供针对新用户的个性化推荐服务。改进协同过滤算法还可以更好地考虑书籍的特征和内容。传统的协同过滤算法主要基于用户行为数据，对于新书籍或少有用户行为数据的书籍，推荐结果可能不准确。通过引入书籍的特征相似度，可以综合考虑用户和书籍的特征相似度，提供更准确、多样化的书籍推荐结果。

综上所述，改进协同过滤算法实现书籍推荐系统可以提高推荐准确性、个性化推荐能力和解决冷启动问题，同时考虑书籍特征的多样性。这将为用户提供更准确、个性化和多样化的书籍推荐，提升用户体验和满意度，促进书籍销售和推广。该领域的研究和应用对电子商务和在线书店的发展以及推荐系统领域的进步具有重要意义和影响，同时也对其他领域的推荐系统提供了借鉴。相信通过不断改进和创新，书籍推荐系统在满足用户需求和推动图书销售方面将展现出卓越的表现。

1.2 国内外研究现状

协同过滤（Collaborative Filtering, CF）^[2]的概念最早于 1992 年由 Goldberg 等^[3]人提出，并在多个系统中得到应用。例如，早期的 Tapestry 系统主要用于电子邮件的筛选，而 Group Lens 推荐系统^[4]则用于新闻的筛选和推荐。这些系统的成功应用为后续的推荐系统研究奠定了基础。近几十年，个性化推荐系统经历了一系列的历史演变和因素影响，从早期的基于规则的推荐方法到如今的基于深度学习的改进算法，人们逐步加深对算法准确度和稀疏度的研究，加强推荐系统的信任度和可移植性。如蔡依芳等在研究中提出，算法在使用过程中仍存在诸多的疑虑，比如算法可扩展的范围、评价矩阵会产生稀疏性等问题。所以在对算法进行的过程中就需要加深对数据预处理、特征选择和降维、信息聚类以及基于邻域和模型等方法的学习。

近年来，为了改善数据稀疏性和算法可扩展性，研究人员做了许多研究，例如通过降维技术或聚类技术来改善传统 CF 算法的不足。Koochi H 等^[5]提出了一种基于用户的模糊 C-均值方法，提高了推荐准确率，但没有解决数据稀疏的问题。Su X 等^[6]使用了基于用户聚类的协同过滤算法，通过对用户评分矩阵运用 K-均值聚类算法，把相似度较高的用户分到同一个簇中，以减少搜索最近邻的时间，但是由于初始质心是随机选取的，可能导致质心聚集造成推荐质量下降。孙小华等^[7]在协同过滤中结合 K-近邻（KNN）算法改善了数据稀疏性造成的影响，但对较大数据集的处理效果仍不理想。刘艺等^[8]采用 BP 神经网络来预测评分，虽然可以改善数据稀疏造成的影响，但需要花费更长的近邻查找时间。

K-Means 算法^{[9][10]}作为聚类算法中最流行的算法，在 1967 年被 MacQueen 首次使用，相较于其他的聚类算法，K-Means 算法以效果较好、思想简单的优点在聚类算法中得到了广泛的应用。但是，K-Means 算法也有其自身的局限性，比如算法中聚簇个数 K 需要事先确定，初始聚类中心由随机选取产生，离群点对聚类结果的影响等。针对上述的缺点，各个领域的学者提出了不同的改进算法。其中，确定 K 值的方法有手肘法^[11]、Gap Statistic^[12]、基于混合距离的方法（MBHD，method based on hybrid distance）^[13]等算法。基于减少欧氏距离计算次数的优化方法注意到在对海量数据进行聚类时，K-Means 聚类算法的计算量增长很快，其中衡量样本点间相似度的欧氏距离计算所占比例较高。为了降低 K-Means 的算法复杂度，Capo 等^[14]从减少欧氏距离计算次数的角度出发，结合网格聚类的特点，将网格内的样本点近似成一个网格质心进行 K-Means 聚类，实现 K-Means 在海量数据下的快速聚类。基于并行化的优化方法针对大数据背景下串行 K-Means 聚类效率低下的问题，通过对聚类过程中每一次迭代的聚类中心相关计算的并行化，提高了 K-Means 的可靠性和效率。

基于对推荐算法的改进，我国对于推荐系统的研究也有了很大的进展，如学者饶俊阳^[15]等就新闻领域的个性化推荐做了研究，将语义相似度模型引入基于内容的推荐系统中，挖掘两者之间的语义关联。国内的很多行业也纷纷使用个性化的推荐系统，阿里巴巴、京东和拼多多等中国电商巨头利用推荐系统来满足用户的个性化购物需求和偏好。在此系统中会通过分析用户的购买记录、浏览行为、搜索历史和社交网络等数据，来精确地推荐用户感兴趣的商品和优惠活动，提供一对一的准确服务。社交媒体平台如快手、抖音也广泛使用个性化推荐系统，在社交媒体中推荐系统会根据用户的兴趣、关注的人物、点赞和分享行为等信息，如关注的用户动态、热门话题和广告，为用户推荐符合其兴趣的内容。音乐和视频流媒体平台，如网易云音乐、QQ 音乐等也利用推荐系统来为用户找到自己的兴趣爱好。系统会根据用户的听歌记录、收藏和评分行为，以及不同用户间的相似兴趣，为目标用户推荐新的音乐和视频内容。新闻阅读和内容平台，如网易新闻、小红书和知乎等也会采取推荐系统进行针对性的推荐。系统会通过分析用户的观看历史、点赞和兴趣标签等信息，为用户推荐相关内容的视频、图片以及问题回答。在国内对于推荐系统的研究不仅仅体现在功能上，在推荐算法的技术领域也有突破性的进步，比如基于内容的、知识的、协同过滤的、深度学习模型和神经网络的技术等^[7]。这些算法改进技术在推荐系统上的运用也越来越广泛和准确。同时，中国的互联网企业也在大数据处理、实时推荐和增量更新等方面进行了技术创新，以提高效率和准确度。国外的 Netflix、Hulu 和 YouTube 等视频流媒体平台也在个性化推荐方面取得了显著成果。流媒体平台可以利用个性化推荐系统来分析用户的观看历史、评分和喜好，以及用户的

相似兴趣,为目标用户推荐个性化的电影、电视剧和视频内容。社交媒体平台 LinkedIn、Twitter 等也使用个性化推荐系统来为用户推送感兴趣的内容和广告。在社交媒体中推荐系统会通过分析用户的社交关系、兴趣标签、点赞和分享行为等数据,为用户提供一对一的广告展示和内容推荐。像 Spotify 和 Apple Music 等音乐流媒体平台也会采用推荐系统来为用户推荐可能喜欢的东西。如分析用户的听歌历史、收藏和喜好,以及用户的一些搜索行为,为目标用户提供专属的歌单建议和歌曲推荐。

国外对于协同过滤算法的研究上一直处于领先地位,研究者们不断提出新的算法和改进措施,以提高推荐的准确性和效率^[17]。例如,通过引入机器学习技术来优化算法的性能,或者利用社交网络等信息来增强推荐的个性化程度。国外的电商平台,如亚马逊等,早已将协同过滤算法应用于书籍等商品的推荐系统中,这些平台通过精准的用户画像和大数据分析技术,为用户提供高度个性化的购物体验^[18]。随着推荐系统的成功应用,人们越来越多的关注推荐系统的效果评估和算法的健壮性、安全性等问题。2015 年 Alan Said 等人^[19]在 RecSys 会议上发表论,阐述了一种清晰明了的推荐结果评价方式,同年, Kille B 等人^[20]发表论文,讨论了基于流式数据的离线评价方式和对照试验,掀起了推荐算法评估的研究热潮。近年来,随着人工智能技术的不断发展,国外研究者开始探索将深度学习、强化学习等先进技术应用于推荐系统中,如 RecSys 会议自 2016 年起开始举办定期的推荐系统深度学习研讨会,旨在促进研究和鼓励基于深度学习的推荐系统的应用。2017 年 Karatzoglou A 等人^[21]在论文中介绍了深度学习在推荐系统中的应用,描述了基于深度学习的内容推荐和协同过滤推荐方法,深度学习成为当前推荐系统研究的热点。学者 Wenjun^[22]就深度学习、注意力网络和聚类融合算法的智能推荐系统进行了研究,进一步提高了推荐的准确性和用户满意度。

总之,当前国内外对于推荐算法和推荐系统的研究共同目标是相同的,旨在达到用户满意的效果。随着时间的推移,个性化推荐系统将不断借鉴和融合全球范围内的最新科技进展和创新,整合更多数据源和智能技术。

1.3 论文研究内容及论文结构

本节是对本论文的研究内容和结构进行阐述。

1.3.1 研究内容

本文是对协同过滤算法进行改进,并将改进后的算法应用到个性化的书籍推荐系统中。一般的书籍推荐系统会通过皮尔逊等相关系数的计算实现书籍的推荐,即实时根据用户的行为计算并推荐。虽然此算法的适应性强可以考虑到用户的行为的实时变化,但是皮尔逊相关系数仅考虑到了用户对物品的评分行为,不考虑用户的其他属性信息,这

就会导致推荐结果过于广泛或不够准确。尤其是对于一些热门的物品来说,皮尔逊相关系数可能会推荐给更多用户,而忽略了个性化的需求^[23]。因此本文在研究过程中,将书籍的推荐与用户个人特征、喜好变化相结合对算法进行改进,做出一定水平上的优化。即在传统协同过滤推荐算法的基础上把用户个人特征综合相似度加权、K-Means++聚类算法、借阅量最大堆等技术加以应用做改进。

研究内容的重点涵盖了以下几个方面:

1) 本文所采用的数据集是通过第三方平台 Book-Crossings 获取的,具体表现为 1837 名用户对 2937 本书籍的 184573 次评分,评分范围为 1-10,评分的范围体现了用户对书籍的喜爱程度。获取数据集后通过程序将其爬取的数据集进行清洗与预处理等操作。

2) 本文通过引入用户综合特征相似度加权对协同过滤算法进行改进,算法在计算用户之间的距离时,考虑了职业、年龄、性别三个属性的相似度,这种相似度计算中,通过建立用户评分模型,计算出用户的相似度,随后将个人特征相似度矩阵和职业相似度矩阵进行加权求和,形成用户的综合相似度矩阵,实现用户之间的相似度计算。

3) 本文引用了 K-Means++ 聚类算法对协同过滤算法进行优化,该算法是基于个人特征相似度矩阵和职业相似度矩阵进行用户聚类,通过不断迭代更新质心,让拥有相似兴趣的用户更有可能出现在同一聚类中,然后在针对目标用户时,我们只需要在和目标用户相似度较高的几个用户类别中寻找最近邻居用户进行推荐。

4) 本文引入借阅量最大堆的技术以降低数据稀疏度对推荐结果的影响,即如果用户无特征和行为数据,或者推荐书籍过少,则通过计算借阅量 Top-N 的书籍去补充推荐结果。

5) 为了验证本文提出算法的准确度,引入了轮廓系数来评价聚类效果好坏,并设计了一系列实验将本文提出的改进算法与基于 K-Means 聚类的协同过滤算法、个人特征相似度加权推荐算法、传统的协同过滤算法和基于矩阵分解的协同过滤算法进行误差、准确率等不同角度的数据分析与比对。

6) 将本文提出的 KM++-CF 推荐算法应用到个性化书籍推荐系统中进行实现。该系统主要通过四个模块来展现,分别是用户管理模块、书籍管理模块、借阅管理模块和书籍推荐模块,其中书籍推荐模块是重点。

1.3.2 研究结构

本文共分为五个部分来进行研究,每节的安排如下:

第一章:绪论。此部分对推荐系统和推荐算法的背景进行了介绍,回顾了国内外的研究现状,最后,明确了本文的主要研究内容和结构安排。

第二章：相关理论和技术介绍。在该部分明确了推荐系统在实际应用领域中的重要性，解释了一些推荐算法的概念及作用，并对本文研究所用到的聚类算法、用户特征相似度加权、借阅量最大堆等相关技术做了介绍。

第三章：基于 K-Means++ 聚类改进的协同过滤算法。先是对目前协同过滤算法以及本文算法研究的关键问题进行分析，基于这些提出了基于 K-Means++ 聚类改进的协同过滤算法（记作 KM++-CF）。在算法改进过程中，首先使用开源数据集，进行数据预处理和清洗工作，然后对用户年龄、性别和职业相似度通过皮尔逊系数计算出用户的综合特征相似度，并采用 K-Means++ 聚类算法对综合特征相似用户进行聚类。最后结合用户特征、职业标签生成推荐书籍，若推荐书籍过少，则通过计算书籍借阅量 Top-N 书籍补充推荐结果。最后，还对改进算法的步骤及伪代码进行了介绍。

第四章：实验结果与分析。是针对改进算法 KM++-CF 的研究而进行的实验，包括对实验环境、算法改进的评估指标、数据集、参数寻优实验的介绍。以及对本文的 KM++-CF 推荐算法、基于 K-Means 聚类的协同过滤算法、个人特征相似度加权推荐算法、传统的协同过滤算法和基于矩阵分解的协同过滤算法的实验结果对比分析。

第五章：基于 KM++-CF 的推荐系统的实现。是对个性化书籍推荐系统的设计和功能的实现。即将第三章提出的改进的推荐算法应用到此书籍推荐系统中，并对书籍推荐系统页面、推荐书籍的详细信息页面以及不同用户登录下不同的书籍推荐结果页面进行了展示，以验证本文算法改进的成果。

综上所述，本研究通过对个性化推荐系统的介绍和分析，探讨了推荐系统相关理论技术，提出了基于协同过滤算法的改进方法，并通过实验和推荐系统的实现验证了算法的有效性，这些研究成果对于提升推荐系统的个性化能力和用户体验具有一定的价值和应用意义。

本章小结

本章作为全文的伊始，不仅对本课题的研究背景意义和算法进行了描述，还同时介绍了文章结构，为下文的研究做铺垫。

第二章 相关理论和技术介绍

本章先对推荐系统和推荐算法做了详细的描述，然后介绍了与本文研究相关的技术理论。正是由于这些强大的理论知识和技术方法做后盾，才能更好地进行算法改进。

2.1 推荐系统

推荐系统^[24]的发展可以追溯到 20 世纪 90 年代初，当时互联网的普及和电子商务的兴起催生了对个性化推荐的需求。推荐系统包括了推荐算法所需的其他组件，如数据收集和预处理、用户界面、推荐策略等。推荐系统的核心原理是通过对用户行为数据的研究，从而得到物品模型和用户模型，用户模型涵盖了用户的兴趣、偏好和历史行为等信息，而物品模型则包括了物品的特征和内容等信息。通过分析和挖掘这些数据，推荐系统能够了解用户的喜好并找出与之相关的物品^[25]。然而这些的关键在于利用算法和技术，从数据中找到关键点，并建立起用户与物品之间的联系。最后通过精确的推荐来增加用户的满意度和体验感，从而达到个性化推荐的目的。其基本架构如图 2.1。




图 2.1 推荐系统基本架构图

Fig. 2.1 Recommended system basic architecture diagram

对于推荐系统来说,用户可以通过评分来预测对物品的喜爱程度,包括显式评分和隐式评分^[26]。其中用户直接对项目进行评分就是显式的,比如可以使用 1-5 的数值来表示满意程度或喜好程度,这种评分方式是用户主动给出的,可以提供明确的反馈信息。每个分值代表用户对商品的偏爱程度,5 表示非常喜欢,4 表示喜欢,3 表示还行,2 表示不喜欢,1 表示很不喜欢。而隐式评分不需要用户给出对商品的评分值,推荐系统会通过对用户的某些行为进行分析,比如通过对用户的历史购物记录、浏览网页的时间长短等一些行为来进行分析得到隐式评分数值。用户给好友进行了分享或者点赞了某个相关内容,就表示对这个商品很喜欢,然后上述算法会把用户对商品的评分情况进而转变为用户和项目的评分矩阵。如果评分了就会出现数值,若没有对项目评分就没有数值产生,问号则代表用户的评分需由兴趣度相似的用户来预测进行。

现如今,在移动互联网的快速发展下,许多公司使用大数据来了解用户信息和制定销售策略,从而使得个性化推荐系统的应用也越来越广泛,图 2.2 概括了推荐系统不同的应用领域。




图 2.2 推荐系统应用领域

Fig. 2.2 Recommended system application domain

电子商务推荐系统的最大优势在于它能够根据客户的兴趣、爱好、习惯,以及各个客户之间的相关性主动为客户做出推荐,从而有助于提高用户购买的准确性和效率,增加销售额和客户满意度。推荐的形式包括向客户推荐商品,提供个性化的商品信息、及其他客户的喜恶等,并且给出的推荐也是实时更新的。即当系统中的产品库和客户的兴趣等资料发生改变时,给出的推荐信息也会自动改变。总的来说,电子商务推荐系统的作用主要表现在三个方面:①将电子商务网站的浏览者转变为购买者。有时客户只是看

看网站的内容而没有购买的意思，推荐系统可以帮客户找到他们感兴趣的、愿意买的商品。②提高电子商务网站的交叉销售能力。基于用户已经购买的商品，推荐客户购买一些相关的商品。③提高客户对电子商务网站的忠诚度。推荐系统可以提供符合客户个性化需求的购物信息，因此能够吸引老客户访问网站。

社交媒体平台的推荐系统在用户体验和参与度方面扮演着至关重要的角色。通过个性化的好友推荐，它能够帮助用户找到与自己兴趣相投的朋友，增强社交互动和连接。内容推荐则根据用户的喜好和偏好，提供相关、吸引力强的文章、图片和视频，让用户在海量信息中更轻松地发现感兴趣的内容。而广告推荐能够根据用户的兴趣和行为数据，精准地投放广告，提高广告的点击率和转化率。此外，社交活动推荐能够为用户推荐适合参与的派对、聚会和活动，丰富社交生活。同时，个性化的消息推荐能够根据用户的关注和交互行为，为其推送相关的消息和动态，保持用户对平台的活跃度和依赖。然而，在实现个性化推荐的同时，平台也需要注重用户隐私保护，确保推荐系统的可信度和可接受性，以营造一个安全、可靠的社交媒体环境。通过不断优化推荐算法和策略，社交媒体平台可以为用户提供更好的体验，并促进社交互动的发展。

就旅游和餐饮领域而言，推荐系统的应用能够为用户提供个性化的推荐服务，帮助他们更好地选择和享受旅游景点和餐饮场所。通过分析用户的兴趣、偏好和行为数据，推荐系统可以推荐适合的旅游目的地、景点和行程安排，让用户发现新的目的地和体验。在餐饮方面，推荐系统可以根据用户的口味偏好、饮食习惯和消费行为，推荐合适的餐厅、菜品和美食活动，帮助用户发现新的美食体验和餐饮场所。这样的推荐服务不仅能提高用户的满意度，还有助于旅游和餐饮行业提高销售和服务质量。通过综合考虑用户的数据和保护用户隐私，推荐系统在旅游和餐饮领域的应用可以为用户带来更好的体验和选择。

对于音乐和阅读平台，推荐系统旨在帮助用户发现符合自己兴趣的音乐和阅读内容。通过分析用户的音乐偏好、收听历史和阅读喜好，推荐系统能够提供相似风格的音乐、热门歌手的新歌以及与用户兴趣相关的书籍和文章等推荐内容。这样的个性化推荐不仅节省用户的搜索时间，还能开拓用户的音乐和阅读视野，提供更丰富的体验。同时，推荐系统也为音乐和阅读行业提供了更精准的推广和营销机会，帮助用户发现更多优质的音乐和阅读资源。通过综合用户的行为数据和保护隐私，推荐系统在音乐和阅读领域的应用不断优化，为用户提供更好的音乐和阅读体验。

总的来说，推荐系统通过分析用户的行为和物品的特征，建立用户与物品的模型，并生成个性化的推荐结果^[27]。这种个性化推荐能够帮助用户发现新的内容、降低信息过载，并提供更满意和有针对性的用户体验。

2.2 推荐算法

推荐算法^[28]是大数据领域中常用的一种算法，旨在根据用户的个性化需求和行为，为其提供个性化的推荐内容。其原理是通过收集和预处理用户的行为数据和物品的特征数据，建立用户模型和推荐模型，并最终生成和排序推荐结果^[29]。本小节是对本文研究所用到的推荐算法进行介绍。

2.2.1 基于内容的推荐算法

基于内容的推荐算法^[30]是一种常用于推荐系统中的算法，它通过分析物品的内容特征来进行推荐，而不依赖于其他用户的数据。这种算法的核心思想是将物品的特征和用户的偏好进行匹配，从而预测用户对某个物品的喜好程度。

在基于内容的推荐算法中，首先需要对物品进行特征提取和表示。这涉及到使用各种技术来分析物品的内容，如自然语言处理、图像处理等。对于图像或音频内容，可以使用特征提取算法来提取视觉或音频特征。这些特征将帮助描述物品的属性和特点。接下来，基于内容的推荐算法会根据用户的个人偏好和历史行为，通过计算物品与用户偏好之间的相似度，来确定物品的推荐程度。比如图 2.3 中的实例就展现出了基于内容推荐的原理，通过推荐书籍的元数据，发现了用户 A 和用户 C 喜爱书籍信息的相关性，然后基于用户 A 以往的喜好记录，推荐给用户 A 用户 C 喜欢的书籍。




图 2.3 基于内容的推荐算法原理图

Fig. 2.3 Content based recommendation algorithm schematic

基于内容的推荐算法的优点之一是独立性，它不需要依赖其他用户的数据，可以独立进行推荐，尤其适用于新用户或冷启动问题^[31]。此外，它能够提供相对准确的推荐结果，因为它考虑了物品本身的特征，而不仅仅依赖于用户的历史行为。然而，基于内容

的推荐算法也存在一些限制。首先，它倾向于推荐与用户过去喜欢的物品相似的物品，可能无法提供多样化的推荐。这种算法很难发现用户的潜在兴趣和新领域。其次，它对物品的内容特征非常敏感，若物品信息不完整或特征提取不准确，可能导致推荐的不准确性。最后，基于内容的推荐算法难以捕捉到用户的个性化兴趣变化和时序信息。

总而言之，基于内容的推荐算法是一种常用的推荐算法，它通过分析物品的内容特征来为用户提供个性化的推荐服务。尽管存在一些局限性，但结合其他推荐算法，可以进一步提高推荐的准确性和多样性，从而提供更好的用户体验。这种算法在推荐系统中发挥了重要的作用，帮助用户发现符合其兴趣的物品，并丰富其消费体验。

2.2.2 协同过滤推荐算法

协同过滤 (Collaborative Filtering, CF) 可以说是推荐领域最为知名的经典算法之一，其最早来源于亚马逊于 2003 年发表的论文，此篇的诞生也让协同过滤在推荐领域大放异彩，并引起一股热潮^[32]。在各类推荐场景中，我们往往能得到关于用户 (User) 对物品 (Item) 的反馈、评分、评论等海量的信息，所谓的协同过滤就是要在海量的信息中筛选过滤出目标用户可能会感兴趣的物品的一个过程。在协同过滤推荐算法中，可以分为基于内存的协同过滤和基于模型的协同过滤两种^[33]。其中基于内存的协同过滤又可以分为两种常见的方法：基于用户的协同过滤 (User-CF) 算法和基于物品的协同过滤 (Item-CF) 算法。

(1) User-CF 算法^[34]从用户的角度出发，通过比较用户之间的行为相似性来进行推荐。首先，算法会建立用户-物品评分矩阵，其中每个元素表示用户对物品的评分或行为。然后，通过计算用户之间的相似度，如余弦相似度或皮尔逊相关系数，来找到与目标用户最相似的一组用户。最后，根据这组相似用户的评分数据，预测目标用户对尚未评价的物品的喜好程度，进行推荐。举例来说，当要给用户甲推荐物品时，可以先找到一个和用户甲兴趣最相近的用户乙。然后，获取用户乙对于用户甲尚未了解的物品的喜好程度，并预测用户甲对这些物品的评分。最后，从几个物品中挑选出评分最高的，作为给用户甲的最终选择。这个过程就涉及到寻找与目标用户兴趣极度相似的用户集合，并从中找到用户最喜欢的且目标用户尚未接触过的物品进行推荐，通过这种方式，可以提供个性化、符合用户喜好的推荐结果。

那么根据算法我们再具体一些，自然而然就会提出一个问题，那就是如何度量两个用户之间的相似度。比如说在现实生活中如何准确地判断两个人的兴趣是否相似。假设你喜欢某种类型的衣服，恰巧你的室友也喜欢这种类型的衣服，那显然你们的共同话题

会比较多，也就是你们有共同的兴趣爱好，你们之间的相似度也就更接近，我们刚好可以利用这一点来计算。

例如，假设有用户 μ 和用户 ν ，令 $N(\mu)$ 代表用户 μ 喜欢的物品合集，令 $N(\nu)$ 代表用户 ν 喜欢的物品合集。那么 $N(\mu) \cap N(\nu)$ 则代表的是用户 μ 和用户 ν 双方同时都喜欢的物品， $N(\mu) \cup N(\nu)$ 代表的是用户 μ 和用户 ν 都喜欢的物品的合集，因此可以利用以下公式来计算相似度：

$$W_{\mu\nu} = \frac{|N(\mu) \cap N(\nu)|}{|N(\mu) \cup N(\nu)|} \quad (2.1)$$

上述公式叫做 Jaccard 公式^[35]，直观上理解就是在物品集合中，用户 μ 与用户 ν 都共同喜欢的数量除以他们喜欢的总和，如果恰巧 μ 和 ν 喜欢的物品是一模一样没有差别的，那么 μ 和 ν 的相似度为 1。

还可以用余弦相似度公式^[36]来计算，也就是分母部分变成了 μ 喜欢的物品的数量与 ν 喜欢的物品的数量的乘积再开平方，而不再是他们之间的交集。公式如下：

$$W_{\mu\nu} = \frac{|N(\mu) \cap N(\nu)|}{\sqrt{|N(\mu)N(\nu)|}} \quad (2.2)$$

(2) Item-CF 算法^[37]是一种基于物品相似性的推荐方法，也是目前业界使用最广泛的算法之一，像亚马逊、Netflix、YouTube 等平台使用的推荐算法都是基于 Item-CF。此算法从物品的角度出发，通过比较物品之间的相似性来进行推荐。首先，算法会建立物品-用户评分矩阵，其中每个元素表示用户对物品的评分或行为。然后，通过计算物品之间的相似度，如余弦相似度或杰卡德相似度，来找到与目标物品最相似的一组物品。最后，根据目标用户对这组相似物品的评分数据，预测目标用户对尚未评价的物品的喜好程度，进行推荐。

不同于那些直接使用物品属性来计算的算法，该算法通过分析用户行为来计算物品之间的相似度。这样不仅可以发现用户对某些物品的喜好，并能基于这些相似程度，从而推荐其他具有相似特征的物品给用户。通过这种方式，可以充分得到用户满意的推荐。

物品相似度的计算公式：

$$W_{\mu\nu} = \frac{|N(\mu) \cap N(\nu)|}{N(\mu)} \quad (2.3)$$

在上式的表达中，分母 $N(\mu)$ 表示的是喜欢此物品的用户的总体数量的多少，而分子 $N(\mu) \cap N(\nu)$ 是表示同时喜欢物品 μ 和 ν 的用户数量。因此上式可以理解成，喜欢 μ 的用户当中有多少也喜欢 ν 的，如果喜欢 μ 的都喜欢 ν ，那么 $W_{\mu\nu}=1$ 。上述公式看起来还是很合理的，但是如果物品 ν 很热门，超级多的人都喜欢，那么上式中分子与分母就会很接近，此时 $W_{\mu\nu}$ 就会很接近1。即任何商品都和热门商品之间的相似度很高，这会导致 Item-CF 算法会总是推荐热门商品，所以这并不是一个好的计算方式。

因此可以采用下面的公式：

$$W_{\mu\nu} = \frac{|N(\mu) \cap N(\nu)|}{\sqrt{|N(\mu)| |N(\nu)|}} \quad (2.4)$$

上式的改进在于，如果 $N(\nu)$ 很大的话，分母也会相应变大，相当于惩罚了物品的权值，减轻了热门物品会和很多其他物品相似的可能性。

在建立起了物品的相似度矩阵之后，与 User-CF 算法一样，我们也要面临一个问题，就是如何从众多相似的物品中挑选出用户最感兴趣的物品。因此 Item-CF 算法通过以下公式计算用户 μ 对物品 j 的感兴趣程度 P ：

$$P(\mu, j) = \sum_{i \in S(j, K) \cap N(\mu)} W_{ji} R_{\mu i} \quad (2.5)$$

上式中的 $N(\mu)$ 是用户喜欢的物品集合， $S(j, K)$ 是和物品 j 相似度最高的 K 个物品的集合，即物品 j 和 i 的相似度。 $R_{\mu i}$ 是用户对 μ 物品 i 的兴趣（对于隐反馈数据集，如果用户对物品 i 有过历史行为，即可令 $R_{\mu i}=1$ ）。通俗理解就是，对于用户 μ 喜欢的物品列表中的每一个物品 i ，都可以根据物品相似度矩阵找到与其相似度最近的 K 个物品，令 K_{ij} ， $j=1, 2, \dots, K$ ，然后使用物品相似度 W_{ji} 来表示用户对物品 j 的感兴趣程度。最后将筛选出来的物品按照用户对其感兴趣的程度进行逆序排序，取全体列表或者列表前 K 个物品推荐给用户，至此 Item-CF 算法完成。




图 2.4 基于内存的协同过滤推荐算法

Fig. 2.4 Memory based collaborative filtering recommendation algorithm

由图 2.4 可知，基于内存的协同过滤算法是一种简单易实现的推荐算法，它通过比较用户之间的相似性或物品之间的相似性来进行推荐。这种算法不需要事先训练，可以直接使用实时的用户行为数据进行推荐，具有实时性好、可扩展性强和个性化效果好的优势^[38]。此外，基于内存的协同过滤算法的推荐结果是基于用户行为数据计算得出的，因此具有较强的可解释性，用户可以理解推荐结果是基于其他用户或物品的行为数据得出的。

总而言之，协同过滤推荐算法是一种常用的推荐算法，它通过比较用户之间的相似性或物品之间的相似性来进行推荐。尽管存在一些局限性，但结合其他推荐算法，可以进一步提高推荐的准确性和多样性，从而提供更好的用户体验。这种算法在推荐系统中发挥了重要的作用，帮助用户发现符合其兴趣的物品，并丰富其消费体验。

2.2.3 矩阵分解推荐算法

矩阵分解算法^[39]是一种常用的推荐算法，它通过将用户-物品评分矩阵分解为低维的用户矩阵和物品矩阵的乘积，来进行推荐。具体来说，假设我们有一个用户-物品评分矩阵，其中每一行表示一个用户对不同物品的评分或行为，每一列表示一个物品被不同用户评分或行为。这个评分矩阵通常是非常稀疏的，大部分项都是未评价的。矩阵分解算法的目标是找到一个低维的用户矩阵和物品矩阵，使得它们的乘积尽可能地逼近原始的评分矩阵。通过学习得到这两个矩阵，就可以预测用户对未评价物品的喜好程度，从而进行推荐。其原理如图 2.5 所示。




图 2.5 矩阵分解推荐算法原理图

Fig. 2.5 Schematic diagram of matrix decomposition recommendation algorithm

矩阵分解算法的核心步骤包括^{[40][41]}:

- 1) 构建用户-物品评分矩阵。
- 2) 将评分矩阵分解为两个低维矩阵的乘积，一个代表用户特征矩阵，另一个代表物品特征矩阵。
- 3) 计算用户特征向量与物品特征向量的内积，得到用户对每个物品的预测评分。
- 4) 根据预测评分对物品进行排序，并选择最符合用户偏好的物品作为推荐。

总的来说，矩阵分解算法的目的是通过机器学习手段填补用户行为矩阵中缺失的数据，即用户未评分的元素，以实现为用户做推荐的目标^[42]。这种算法的优点在于它能够有效地处理稀疏数据，即用户对大量物品的评分中只有少量是已知的，因此通过矩阵分解，可以预测用户对未评分物品的偏好，从而为用户提供个性化的推荐。

2.3 聚类算法

2.3.1 K-Means 聚类算法

K-Means 聚类算法^[43]是一种常用的无监督学习算法，用于将数据点划分为不同的聚类群组。该算法的目标是通过最小化数据点与其所属聚类中心之间的距离来实现聚类。在算法开始时，需要指定聚类的数量 K ，然后随机选择 K 个数据点作为初始聚类中心。接下来，对于每个数据点，计算其与各个聚类中心之间的距离，将其归类到距离最近的聚类中心所属的类别中。然后，根据已经归类的数据点，更新聚类中心的位置为每个类别中数据点的平均值。重复进行这些步骤，直到聚类中心的位置不再变化或达到预定的迭代次数。最终，得到的聚类中心和数据点的分类结果可以用于分析数据集的模式、群组或者进行后续的决策。K-Means 聚类算法简单而高效，适用于各种领域的数据分析和挖掘任务。

K-Means 聚类算法的工作过程如下^{[44][45][46]}：首先，需要为数据集确定要划分的簇数 K ，接下来，就选择 K 个初始质心（centroid），数据点开始会被分配给最接近的质心以形成簇，然后，针对每个簇内的数据点去计算新的质心，将质心位置更新为这些数据点的中心。最后，将数据点重新分配到最接近的质心，让簇再次形成。上述过程不断迭代，直到满足特定的终止条件（例如，质心不再改变，簇内数据点不再变化）为止。通过工作过程，我们可以知道 K-Means 的性能表现出色，其优势之一是对大型数据集的高效处理，它适用于分布均匀的数据，对于处理连续性数据效果较好，所以在用户分群、市场细分和图像压缩等应用领域 K-Means 算法都有着重要的作用。通过图 2.6 可以更加深刻地理解 K-Means 算法的执行过程。




图 2.6 K-Means 算法执行过程

Fig. 2.6 K-Means algorithm execution procedure

不过该算法也存在一些局限性，就是其结果受初始质心位置的影响很大，因此如果初始质心不一样，就可能会导致出现不同的聚类结果^[47]。这是因为 K 值的选择对聚类产生重要影响，因此在开始聚类之前需要仔细选择 K 的值。而且 K-Means 对异常值较为敏感，有时会出现异常值影响聚类结果。还有在面对高维数据集的情况下，数据的维度可能会影响聚类效果，这就需要使用降维技术进行数据预处理。而 K-Means 算法计算数据点之间的距离采用的方法是欧几里得距离公式，此公式通常用来衡量特征空间中的点。

这个公式描述了两个点之间的直线距离，如有两个点 $p = (x_1, y_1)$ 和 $q = (x_2, y_2)$ ，它们之间的欧氏距离 d 就为：

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2} \quad (2.6)$$

在 K-Means 中，每个数据点到质心的距离就是欧氏距离用于度量的数据点^[48]。在这个过程中，每个数据点都会被分配到距离最近的质心所在的簇中。然后，更新质心的位置，此位置是根据簇内所有点的均值来计算的，更新的公式如下所述。

假设有一组数据点 $x = (x_1, x_2, \dots, x_n)$ ，其中 x_n 代表一个数据点， $x_n = (x, y, z, \dots)$ 即多维空间中的一个点。如果有 k 个簇，则每个簇 C_k 的质心 M_k 由其成员的均值给出。

其公式如下：

$$M_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i \quad (2.7)$$

这个公式表示质心是属于同一簇的数据点的均值，其中 $|C_k|$ 是簇 C_k 的大小，即包含的数据点数量。

总体来看，K-Means 是一种强大且易于理解的聚类算法，能够有效处理大型数据集，且在很多领域都得到了广泛应用。为了获得最佳的聚类效果，需要更加仔细地选择 K 值、预处理数据、处理异常值还有数据的维度等方面的问题^[49]。因此在对 K-Means 算法进行实际使用时需要综合考虑多方面的因素，以确保更好的聚类结果。

2.3.2 K-Means++ 聚类算法

K-Means++ 聚类算法^[50]是一种改进的 K-Means 聚类算法，用于将数据点划分为不同的聚类群组。聚类是一种无监督学习的技术，旨在发现数据集中的内在结构和模式，将相似的数据点归为一类^[51]。在传统的 K-Means 算法中，初始聚类中心的选择是随机的，这可能导致算法陷入局部最优解，并且对于不同的初始聚类中心选择，可能得到不同的聚类结果^{[52][53]}。K-Means++ 算法通过引入随机性和距离权重，能够选择更好的初始聚类中心，提高算法的准确性和稳定性。

K-Means++ 算法的思想是通过迭代选择合适的初始聚类中心，以更好地代表数据集的不同簇。它的步骤描述如下^[54]：

假设有一组数据点 $x = (x_1, x_2, \dots, x_n)$ ，其中 x_n 代表一个数据点， $x_n = (x, y, z, \dots)$ 即多维空间中的一个点。首先，从 x 中随机选择一个数据点 x_1 作为第一个聚类中心。接下

来，对于剩下的数据点，计算每个数据点到已选择的聚类中心 x_1 的最短距离 $D(x)$ （即与最近的聚类中心的距离）。值越大也就是距离越远的数据点被选择为下一个聚类中心的概率较高。这样聚类中心之间的距离会更大，能够更好地覆盖数据集的不同簇。

然后计算每个样本被选为下一个聚类中心的概率 $P(k)$ ，公式如下：

$$P(k) = \frac{D(x)^2}{\sum_{x_n \in X} D(x)^2} \quad (2.8)$$

最后，用轮盘法选出概率最大的值对应的点作为下一个聚类中心。重复以上步骤，直到选择完所有的聚类中心。




图 2.7 转盘法累计概率实例

Fig. 2.7 Example of cumulative probability by rotating disk method

其中轮盘法^[55]的基本思想是，各个个体被选中的概率与其适应度大小成正比，步骤如下：

- ①计算出数据集中，每个个体的适应度 $f(i=1,2,\dots,m)$ ， m 为数据集大小；
- ②计算每个个体被选中的概率：

$$P(x_i) = \frac{f(x_i)}{\sum_{j=1}^m x_j} \quad (2.9)$$

③计算出每个个体的累积概率：

$$q_i = \sum_{j=1}^i P(x_j) \quad (2.10)$$

④由图 2.7 的累计概率实例可知，在 $[0, 1]$ 区间内产生一个均匀分布的伪随机数 r ；

⑤若 $r \leq q_1$ ，则选择个体 1，否则选择个体 k ，使得 $q_{k-1} < r \leq q_k$ ；

⑥重复④、⑤共 m 次。

聚类中心全部选择结束后，使用得到的聚类中心，对所有数据点进行聚类，并计算每个数据点到其所属聚类中心的距离。根据聚类结果，更新聚类中心的位置为每个聚类中心所关联的数据点的平均值。继续迭代以上步骤，直到聚类中心的位置不再变化或达到预定的迭代次数。最终，得到的聚类中心和数据点的分类结果可以用于分析数据集的模式、群组或者进行后续的决策。

K-Means++ 聚类算法的优势在于更好的初始聚类中心选择、更快的收敛速度和稳定的聚类结果。通过选择更好的初始聚类中心，可以减少算法对初始状态的敏感性，并且能够更好地划分出不同的聚类群组。同时，通过引入距离权重，算法能够更快地收敛到最终的聚类结果，并且聚类结果更加稳定。

总而言之，K-Means++ 聚类算法是一种改进的 K-Means 算法，通过引入随机性和距离权重，能够选择更好的初始聚类中心，提高算法的准确性和稳定性。它在数据挖掘、模式发现和群组分析等领域具有广泛的应用。

2.4 加权的用户个人特征相似度

推荐系统的用户数据一般都是在用户注册的时候产生的，例如用户的基本信息（职业、性别、年龄等）。但是在一些其他的研究数据中发现，用户的个人特征对用户的喜好起着至关重要的作用，有研究就曾表明，随着阅历的增加、年龄的加大，人们喜欢的书籍会从绘本、故事、小说再到经济、哲学、人文、散文等类别，这就说明年龄相仿的用户，书籍类别的喜好程度也有很大的相似度^[56]。

用户个人特征相似度加权主要是通过以下方式实现。对于每一对不同的职业（假设为职业A和职业B），首先，获取在这两个职业下用户对每本书的评分信息，然后，使用皮尔逊相关系数，通过计算评分的均值以及方差等统计信息来计算这两个职业的相似度。计算两个职业A和B的相似度的核心公式为：

$$\text{Similarity}(A, B) = \frac{\text{covariance}(A, B)}{\text{std_dev}(A) * \text{std_dev}(B)} \quad (2.11)$$

其中, $\text{covariance}(A, B)$ 是 A 和 B 的协方差, $\text{std_dev}(A)$ 和 $\text{std_dev}(B)$ 分别是 A 和 B 的标准差。职业相关信息计算完毕后, 开始看其他的用户特征信息, 如果说两个用户的性别是相同的, 那么此时我们说性别相似度为 1, 如果不同, 则相似度为 0。

接下来就计算两个用户之间的年龄差异, 如果差值大于 7 岁, 计算年龄相似度。年龄相似度公式为:

$$\text{SimilarityAge} = \frac{7}{\text{abs}(\text{Age}_{u_1} - \text{Age}_{u_2})} \quad (2.12)$$

其中, abs 代表绝对值, Age_{u_1} 和 Age_{u_2} 分别是 u_1 和 u_2 的年龄。如若年龄差小于 7 岁, 则相似度为 1, 在这里使用了简单的加权求和, 对于年龄相似度来说, 若年龄差异大于 7 岁, 则按比例缩小。

这样, 通过职业相似度、性别相似度和年龄相似度的综合计算, 得到了用户之间的距离 distance , 这个距离用于 K 均值聚类算法, 将用户分成不同的类别。用户之间的距离被定义为年龄、职业、性别相似度之和的负值, 即:

$$\text{distance}(u_1, u_2) = -\text{similarity}(u_1, u_2) \quad (2.13)$$

总的来说, 传统的推荐算法都是基于用户对项目的评分来计算相关相似度的, 没有考虑用户相关特征信息, 各种特征与项目结合起来推荐很值得考虑, 因此可以利用用户的个人特征信息来更准确的计算用户之间的相似度。

2.5 借阅量最大堆

堆是一种数据结构, 它遵循特定的顺序性质^[57]。借阅量堆的目的是确保推荐系统能够快速访问当前最受欢迎或借阅次数最多的书籍, 从而提高推荐的相关性和吸引力。在书籍推荐系统中, 构建一个借阅量最大堆是提升推荐质量的有效手段, 这个堆不仅捕捉

了当前最受用户欢迎的书籍，而且随着借阅活动的持续，它能够动态地反映出用户的阅读兴趣和市场的最新趋势。

通过这种方式，推荐系统可以确保推荐列表中包含高人气的书籍，从而吸引用户的注意力，并可能激发他们探索新的阅读领域。其次对于新加入的用户，借阅量最大堆尤其重要，因为在没有足够的历史数据来构建个性化推荐的情况下，它可以作为一个通用的推荐起点。这些热门书籍为新用户提供了一个广泛的选择，直到系统能够通过用户互动积累足够的信息来提供更加定制化的推荐。此外，借阅量最大堆的数据还可以帮助平台运营者进行深入的趋势分析。通过监测哪些书籍的借阅量在上升，哪些在下降，运营者可以洞察到用户兴趣的微妙变化，从而及时调整采购策略，优化库存，甚至设计相关的营销活动来吸引读者。例如，如果发现某一类书籍的借阅量持续增长，图书馆或书店可能会考虑增加这类书籍的采购量，或者在显著位置展示这些书籍，以满足用户的需求。

总而言之，借阅量最大堆为书籍推荐系统提供了一个强有力的工具，它不仅增强了推荐的相关性和多样性，还为平台的运营决策提供了数据支持，有助于提升整体的服务质量和用户满意度。

本章小结

本章主要是对本文所研究的推荐算法和推荐系统的相关理论和技术方法做介绍，为后文的算法改进奠定基础。

第三章 基于 K-Means++ 聚类改进的协同过滤算法

本章是本文的重点环节，即对算法改进的研究。首先是对算法问题进行分析，然后介绍采取协同过滤算法进行改进的具体手段。最后，基于这些算法改进提出了一种基于 K-Means++ 聚类改进的协同过滤算法（记作 KM++-CF）。

3.1 算法问题的分析

传统的协同过滤算法主要利用项目评分来进行推荐，但它们往往没有综合考虑用户的喜好问题，并且性能相对较弱，难以解决冷启动等问题^[58]。实际上，在真实的推荐系统中，用户的喜好是时刻变化的，而非固定不变的。因此，为了提高系统的准确性，可以利用用户的个人特征信息（年龄、性别）和用户的职业特征，将相似度高的用户归为同一聚类。这种方法不需要遍历所有空间来查询目标用户的最近邻居，而是将相似性高的用户放入同一聚类中，更快地找到与目标用户相似的用户群体，然后提供个性化的推荐。下面是在改进协同过滤算法之前对相关问题的详细分析。

3.1.1 协同过滤算法优劣分析

协同过滤算法是一种基于用户行为和相似性的推荐算法，其优点在于能够实现个性化推荐和数据驱动的推荐过程。通过分析用户之间的行为相似性，该算法能够为每个用户生成个性化的推荐结果，提高用户满意度和体验。相比于其他算法，协同过滤算法不需要依赖领域知识或物品特征，而是通过用户行为数据进行推荐^[59]。这使得算法具有较高的通用性，适用于不同类型的物品和领域。优点主要体现在：首先，协同过滤算法能够为每个用户生成个性化的推荐结果。通过分析用户的历史行为和与其他用户的相似性，算法能够理解用户的偏好和兴趣，从而推荐符合用户个性化需求的物品。这使得用户能够获得更加个性化、针对性强的推荐结果，提高用户满意度和使用体验。其次，协同过滤算法是一种数据驱动的推荐算法。它不需要依赖领域专家的知识或物品的特征，而是通过分析用户行为数据来进行推荐。这使得算法更具通用性，可以适用于不同领域和类型的物品。无论是电影、音乐、图书还是商品推荐，在有足够的用户行为数据支持下，协同过滤算法都能够提供准确有效的推荐结果。然后，协同过滤算法具有较好的可扩展性。随着用户数量和物品数量的增加，算法能够自动适应并处理大规模的数据集。这使得协同过滤算法在大型推荐系统中得到广泛应用，并能够满足不断增长的用户需求。最后，协同过滤算法还可以帮助用户发现潜在的兴趣和新领域，通过分析用户的行为模式 and 与其他用户的相似性，算法可以推荐用户可能感兴趣但尚未发现的物品。这为用户提供了探索新领域、拓宽兴趣范围的机会，丰富了用户的体验和消费选择。

但是协同过滤算法在处理新用户、新项目以及大规模数据集上也存在一些不足之处,大致包含以下几个方面。

(1) 数据稀疏性问题

在刚开始运行的推荐系统中,由于系统资源中缺乏大量读者对书籍的评价,因此很难通过这些评价找到相似的读者,这意味着大部分用户只对少数项目进行了评分或交互,从而会导致很难找到足够数量的相似用户或相似项目来进行准确的推荐^[60]。这种数据稀疏性问题会导致协同过滤算法的推荐结果可能不够准确和个性化。

(2) 冷启动问题

协同过滤算法面对新项目或者新用户的时候会产生冷启动的问题。这是由于缺乏足够的行为数据,新用户就无法找到相似的用户进行准确的推荐,新项目也是一样,缺乏用户行为数据导致难以确定其与其他项目的相似度。因此在没有足够数据进行相似度计算的情况下,传统协同过滤算法很难产生个性化和多样化的推荐结果^[61]。

(3) 算法的可扩展性

在处理大规模数据集时会面临计算复杂度和存储需求的挑战,计算用户相似度或项目相似度的过程中对资源和时间的损耗很多。此外,想要存储相似度矩阵或邻居关系,也需要大量的内存空间,同样限制了协同过滤算法在大规模的数据集上的应用。

(4) 偏好漂移问题

用户的个人喜好可能会随着时间的推移而发生变化,而传统协同过滤算法无法及时适应用户的变化,从而导致推荐结果不准确或与用户当前兴趣不匹配。也就是说用户的历史行为可能无法完全反映其当前的偏好,从而影响推荐的准确性。

(5) 算法的脆弱性

传统协同过滤算法对于噪声和异常值比较敏感,如果存在错误的评分数据或恶意数据操作等干扰,可能会对推荐结果产生不良影响。而且即使是单个用户的错误评分或恶意操作也可能对整个相似度计算和推荐结果产生较大的影响。

综上所述,在实际应用中需要结合其他推荐算法或技术来提高推荐的准确性和性能。综合考虑算法的优缺点,并根据具体场景和需求进行选择 and 调整,构建更有效的推荐系统。

3.1.2 用户特征与书籍评分分析

当在算法改进中进行用户相似度分析时,首先需要考虑的是用户的个人特征。这包括用户的性别、年龄等基本信息,以及更具体的特征,如职业、教育程度、兴趣爱好等,这些特征可以通过用户注册信息时获取。而且在分析用户特征时,采用聚类分析来发现

不同用户群体之间的差异和相似性。拿本文所研究的三个用户特征应用到个性化推荐算法中去举例来说。第一，随着年龄不断增加，对于用户的喜好起着很大影响。对于书籍来说，儿童更喜欢绘本、故事等类别的书籍。少年时期更喜欢小说，中年时期更喜欢哲学、经济、历史相关的书籍。这些例子都反应出了年龄对于用户爱好的影响。第二，不同性别的人喜好也是不一样的，针对书籍来说，女性的更喜欢情感类别多的书籍。而男生更喜欢武侠等打斗场景和其它经济、历史、科学相关的书籍。第三，不同职业对于书籍类别的喜爱差别也各不相同。而职业所学习的知识与书籍类别也是强相关的，比如 IT 行业需要计算机相关书籍，金融相关职业需要经济学相关书籍。所以说通过聚类，可以帮助我们更了解用户，从而更好地理解他们对书籍评分的动机和倾向。

在进行用户特征分析的同时，也需要对书籍评分进行分析，包括对书籍评分的统计指标，如平均评分、评分分布等进行分析。通过这些我们可以了解书籍评分的分布情况，从而得知用户对不同类型的书籍的喜好程度，最终可以确定哪些书籍更适合被推荐给特定的用户群体。

为了将用户特征与书籍评分联系起来，我们可以使用协同过滤算法。协同过滤算法是基于用户与用户之间或书籍与书籍之间的相似性来进行推荐的。通过计算用户特征与书籍评分之间的相似度，可以找到与用户兴趣相匹配的书籍，并为其进行个性化的推荐。为了使推荐更加准确，再使用 K-Means++ 算法对用户特征进行聚类，根据用户的个人特征和评分记录，将用户分为不同的群组，每个群组代表了具有相似特征和评分行为的用户群体。对于一个特定用户在确定其所属的聚类群组后，就使用余弦相似度来计算该用户与同一聚类群组中其他用户之间的相似度。然后，基于用户群组内其他用户的评分行为，利用协同过滤算法为该用户生成对应的推荐列表，再根据相似用户对书籍的评分来推荐可能喜爱的书籍。

综上所述，通过对用户特征和书籍评分数据的深入分析可以发现，对用户综合相似度进行计算，可以实现更准确和个性化的书籍推荐，提升用户体验和满意度。

3.2 KM++-CF 推荐算法的改进思想

本文在对 KM++-CF 算法研究的过程中，首先，针对用户特征进行深度挖掘，通过分析用户的个人特征，针对相似度进行优化计算，采用加权方法来计算用户间的相似度，以便于赋予不同特征不同的权重，从而提高相似度计算的准确性以及个性化推荐的相关性。然后，利用了 K-Means++ 聚类算法对用户进行聚类，以发现具有相似阅读偏好的用户群体，从而提高推荐的准确性。最后，还利用了借阅量最大堆来存放借阅量高的书籍，

这种方式可以通过实时更新的借阅量堆来追踪流行书籍，为新用户或在缺乏个性化数据的用户提供通用推荐。具体改进内容如下面 3 个小节所展示。

3.2.1 用户综合特征性相似度

基于用户的综合特征相似度矩阵对协同过滤算法进行改进的原因在于，传统的协同过滤算法往往只关注用户对物品的一些历史行为数据，很容易就忽略用户属性的权重。尤其是在书籍推荐系统中，通过图 3.1 我们可以清晰地看到每个用户都有自己的属性特征（年龄、性别、职业）和相对应喜爱的书籍。在某些情况下，仅仅使用用户行为数据可能无法准确反映用户的兴趣和偏好。因此，引入用户的综合特征相似度矩阵可以更全面地考虑用户的个人特征，提高推荐算法的准确性和个性化程度。




图 3.1 用户特征与喜爱书籍关系图

Fig. 3.1 User characteristics and favorite books relationship graph

首先，用户的综合特征包括个人资料、兴趣爱好、阅读偏好等，这些特征能够更全面地描述用户的喜好和阅读需求。通过综合考虑用户的多个特征，算法可以更好地捕捉用户的个性化需求，提高推荐算法的准确性。例如，对于一个喜欢教育和心理题材的用户，仅仅基于其阅读行为数据可能无法准确预测其对其他类型的书籍的喜好，但通过综

合考虑用户的兴趣爱好和阅读偏好，可以更准确地推荐适合用户的书籍。其次，书籍推荐需要考虑到书籍的特征和内容。传统的协同过滤算法主要依赖用户行为数据进行推荐，但对于新书籍或少有用户行为数据的书籍，算法可能无法准确推荐。通过使用用户的综合特征相似度矩阵，算法可以利用用户的特征信息进行推荐，从而解决冷启动问题，提供更准确的推荐结果。

本文在 KM++-CF 算法中基于用户综合特征性相似度的改进主要是在计算用户之间的距离时考虑了年龄、性别以及职业属性的相似度，并在计算中对不同属性的权重进行了调整。假设有用户 u 和用户 v ，首先计算两个用户职业之间的相似度，即把看过这本书且职业相同的人对同一本书籍的评分求平均值，用作该职业对这本书的评分，然后对于每对职业来说，计算两个职业都评分的书籍的交集，针对每本书的评分利用皮尔逊系数计算出职业相似度 P 值，如果没有共同评分的书籍则 P 值为 0。然后计算年龄相似度 A 值，当 $|Age_u - Age_v| > 7$ 时，年龄相似度 A 值通过年龄差权重得出；当 $|Age_u - Age_v| \leq 7$ 时，年龄相似度 A 值为 1。最后计算性别相似度 F ，当两个用户性别相同时，性别相似度 F 值为 0，不相同 F 值则为 1。最终得到用户之间的综合相似度 S 的值，需要注意的是，方便后续聚类的相关计算，最终取综合相似度的负值表示用户之间的距离，也就是说距离越近也就越相似，即 $S = -(A + F + P)$ 。




图 3.2 用户和书籍信息实例图

Fig. 3.2 User and book information example diagram

由于图 3.2 可知，用户 A 和用户 B 都喜欢 Book1、Book2 和 Book3 并进行了评分，假设数据集中有 I 个用户，教师职业对书籍的评分为 x_{Ai} ，IT 职业对书籍的评分为 x_{Bi} ，

其中 7 位老师对 Book1、Book2 和 Book3 分别进行了评分，12 位 IT 对 Book1、Book2 和 Book3 分别进行了评分。

计算用户 A 和用户 B 的综合特征相似度的具体步骤如下：

①已知用户 A 的职业为教师，分别计算数据集中所有教师对于 Book1、Book2 和 Book3 的平均评分，作为教师职业对 Book1、Book2 和 Book3 的评分。

$$\begin{aligned} Book1_A &= \frac{\sum_{i \in I} x_{Ai}}{i} = \frac{56}{7} = 8 \\ Book2_A &= \frac{\sum_{i \in I} x_{Ai}}{i} = \frac{35}{7} = 5 \\ Book3_A &= \frac{\sum_{i \in I} x_{Ai}}{i} = \frac{49}{7} = 7 \end{aligned} \quad (3.1)$$

②已知用户 B 的职业为 IT，分别计算数据集中所有 IT 对于 Book1、Book2 和 Book3 的平均评分，作为 IT 职业对 Book1、Book2 和 Book3 的评分。

$$\begin{aligned} Book1_B &= \frac{\sum_{i \in I} x_{Bi}}{i} = \frac{108}{12} = 9 \\ Book2_B &= \frac{\sum_{i \in I} x_{Bi}}{i} = \frac{48}{12} = 4 \\ Book3_B &= \frac{\sum_{i \in I} x_{Bi}}{i} = \frac{60}{12} = 5 \end{aligned} \quad (3.2)$$

③Book1、Book2 和 Book3 为教师职业和 IT 职业共同评分书籍的交集，利用皮尔逊系数，根据职业对共同读过的书籍的评分，计算出职业相似度 $SimilarityP$ 。

$$SimilarityP = \frac{\sum_{i \in I} (x_{Ai} - \bar{x}_A)(x_{Bi} - \bar{x}_B)}{\sqrt{\sum_{i \in I} (x_{Ai} - \bar{x}_A)^2} * \sqrt{\sum_{i \in I} (x_{Bi} - \bar{x}_B)^2}} \quad (3.3)$$

其中 x_{Ai} , x_{Bi} 分别表示用户 A 和用户 B 对书籍 i 是否有交互(或者具体的评分值):

$$\bar{x}_A = \frac{(Book1_A + Book2_A + Book3_A)}{3} \approx 6.667 \quad (3.4)$$

$$\bar{x}_B = \frac{(Book1_B + Book2_B + Book3_B)}{3} = 6 \quad (3.5)$$

即:

$$SimilarityP = \frac{\sum_{i \in I} (x_{Ai} - 6.67)(x_{Bi} - 6)}{\sqrt{\sum_{i \in I} (x_{Ai} - 6.67)^2} * \sqrt{\sum_{i \in I} (x_{Bi} - 6)^2}} \approx 1.403 \quad (3.6)$$

④已知用户 A 的年龄为 25 岁, 用户 B 的年龄为 33 岁, 差值大于 7 岁。计算用户 A 和用户 B 的年龄相似度 $SimilarityAge$ 。

$$SimilarityA = \frac{7}{abs(Age_A - Age_B)} = \frac{7}{|25 - 33|} = 0.875 \quad (3.7)$$

⑤由于用户 A 和用户 B 的性别不同, 所以其性别相似度 $SimilarityF$ 为 0。

⑥用户 A 和用户 B 的综合相似度 $Similarity(A, B)$ 如下:

$$Similarity(A, B) = -(SimilarityP + SimilarityA + SimilarityF) = -2.278 \quad (3.8)$$

由上述计算过程可以得出基于用户的综合特征相似度矩阵对协同过滤算法进行改进, 可以提高个性化推荐准确性, 算法能够更全面地了解用户的偏好和兴趣, 使用户得到更符合其兴趣和需求的推荐结果。对于新用户或新物品, 行为数据可能不足或缺乏。通过使用用户的综合特征相似度矩阵, 算法可以利用用户的特征信息进行推荐, 从而解决冷启动问题, 提供更准确的推荐结果。而且用户的兴趣和偏好可能会随着时间的变化

而改变。通过使用基于用户的综合特征相似度矩阵的算法，可以更好地捕捉用户特征的变化，及时更新推荐结果，提高推荐的时效性和准确性。

3.2.2 利用 K-Means++ 聚类算法

在协同过滤算法中，初始聚类中心的选择对于算法的性能和效果至关重要。传统的协同过滤算法中，初始聚类中心是随机选择的，这可能导致算法陷入局部最优解，影响了聚类结果的准确性和稳定性。为了改进协同过滤算法的初始聚类中心选择，可以采用 K-Means++ 算法。K-Means++ 算法通过引入随机性和距离权重的概念，能够选择更优的初始聚类中心，提高聚类结果的质量。具体而言，K-Means++ 算法通过迭代选择合适的初始聚类中心，根据数据点与已选择聚类中心的距离进行加权选择，使得距离较远的数据点更有可能被选为下一个聚类中心。这种选择方式有助于确保初始聚类中心的分布更广泛，能够更好地代表数据集的不同簇。初始质心选取的基本思路就是，初始的聚类中心之间的相互距离要尽可能的远。算法描述如下：

步骤一：随机选取一个样本作为第一个聚类中心 c_1 ；

步骤二：

①计算每个样本与当前已有类聚中心最短距离（即与最近一个聚类中心的距离），用 $D(x)$ 表示；

②这个值越大，表示被选取作为聚类中心的概率较大；

③最后，用轮盘法选出下一个聚类中心；

步骤三：重复步骤二，知道选出 K 个聚类中心。

选出初始点后，就继续使用标准的 K-Means 算法了。




图 3.3 样本分布图

Fig. 3.3 Sample distribution diagram

从效率上看 K-Means++能显著的改善分类结果的最终误差。尽管计算初始点时花费了额外的时间，但是在迭代过程中，K-Means 本身能快速收敛，因此算法实际上降低了计算时间。下面结合一个简单的例子说明 K-Means++是如何在本文中选取初始聚类中心的。假设数据集共有 8 个样本，分布以及对应序号如图 3.3 所示。

经过步骤一，6 号点被选择为第一个初始聚类中心，那在进行步骤二时每个样本的 $D(x)$ 和被选择为第二个聚类中心的概率如表 3.1 所示：

表 3.1 聚类中心概率表

Table 3.1 Experiment

序号	1	2	3	4	5	6	7	8
$D(x)$	$2\sqrt{2}$	$\sqrt{13}$	$\sqrt{5}$	$\sqrt{10}$	1	0	$\sqrt{2}$	1
$D(x)^2$	8	13	5	10	1	0	2	1
$P(x)$	0.2	0.325	0.125	0.25	0.025	0	0.05	0.025
Sum	0.2	0.525	0.65	0.9	0.925	0.925	0.975	1

其中的 $P(x)$ 就是每个样本被选为下一个聚类中心的概率。最后一行的 Sum 是概率 $P(x)$ 的累加和，用于轮盘法选择出第二个聚类中心。方法是：随机产生出一个 0~1 之间的随机数，判断它属于哪个区间，那么该区间对应的序号就是被选择出来的第二个聚类中心了。例如 1 号点的区间为[0, 0.2)，2 号点的区间为[0.2, 0.525)。从上表可以直观的看到第二个初始聚类中心是 1 号，2 号，3 号，4 号中的一个的概率为 0.9。而这 4 个点正好是离第一个初始聚类中心 6 号点较远的四个点。这也验证了 K-Means++的思想：即离当前已有聚类中心较远的点有更大的概率被选为下一个聚类中心。可以看到，该例的 K 值取 2 是比较合适的。当 K 值大于 2 时，每个样本会有多个距离，需要取最小的那个距离作为 $D(x)$ 。

由上述过程可知，本文的 KM++-CF 算法基于 K-Means++的改进在于随机一个初始化质心之后，对于剩下的数据点，计算每个数据点到已选择的聚类中心的最短距离（即与最近的聚类中心的距离）。通过计算选出概率最大的值对应的点作为下一个中心。不断迭代，直到选择完所有的聚类质心。然后引入了用户个人综合相似度矩阵，利用用户之间的综合特征相似度通过 K-Means++算法将用户分成不同的簇进行聚类，计算簇中用户的平均年龄、性别、职业信息作为新的质心，通过不断迭代计算，更新质心，以达到最佳聚类效果，从而实现在每个群组的内部进行更精准推荐。聚类过程如图 3.4 所示。



图 3.4 K-Means++ 聚类过程

Fig. 3.4 K-Means++ clustering process

通过对聚类过程的了解,可以得出基于 K-Means++ 算法改进协同过滤算法的初始聚类中心选择的优势在于:

1) 提高聚类结果的准确性, K-Means++ 算法选择更优的初始聚类中心,使得聚类中心的位置更能够代表不同簇的特征,从而提高聚类结果的准确性。

2) 增强算法的稳定性, K-Means++ 算法的初始聚类中心选择更加稳定,即使对于不同的初始选择,算法得到的聚类结果也相对一致。这有助于提高算法的稳定性和可重复性。

3) 改善算法的收敛速度, K-Means++ 算法选择更好的初始聚类中心,使得聚类中心之间的距离更大。这样一来,在算法的迭代过程中,聚类中心的更新更有意义,能够更快地收敛到最终的聚类结果。

综上所述,采用 K-Means++ 算法改进协同过滤算法,可以提高聚类结果的准确性、稳定性和收敛速度,对于协同过滤算法的性能和推荐结果的质量都具有积极的影响。

3.2.3 利用借阅量最大堆

在推荐过程中,为了能够考虑到书籍的热门程度,就在算法的使用中引入借阅量最大堆,在最大堆中存放的是借阅次数高的书籍,如果推荐的书籍不够时,将从借阅量最大堆中取,以解决算法稀疏性的问题。这里的堆堆可以看成是一棵树,并且这棵树的子树也是堆。而最大堆就是父节点大于子节点,根节点是最大的节点;最小堆就是父亲节点小于子节点,根节点是最小的节点。假设已知 6 本书的借阅量分别为 1, 9, 7, 5, 18 和 4, 借阅量最大堆构建过程如图 3.5 所示。




图 3.5 最大堆构建过程

Fig. 3.6 Maximum heap building process

因此在进行书籍推荐时（最终推荐书籍为 3 本），借阅量最大堆的工作如下：首先，构建用户的书籍评分矩阵，然后遍历借阅列表，查询书籍和用户是否存在，并统计每本书被借阅的次数。在此基础上，为每个用户创建一个推荐对象，并添加到推荐列表中。接下来，对推荐列表进行清洗，去除重复的推荐对象。然后，构建一个按借阅量排序的最大堆，并创建一个针对每个用户的评分最大堆。对于每个用户，重新构建借阅量的最大堆，然后创建一个存储书籍相似度的映射表。对于每本书籍，检查用户是否已经看过并评分，查找看过该书籍的用户列表，计算用户与每个用户的相似度，并根据相似度计算推荐值。最后，对书籍相似度映射表进行排序，取评分最高的三本书籍作为最终推荐结果。如果推荐书籍不足三本，从借阅量最大堆中补充。通过以上这些步骤确保能够生成准确且个性化的推荐结果，降低书籍稀疏性对推荐结果的影响。

3.3 KM++-CF 推荐算法流程

基于上一小节中算法的改进，提出了 KM++-CF 算法。本小节是对 KM++-CF 算法的步骤和伪代码的介绍。

3.3.1 算法步骤

在对 KM++-CF 算法的研究过程中可以知道，一般的协同过滤推荐算法在用户数量大的情况下，推荐结果效率较低，面临新用户还会产生冷启动等问题。因此 KM++-CF

算法是结合传统协同过滤算法的优势，再对算法进行的改进。改进过程中先进行用户个人特征综合相似度加权，再通过 K-Means++ 算法将数据进行聚类等操作，得出更准确的推荐结果。图 3.6 简单的展示了 KM++-CF 算法的流程。




图 3.6 KM++-CF 算法原理流程

Fig. 3.6 KM++-CF algorithm principle flow

KM++-CF 算法的具体推荐步骤如下：

步骤一：通过程序对数据进行预处理和清洗工作，对清洗后的书籍评分、用户年龄、职业数据进行缺失值填补、标转化处理等。

步骤二：引入用户个人特征矩阵（年龄、性别）和职业相似度矩阵计算用户之间的综合相似度。首先，对于每一对不同的职业，都要获取在这两个职业下用户对相同书籍的评分信息，然后使用皮尔逊相关系数，通过书籍评分计算这两个职业对书籍喜好程度的相似度，如果两个职业没有相同的书籍评分记录那么相似度则为 0。其次，计算用户之间年龄相似程度。如果年龄差值小于 7 岁，相似度权重记为 1，大于 7 岁则利用年龄差权重计算出相似度。然后，计算性别相似度。若性别相同，相似度权重记为 1，否则权重记为 0。最后，将个人特征相似度和职业相似度进行加权计算，从而得到用户之间的综合相似度。

步骤三：采用 K-Means++ 算法将综合特征相似的用户进行聚类。首先随机一个数据点初始化质心之后，计算剩下的每个数据点到已选择的聚类中心的最短距离。通过计算选出概率最大的值对应的点作为下一个中心。不断迭代，直到选择完所有的聚类质心。

步骤四：引入用户个人综合相似度矩阵，利用用户之间的综合特征相似度通过 K-Means++算法将用户分成不同的簇进行聚类，计算簇中用户的平均年龄、性别、职业信息作为新的质心。

步骤五：重复步骤四，通过不断迭代计算，更新质心，以达到最佳聚类效果。

步骤六：结合用户的个人特征、职业标签选取最近邻居书籍进行差集推荐。

步骤七：如果出现用户无特征和行为数据或者推荐的书籍不足，则利用书籍借阅量最大堆，通过计算借阅量 Top-N 的书籍来补充推荐结果，以降低数据稀疏性对推荐结果的影响。

3.3.2 算法伪代码

对于 KM++-CF 算法来说，是通过结合用户个人特征相似度加权，并通过 K-Means++聚类及借阅量最大堆来进行实现的，其主要伪代码如下。

KM++-CF 算法伪代码

算法：KM++-CF 推荐算法

输入：

职业列表 *professionList*

相关用户数据集 *userDOList*

输出：

用户书籍推荐列表 *recommendList*

方法：

- 1: *professionList* = {"IT", "DOCTOR", "TEACHER"} //设置职业列表，用于后续计算职业相似度
 - 2: *userDOList* = *userDao.listAllUsers()* //获取用户数据，用于进行聚类分析
 - 3: *SimilarityMap* = *CalProfessionSimilarity()* //根据用户的职业信息计算相似度
 - 4: *clusterList* = *getClusterList()* //初始化聚类列表
 - 5: *clusterCenteringList* = *getClusterCenterList()* //初始质心列表
 - 6: **for** *i* = 0 to *k* - 1 **do**
 - 7: *clusterList.add(newList())* //为每个聚类创建一个新的列表
 - 8: *clusterCenteringList.add(null)* //初始化质心列表
 - 9: **end for**
 - 10: *Collections.shuffle(userDOList)* //随机选择初始质心，增加算法的随机性
 - 11: **for** *i* = 0 to *k* - 1 **do**
-

```

12:   clusterCenteringList[i] = getClusterCenter() //计算当前质心与与已有聚类中心距
    离，利用轮盘法选择下个聚类中心，并初始化到列表。
13: end for
14: maxClusterTimes = 500 //设置算法的最大迭代次数，防止无限循环
15: Change = true //用于判断质心是否发生变化，控制迭代过程
16: count = 1 //记录当前迭代次数
17: while Change && count <= maxClusterTimes do
18:   Change = false //假设质心没有变化
19:   clusterList = newList[k] //重置聚类列表，为新一轮迭代做准备
20:   for user ∈ userDOList do
21:     closestClusterIndex = CalDistance(user,clusterCenteringList) //计算用户到各
    个质心的距离
22:     if user ∈ clusterList[closestClusterIndex] then
23:       clusterList[closestClusterIndex].add(user) //将用户分配到最近的质心所
    在的聚类
24:       Change = true //标记质心可能发生变化
25:     end if
26:   end for
27:   newCenterList = CenterUpdate(clusterList) //根据当前聚类重新计算质心
28:   if isChange(oldCenterList,newCenterList) then
29:     clusterCenteringList = newCenterList //若质心发生变化，则更新质心列表
30:   end if
31:   count + + //记录迭代次数
32: end while

```

本章小结

本章先针对算法的问题进行了分析和研究，然后进行了协同过滤算法的改进，最终提出了 KM++-CF 推荐算法，并对改进算法的步骤及伪代码进行展示。

第四章 实验结果与分析

本章是基于第三章对改进算法的研究而进行的实验，包括对实验环境的介绍、算法改进的评估指标、数据集、参数寻优实验结果的介绍，以及数据稀疏性影响对比实验和算法推荐效果对比实验的结果介绍与分析。

4.1 实验环境

在科研领域，实验环境配置是研究项目的关键组成部分。它涵盖了硬件、软件和各种设置，对于确保实验的可重复性和可验证性至关重要。本文的实验是获取的开放数据集 Book-Crossings 中的 1837 名用户对 2937 本书籍的 184573 次评分。使用笔记本电脑进行算法改进研究及对比实验。其中，表 4.1 为软件配置表，表 4.2 为硬件配置表。

表 4.1 实验环境软件配置

Table 4.1 Experimental environment software configuration

名称	配置信息
开发语言	Java、JSP、HTML、CSS
开发框架	Spring MVC
服务器操作系统	CentOS 6.8
客户端操作系统	Mac OS
数据库系统	MySQL 5.6

表 4.2 实验环境硬件配置

Table 4.2 Experimental environment hardware configuration

名称	配置信息
计算机	MacBook pro
CPU	Apple M1
内存	16G

4.2 算法的评估指标

本文通过平均绝对误差(MAE)和准确率(Precision)两个指标来评估推荐系统相关算法的优劣，使用轮廓系数（Silhouette Coefficient）作为评价聚类效果的标准。

(1) 平均绝对误差(MAE)^[62]是一个衡量预测模型在回归分析中准确性的统计指标,它通过计算预测值与实际观测值之间差异绝对值的平均数来评估模型的整体误差,(MAE)的值越小,表示模型的预测结果与真实情况的偏差越小,从而反映出来模型的预测性能越好。对于推荐系统来说,通常表示用户实际评分和预测评分之间的差异。

MAE公式如下:

$$\text{MAE} = \frac{\sum_{i=1}^N |p_i - q_i|}{N} \quad (4.1)$$

其中 N 表示用户评过分的项集合数量; p_i 表示用户对项目分的预测评分; q_i 表示对项目分的实际评分。

(2) 准确率(Precision)^[63]是评价分类模型性能的指标之一,特别是在推荐系统中常用来衡量推荐列表的相关性,通过计算推荐给用户的物品中用户实际感兴趣的比例来定义。高准确率意味着推荐内容更加贴合用户的实际需求,从而提高用户的满意度和系统的实用性,因此可以说准确率衡量的是推荐列表中相关项目(即用户实际上喜欢或会交互的项目)所占的比例。

Precision的公式如下:

$$\text{Precision} = \frac{\sum_{u \in U} |R(u) \cap T(u)|}{\sum_{u \in U} |R(u)|} \quad (4.2)$$

其中, U 代表测试集, $R(u)$ 为算法针对用户 u 产生的推荐列表, $T(u)$ 为用户 u 在测试集上的所对应的行为记录。

在实际应用中,准确率的计算可能会根据具体的推荐场景和需求有所变化。在本文中的研究中准确率显示了在所有被推荐给用户的物品中,有多少是用户真正感兴趣或相关的,比例越高,说明推荐系统的性能越好。

(3) 轮廓系数(Silhouette Coefficient)^[64],是用于评价聚类效果好坏的一种指标,可以理解为描述聚类后各个类别的轮廓清晰度的指标。其包含有两种因素—内聚度和分离度。内聚度可以理解为反映一个样本点与类内元素的紧密程度。分离度可以理解为反映一个样本点与类外元素的紧密程度。

举例来说,在机器学习中聚类算法算作相对重要的一部分算法,也常在低资源和无标注的情况下使用,其中 K-Means 作为聚类算法中的一种,充当着重要的角色。由于其

思想较为简单，易于理解和方便实现，所以经常被用来做数据的处理，但是 K-Means 算法有一个致命的缺点就是如何选择 K 值。因为 K 值的选择至关重要，选择的好可以有较好的聚类效果。

通常情况下，K 值的选择人们会根据先验的知识给定一个估计的值，或者是利用 Canopy 算法计算出一个大致的 K 值^[65]。更多的情况下，还是利用后验的方式进行 K 值的选择。也就是在给定 K 的范围 $[a, b]$ 下，对不同的 K 值分别进行聚类操作，最终利用聚类效果的评价指标，来给出相应的最优聚类结果。这种评价聚类结果效果的指标就包含轮廓系数。

Silhouette Coefficient 的公式如下：

$$S(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (4.3)$$

其中， $a(i)$ 代表样本点的内聚度， $\max$ 代表最大值，计算方式如下：

$$a(i) = \frac{1}{n-1} \sum_{j \neq i}^n \text{distance}(i, j) \quad (4.4)$$

其中 j 代表与样本 i 在同一个类内的其他样本点， distance 代表了求 i 与 j 的距离。所以 $a(i)$ 越小说明该类越紧密。 $b(i)$ 的计算方式与 $a(i)$ 类似。只不过需要遍历其他类簇得到多个值 $\{b_1(i), b_2(i), b_3(i), \dots, b_m(i)\}$ 从中选择最小的值作为最终的结果。所以原 $S(i)$ ：

$$S(i) = \begin{cases} 1 - \frac{a(i)}{b(i)} & , \quad a(i) < b(i) \\ 0 & , \quad a(i) = b(i) \\ \frac{a(i)}{b(i)} - 1 & , \quad a(i) > b(i) \end{cases} \quad (4.5)$$

由上式可以发现：

当 $a(i) < b(i)$ 时，即类内的距离小于类间距离，则聚类结果更紧凑。 S 的值会趋近于1。越趋近于1代表轮廓越明显。相反，当 $a(i) > b(i)$ 时，类内的距离大于类间距离，说明聚类的结果很松散。 S 的值会趋近于-1，越趋近于-1则聚类的效果越差。

由此可得，轮廓系数 S 的取值范围为 $[-1, 1]$ 下，轮廓系数越大聚类效果越好。

通过上述介绍可以得到轮廓系数的计算方法，接下来介绍轮廓系数如何确定 K 值，首先需要将 K 值设定为具体的多个数值，范围可以人为规定，如 2 到 10。然后在每个 K 值下进行聚类，计算聚类结果的轮廓系数，最后将轮廓系数最大的 K 值作为最终的 K 值，在 K 值确定的过程中，对于簇结构为凸的数据轮廓系数会较高，簇结构非凸的数据轮廓系数会较低^[66]。

还需要注意的是，轮廓系数的计算依赖于具体的聚类算法和数据集，不同的算法可能会产生不同的聚类结果和轮廓系数值，因此不能直接用于比较不同算法的优劣。

4.3 数据集

4.3.1 数据来源

本文所用到的数据集是网上的开放数据集 Book-Crossings。此图书社区包含不到二十八万个用户对二十七万多本书进行的一百多万条评分，评分范围由一到十的。除了显式评分还包含隐式评分，这些用户的年龄等人口统计学属性(demographic feature)都以匿名的形式保存并供分析。值得一提的是这个数据集是由 Cai-Nicolas Ziegler 使用爬虫程序在 2004 年从 Book-Crossings 图书社区上所采集的，并提供了 CSV 格式和 SQL 格式的文件，以便人们使用。

本文在实验中选取了 Book-Crossings 数据集中的 1837 名用户对 2937 本书籍的 184573 次评分，这一选择为推荐算法的性能评估提供了一个具有实际意义的大规模数据环境，这些数据不仅覆盖了广泛的用户群体和多样化的书籍，还有规范的评分范围，为用户提供了丰富的选项来精确表达他们对书籍的喜好，从而有助于捕捉用户偏好的细微差别。其中部分数据集信息如图 4.1 所示。主要数据类别包括用户 ID、职业、年龄、性别、书籍 ID、书籍评分。特征对应英文如表 4.3 所示。

1	User-ID;"ISBN";"Book-Rating";"Age";"Occupation";"Gender"
2	276725;"034545104X";"1";"23";"1"
3	276726;"0155061224";"5";"37";"1";"0";"0"
4	276727;"0446520802";"7";"26";"0";"1";"0"
5	276729;"052165615X";"-3";"0";"0";"3";
6	276729;"052165615X";"6";"32";"0";"2";"0"
7	276733;"2080674722";"10";"20";"0";"0"

图 4.1 原始数据集

Fig. 4.1 Raw data set

表 4.3 特征含义取值表

Table 4.3 Feature Meaning Value table

特征名称	含义	值
User-ID	用户 ID	值代表用户唯一 ID
Age	年龄	年龄 20 岁-35 岁
Gender	性别	0: 女, 1: 男
Occupation	职业	0: IT, 1: 医生, 2: 老师
ISBN	书籍 ID	值代表书籍唯一 ID
Book-Rating	书籍评分	评分 1 分-10 分

此外, Book-Crossings 数据集作为推荐系统研究中广泛认可的标准测试集, 使得本研究的实验结果具有高度的可比性和可信度。通过在这样的真实数据集上进行实验, 不仅可以验证推荐算法在现实世界中的有效性和适用性, 还能为未来的研究和实际项目部署提供宝贵的经验和见解。

4.3.2 数据预处理

在任何数据分析和实验中, 数据预处理都是一个关键的步骤, 它确保了数据的质量和一致性, 从而提高了算法模型的性能和结果的可靠性。本文选用的开源数据集主要有六个字段, 用户 ID、书籍 ID、书籍评分、职业、年龄、性别, 并需要在使用数据集前对其进行预处理。图 4.2 为数据集的进行预处理操作的主要流程。




图 4.2 数据预处理流程

Fig. 4.2 Data preprocessing process

数据预处理的具体操作表现为:

- 1) 对用户 ID 和书籍 ID 同时重复或异常的数据做删除操作, 并处理入库。
- 2) 对数据集中书籍评分字段为空的和值的格式为异常 (字段为非数字且小于 1) 的字段进行识别, 然后通过对已处理用户的相关字段计算出来的平均值, 对空值或异常值进行补充, 并处理入库。

3) 对职业和年龄字段缺失数据, 通过指定范围的随机值进行补充操作, 并处理入库。例如, 0 代表 IT, 1 代表医生, 2 代表老师, 年龄范围 20-35。

4) 在完成数据的预处理操作后, 将数据集分为训练集 (70%) 和测试集 (30%), 这样的划分可以确保模型既能够充分学习训练数据的特征, 又能够在未见过的数据上表现良好, 进而为后续的实验做准备。

针对图 4.1 中的数据进行数据预处理入库后的结果, 如图 4.3 所示。

	user_id	item_id	pref_value	age	occupation	gender
1	276725	034545104X	1	23	1	1
2	276726	0155061224	5	35	1	0
3	276727	0446520802	7	26	0	0
4	276729	052165615X	6	32	0	0
5	276733	2080674722	10	20	0	0

图 4.3 数据预处理结果

Fig. 4.3 Data preprocessing result

4.4 KM++-CF 的参数寻优

通过对 Book-Crossings 数据集中的 1837 名用户对 2937 本书籍的 184573 次评分中的用户采用 K-Means++ 聚类算法进行聚类, 做参数寻优实验, 最终确定一个聚类数目 K 的取值。聚类数目 K 取 6 组数, 对每个 K 值进行聚类操作。每个 K 值下的聚类结果, 用轮廓系数公式计算相应样本点的轮廓系数。

不同聚类数目 K 下的轮廓系数值见表 4.4。

表 4.4 不同聚类数目下的轮廓系数

Table 4.4 Contour coefficients under different cluster numbers

聚类数目 K	轮廓系数 S
12	0.313462
14	0.563510
16	0.635218
18	0.662452
20	0.582612
22	0.492753




图 4.4 不同聚类数目下的轮廓系数折线图

Fig. 4.4 Line graph of contour coefficients under different cluster numbers

由图 4.4 可以清晰地看到，当聚类数目为 18 时，K-Means++ 聚类算法的轮廓系数最高，即此时算法的性能最高。因此在接下来的研究中将在聚类数目 18 时进行实验。

4.5 数据稀疏性影响对比实验

本文对推荐系统研究的过程中采用了借阅量最大堆的技术，如果用户出现无特征和行为数据的情况，从而导致推荐书籍过少，就可以通过计算借阅量 Top-N 的书籍补充推荐结果，以降低数据稀疏性对推荐结果的影响。为了验证借阅量最大堆技术的有效性，开展了数据稀疏性的相关实验。

本实验数据集从原数据集中筛选出了书籍评分少于 3 本的 368 名用户的 21423 次评分。分为训练集（占 70%）和测试集（占 30%），聚类数目 K 取 18，邻居数分为 6 个不同的种类（5-30，间隔为 5），从准确率的角度与个人特征相似度加权推荐算法、传统协同过滤推荐算法、基于 K-Means 聚类的协同过滤算法和基于矩阵分解的协同过滤算法进行了数据分析和对比。从而验证采用借阅量 Top-N 的书籍补充推荐结果，可以很大程度上减少用户行为数据缺失时对推荐结果的影响。

在实验中计算最近邻居数不同时每种算法推荐的准确率，来考察最近邻居数比例不同对推荐结果的影响。KM++-CF 推荐算法、基于 K-Means 聚类的协同过滤算法、个人特征相似度加权推荐算法、传统的协同过滤算法和基于矩阵分解的协同过滤算法的准确率的实验结果对比，如表 4.5 所示。

表 4.5 五种算法的准确率对比表

Table 4.5 Precision comparison table of five algorithms

最近邻居数	5	10	15	20	25	30
传统协同过滤算法准确率 P	0.12	0.14	0.18	0.22	0.23	0.28
个人特征相似度加权算法准确率 P	0.13	0.16	0.18	0.24	0.25	0.32
KM++-CF 算法准确率 P	0.21	0.26	0.29	0.34	0.37	0.39
矩阵分解协同过滤算法准确率 P	0.20	0.24	0.25	0.32	0.35	0.38
K-Means 协同过滤算法准确率 P	0.14	0.18	0.22	0.24	0.28	0.33

为了清晰的展示本文的 KM++-CF 推荐算法与其它五种算法在准确率角度的对比，其折线图如图 4.5 所示。




图 4.5 五种算法的准确率对比折线图

Fig. 4.5 Precision comparison line chart of five algorithms

结果表明，KM++-CF 推荐算法展现出了较高的准确率，也就是说在用户行为数据缺失的情况下，通过借阅量最大堆对推荐结果进行补充后，用户很大程度上可以找到喜欢的书籍，进一步证实了借阅量最大堆会降低数据稀疏度对推荐结果的影响。

4.6 算法推荐效果对比实验

本小节是对本文提出的 KM++-CF 算法进行实验。利用 Book-Crossings 的数据集，数据集分为训练集（占 70%）和测试集（占 30%），聚类数目 K 取 18，邻居数分为 6 个不同的种类（5-30，间隔为 5），从平均绝对误差（MAE）、准确率（Precision）的角度对 KM++-CF 推荐算法、基于 K-Means 聚类的协同过滤算法、个人特征相似度加权推荐算法、传统的协同过滤算法和基于矩阵分解的协同过滤算法进行了数据分析和对比。下面是对几个角度的详细介绍。

4.6.1 不同邻居数下推荐的平均绝对误差的角度

计算最近邻居数不同时 KM++-CF 推荐算法、基于 K-Means 聚类的协同过滤算法、个人特征相似度加权推荐算法、传统的协同过滤算法和基于矩阵分解的协同过滤算法的平均绝对误差，考察最近邻居数不同时对推荐结果的影响，五种算法的 MAE 值实验结果对比，如表 4.6 所示。

表 4.6 不同最近邻居数下五种算法的 MAE 对比表

Table 4.6 Comparison table of MAE for five algorithms under different nearest neighbor numbers

最近邻居数	5	10	15	20	25	30
传统协同过滤算法 MAE 值	0.723	0.755	0.745	0.740	0.746	0.742
个人特征相似度加权算法 MAE 值	0.670	0.702	0.710	0.725	0.732	0.730
KM++-CF 算法 MAE 值	0.655	0.675	0.680	0.683	0.685	0.692
矩阵分解协同过滤算法 MAE 值	0.672	0.691	0.702	0.715	0.710	0.715
K-Means 协同过滤算法 MAE 值	0.685	0.697	0.713	0.735	0.733	0.735

根据表格我们可以清晰地看到随着邻居数的增加，各算法的 MAE 值均有上升再趋于平稳的趋势，但 KM++-CF 推荐算法相对于其它四种算法而言，始终保持着相对较低的水平，这就显示出此算法在处理不同规模邻居数时的稳定性和优越性，也说明本文改进的算法预测的分值与实际的分值更接近。

为了清晰的展示本文的 KM++-CF 推荐算法与其它五种算法在平均绝对误差角度的对比，其折线图如图 4.6 所示。




图 4.6 不同最近邻居数下五种算法的 MAE 对比折线图

Fig. 4.6 MAE comparison line chart of five algorithms under different nearest neighbor numbers

结果表明，KM++-CF 推荐算法在所有邻居数种类中均展现出了最低的 MAE 值，这说明该算法在预测用户评分方面更为精确，与实际观测值的偏差更小。

4.6.2 不同邻居数下推荐的准确率的角度

计算最近邻居数不同时五种算法推荐的准确率，考察最近邻居数比例不同对推荐结果的影响，五种算法的准确率实验结果对比，如表 4.7 所示。

表 4.7 不同邻居数下五种算法的准确率对比表

Table 4.7 Comparison table of precision of five algorithms under different neighbor numbers

最近邻居数	5	10	15	20	25	30
传统协同过滤算法准确率 P	0.12	0.28	0.40	0.47	0.62	0.74
个人特征相似度加权算法准确率 P	0.15	0.35	0.44	0.55	0.68	0.76
KM++-CF 算法准确率 P	0.30	0.51	0.69	0.77	0.86	0.90
矩阵分解协同过滤算法准确率 P	0.25	0.39	0.55	0.62	0.72	0.80
K-Means 协同过滤算法准确率 P	0.18	0.37	0.48	0.61	0.70	0.79

为了清晰的展示本文的 KM++-CF 推荐算法与其它五种算法准确率的对比，其折线图如图 4.7 所示。




图 4.7 不同邻居数下五种算法的准确率对比折线图

Fig. 4.7 Line chart of comparison of precision of five algorithms under different neighbor numbers

结果表明,本文的 KM++-CF 推荐算法与其它四种算法相比展现出了较高的准确率,这意味着该算法能够更准确地捕捉到用户的兴趣点,提供更相关性的推荐。而且本文提出的 KM++-CF 推荐算法结合用户的个人特征和聚类信息来进行推荐,考虑了用户的个人偏好和群体偏好,因此该算法可以更精确地推荐适合用户的物品。

总的来说,准确率是衡量推荐算法性能的重要指标,但需要考虑多个因素和综合评估不同算法的表现。对于特定的数据集和应用场景,不同的算法可能会有不同的准确率表现。但是上述实验结果进一步证实了 KM++-CF 推荐算法在提升用户满意度和系统实用性方面存在优势,即本文改进的推荐算法比基于 K-Means 聚类的协同过滤算法、个人特征相似度加权推荐算法、传统的协同过滤算法和基于矩阵分解的协同过滤算法的推荐效果好。

4.6.3 不同训练集下推荐的平均绝对误差的角度

通过改变训练集的比例(30%-90%)考察训练集比例不同时,五种算法的平均绝对误差,进一步得到算法对推荐结果的影响。五种算法实验结果对比,如表 4.8 所示。

表 4.8 不同训练集比例下五种算法的 MAE 对比表

Table 4.8 Comparison table of MAE for five algorithms under different training set ratios

训练集比例	30%	40%	50%	60%	70%	80%	90%
传统协同过滤算法 MAE 值	0.760	0.752	0.741	0.730	0.720	0.723	0.728
个人特征相似度加权算法 MAE 值	0.758	0.740	0.735	0.728	0.715	0.702	0.710
KM++-CF 算法 MAE 值	0.729	0.720	0.710	0.697	0.687	0.683	0.679
矩阵分解协同过滤算法 MAE 值	0.742	0.736	0.720	0.711	0.702	0.693	0.697
K-Means 协同过滤算法 MAE 值	0.746	0.738	0.726	0.715	0.706	0.702	0.700

为了清晰的展示本文的 KM++-CF 推荐算法与基于 K-Means 聚类的协同过滤算法、个人特征相似度加权推荐算法、传统的协同过滤算法和基于矩阵分解的协同过滤算法的准确率在训练及比例不同时，平均绝对误差的对比，其折线图如图 4.8 所示。




图 4.8 不同训练集比例下五种算法的 MAE 对比折线图

Fig. 4.8 MAE comparison line chart of five algorithms under different training set ratios

结果表明，在不同的训练集比例下，KM++-CF 推荐算法较其它四种算法来说 MAE 值始终维持在较低水平。也就是说，本文提出的 KM++-CF 算法在数据集比例增大时能够更好地处理推荐问题，使推荐结果更准确。

综上所述,从平均绝对误差和准确率的不同角度对五种算法进行实验分析后,可以得到本文提出的 KM++-CF 推荐算法在不同的邻居数种类和训练集比例下,展现出了优越的平均绝对误差控制和较高的准确率。这表明本文提出的 KM++-CF 推荐算法是一种有效的、优越的推荐算法,能够为用户提供更准确、更相关的推荐。

本章小结

本章利用 Book-Crossings 数据集来进行实验设计和结果分析,将本文的改进算法、基于 K-Means 聚类的协同过滤算法、个人特征相似度加权推荐算法、传统的协同过滤算法和基于矩阵分解的协同过滤算法在几种情况下进行平均绝对误差、准确率的对比,最终通过对比实验表明了本文提出的算法推荐效果更好。

第五章 基于 KM++-CF 的推荐系统的实现

本章主要是依据目前互联网电商的需求并结合实际，将本文提出的改进算法对书籍推荐系统进行实现，以验证本文算法改进的成果。即个性化书籍推荐系统的设计与相关功能的实现。

5.1 系统需求分析

目前，消费者在选择和购买商品时面临巨大的选择困难和信息过载，这尤其体现在图书领域，因为书籍的种类繁多，涵盖了各个领域和主题，消费者很难在众多的选项中找到最适合自己的书籍，为此本文进行了基于 KM++-CF 的书籍推荐系统的实现，其需求分析涉及多个关键方面，首先，系统需要能够收集和分析用户的借阅历史和评分数据，以便构建精准的用户偏好模型。其次，必须具备高效的数据处理能力，以便从大量的书籍中识别出与用户兴趣相关的项目。此外，系统应能够处理稀疏数据和冷启动问题，确保新用户和新书籍也能获得有效的推荐。系统还应支持实时更新，以反映用户兴趣的变化和新的借阅行为。最后，为了提供个性化的推荐，系统需要具备用户和书籍相似度的计算与更新机制，以及生成推荐列表的算法。这些需求共同确保了推荐系统能够为用户提供高质量、相关性强的书籍推荐，从而提升用户体验和满意度。

本书籍推荐系统的功能主要从以下方面来实现，功能模块如图 5.1 所示。




图 5.1 功能模块图

Fig. 5.1 Functional module diagram

5.2 系统设计

本系统采用单体架构进行设计,从而实现前端交互和后端数据处理,并通过定时任务对数据进行定时推荐。具体来说,前端使用 Html、CSS、JS 技术和 Boot Strap 框架在 Vs Code 上进行开发。后端程序使用 Java 语言和 Spring Boot 框架在 Idea 上进行开发。数据存储选用 MySQL 关系型数据库,缓存数据使用 Redis 非关系型数据库。通过前后端分离架构和 Nginx 网关保证系统的正常稳定运行。

其系统架构图如图 5.2 所示。




图 5.2 系统架构设计图

Fig. 5.2 System architecture design diagram

5.3 系统实现

本系统的功能主要就是实现书籍的推荐与展示功能。管理员用户进入本系统后,对书籍信息进行修改或上架处理,以便普通用户借阅和查看。普通用户登入本系统后,直接在页面看到系统自动推荐的书籍,可以将自己想要借阅的书籍信息(书名或作者)输入到对应的搜索框中,输入后系统会调用相应的接口,对数据进行预处理工作。用户借阅书籍后,会根据第三章提出的 KM++-CF 算法对用户进行书籍推荐,并将推荐的书籍显示在系统页面中。系统推荐时的业务流程如图 5.3 所示。




图 5.3 书籍推荐系统业务流程

Fig. 5.3 Book recommendation industry system business process

本文在书籍推荐系统的实现过程中，主要实现了用户管理模块、书籍管理模块、借阅管理模块、书籍个性化推荐模块，具体功能如下。

（1）用户管理模块

主要控制用户进入系统时的登录和注册操作。当用户进入系统并登录时，首先会检测是否已经注册账号，如果已经注册账号则使用已有的账号进行登录。如果没有账号会跳转到手机注册页面，同时输入用户的职业和年龄信息。提醒用户绑定手机，同时自动为用户注册一个全新的账号。

（2）书籍管理模块

主要针对系统中书籍的基本管理操作，如果用户为普通用户，则用户只能针对书籍进行借阅、评分操作。如果用户作为管理员，则可以新增或删除用户书籍信息、修改封面和书籍简介等。通过上架功能将录入的书籍展示给普通用户借阅和查看。

（3）借阅管理模块

主要针对书籍借阅时的基本管理操作。主要用于普通用户对书籍的查看、借阅、和评分操作。当用户借阅书籍时，会检查当前书籍是否已经被借阅，当书籍已被借阅时会

提醒用户。如果还有库存容量，则借阅成功。生成书籍借阅记录。同时用户归还书籍时可以对书籍进行评分，此评分也是用作书籍推荐的主要数据来源。

（4）书籍个性化推荐模块

主要是针对普通用户的职业、年龄、借阅记录结合本文优化后的书籍推荐算法并产生相关用户的推荐书籍。本系统会在用户浏览书籍主页面时，将算法推荐的 3 本书籍展示在系统左侧，用户可通过点击快速进入的书籍详情进行借阅。其中，在书籍个性化推荐模块中，如果用户特征和行为数据完整，那么系统将自动推荐 3 本书供用户参考，若出现用户特征和行为数据的情况，那么将会出现推荐书籍少于 3 本的状况，就根据借阅量最大堆技术实现书籍补充推荐，步骤如下：

步骤一：登陆系统，查询用户注册的基本信息；

步骤二：查询某个用户是否有书籍评分数据，如果没有执行步骤五，如果有执行步骤三；

步骤三：通过 $KM++-CF$ 算法结合用户的个人综合特征和行为数据产生推荐结果；

步骤四：推荐结果是否包含 3 本书，包含就把推荐结果录入数据库，不包含执行步骤五；

步骤五：选出借阅量 $Top-N$ 的书籍补充推荐，把推荐结果录入数据库。

步骤六：重复步骤二至五，直到所有用户推荐完成结束。

由上述步骤可知，系统算法会通过计算借阅量 $Top-N$ 的书籍补充推荐结果，这种方式很大程度上降低了数据稀疏性对推荐结果的影响。

5.4 系统页面展示

用户成功登录到此系统后，默认进入书籍推荐的系统页面，页面中部可以直接看到部分书籍信息。由于本系统限定为推荐 3 本可能会喜欢的书籍，因此最终推荐的书籍，将会在用户进入系统后，直接展示在系统页面左侧列表框内。书籍推荐系统登入后显示的页面，如图 5.4 所示。




图 5.4 书籍推荐系统页面
Fig. 5.4 Book recommendation system page

如果想要查询推荐书籍的详细信息，可以通过点击书籍推荐系统页面左侧的推荐列表直接进入到推荐书籍的详情页面，包括书籍的名称、作者、借阅次数、出版社等信息。如图 5.5 所示。



图 5.5 推荐书籍详情页面
Fig. 5.5 Recommended book details page

在针对不同用户访问时会定时的对用户行为特征数据进行数据处理并产生推荐结果，在后端程序中会定时处理系统中所有用户的特征数据，如果用户特征数据为空或者推荐结果少于 3 本，将选借阅量最大的几本书籍进行补充。下面针对两个不同的用户分别进行系统登录展示：

1) 用户 1（系统右上角为用户名）的行为数据较完善，在系统中产生了 3 本书籍推荐结果，如图 5.6 所示。

图书管理系统 个人信息 我的借还 (书名,作者) 搜索 UserWang 退出					
根据您借阅喜好推荐的书籍如下:					
心理学的邀请					
算法导论					
代码大全					
图书列表					
书名	作者	出版社	出版日期	库存数量	操作
代码大全	史蒂夫·麦克康奈尔	电子工业出版社	2006-03-03 04:00:00	3	查看详情
怪诞行为学	艾瑞里	中信出版社	2010-09-10 04:00:00	1	查看详情
计算机程序的构造和解释	Harold Abelson, Gerald Jay Sussman	机械工业出版社	2004-02-04 09:00:00	1	查看详情
Don't Make Me Think	Steve Krug	New Riders Press	2005-08-18 04:00:00	1	查看详情
Effective java	Joshua Bloch	机械工业出版社	2009-01-01 04:00:00	1	查看详情
修改代码的艺术	Michael Feathers	人民邮电出版社	2007-09-25 04:00:00	1	查看详情
算法导论	Thomas H.Cormen	机械工业出版社	2006-01-20 05:00:00	4	查看详情
Practices of an Agile Developer	Venkat Subramaniam	Oreilly & Associates Inc	2006-04-04 04:00:00	1	查看详情

图 5.6 行为数据完善用户的书籍推荐页面

Fig. 5.6 Book recommendation page for users with complete behavior data

2) 用户 2（系统右上角为用户名）的行为数据缺失，只产生了 1 本书籍推荐结果，其它 2 本推荐的书籍由借阅量最大的书籍进行补充，如图 5.7 所示。

图书管理系统 个人信息 我的借还 (书名,作者) 搜索 UserLiu 退出					
根据您借阅喜好推荐的书籍如下:					
经济学 (借阅量: 598)					
投资学基础 (借阅量: 492)					
编程珠玑					
图书列表					
书名	作者	出版社	出版日期	库存数量	操作
代码大全	史蒂夫·麦克康奈尔	电子工业出版社	2006-03-03 04:00:00	3	查看详情
怪诞行为学	艾瑞里	中信出版社	2010-09-10 04:00:00	1	查看详情
计算机程序的构造和解释	Harold Abelson, Gerald Jay Sussman	机械工业出版社	2004-02-04 09:00:00	1	查看详情
Don't Make Me Think	Steve Krug	New Riders Press	2005-08-18 04:00:00	1	查看详情
Effective java	Joshua Bloch	机械工业出版社	2009-01-01 04:00:00	1	查看详情
修改代码的艺术	Michael Feathers	人民邮电出版社	2007-09-25 04:00:00	1	查看详情
算法导论	Thomas H.Cormen	机械工业出版社	2006-01-20 05:00:00	4	查看详情

图 5.7 行为数据稀缺用户的书籍推荐页面

Fig. 5.7 Book recommendation page for users with scarce behavior data

作为管理员用户登录时，在进入系统后可以进入用户管理页面对用户进行管理。如果需要新增书籍可以直接点击新增按钮进行相关信息录入，删除或修改书籍信息的话，可以直接在搜索框对书籍的相关信息进行搜索再进行操作。

对于书籍的归还，也需要管理员进行操作。管理员进入系统后需要进入借阅管理页面，在归还过程中需要管理员输入用户对所借阅书籍的评分。归还后系统也会将评分上传到数据库中，系统根据相关评分及用户信息，实时更新前端页面进行展示。因此书籍的个性化推荐与书籍归还时用户进行的评分也是息息相关的，书籍归还时的评价页面如图 5.8 所示。




图 5.8 书籍评价页面

Fig. 5.8 Book evaluation page

本章小结

本小结是将本文提出的 KM++-CF 的推荐算法应用到了个性化的书籍推荐系统中，实现了一个可以准确进行个性化书籍推荐的系统，以满足人们在挑选琳琅满目的书籍时出现无从下手的局面。

结 论

推荐系统作为互联网应用的关键组成部分，一直受到广泛的关注和研究。传统的推荐算法在提高系统准确性方面取得了一些成功，但在个性化水平上仍有待提高。本文通过对参考文献的学习和了解，认识到了书籍推荐系统的现状，并分析了目前推荐系统的不足之处。为了更快速全面地捕捉用户兴趣和偏好，基于对协同过滤算法的研究本文提出了一种基于 K-Means++ 聚类改进的协同过滤算法（记作 KM++-CF）。

本文提出的 KM++-CF 推荐算法的主要工作总结如下，首先，引入用户个人特征相似度和职业相似度矩阵，计算出用户综合特征相似度矩阵。然后，通过 K-Means++ 聚类算法将综合相似度高的用户进行聚类，得到聚类效果最优的簇数。最后，结合用户的兴趣标签、借阅量最大堆和书籍的特征信息，得到最终的推荐结果，以降低数据稀疏性等方面对推荐结果的影响。此算法通过考虑用户的年龄、性别和职业，更全面地刻画了用户的特征，从而提高了推荐的个性化水平，优化了传统的推荐系统主要关注用户的历史行为和物品特征，而忽略了用户自身的特征信息的问题。还通过建立职业相似度矩阵，更好地挖掘了用户之间的隐含关系，这使得推荐系统更有针对性地向用户推荐可能感兴趣的物品。而且随着 K 均值聚类的引入，能更有效地将用户划分为具有相似特征的群体，有助于提高推荐系统在不同用户群体中的适应性，更好地满足不同群体用户的个性化需求。此外在对无特征和行为数据过少的用户进行推荐时引入借阅量最大堆技术，有效的降低了数据稀疏性对推荐结果的影响。

本文还通过对比实验证明了提出算法的有效性。在不同邻居数或数据集下，不管是从推荐的平均绝对误差还是准确率上看，本文提出的 KM++-CF 算法与基于 K-Means 聚类的协同过滤算法、个人特征相似度加权推荐算法、传统的协同过滤算法和基于矩阵分解的协同过滤算法相比，能够为用户提供更准确、更相关的推荐，同时保持高效的计算性能，这为进一步优化推荐系统提供了有力的支持。此外，为了验证算法改进的成果，本文依据目前互联网电商的需求并结合实际，将本文提出的 KM++-CF 的推荐算法应用到了个性化的书籍推荐系统中，实现了一个可以准确进行个性化书籍推荐的系统，以满足人们在挑选琳琅满目的书籍时出现无从下手的局面。

本文虽然实现了基于协同过滤算法的书籍推荐系统的研究，但是由于本人的学术水平有限以及研究改进算法的时间有限，本文存在很多的缺点与不足，未来我将尝试从以下方面入手，继续改进和优化基于年龄、性别和职业的用户相似度计算方法，加深对协同过滤算法改进的研究：

1) 多模态信息整合, 推荐系统可以收集用户的多种信息, 包括用户的行为数据 (如浏览记录、购买记录等) 和社交网络信息 (如好友关系、分享行为等)。通过整合这些多模态数据, 可以更全面地了解用户的兴趣和偏好。

2) 动态用户建模, 用户的兴趣和偏好是会随着时间变化的, 传统的用户建模方法往往只考虑静态的用户特征和偏好, 无法及时适应用户兴趣的变化。因此, 推荐系统需要探索实时用户建模的方法, 使系统能够更好地捕捉用户兴趣的变化, 并提供及时的推荐。

3) 深度学习应用, 深度学习模型具有强大的学习能力, 可以学习到用户特征之间的复杂非线性关系, 进一步提高用户相似度的准确性。通过引入深度学习模型, 推荐系统可以从大量的用户行为数据中学习到更准确、更细粒度的用户特征表示。

4) 在线学习和反馈机制, 推荐系统需要建立用户反馈的在线学习机制, 通过用户行为的反馈动态调整相似度计算, 提供更个性化的推荐。系统可以实时监测用户对推荐内容的点击、购买等行为, 根据用户的反馈信息进行在线学习和调整。

5) 推荐系统的社会影响研究, 这项研究可以关注推荐系统对用户的观点形成、信息过滤和社交网络结构等方面的影响。通过深入了解推荐系统的社会影响, 可以更好地设计和优化推荐算法, 使其更符合用户的需求, 并避免潜在的负面影响。

综合而言, 我相信这些进一步的研究方向将推动个性化推荐系统朝着更智能、更精准以及更符合用户期望的方向去发展, 为个性化推荐领域的研究和实际应用做出更大的贡献。

参 考 文 献

- [1] 姜宇, 黄芳. 大数据时代下计算机软件技术的运用[J]. 数字技术与应用, 2023, 41(12): 34-36.
- [2] 赵俊逸, 庄福振, 敖翔, 等. 协同过滤推荐系统综述[J]. 信息安全学报, 2021, 6(05): 17-32.
- [3] Goldberg D, Nichols D A, Oki B M, et al. Using collaborative filtering to weave an information TAPESTRY[J]. Communications of the ACM, 1992, 35(12): 61-70.
- [4] Resnick P, Iacovou N, Suchak M, et al. GroupLens: an open architecture for collaborative filtering of netnews[C]. Proceedings of the 1994 ACM Conference on Computer Supported Cooperative Work, Oct 22-26, 1994. New York, NY, USA: ACM, 1994: 175-186.
- [5] Koohi H, Kiani K. User based collaborative filtering using fuzzy C-means[J]. Measurement, 2016, 91(1): 134.
- [6] Su X, Khoshgoftaar T M. Collaborative filtering for multi-class data using belief nets algorithms[J]. International Journal on Artificial Intelligence Tools, 2008, 17(1): 71.
- [7] 孙小华, 陈洪, 孔繁胜. 在协同过滤中结合奇异值分解与最近邻方法[J]. 计算机应用研究, 2006, 23(9): 206.
- [8] 刘艺, 冯钧, 魏童童, 等. 一种改进的协同过滤推荐算法[J]. 计算机与现代化, 2017(1): 1.
- [9] MacQueen J. Some methods for classification and analysis of multivariate observation[C]. //Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability. Berkeley: University of California Press, 1967: 281-297.
- [10] 贾瑞玉, 李玉功. 类簇数目和初始中心点自确定的K-means算法[J]. 计算机工程与用, 2018, 54(7): 152-158.
- [11] Arthur D, Vassilvitskii S. K-means++: the advantages of careful seeding[J]. Proceedings of Theghteenth Annual Acm Siam Symposiumon Discrete Algorithms Society for Industrial & Applied Mathematics, 2007, 11(6): 1027-1035.
- [12] Tibshirani R, Hastie W T. Estimating the umber of clusters in a data Et via the gap statistic[J]. Journal of the Royal Statistical Society, 2001, 63(2): 411-423.
- [13] 周美琪. 基于混合推荐的个性化图书推荐系统的设计与实现[D]. 北京印刷学院, 2023.
- [14] Capo M, Perez A, Lozano J A. An efficient approximation to the K-means clustering for massive data[J]. Knowledge-Based Systems, 2017, 117(2): 56-69.
- [15] 饶俊阳, 贾爱霞, 冯岩松, 等. 基于本体结构的新闻个性化推荐[J]. 北京大学学报: 自然科学版, 2014, (1): 2-9.
- [16] 王蓉, 刘宇红, 张荣芬. 基于混合聚类与融合用户属性特征的协同过滤推荐算法[J]. 现代电子技术, 2021, 44(06): 179-182.
- [17] 刘昊东. 基于改进的协同过滤算法在课程资源推荐系统的应用[D]. 南京邮电大学, 2023.
- [18] 贾贵嫔. 数据挖掘在电子商务推荐系统中的应用研究[J]. 新经济, 2016, (24): 41-42.
- [19] Said A. Replicable Evaluation of Recommender Systems[C]. ACM Conference on Recommender Systems. ACM, 2015: 363-364.
- [20] Hopfgartner F, Kille B, Heintz T, et al. Real-time Recommendation of Streamed Data[C]. ACM Conference on Recommender Systems. ACM, 2015: 361-362.

- [21] Karatzoglou A, Hidasi B. Deep Learning for Recommender Systems[C]. the Eleventh ACM Conference. ACM, 2017: 396-397.
- [22] Wenjun L. Intelligent Recommendation System Based on the Infusion Algorithms with Deep Learning, Attention Network and Clustering[J]. International Journal of Computational Intelligence Systems, 2023, 16(1): 21-34.
- [23] Wang E, Chen Y, Li Y. Research on a Hotel Collaborative Filtering Recommendation Algorithm Based on the Probabilistic Language Term Set[J]. Mathematics, 2023, 11(19): 31-44.
- [24] You J. E-commerce Recommendation Algorithm Based on Big Data Analysis and Genetic Fuzzy Clustering[J]. Financial Engineering and Risk Management, 2023, 6(9): 3-14.
- [25] Xiaojuan C, Huiwen D. Research on Personalized Recommendation Methods for Online Video Learning Resources[J]. Applied Sciences, 2021, 11(2): 804-804.
- [26] 马健, 杜泽宇, 李树青. 基于多兴趣特征分析的图书馆个性化图书推荐方法[J]. 现代图书情报技术, 2012, (06): 1-8.
- [27] 周正国. 个性化书籍推荐系统探究[J]. 信息与电脑(理论版), 2012, (22): 184-185.
- [28] 方芳. 基于深度学习的推荐算法框架研究[J]. 长江信息通信, 2023, 36(07): 43-45.
- [29] Wang Y, Zhu Y, Zhang Z, et al. Design of Hybrid Recommendation Algorithm in Online Shopping System[J]. Journal of New Media, 2021, 3(4): 119-128.
- [30] Jianrui C, Tingting Z, Qilao Z, et al. Delayed evolutionary game clustering-based recommendation algorithm via latent information and user preference[J]. Engineering Applications of Artificial Intelligence, 2023: 124.
- [31] 孟祥福, 霍红锦, 张霄雁, 等. 个性化新闻推荐方法研究综述[J]. 计算机科学与探索, 2023, 17(12): 2840-2860.
- [32] 董杨帆. 改进协同过滤算法的图书推荐系统设计与实现[J]. 情报探索, 2021, (07): 46-51.
- [33] 向俊伟. 基于聚类的协同过滤推荐算法及其并行化研究[D]. 南京邮电大学, 2023.
- [34] 苏湛, 陈学谦, 艾均, 等. 基于用户相似性选择及标签距离的推荐算法[J]. 应用科学学报, 2023, 41(06): 940-957.
- [35] 林建辉, 王茜冉, 詹可强. 基于聚类与差异协调的协同过滤推荐算法[J]. 兰州文理学院学报(自然科学版), 2023, 37(06): 50-54.
- [36] 蒋云, 倪静, 房宏扬. 融合社交行为和标签行为的推荐算法研究[J]. 计算机应用研究, 2019, 36(07): 1965-1969.
- [37] 于金明, 孟军, 吴秋峰. 基于改进相似性度量的项目协同过滤推荐算法[J]. 计算机应用, 2017, 37(05): 1387-1391+1406.
- [38] 凌婷. 协同过滤推荐算法研究进展[J]. 信息记录材料, 2023, 24(11): 16-18.
- [39] 纪平, 胡学友, 杨文娟, 等. 基于矩阵分解的协同过滤推荐算法[J]. 合肥学院学报(综合版), 2020, 37(05): 10-18.
- [40] 张晶晶. 基于矩阵分解的协同过滤推荐算法研究与实现[D]. 南京邮电大学, 2023.
- [41] 周小博. 基于改进相似度的矩阵分解推荐算法研究[J]. 工业控制计算机, 2023, 36(07): 107-109.
- [42] 东苗, 王启宗. 基于矩阵分解和层次聚类的协同过滤推荐算法[J]. 电子技术与软件工程, 2020, (17): 183-185.

- [43] Yu C, Huang L. A Web service QoS prediction approach based on time- and location-aware collaborative filtering[J]. Service Oriented Computing and Applications, 2016, 10(2): 135-149.
- [44] Sui X, Yu F, Tong Z, et al. The Improvement and Application of Collaborative Filtering Algorithm Based on Item[J]. Frontiers in Artificial Intelligence and Applications, 2018: 840-845.
- [45] Wang R, Imran M, Saleem K. A microservice recommendation mechanism based on mobile architecture[J]. Journal of Network and Computer Applications, 2020: 152.
- [46] 邵小青, 贾钰峰, 章蓬伟, 等. 基于K-Means聚类算法的数据分析[J]. 科学技术创新, 2021, (23): 85-86.
- [47] 郝雅娴. K-Means聚类中心最近邻推荐算法[J]. 山西师范大学学报(自然科学版), 2021, 35(01): 72-78.
- [48] Chen Y, Sun J, Xu Z, et al. A Study of Digital Museum Collection Recommendation Algorithm Based on Improved Fuzzy Clustering Algorithm[J]. International Journal of Computational Intelligence and Applications, 2023, 23(01): 20-30.
- [49] Ouyang P. The construction of college students' job recommendation model based on improved k-means-CF[J]. International Journal of Computational Systems Engineering, 2023, 7(2-4): 190-198.
- [50] 张玉琴, 梁莉, 张建亮, 等. 基于改进K-means++和DBSCAN的大数据聚类方法[J]. 国外电子测量技术, 2022, 41(09): 40-46.
- [51] 韩煜, 王青, 刘丽娜. K-means聚类算法的优化研究 [J]. 软件, 2023, 44(10): 58-61.
- [52] 郭文娟. 基于优化初始聚类中心的K-means聚类算法[J]. 科技风, 2022, (04): 63-65.
- [53] 曲福恒, 宋剑飞, 杨勇, 等. 基于min-max准则与区域划分的I-k-means-+聚类算法[J]. 吉林大学学报(理学版), 2023, 61(05): 1131-1138.
- [54] 郭宪超, 李廷元. 基于K-means++时间聚类的飞行航迹预测[J]. 现代计算机, 2022, 28(03): 54-57.
- [55] 谢红, 杨良洁, 解武. 基于改进的空间金字塔词袋模型的图像分类算法研究[J]. 应用科技, 2018, 45(04): 89-94.
- [56] Xu Zihang, Zhu Jiawei. Application of Sensor and Fuzzy Clustering Algorithm in Hybrid Recommender System[J]. Journal of Sensors, 2022: 20-33.
- [57] 刘贞, 张小真. 基于堆栈模型的数据挖掘算法研究[J]. 西南师范大学学报(自然科学版), 2002, (03): 312-315.
- [58] 董昊烨, 樊重俊. 基于对比学习的图书推荐系统冷启动研究[J]. 智能计算机与应用, 2023, 13(11): 112-118.
- [59] 郑歆. 协同过滤算法在图书推荐系统中的应用[J]. 长江信息通信, 2023, 36(12): 60-62.
- [60] 付羽道, 王祎珺, 敖明明等. 一种基于协同过滤的图书推荐平台[J]. 中国科技信息, 2021, (10): 117-118.
- [61] 魏浩, 张伟, 郭新明. 应用聚类分析的协同过滤推荐算法[J]. 福建电脑, 2021, 37(05): 1-4.
- [62] 刘贤锋, 刘同存. 基于属性聚类的项目评分预测推荐算法研究[J]. 统计与决策, 2012, (18): 9-11.
- [63] 易茹. 基于K均值聚类算法的数字媒体推荐方法研究[J]. 长春工程学院学报(自然科学版), 2020, 21(04): 99-102.
- [64] 王辉, 赵玮, 祁薇. 基于用户特征的K-means聚类算法应用与改进研究[J]. 电脑知识与技术, 2018, 14(35): 17-19.

- [65] 曾蔚. 一种基于K-均值的用户行为聚类算法[J]. 绵阳师范学院学报, 2015, 34(08): 94-98.
- [66] 刘庆鹏, 陈明锐. 优化稀疏数据集提高协同过滤推荐系统质量的方法[J]. 计算机应用, 2012, (4): 7-13.