

# 基于协同过滤算法的电影推荐系统设计与实现

邢艳芳

(南京传媒学院, 南京 211172)

**摘 要:** 电影作为海量信息的一个重要载体, 存在信息过载问题, 因此将推荐算法应用于电影推荐具有重大意义。文中主要研究基于协同过滤算法的电影推荐系统, 该系统主要由三部分组成, 包括前台的电影界面展示、系统的推荐算法以及后台数据集; 首先, 该系统通过网络爬虫爬取与电影相关的数据; 其次, 通过协同过滤算法过滤出用户感兴趣的电影; 最后, 通过图形用户界面进行数据交互, 针对数据集中的用户推荐数据集中的相关电影, 系统最终的运行结果与预期呈现的结果基本一致。

**关键词:** 推荐系统; 协同过滤算法; 爬虫; 图形用户界面; 电影数据

**中图分类号:** TP391.3    **文献标识码:** A    **文章编号:** 1009-2552(2025)05-0009-06

**DOI:** 10.13274/j.cnki.hdzt.2025.05.002

## Design and implementation of movie recommendation system based on collaborative filtering algorithm

XING Yan-fang

(Communication University of China, Nanjing 211172, China)

**Abstract:** Movie is served as an important carrier of massive information, and has the problem of information overload. Therefore, it has great significance for applying the recommendation algorithm to movie recommendation. This topic mainly studies the movie recommendation system based on collaborative filtering algorithm, which is mainly composed of three parts, including the foreground movie interface display, the system recommendation algorithm and the background data set. The system crawls data related to movies through web crawler, filters out movies that users are interested in through collaborative filtering algorithm, and finally carries out data interaction through graphical user interface to recommend related movies in data set for users in data set, the final results of the system are similar to the expected results.

**Key words:** recommendation system; collaborative filtering algorithm; crawler; GUI; movie data

## 0 引 言

在信息过载的时代, 如何在大量数据中准确挖掘出用户的潜在需求、为用户节约时间、追踪用户喜好变化、为用户精准推荐, 对信息消费者和信

息生产者日益重要。推荐系统与搜索引擎的产生, 都是为了解决信息过载问题的, 并且均可以快速给用户实用信息工具, 区别在于搜索引擎需要通过用户主动提供准确的关键词获取信息, 而推荐系统不需要用户有很明确的需求。首先, 推荐系统分析用户的历史行为; 其次, 给用户建模; 最后, 将能满足用户兴趣和需求的物品推荐给用户。推荐算法的研究与个性化推荐概念都是在 20 世纪 90 年代提出的<sup>[1]</sup>, 此后, 这种主动式的个

**基金项目:** 2023 年校级教学改革研究项目(JG202305); 2023 年教育部第二期供需对接就业育人项目(202301-03787); 2022 年全国高等院校计算机基础教育研究会计算机基础教育教学研究项目(2022-AFCEC-093)

**作者简介:** 邢艳芳(1981-), 女, 硕士, 副教授, 研究方向为嵌入式系统、人工智能等。

性化推荐在电商领域和电影视频领域开始有了广泛的应用<sup>[2]</sup>,各大互联网企业建立了自身独特的推荐系统。Netflix 和亚马逊是推荐系统领域的领头羊,不同之处在于亚马逊致力于电商领域,而 Netflix 将推荐系统应用于电影视频领域。Netflix 算法基于物品的推荐算法,把和用户曾经喜欢、相似的影片推荐给用户。

国内的电影推荐系统在网络视频和用户的成长加持下逐步发展起来。豆瓣电影在国内的电影分享社区中占据举足轻重的地位,其主要工作原理是基于用户的一些表达个人喜好的操作产生推荐结果。例如,用户对电影的评分、评价、点赞和分享等都可以被视为表达个人喜好。

本文则利用推荐算法中的协同过滤算法设计一个电影推荐系统,通过电影之间的相似度与用户的历史行为向用户推送与之相关的影片,使用户的观影兴趣更加浓烈。

1 系统算法概述

1.1 基于物品的协同过滤算法

基于物品的协同过滤算法是目前推荐算法中应用最多的算法之一,UserCF 算法存在一些缺陷,如用户量增多、计算复杂度变大,且该算法很难对推荐结果做出较好的解释<sup>[3]</sup>,因此 ItemCF 算法被提出以及广泛应用。首先,该算法主要根据数据库中所有用户对某件物品的评价;其次,计算每两件物品之间的相似度;最后,将相似度较高的物品推荐给感兴趣的用户。例如,已知物品与相似物品的风格类似、价格相仿,所以用户在选择已知物品的同时也会留意到相似物品。根据用户 B 和用户 C 可知,喜欢已知物品,也会喜欢相似物品;再根据用户 D 不喜欢已知物品,也会不喜欢相似物品。由此可以通过用户 A 喜欢已知物品推出用户 A 可能会喜欢相似物品,如图 1 所示。

基于 ItemCF 算法的一般推荐步骤如下:①采集用户个人信息,主要是行为记录与个人喜好;②计算物品之间的相近度;③通过 ItemCF 算法预测用户对物品的评价,从而给用户生成符合用户兴趣的推荐列表。

与 UserCF 算法相比,ItemCF 算法的解释性更好,可以使用户对推荐系统的信任度增加。




图 1 基于物品的协同过滤

ItemCF 算法存在以下问题:在冷启动<sup>[4]</sup>的情况下无法直接使用,如果不加干预,该算法会优先推荐热门物品。

1.2 余弦相似度

将某用户和其对物品的评分类比成一个矩阵  $[A,B]$ ,也可以理解为一个  $a$  维向量, $a$  代表用户的数量, $B$  代表物品的数量。通过计算两向量(用户)的余弦夹角计算这两个用户之间的相似度,夹角越小,余弦值则越大,那么相似度也就越高<sup>[5]</sup>。假设有两向量,其中  $A$  向量表示目标用户, $B$  向量表示其他用户,则用户  $A$  和用户  $B$  的余弦相似度计算如公式(1)所示。

$$\cos(A,B) = \frac{A \cdot B}{|A| \cdot |B|} = \frac{\sum_{i=1}^n (a_i \cdot b_i)}{\sqrt{\sum_{i=1}^n (a_i)^2} \cdot \sqrt{\sum_{i=1}^n (b_i)^2}} \tag{1}$$

2 系统设计思路

2.1 系统需求分析

该电影推荐系统的 GUI<sup>[6]</sup> 主要包括以下功能:新用户注册界面、系统用户登录界面、电影搜索页面和电影推荐与热门电影页面和电影详情页面等。

用户注册与登录界面:倘若是新用户,需要注册账户和设置密码;如果是数据库中的已知用户,直接登录即可。

电影推荐与热门电影页面:电影推荐界面是该电影推荐系统的核心部分,主要利用推荐算法为用户推荐符合其喜好的电影及热门电影,该系

统的推荐算法选择基于物品的协同过滤算法,相似度的计算选择余弦相似度的方法计算。针对用户的电影推荐,主要通过用户喜爱的电影类型,以及用户过往电影评分等方面进行推荐。热门电影推荐部分主要根据电影的评分指标进行推荐。例如,将评分大于 8.5 分的电影作为热门电影推荐给用户。

电影搜索与详情页面:电影搜索页面主要是通过用户输入电影名称,系统将电影评分以及电影链接反馈给用户。电影详情页面与搜索页面一样输入电影名称,然后系统将电影的详细资料,如电影导演、编剧、国家、片长、评分、电影简介和电影海报等一系列信息反馈给用户。

2.2 系统架构模型

该系统使用三层架构进行开发设计,三层架构在系统开发中使用比较普遍,主要优点是可以使模块的可移植性以及可重用性增强,并且可以使层与层之间的依赖降低,分层工作,从而提高工作效率。本系统的三层架构:数据层、系统核心层、用户交互层。数据层:主要是通过爬虫爬取豆瓣网的电影相关信息以及用户相关信息<sup>[7]</sup>。系统核心层:主要是指推荐算法模块,该系统主要使用 ItemCF 算法实现推荐。用户交互层:主要功能是将系统可视化,需使用 PyQt5 技术构建一个 GUI 界面的方式实现。系统架构图如图 2 所示。

2.3 系统推荐流程

用户在使用该电影推荐系统时,如果该用户是新用户,或者说系统数据集中没有该用户的相关信息,则系统会提醒该用户注册账号,并让该新用户选择其喜欢的电影类型,最后进行推荐界面渲染展示;如果该用户是老用户,即数据集中有该用户的信息,则系统直接读取该用户的推荐信息,从而进行电影推荐并渲染展示<sup>[8]</sup>。该电影推荐系统的具体推荐流程,如图 3 所示。

3 系统功能模块详细设计

3.1 数据相关模块

该系统所用到的电影相关数据通过爬虫获取,电影数据来源是豆瓣电影网站的影片信息以及对应电影下面评论的用户信息。本次系统的爬虫设计主要功能如下:爬取电影相关数据、爬取电




图 2 系统架构图




图 3 系统推荐流程图

影页面短评下面的五位用户 ID 以及看过的电影信息、爬取对应电影的海报<sup>[9]</sup>。

此次爬虫选取的电影接口为 `https://movie.douban.com/j/new_search_subjects?sort=U&range=0,10&tags=%E7%94%B5%E5%BD%B1&start=0`<sup>[10]</sup>,其中 `start=0` 为接口索引参数,`start=0` 表示第一页的电影数据,每页有 20 部电影,本次爬虫最终爬取了 2600 部电影、2500 个用户。最后一次爬取电影数据时间为 2023 年 3 月中旬。

爬虫过程如下:首先,使用 Requests 技术模拟浏览器发送网络请求获取电影列表页面信息,将其转换成 Json 格式<sup>[11]</sup>。第一次数据挖掘通过关键字索引获取到电影名称、电影评分、导演、电影 ID、电影链接、电影海报以及主演信息。第二次数据挖掘借助第一次数据挖掘时获取到的电影 URL 链接,再借助 Xpath、Re 正则表达式等辅助工具获取到电影英文名、编剧、电影类型、国家、电影语言、上映日期、电影片长、电影简介以及电影下面 5 个用户界面 URL。第三次数据挖掘借助第二次数据挖掘时获取到的用户界面 URL,再借助一些辅助工具获取到用户 ID、用户评论的电影 ID 以及对应的电影评分。

其次,电影海报图片下载处理,将第一次数据挖掘时获取到的电影海报存储到一个文件夹下,并且将电影的名称命名为电影海报的名称,最终存储的电影海报为 JPG 格式。为了方便之后的用户交互界面中电影海报的展示,利用 Python 中的 PIL 工具包,将电影海报图片从 JPG 格式转换为清晰度更高的 PNG 格式。

最后,就是数据的存储,系统数据使用 CSV 文件存储。一共有三个 CSV 文件,一个用来存储电影数据 `movies.csv`;一个用来存储用户电影评分数据 `users.csv`;还有一个 CSV 文件单独存储用户数据 `users_info.csv`,主要包括用户 ID、重置密码以及喜欢的电影类型。另外,在数据存储到 CSV 文件后又进行了简单的数据清洗,主要是将重复值删除。

### 3.2 电影推荐功能模块

电影推荐功能模块是该推荐系统的核心部

分,推荐结果主要为热门电影推荐以及个性化电影推荐。该系统的推荐算法基于 ItemCF 算法,其推荐结果最终在 GUI 界面展示。

推荐算法流程如下:首先,读取用户电影数据;其次,进行电影和用户 ID 映射构建用户-物品矩阵;再次,建立余弦相似度矩阵;最后,进行热门电影和个性化电影推荐。推荐算法的具体实现思路:①定义一个函数,参数传入电影 ID,最终返回与该电影相似度最高的若干部电影。②根据数据集中的用户数据,选出用户评分大于 4 的电影 ID 并传入上个步骤的函数中,从而避免推荐电影重复率过高的状况。③将上述函数返回的推荐电影结果暂存再推荐窗口出。最终的 GUI 展示主要是利用第三步中返回的电影 ID 到数据集中检索相关的电影的其他信息。

### 3.3 用户交互模块

该系统的用户交互层主要使用 PyQt5 技术搭建一个 GUI 界面的形式来实现,该模块主要作用是实现电影数据可视化。GUI 可视化界面主要包括用户登录与注册界面、电影推荐列表显示、热门电影推荐列表显示、电影搜索界面展示、电影详情页展示以及个人主页展示<sup>[12]</sup>。当一个用户进入该电影推荐系统的时候,首先,必须在登录页面输入用户名和密码;其次,系统将检查在系统数据集中是否有该用户,以及密码输入是否准确;如果用户输入的账号和密码都没有问题,那么该用户将登录完成;最后,直接进入推荐主页面。主页中包括电影搜索键、电影详情页面按钮以及个人主页按钮。

## 4 系统功能测试

### 4.1 登录注册界面

用户图形界面中最经典的就是登录注册界面,当一个用户进入系统时,第一步大多是进行账号登录或注册。该 GUI 界面使用如下组件:QLabel、QLineEdit、QPushButton 各两个,首先,利用嵌套布局实现界面搭建;其次,利用 `setPlaceholderText` 设置占位符,使用 `setEchoMode` 设置密码掩码<sup>[13]</sup>;再次,要连接用户名和密码的检测函数,如果用户名和密码输入为空,则登录按钮失效;最后,把注册界面通过 `clicked` 信号连接到注册按

钮上。

如果是新用户进入该电影推荐系统,则点击登录界面中的注册按钮,之后用户会进入账号注册界面。注册功能的 GUI 界面实现使用的组件有 QLabel 和 QLineEdit 各 3 个以及 1 个 QPushButton,加上嵌套布局和 clicked 信号连接。细节功能与登录界面类似。

另外,还有一个针对解决用户冷启动问题的询问界面,新用户注册成功后会出现一个询问用户喜好的界面<sup>[14]</sup>,通过初步询问用户喜爱的电影类型向用户推荐适合该用户的电影。

#### 4.2 用户主界面

用户成功登录到电影推荐系统,之后会进入用户主界面,如图 4 所示。该界面的左侧为针对用户喜好的个性化电影推荐,右侧为目前热门的部分高分电影。用户主界面的 GUI 界面中,电影内容部分是通过 QTableWidgetItem 进行布局的,另外界面的呈现方式中,电影与电影之间主要是通过表格的形式排列的,而每张表格对应到 GUI 中是通过 setColumnCount 和 setHorizontalHeaderLabels 设置表格的总列数和每列的名称的,最后在通过 setItem 的方法将电影信息写入表格中<sup>[15]</sup>。



图 4 用户主界面

在用户主界面的窗口中可以看到个人主页按钮,点击该按钮就会进入用户个人主页界面,该界面呈现一些简单的个人信息,包括在豆瓣评论的电影数量以及喜欢的电影类型。

#### 4.3 电影搜索与详情界面

从图 4 用户主界面窗口可以看到电影搜索与电影详细页面按钮。点击电影搜索按钮,可以进入图 5 所示界面,该界面便是电影搜索页面。

该搜索界面的搜索方式中支持模糊搜索,即便在搜索框中输入的电影名称不完整,只要在电影数据集中有类似的电影便会呈现出来,如图 5 搜索框中的搜索方式体现了模糊搜索,其反馈信息有电影名称、评分与链接。



图 5 电影搜索界面

同理,点击用户主界面的电影详细页面便可进入电影详情搜索界面,该界面是呈现电影详细页面前的一个过渡界面,在该界面用户将想要查看详细页面的完整的电影名称输入后搜索,如果在电影数据集中有该电影的相关信息,则会跳转到如图 6 所示的电影详细页面。在电影详细页面中可以看到电影的海报、电影导演、演员、评分、类型和简介等相关信息。




图 6 电影详细界面

经测试,该电影推荐系统的主要功能完整,在登录注册界面、用户主界面、电影搜索界面、电影详细界面、用户个人主页界面上呈现了预期效果。

## 5 结束语

本系统就电影信息过载问题制作了一个基于协同过滤算法的电影推荐系统,选择的协同过滤算法是 ItemCF 算法,相似度算法选择的是余弦相似度算法。最终通过电影之间的相似度与用户的历史行为给用户推荐其可能感兴趣的电影。

该系统所用到的电影数据以及用户数据都是在豆瓣电影网站上通过爬虫爬取到的,主要爬取的电影数据有电影名称、导演、片长、评分、类型、电影简介和电影海报等内容,最后可视化渲染时会用到这些电影相关的数据;用户数据主要是通过用户看过的电影分析用户喜欢的电影类型以及用户历史行为 and 用户名等数据,用来构建用户 - 电影矩阵时使用。

系统的用户交互可视化使用 PyQt5 技术实现,利用 PyQt5 中的一些组件搭建界面。该 GUI 界面主要包括登录注册界面、用户主界面、电影搜索界面、电影详细界面和用户个人主页界面。另外,还对该系统进行了测试,测试最终呈现效果和预期想象的一致。

## 参考文献:

- [1] 徐永燊. 基于协同过滤的体育运动员适宜项目推荐方法研究[J]. 信息技术,2022(4):147-151.
- [2] 吴猛华. 基于协同过滤的影视推荐系统设计与实现[D]. 上海:华东师范大学,2022.
- [3] 马帅. 基于用户行为和特征标签的电影推荐算法研究[D]. 武汉:武汉邮电科学研究院,2022.
- [4] 邵煜,谢颖华. 协同过滤算法中冷启动问题研究[J].

计算机系统应用,2019,28(2):246-252.

- [5] 王楠. 基于多种因素的 POI 推荐模型研究[D]. 哈尔滨:黑龙江大学,2019.
- [6] 陶文玲,侯冬青. PyQt5 与 Qt 设计师在 GUI 开发中的应用[J]. 湖南邮电职业技术学院学报,2020,19(1):19-21.
- [7] 杨健,陈伟. 基于 Python 的三种网络爬虫技术研究[J]. 软件工程,2023,26(2):24-27,19.
- [8] 李元吉. 个性化特征的电子商务智能推荐系统[J]. 信息技术,2021(3):131-135,142.
- [9] Yu Lin-xuan, Li Ye-li, Zeng Qing-tao, et al. Summary of web crawler technology research[J]. Journal of Physics: Conference Series, 2020, 1449:12036.
- [10] 段文菁. 融合知识图谱的多层兴趣建模及其在推荐系统中的应用[D]. 太原:太原理工大学,2022.
- [11] Zhang Lei, Chen Ze-ning, Yang Shu-feng. Research on the application of crawler technology in machine learning[J]. Journal of Physics: Conference Series, 2021, 1865(4):042040.
- [12] 魏子钦,单豫洲,梁艳美. 基于混合推荐算法的电影推荐研究[J]. 信息与电脑:理论版,2022,34(9):166-168.
- [13] Said Kabir Sulaiman, Nie Li-ming, Lin Yuan-chang, et al. Automated GUI widgets classification[J]. Frontiers of Computer Science, 2022, 17(1):3.
- [14] 史海燕,倪云瑞. 推荐系统冷启动问题研究进展[J]. 图书馆学研究,2021(12):2-10.
- [15] 黄率. 基于 PYQT5 的 AI 图像识别工具[J]. 现代工业经济和信息化,2023,13(1):90-91,94.

(责任编辑:卢桂娟)

(上接第 8 页)

- [10] Hong D, Zhang Z, Xu X. Automatic modulation classification using recurrent neural networks[C]. 2017 3rd IEEE International Conference on Computer and Communications (ICCC). IEEE, 2017:695-700.

- [11] Zhang F, Luo C, Xu J, et al. An efficient deep learning model for automatic modulation recognition based on parameter estimation and transformation[J]. IEEE Communications Letters, 2021, 25(10):3287-3290.

(责任编辑:卢桂娟)