



计算机科学

Computer Science

ISSN 1002-137X, CN 50-1075/TP

《计算机科学》网络首发论文

题目：基于大语言模型的推荐系统综述
作者：史鸿旭，刘艺，刘坤
网络首发日期：2026-02-05
引用格式：史鸿旭，刘艺，刘坤. 基于大语言模型的推荐系统综述[J/OL]. 计算机科学. <https://link.cnki.net/urlid/50.1075.tp.20260205.0906.004>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于大语言模型的推荐系统综述

史鸿旭 刘艺 刘坤

军事科学院 北京 100091
(1649220316@qq.com)

摘要 随着互联网应用的普及和信息过载问题的加剧，推荐系统在提供个性化服务、提升用户体验方面发挥着日益重要的作用。传统推荐方法和深度学习技术虽在用户-物品交互建模上取得显著进展，但仍受限于数据稀疏、冷启动以及对用户深层意图理解不足等问题。近年来，大语言模型凭借卓越的语义理解、知识迁移、生成能力及逻辑推理能力，为推荐系统研究开辟了新的方向。文中全面综述了基于大语言模型的推荐系统研究进展，重点分析了大语言模型在推荐流程中的融合路径与技术演进，涵盖特征工程与数据增强、特征编码与语义表示、推荐结果生成、系统与用户交互以及推荐流程协调控制等关键环节，揭示了大语言模型在提升推荐准确性、可解释性和动态适应性等方面的独特优势。此外，探讨了模型计算效率、知识可信性、系统公平性及数据安全等现实挑战，并展望了未来发展方向。通过系统整理与深入剖析，旨在为推荐系统领域的理论创新与实践应用提供参考与启示。

关键词： 大语言模型；推荐系统；序列推荐；可解释推荐；对话推荐；多模态推荐

中图分类号 TP391

Survey of Recommendation Systems Based on Large Language Models

SHI Hongxu, LIU Yi and LIU Kun

Academy of Military Sciences, Beijing 100091, China

Abstract With the proliferation of internet applications and the exacerbation of information overload, recommendation systems have been playing an increasingly important role in providing personalized services and enhancing user experience. Although traditional recommendation methods and deep learning techniques have made remarkable progress in modeling user-item interactions, they still suffer from limitations such as data sparsity, cold start problems, and insufficient understanding of users' deep intents. In recent years, large language models, armed with exceptional capabilities in semantic understanding, knowledge transfer, generation, and logical reasoning, have opened up new directions for recommendation system research. This paper presents a comprehensive survey of the research progress on recommendation systems based on large language models, focusing on analyzing their integration paths and technological evolution in the recommendation process. It covers key stages including feature engineering and data augmentation, feature encoding and semantic representation, recommendation result generation, system-user interaction, and coordinated control of the recommendation process, revealing the unique advantages of large language models in improving recommendation accuracy, interpretability, and dynamic adaptability. Furthermore, this paper discusses practical challenges such as model computational efficiency, knowledge credibility, system fairness, and data security, and prospects the future development directions. Through systematic organization and in-depth analysis, this paper aims to provide references and insights for theoretical innovation and practical applications in the field of recommendation systems.

Keywords Large language models, Recommendation systems, Sequential recommendation, Explainable recommendation, Conversational recommendation, Multimodal recommendation

基金项目：国家自然科学基金青年基金资助项目（72201275）；第八届中国科协青年人才托举工程项目（2022QNRC001）
This work was supported by the National Natural Science Foundation of China for Young Scientists (72201275) and the 8th Young Elite Scientists Sponsorship Program by CAST (2022QNRC001).
通信作者：刘坤 (lauk@pku.edu.cn)

1 引言

随着互联网技术的迅猛发展以及数字化信息的爆炸式增长,信息过载(Information Overload)问题日益突出。据 Spacelift 统计^[1],2024 年全球每天产生的数据量达到 3.2877 亿 TB,在如此庞大的信息环境中,用户如何在海量数据中高效、准确地筛选出符合自身需求的内容,已成为亟待解决的重要课题。推荐系统(Recommender Systems, RS)作为缓解信息过载、提升信息筛选效率的关键技术,近年来受到了学术界和工业界的广泛关注。其目标在于帮助用户找到相关且个性化的商品、内容或服务,既有效提升了用户体验,也为平台创造了更高的商业价值。因此,推荐系统已成为应对信息筛选效率与用户体验矛盾的核心技术手段,并在实际应用中展现出巨大的潜力和研究价值。

推荐系统的核心在于综合利用用户与物品之间显式/隐式交互数据以及各类辅助信息(如用户属性、物品特征及上下文环境等),通过建模用户偏好与物品特性间的关系,准确预测用户对未知项目的兴趣程度,从而为用户提供个性化推荐服务。^[2-3]

近年来,大语言模型(Large Language Models, LLMs)的出现为推荐系统领域带来了新的研究范式。大语言模型凭借其在海量文本数据上的预训练,具备了卓越的语义理解与生成能力,能够有效捕捉语言中的上下文关系与深层含义。这一特性使其在处理推荐系统中的文本信息、用户行为序列以及多模态数据时展现出独特优势^[4]。同时,大语言模型的零样本(Zero-Shot)和少样本(Few-Shot)学习能力为其在数据稀疏场景下的应用提供了可能,而其推理能力则为生成解释性推荐和实现复杂决策提供了技术支持^[5]。这些优势不仅弥补了传统推荐系统在知识表示与

用户建模上的不足,还为推荐系统向智能化、交互化方向发展奠定了基础。

基于大语言模型的推荐系统研究已在多个领域取得了初步进展,例如电子商务^[6]、新闻推荐^[7]、影音娱乐^[8]和社交媒体^[9]等。研究者们尝试将 LLMs 应用于推荐系统的多个关键环节,以提升推荐性能和用户体验。具体而言,用户偏好建模方面,LLMs 通过分析用户的文本数据,捕捉用户的兴趣和动机,从而更精准地构建个性化偏好模型;物品内容理解环节,LLMs 利用其自然语言处理能力,自动提取物品文本描述中的语义特征,提供更丰富的内容表示;在推荐结果生成阶段,LLMs 可通过生成式方法直接输出个性化推荐结果,或增强现有算法的可解释性与准确性;此外,在对话式推荐场景下,LLMs 为多轮人机交互提供了自然语言理解与生成支持,使系统能够实时感知用户需求变化、主动引导用户表达偏好,提供自然流畅的交互式推荐体验。然而,这一新兴领域仍面临诸多挑战,包括模型计算效率优化、数据隐私保护以及推荐结果的可解释性与公平性问题^[10]。这些挑战不仅关乎技术实现的可行性,也涉及到推荐系统在实际应用中的伦理与社会影响。因此,系统性地梳理现有研究成果,分析其方法论与应用场景,并展望未来的发展方向,具有重要的学术价值和现实意义。

现有综述已从不同方面对大语言模型推荐系统展开系统梳理。Zhao 等人^[11]从预训练、微调 and 提示三大技术范式系统梳理了大语言模型赋能推荐系统的核心方法;Wu 等人^[4]系统地将基于 LLMs 的推荐方法分为判别式与生成式两大范式,分析比较两大范式下现有方法的技术路径与性能。Lin 等人^[3]系统梳理了 LLMs 在推荐系统中的应用进展,并从将 LLMs 适配到推荐系统的

位置和方式两个维度对相关工作进行了归纳，针对这两个核心问题给出了详尽的分析与发展路径。Liu^[12]等人系统梳理了大语言模型增强推荐系统的最新进展，从知识、交互和模型三个层面全面归纳并细致分析了各类方法与未来趋势；Huang 等人^[13]系统梳理了基础模型在推荐系统三大主流范式（特征增强、生成式、智能体式）中的整合方式及其在多种推荐任务中的应用，强调了多模态和智能体能力。

相较于已有综述，本文以全流程的视角，通过细化大语言模型在特征工程与数据增强、特征编码与语义表示、推荐结果生成、系统与用户交互、推荐流程协调控制等推荐流程核心环节中的具体作用，系统剖析其融合路径与技术演进，并深入分析当前主流方法的优缺点及适用场景，归纳相关数据集与评测基准。此外，本文指出基于大语言模型的推荐系统面临模型效率、知识可信性、系统公平性与数据安全等现实挑战，并提出未来发展方向。为提供全面的综述与清晰的技术发展路径，将早期规模相对较小的语言模型（如 BERT^[14]、GPT2^[15]等）也纳入本文“基于大语言模型的推荐系统”的讨论。以期对相关领域研究人员和技术开发人员提供系统的理论参考与实践支持。

2 基础理论

推荐系统在信息时代中扮演着不可或缺的角色，通过挖掘用户行为与偏好数据，为用户提供个性化的内容和服务推荐^[2]。随着互联网数据规模激增与计算能力的提升，推荐系统经历了从传统方法向现代技术驱动的深刻变革。本章旨在回顾推荐系统的基础理论与技术演进路径，聚焦于推荐系统理论发展和技术迭代，为后续基于大语言模型的推荐系统研究奠定理论与技术基础。

2.1 推荐系统发展概述

推荐系统最早起源于二十世纪九十年代

^[16]，其目的是通过自动化方式帮助用户在海量信息中发现感兴趣的内容或产品，从而解决日益突出的信息过载问题。随着互联网的快速发展，特别是电子商务和在线媒体的兴起，推荐系统作为业务系统的核心组成部分，得到了广泛的应用和发展。

传统推荐系统主要包括协同过滤（Collaborative Filtering）、基于内容的推荐（Content-based Recommendation）以及混合推荐方法（Hybrid Methods）。协同过滤通过分析用户-物品交互矩阵，挖掘用户或物品之间的潜在相似性，实现个性化推荐；基于内容的推荐则依赖于物品的属性特征与用户历史偏好的匹配，以捕捉用户兴趣，实现个性化推荐；混合方法则结合上述两类思路，提升推荐的多样性与准确性。这些方法在目标和用户单一以及物品较少等场景下有效，但在面对数据稀疏、冷启动及动态兴趣建模等复杂实际问题时，逐渐暴露出建模能力受限、泛化性不足等局限性。

深度学习的兴起突破了传统方法的瓶颈^[17]。神经协同过滤（NCF）通过多层感知机（MLP）替代传统内积操作^[18]，增强了对非线性交互的建模能力。深度矩阵分解（Deep Matrix Factorization）进一步融合神经网络与矩阵分解^[19]，提升了特征表示的丰富性。此外，卷积神经网络（CNN）^[20]与循环神经网络（RNN）^[21]被引入以捕捉用户行为的时空模式，例如基于 CNN 的序列推荐^[22]和基于 RNN 的时序兴趣建模^[23]。图神经网络（GNN）则通过建模用户-物品关系图，显著提升了推荐的结构化推理能力^[24]。这些技术的广泛应用，使推荐系统在准确性与个性化方面取得了长足进步。

预训练语言模型（Pre-trained Language Models, PLMs）在推荐系统中的应用进一步拓展

了技术边界。PLMs（如 BERT^[14]等）可以建模用户行为序列，提升个性化推荐的准确性（如 BERT4Rec^[25]等），还可以通过对物品描述、用户评论等文本数据的语义编码，生成高质量的内容特征表示，增强了基于内容的推荐效果。同时，PLMs 可通过分析用户生成文本构建细粒度用户画像，提升个性化推荐精度。在对话式推荐场景中，PLMs 支持自然语言交互，能够理解用户意图并生成上下文相关的推荐结果。这种技术路径在处理文本密集型任务时表现出显著优势，为推荐系统的智能化提供了新方向。

大语言模型的出现标志着推荐系统进入智能化与生成式的新阶段^[4]。LLMs 具有强大的语义理解、知识推理与生成能力，能够利用开放域知识增强用户偏好建模与物品内容理解。其零样本和少样本学习能力有效缓解了冷启动问题，而跨领域知识迁移能力则为统一推荐框架的构建提供了可能。此外，LLMs 支持通过自然语言提示直接生成推荐结果与解释文本，推动了可解释推荐与对话式推荐的发展。尽管 LLMs 在推荐系统中的应用尚处于探索阶段，但其潜力已在知识增强、特征编码、生成式推荐和对话式交互等任务中初步显现，为推荐系统发展提供了广阔前景^[11]。

从理论本质来看，基于大语言模型的推荐方法与传统推荐方法存在关键差异。首先，在知识来源与表示范式方面，传统推荐方法主要基于特定领域内的用户-物品交互数据进行建模：协同过滤通过相似度计算或矩阵分解挖掘协同信号，基于内容的推荐依赖浅层文本特征（如 TF-IDF^[26]）进行匹配，即使深度推荐模型（如 NCF^[27]、Wide&Deep^[28]）引入了 ID 嵌入和神经网络进行特征交互，其知识边界仍局限于特定领域的标注数据和显式交互记录。相比之下，大语

言模型通过在大规模异构文本语料上的预训练，习得了丰富的开放域世界知识和深层语义理解能力，能够将用户偏好与物品属性映射至统一的连续语义空间，从而支持跨领域的知识迁移与泛化。其次，在推理机制方面，传统推荐方法多侧重于基于历史交互数据的判别式预测任务（如评分预测、点击率预测），而大语言模型通过自回归生成机制支持多步推理和自然语言解释生成，能够处理需要复杂推理的推荐场景。此外，在任务适应性方面，传统推荐模型的架构设计高度依赖任务特定的数据和领域知识，难以直接迁移至未见过的推荐任务；而大语言模型展现出显著的零样本和少样本学习能力，可通过提示工程或指令微调实现灵活的任务适配。

随着深度学习技术的应用，推荐系统可被刻画为包含六个关键阶段的信息循环流程，如图 1 所示，该流程图系统反映了大语言模型赋能下推荐系统的整体架构。注意，此流程图是对推荐流程的通用描述，在实际技术应用中，某些阶段可能被跳过或合并。




图 1 推荐系统流程图

Fig.1 Flowchart of the Recommendation Systems

（1）数据采集与预处理阶段旨在采集用户与系统的交互记录，包括点击、搜索、下载、点赞、收藏、评分、评论以及购买记录等用户行为数据。除了交互记录，还需要采集一系列基本信息，如用户特征、商品属性和上下文信息等。在采集过程中，可能存在噪声和冗余数据，因此需要进行初步的预处理操作，并以特定格式存储在

数据库中，以便进一步的处理。

(2) 特征工程与数据增强阶段旨在从原始数据中提取和优化特征，为后续建模提供高质量输入。这一阶段通过特征选择与转换，捕捉用户行为、物品属性及上下文的潜在模式。数据增强则通过样本扩充或合成，解决数据稀疏与多样性不足的问题，提升系统鲁棒性。近年来，深度学习推动了特征工程的自动化发展，使特征提取更高效，支持多模态数据的综合处理，为推荐系统奠定坚实基础。

(3) 特征编码与语义表示阶段将处理后的特征（ID、文本和多模态）转化为适合神经模型处理的稠密语义嵌入，通过捕捉深层语义信息，支持复杂的偏好建模、多模态特征融合以及跨域知识迁移。现代推荐系统通过多模态编码器，整合文本、图像等信息，生成更具语义深度的表示，为后续推荐提供丰富的输入支持。

(4) 推荐结果生成阶段基于来自上一阶段的特征表示，生成个性化推荐，如用户-物品偏好得分、推荐列表、推荐解释等。其核心在于利用协同过滤、基于内容推荐等技术，建模用户偏好与物品特性间的关系。深度学习技术的引入提升了对复杂交互的捕捉能力，通过神经网络优化推荐策略，确保结果的准确性与多样性，是推荐流程的核心环节。

(5) 系统与用户交互阶段负责推荐结果的呈现与用户反馈的收集，影响用户体验与系统迭代。传统单向推荐逐渐向交互式模式演进，支持多轮对话与动态反馈。这一阶段通过灵活的交互设计，实时调整推荐内容，提升用户参与度和满意度，是流程中连接系统与用户的纽带。

(6) 推荐流程协调控制阶段负责整个推荐流程的监控、动态管理和优化，统筹数据流、模型与资源分配。通过智能化控制策略，如自适应

调整与多模型协同，确保系统高效运行。这一阶段整合各环节功能，推动推荐流程的持续改进，是信息循环的指挥中枢。

2.2 大语言模型发展概况

大语言模型是基于人工神经网络的语言模型，通常拥有数十亿至数千亿参数，通过在海量文本数据上进行预训练，能够在自然语言理解和生成任务中表现出卓越性能^[29]。其发展历程经历了多个阶段的技术变革，从早期的统计方法到神经网络的引入，再到预训练范式和大模型的突破，逐步推动了自然语言处理领域的前沿进步。本节从技术视角出发，回顾 LLMs 的核心发展历程。

统计语言模型（Statistical Language Models, SLMs）是最早的语言模型形式，以马尔可夫链为基础的 n -gram 模型为核心技术^[30]。该模型通过统计大规模语料库中词和 n -gram 的频率，估计词序列的条件概率以预测后续词。然而，由于数据稀疏性，许多未见过的 n -gram 被赋予零概率，需通过平滑技术（如拉普拉斯平滑）加以缓解。尽管 SLMs 在早期语音识别和信息检索中应用广泛，但其无法捕捉语言的长距离依赖和深层语义，限制了其进一步发展。

神经语言模型（Neural Language Models, NLMs）的出现标志着从统计方法向神经网络的转变，其关键突破在于将词映射为低维连续嵌入向量，并利用神经网络（如卷积神经网络 CNN、循环神经网络 RNN）聚合上下文信息预测下一词。这一方法有效缓解了数据稀疏性问题，并通过嵌入空间捕捉词间语义相似性。早期 NLMs 多为任务特定模型，需针对特定任务数据训练，其通用性有限，但为后续发展奠定了技术基础。

预训练语言模型是语言模型发展的重大里程

碑^[31], 引入了任务无关的预训练-微调范式。PLMs 在大规模无标注文本数据上进行预训练, 依托 Transformer 架构^[32]捕捉语言的语义与上下文信息。Transformer 模型依赖多头自注意力机制和前馈神经网络, 突破了 RNN 在长序列依赖建模上的限制。自 BERT^[14]模型提出以来, PLMs 通过双向上下文编码和掩码语言建模任务, 大幅提高了语义表示质量。其通用性使其可通过微调适配多种下游任务, 如文本分类、问答和推理, 推动了自然语言处理领域的快速发展。然而, 早期 PLMs 参数多在百万到十亿级, 其能力主要体现在特定任务的微调适配上, 对于零样本学习和复杂推理任务的泛化能力相对有限。

大语言模型标志着从预训练语言模型向超大规模生成式模型的跨越, 其核心特征在于参数规模的显著扩展, 通常达到数十亿至数千亿级别 (如 GPT-3 的 1750 亿参数^[33]、PaLM 的 5400 亿参数^[34])。与 PLMs 相比, LLMs 在技术边界上呈现三个关键差异: 首先, LLMs 通过海量多样语料的预训练, 具备更强的开放域知识存储与跨

任务泛化能力; 其次, LLMs 在少样本和零样本学习上取得突破, 可通过自然语言提示直接完成任务推理, 无需针对特定任务进行微调; 最后, LLMs 引入链式思维 (Chain-of-Thought)^[35]等推理机制, 展现出解决多步骤复杂任务的能力。这些特性使 LLMs 成为通用人工智能的重要基础, 广泛应用于内容生成、知识推理和对话系统等领域。

3 基于大语言模型的推荐系统

依据 2.1 节所刻画的推荐系统流程图, 本节将探讨大语言模型 (LLM) 在推荐流程中参与推荐的阶段或在不同阶段发挥的作用, 这些阶段包括: 特征工程与数据增强、特征编码与语义表示、推荐结果生成、系统与用户交互、推荐流程协调控制。图 2 系统性地归纳了 LLM 在这些核心环节中的具体作用与技术分类。需要注意的是, 鉴于 LLM 具有多任务特性, 同一研究工作中对 LLM 的运用可能会涉及推荐流程的多个阶段。




图 2 大语言模型在推荐系统全流程中的作用与技术分类

Fig.2 The role and technical classification of large language models in the full recommendation system pipeline

3.1 特征工程与数据增强

传统推荐系统主要基于用户行为数据 (如点

击、购买)和结构化特征(如用户 ID、商品 ID)建模,其存在以下两方面的局限:(1)依赖封闭域内的离散 ID 特征(如协同过滤),无法利用开放域语义知识,难以实现跨领域知识迁移;(2)通过隐式反馈(如点击率)间接推测用户偏好,但缺乏对用户动态、多粒度意图的显式建模能力。大语言模型凭借其丰富的开放世界知识、语义理解能力、逻辑推理与生成能力,以用户相关数据(用户档案、用户行为等)、物品相关数据(物品属性、物品描述等)和上下文信息等原始数据作为输入,实现开放域知识注入以及数据的丰富和增强。

3.1.1 生成式数据增强

为缓解原始数据稀疏性问题(如冷启动、长尾物品),大语言模型被用来生成新的样本数据,扩充训练数据集的规模或多样性,优化训练数据分布,实现数据增强。

早期的探索开创性地将 LLM 作为通用的数据生成器,例如 GReaT^[36]模型借助 LLM 生成合成表格数据以增强训练数据,通过学习原始数据的分布,生成具有真实特征的新样本,用于缓解数据不足、不平衡或隐私问题。在此基础上,研究者针对具体推荐场景进行了拓展应用:MINT^[37]框架基于用户历史交互文本生成合成叙事查询,通过概率过滤构建增强训练数据,以解决叙事驱动推荐(NDR)^[38]中数据稀缺问题,实现特征工程层面的数据扩充;ONCE^[39]框架提出生成式推荐方法 GENRE,利用 LLM 通过提示策略生成新闻摘要、用户画像及合成内容,增强文本特征的信息量,缓解数据稀疏性并提升推荐模型的语义理解能力;类似地,在对话推荐场景中,Wang 等人^[40]提出两种基于 LLM 的对话数据增强策略以提升推荐性能:一次性添加所有合成数据以均匀提升物品覆盖率(Once-

Aug),以及利用加权采样生成包含较少流行物品的对话(PopNudge),缓解选择偏见和流行偏见。

进一步地,研究工作开始聚焦于解决推荐系统中的特定挑战。针对没有历史交互的冷启动场景,Wang 等人^[41]使用 LLM 根据用户历史行为的文本描述和新物品描述推断用户对冷启动物品的偏好,生成的增强训练信号整合到下游推荐模型的学习过程中,以缓解冷启动物品的数据稀疏性问题。为缓解电子商务搜索中的长尾查询问题,BEQUE^[42]提出基于 LLM 的三阶段语义增强框架,通过多指令微调、离线反馈和对比学习,利用 LLM 生成高质量的重写查询,有效弥合长尾查询的语义鸿沟。

随着研究的深入,生成式模拟的方法应运而生,其目标不再是生成静态的数据样本,而是模拟动态的交互过程。Agent4Rec^[43]构建 LLM 作为能够模拟真实用户行为的生成式智能体,通过集成用户画像、记忆与情感驱动的行为模块,为推荐系统提供高保真的用户行为模拟与反馈数据。iALP^[44]提出了一种基于模拟的强化学习推荐方法,通过提示让 LLM 根据用户历史生成对候选物品的偏好(动作)和奖励信号,用于离线预训练强化学习策略,从而缓解分布偏移和冷启动问题,并通过在线微调提升模型表现和用户长期收益。

3.1.2 知识注入与特征丰富化

为解决传统推荐模型语义建模不足的问题,可以利用 LLM 在原有数据特征的基础上生成辅助文本特征,注入开放世界知识,丰富用户/物品的特征表示,增强模型对用户偏好和物品内容的理解。

首先,部分工作聚焦于文本内容优化,利用 LLM 生成辅助文本特征,从而为用户/物品提供

更丰富的语义描述。GIRL^[45]提出基于 LLM 的生成式职位推荐框架，其首先通过监督微调指导 LLM 根据简历生成职位描述，构建奖励模型学习招聘反馈，最后采用近端策略优化强化学习进一步对齐生成器与招聘偏好，有效提升传统推荐系统性能；LGIR^[46]在此基础上，结合生成对抗网络（GAN）^[47]对齐低质量生成内容，通过用户行为推断隐式特征，有效缓解了 LLM 虚构问题，提升特征表征能力。在内容生成的自动化方面，Acharya 等人^[48]基于 Alpaca-LoRA 模型^[49]，通过少样本提示生成电影/书籍的语义描述，替代传统爬取方法，将 LLM 生成文本通过 BERT 编码为特征输入，减少数据来源的潜在偏差；EcomGPT^[50]基于电商基础数据（产品信息、用户评论等）设计原子任务，结合少量 ChatGPT 生成的伪标签扩展数据规模，通过指令微调 BLOOMZ^[51]模型，使 EcomGPT 获得泛化到未见电商任务的语义理解能力，显著提升跨任务/数据集的零样本性能；SAGCN^[52]则通过链式提示策略，借助 LLM 提取用户评论中的细粒度语义方面特征，构建多语义图结构，进一步丰富数据的特征表示。

在文本内容优化的基础上，之后的研究逐步转向融合用户兴趣和物品属性的知识建模。HKFR^[53]提出异构知识融合框架，通过 LLM 从用户异构行为信息中提取并融合异构知识，结合推荐任务对 LLM 进行指令微调，实现个性化推荐。KAR^[54]则进一步将 LLM 用于生成用户偏好的推理知识和物品事实知识，这些知识直接基于用户历史行为数据和物品的基本信息生成，并作为补充特征用于增强推荐系统模型的输入表达。ReLand^[55]在工业级场景中首次系统性采用自适应采样种子用户，由 LLM 生成推荐理由构建可控推理池，并通过检索与融合机制将开放世界知

识动态注入传统推荐系统，增强用户行为表征，尤其在稀疏数据场景下显著提升性能。UEM^[56]则通过将用户历史文本压缩为嵌入表示，生成个性化软提示来引导语言模型，增强了长序列用户偏好建模的效率与精准性。

进一步地，部分研究致力于挖掘用户与物品之间的深层语义关系。LLM-Rec^[57]通过多种文本增强提示策略，利用 LLM 生成更丰富、表达性更强的辅助文本特征，深入挖掘并补全物品描述中的关键信息，显著提升了推荐系统对用户偏好和物品特征的理解能力，从而提升推荐质量。RLMRec^[58]整合辅助文本信号，利用 LLM 生成用户/物品画像，并通过跨视图对齐将 LLM 的语义空间与协同关系信号相融合，旨在通过 LLM 增强的表示学习提升现有推荐系统性能。RDRec^[59]提出基于 LLM 的原理蒸馏框架，从用户评论中提炼结构化偏好与物品属性，生成低噪声的语义特征以增强用户/物品画像，提升推荐模型语义推理能力。CUP^[60]轻量级框架通过 LLM 对用户评论文本进行关键信息提取，生成简洁的用户兴趣档案（如关键词或摘要），压缩原始评论文本，为上下文窗口受限的用户-物品双塔式 BERT 模型提供高效输入，捕捉文本中的语义信息。此外，LLMRec^[61]和 LLMRG^[62]进一步通过语义关系生成实现丰富特征表示：LLMRec 提出通过 LLM 推理生成用户-物品交互边、增强物品属性建模及用户画像的图增强策略，利用 LLM 的知识库与语义理解能力补充稀疏交互信号并优化低质量信息，结合去噪机制提升增强数据可靠性；LLMRG 提出基于 LLM 构建个性化推理图谱，通过因果逻辑推断将用户画像与行为序列动态关联，以可解释形式表征用户兴趣，生成的推理图谱经图神经网络编码后，作为补充输入增强传统推荐模型。

此外，还有一些工作通过创新融合机制丰富特征表示。PMG^[63]框架利用 LLM 将用户行为转换为自然语言描述，提取显式关键词与隐式嵌入作为偏好条件，通过多模态生成器增强推荐系统的个性化特征表达，解决行为数据稀疏性并优化语义对齐。LLM4MSR^[64]通过设计场景级和用户级提示，利用冻结的 LLM 推理多层次知识，显

式挖掘场景共性与用户跨场景兴趣，并通过分层元网络将 LLM 输出的高维隐藏状态动态融合至推荐模型，实现场景感知与个性化能力增强。LRD^[65]提出基于潜在关系发现的关系感知序列推荐框架，通过 LLM 生成物品语言知识表示并构建自监督关系提取模块，挖掘语义层面的关联，提升物品间关系的建模能力。

表 1 特征工程与数据增强阶段技术路线优缺点

Table 1 Advantages and disadvantages of technical approaches in feature engineering and data augmentation stage		
技术路线	优点	缺点
生成式数据增强	1.生成多样化的样本，增强数据丰富性，提高用户或物品的覆盖率 2.生成与真实数据分布相似的高质量样本，有效缓解数据稀疏、冷启动及长尾问题 3.实现训练样本的自动化生成，显著降低人工标注成本，尤其适用于标注数据匮乏的场景	1.生成样本的真实性和分布一致性难以保证，可能引入噪声或“幻觉”内容，影响模型性能 2.生成质量高度依赖提示工程与模型能力，设计不当可能导致样本质量低下 3.计算成本高昂，尤其在生成大规模样本时，需消耗大量计算资源
知识注入与特征丰富化	1.注入开放世界知识，提供更丰富的语义信息，提升模型对用户偏好和物品特性的深度语义建模能力 2.有助于缓解特征稀疏问题，通过利用已有文本信息生成补充特征，增强模型在冷启动或长尾场景下的表现	1.辅助特征质量依赖 LLM 本身的知识和推理能力，可能引入事实性错误或“幻觉”信息 2.生成的辅助文本特征增加了下游模型的处理负担，可能导致训练和推理的计算开销增大

3.2 特征编码与语义表示

传统推荐系统主要依赖特定领域内的用户-物品交互数据（如点击、评分等），采用独热编码或浅层嵌入来表示用户和物品，使得传统推荐系统受到数据稀疏性、冷启动问题、跨领域推荐受限、用户潜在偏好与复杂意图建模困难等问题的制约。大语言模型在预训练阶段通过大规模文本语料学习到丰富的语言知识、语义表示能力和上下文依赖关系，从而生成高质量的语义嵌入，这些嵌入不仅捕捉了文本的表面特征，还能反映其深层语义，使其在推荐系统中成为用户和物品表示的有效工具。

3.2.1 文本语义编码

语言模型作为文本特征编码器，将用户档案、物品描述、行为序列或文本提示等自然语言文本转化为蕴含丰富语义信息的高维向量表征，并借助自然语言作为通用信息载体的特性实现跨领域特征对齐，实现跨域推荐和用户/物品表示增强。

早期的探索首先证实了以语言模型替代传统浅层文本编码器的有效性。例如，PLM-NR^[66]以新闻推荐模型 NRMS^[67]为基础，用语言模型替换其文本编码器，利用深度 Transformer 层提取文本上下文表征，通过注意力池化生成语义增强的新闻嵌入，以优化用户兴趣建模与候选匹配，显著提升推荐系统的语义理解能力。沿着这一思路，研究者们迅速将 BERT 等模型应用于更复杂的场景：U-BERT^[68]通过预训练阶段的自监督任务（如掩码观点词预测、观点评分预测）对用户评论文本进行深度编码，构建跨领域通用的用户语义表示，并引入评论共匹配层增强用户-物品的语义交互，提升推荐效果；UNBERT^[69]提出一种用户-新闻匹配模型，其利用预训练模型的丰富语言知识增强文本表示，并通过词级和新闻级两个层面捕捉多粒度用户-新闻匹配信号。然而，语言模型的巨大计算开销限制了其在工业界的直接应用，因此，提升编码效率与实用性的研究应运而生。CTR-BERT^[70]则针对语言模型在

CTR 预测中面临的效率与性能权衡问题, 提出轻量级双塔 BERT 结构, 通过后期融合机制整合文本与表格特征, 实现低延迟高性能的 CTR 预测。PREC^[71]进一步面向实际部署需求, 设计即插即用的多任务预训练器, 通过分层解耦的新闻与用户编码器融合多视图语义特征, 生成可缓存的高质量表示, 以提升轻量级 CTR 模型的语义理解能力与推理效率。

随着研究的深入, 一个重要的技术演进方向是彻底摒弃传统推荐系统对离散 ID 的依赖, 构建可迁移的语义标识符 (Semantic ID) 体系, 以实现跨域推荐和场景自适应。ZESRec^[72]率先利用 BERT 编码物品的自然语言描述, 生成与领域无关的连续通用 ID, 实现了零样本跨域推荐; 在此基础上, UniSRec^[73]通过参数白化与混合专家适配器, 将多领域物品文本统一编码为语义表示, 提升了场景迁移能力; VQ-Rec^[74]基于 UniSRec 进一步引入向量量化技术, 将连续的文本嵌入对齐到离散的推荐空间, 增强了语义标识符的区分性与迁移鲁棒性。

近期的研究进一步深化了语义 ID 的生成、结构化与应用方式。TIGER^[75]框架通过预训练文本编码器 (如 Sentence-T5^[76]) 提取物品语义嵌入, 经残差量化 (RQ-VAE^[77]) 生成层次化语义 ID, 将文本特征转化为结构化离散标识符, 并利用 Transformer 自回归解码实现生成式检索, 显著增强了物品语义表示及跨类目知识共享; 紧接着, Singh 等人^[78]在此体系上, 针对大规模实时场景, 创新性地采用动态分词策略进行分块哈希编码, 实现了内容语义的紧凑表征, 有效提升了冷启动和长尾物品的泛化能力。LMIndexer^[79]则通过渐进训练和对比学习, 直接将文档语义编码为层次化离散序列, 从根本上解决了传统 ID 嵌入分布不匹配及信息损失问题, 进一步增强了

推荐系统的语义表示与泛化能力。为进一步优化语义 ID 的区分性, CoST^[80]提出了基于对比量化的语义标记化方法, 通过对比损失有效捕获物品间的邻域关系, 结合预训练语义嵌入生成高质量离散语义编码, 极大优化了生成式推荐模型的语义索引效率和检索性能。

与此同时, 更大规模的 LLM (如 GPT 系列) 在文本编码中的潜力也得到了系统性验证。TCF^[81]系统性地验证了更大规模的 LLM 作为通用文本编码器时, 其性能上限与泛化潜力超越参数规模较小的模型 (如 BERT 等)。为将 LLM 的强大能力高效迁移至下游任务, Peng 等人^[82]提出三种策略, 将 GPT 嵌入作为特征、正则化项及预训练目标引入基础预训练语言模型, 以整合 LLM 的语义知识, 显著提升广告匹配和新闻推荐等下游任务表现, 验证了大规模 LLM 嵌入相比传统 PLM 在实际应用中的优势。LLM2BERT4Rec^[83]则另辟蹊径, 利用 LLM 生成的物品文本嵌入对 BERT4Rec^[25]的嵌入层进行初始化, 并通过主成分分析对齐维度后训练模型, 进一步增强特征表达能力, 从而有效提升序列推荐的准确性, 进一步印证了 LLM 在推荐系统表征学习中的应用潜力。

为了进一步拓展推荐系统的表达能力, 研究者们尝试将语言模型与代码、表格、社交网络、知识图谱等多源异构信息相结合。在融合结构化信息方面, PTM4Tag^[84]提出基于领域预训练模型 (PTM) 的三元架构, 通过独立建模 Stack Overflow 帖子的标题、描述与代码片段, 融合多模态语义特征增强输入表征; CTRL^[85]将表格数据文本化后输入 BERT, 通过跨模态对比学习对齐协作模型与语言模型的表示, 增强特征编码的语义表达能力, 有效弥补了传统模型在稀疏 ID 特征上的语义不足; SuKD^[86]提出了一种通用的

联合训练框架，将语言模型的微调与点击率预测基线中的现有特征相结合，以提取自然语言处理特征的补充知识。在社交场景下，TwHIN-BERT^[87]提出一种在社交平台 Twitter 的数据上进行训练的多语言模型，它不仅基于文本自监督学习，还结合了基于 Twitter 异构信息网络（TwHIN）中的丰富社交互动信息，在多语言场景和社交相关任务上实现推荐性能的突破；Social-LLM^[88]则聚焦于用户生成内容与社交网络信息的融合，通过 LLM 对用户个人资料描述等文本内容进行语义编码，并与社交网络交互数据融合，构建综合用户表示。进一步地，KERL^[89]和 LKPNR^[90]引入知识图谱以丰富推荐系统的语义与结构信息：KERL 通过语言模型编码实体文本描述，结合知识图谱结构关系构建语义增强的实体表示，利用对比学习对齐实体与上下文偏好，提升推荐系统的语义理解与表征能力；LKPNR 则提出将 LLM 与知识图谱相结合的个性化新闻推荐框架，借助 LLM 强大的文本理解能力生成具有丰富语义信息的新闻表示，用于增强传统方法中的新闻编码。

此外，还有一系列工作从不同角度探索了语言模型作为文本特征编码器在推荐系统中的创新应用。比如，PFCR^[91]在联邦学习框架下，利用 BERT 编码物品描述文本，生成向量化语义表示，构建跨域统一的语义空间，实现隐私保护的语义特征编码；BLaIR^[92]通过联合优化用户评论与物品元数据的语义对齐，将自然语言上下文与商品特征编码至统一表示空间，增强跨域推荐的特征表达能力；NoteLLM^[93]提出一种统一的提示框架，通过指令微调来引导 LLM 学习笔记的压缩表示，并在此基础上实现了物品到物品的笔记推荐；SLIM^[94]提出基于知识蒸馏的逐步推理框架，将 LLM 的链式推理能力迁移至小型语言

模型，通过文本编码器将生成的知识转化为语义向量，增强序列推荐的语义表示能力；BinLLM^[95]创新地将外部模型的协同信息编码为 LLM 可直接理解和操作的二进制序列，促进 LLM 以类文本格式直接利用协同信息，提升推荐性能；Uni-CTR^[96]提出基于 LLM 的跨域统一框架，通过 LLM 的分层语义编码与掩码损失策略实现的领域解耦，实现了跨域点击率预测的协同优化。

3.2.2 多模态信息融合

随着预训练视觉语言模型与多模态大模型的兴起，多模态推荐通过文本、图像、音频等多类型数据的联合建模来学习用户和物品的通用表示，突破了传统单一模态特征编码方法语义关联捕捉不足的局限，显著提升了推荐性能。多模态方法利用不同模态信息的互补性，更全面地刻画用户偏好和物品特性，为跨领域推荐和冷启动问题提供了创新解决方案。

在多模态推荐的早期探索中，MM-Rec^[97]创新地基于预训练视觉语言模型（ViLBERT^[98]）构建多模态新闻表征，通过协同注意力机制建模文本与视觉内容的跨模态关联，精准捕捉用户兴趣，验证了多模态信息融合的显著优势。在此基础上，后续研究开始关注将模态内容作为核心表征以替代传统 ID 的研究新方向。TransRec^[99]提出混合模态（MoM）用户交互反馈场景下的通用推荐框架，通过端到端训练直接从 MoM 物品的原始特征中学习，从而在无需依赖重叠用户或物品的情况下，实现各种场景下的有效迁移学习。紧接着，IDRec vs MoRec^[100]通过对比基于 ID 的推荐模型与基于模态的推荐模型，探讨了如何利用先进的模态编码器（如 BERT 和 Vision Transformer^[101]）替代传统的 ID 嵌入，以提升推荐系统的特征表征能力。

在模态驱动的推荐范式可行性得到验证后，研究重点进一步转向如何学习可迁移的通用多模态表示，以实现更强的跨领域与跨平台能力。MISSRec^[102]提出了一种多模态预训练与迁移学习框架，通过 LLM 融合文本和视觉信息，设计 Transformer 编解码模型捕捉多模态兴趣序列，为跨领域推荐提供高效表示学习方案。PMMRec^[103]更彻底地突破传统 ID 范式，基于 RoBERTa^[104]和 Vision Transformer^[101]构建多模态编码器，通过跨模态对比学习对齐文本/视觉语义空间，并融入用户行为模式增强表示可迁移性，实现特征编码的统一化与鲁棒性。与此同

时，考虑到计算开销，Fu 等人^[105]聚焦于参数高效的迁移方法，系统研究了基于适配器（Adapter）^[106]的技术，通过冻结主干网络并插入轻量级可训练模块，实现了多模态特征的高效迁移与统一语义表示，为该范式在资源受限场景下的应用提供了可行路径。此外，MQL4GRec^[107]提出创新的多模态融合机制，通过量化翻译器将多模态物品内容（如文本与图像）编码为统一的“定量语言”，基于这种统一表示，模型能够通过生成式任务进行预训练和微调，从而实现了跨域与跨模态推荐知识的深度迁移。

表 2 特征编码与语义表示阶段技术路线优缺点

Table 2 Advantages and disadvantages of technical approaches in feature encoding and semantic representation stage		
技术路线	优点	缺点
文本语义编码	1.捕捉文本中的深层语义信息，能显著提升推荐准确性 2.生成的语义表示具有通用性与可迁移性，有助于解决跨领域推荐与冷启动问题	1.传统的离散 ID 与语言模型存在语义鸿沟，需设计复杂处理机制以融合协同信息 2.对计算资源需求高，尤其是编码长文本时，训练和推理成本增加
多模态信息融合	1.综合利用多模态信息，提供更全面的用户和物品表示，提升推荐的多样性和准确性 2.LLM 作为统一桥梁，能有效对齐不同模态的语义空间，促进跨模态知识迁移	1.需要解决模态间数据对齐和融合的复杂技术难题，如时间同步或特征冲突 2.不同模态的数据质量和分布差异可能影响整体性能 3.计算和存储需求显著增加，实际部署成本高昂

3.3 推荐结果生成

推荐结果生成是推荐系统的核心阶段，大语言模型凭借其自然语言理解与生成能力、知识建模与推理能力以及任务泛化与迁移能力，成为目前基于大语言模型的推荐系统领域的研究重点。在本阶段，直接输入通常是文本数据或结合来自特征编码器的神经嵌入的混合数据，输出一般为符合推荐目的和用户偏好的推荐文本或 ID、数值评分、推荐列表、推荐解释等内容。下面围绕大语言模型与推荐系统的交互机制差异，聚焦 LLM 在推荐系统中的应用方式，将属于本阶段的技术按照不同的调优策略分为“调优范式（微调、提示调优、指令调优）”与“非调优范式（提示、上下文学习）”展开介绍。

3.3.1 微调

调优范式下的微调策略通过在特定推荐任务

数据集上对预训练 LLM 的全部或部分参数进行优化，使其适应具体推荐任务（如评分预测、Top-K 推荐）的方法。该范式中，LLM 通常参与特征编码或作为生成模型，通过任务特定损失函数（如点击率预测损失、排名损失）调整模型参数，学习推荐场景特有的用户偏好与物品关联模式。

早期的探索首先证实了将各类推荐任务转化为 LLM 可理解的语言任务的可行性。其中，TabLLM^[108]将表格数据序列化为自然语言字符串，并结合任务描述提示，通过参数高效微调，直接利用 LLM 的先验知识与推理能力进行分类和推荐，验证了 LLM 处理结构化推荐数据的潜力。沿着这一思路，研究者进一步将推荐直接建模为文本生成任务，如 PBNR^[109]采用 T5 模型^[110]与个性化提示，结合生成与排序损失函数直接产

出新闻推荐；GPTRec^[111]基于 GPT-2^[15]架构，通过 Next-K 策略自回归生成推荐列表，结合 SVD 子词切分降低嵌入表规模，直接生成候选项 ID 以优化多样性及内存效率；GenRec^[112]进一步强化了这一范式，论证了 LLM 可凭借其强大的理解和表达能力，直接解析上下文并生成目标推荐项。这些工作共同确立了通过微调 LLM 直接生成推荐结果的核心思路。

随着生成式范式的确立，如何为 LLM 有效表征物品信息变得尤为关键，由此分化出两种主要技术路线。第一种路线选择摒弃传统数值 ID，完全依赖 LLM 的纯文本理解能力。其中的代表工作 Recformer^[113]将物品属性扁平化为“句子”序列，通过联合预训练（掩码语言建模+对比学习）与两阶段微调策略，实现无需 ID 嵌入的端到端冷启动推荐生成；GPT4Rec^[114]将推荐视为“生成与检索”两阶段任务，首先基于用户历史交互的物品标题，用微调的 GPT-2 生成“搜索查询”，再将查询交由外部检索引擎，通过检索相关物品生成最终推荐；LLM-Rec^[115]将用户跨域行为序列的标题拼接为文本，利用语言模型编码语义信息生成用户/物品表示，通过内积评分预测下一交互项，验证 LLM 在缓解数据稀疏与冷启动中的通用表征能力。另一条技术路线则认为，关键问题不在于 ID 本身，而在于如何设计与 LLM 兼容的 ID 表示，从而将结构化协同信息与 LLM 的语义能力相结合。Hua 等人^[116]将推荐任务转化为自然语言生成任务，利用 LLM 直接生成推荐项，通过设计 LLM 兼容的 Item ID（如顺序索引、协同索引、语义索引和混合索引）提升推荐准确性，验证了物品 ID 索引方法对基于 LLM 的生成式推荐模型性能影响显著。在此基础上，研究者探索了更深度的 ID 语义化与集成方法：IDGenRec^[117]通过协同训练 ID 生成器与

推荐模型，将物品编码为语义丰富、平台无关的文本标识符，使 LLM 以端到端文本生成形式直接预测推荐结果，突破了传统数值 ID 的语义局限；CLLM4Rec^[118]通过扩展预训练 LLM 词汇表引入用户/物品 ID 标记，设计软硬提示策略结合协作与内容语义建模，并采用多项式预测头实现高效推荐生成；TokenRec^[119]则更进一步，利用掩码向量化技术将协同过滤信息压缩为离散 ID 标记，使 LLM 能以生成式检索范式无缝整合协同知识。

在解决了核心表征问题后，研究进一步拓展至更复杂的场景与优化目标，旨在深化和扩展 LLM 在推荐结果生成中的能力。一个重要的方向是提升核心生成能力、效率及对齐真实推荐目标。在生成目标上，研究者追求更强的可控性与创造力。例如，BIGRec^[120]通过微调引导 LLM 生成物品描述，随后将其与实际物品的向量表征进行匹配，完成从语言空间到实际物品的映射。更为前沿的 GeneRec^[121]提出利用 LLM 理解用户指令并整合隐式反馈，驱动 AI 生成器动态创造个性化内容，突破了推荐仅限于已有物品库的传统框架。与此同时，优化生成效率和对齐排序目标成为另一研究焦点。针对自回归生成带来的高延迟问题，LlamaRec^[122]提出基于 LLM 的排序范式，通过参数高效微调（QLoRA）^[123]与 Verbalizer 机制^[124]将候选集文本化后输入 LLM，直接输出概率分布完成推荐结果生成；LITE-LLM4REC^[125]通过分层 LLM 结构优化序列推荐，利用 Item LLM 将项目上下文编码为感知向量，Recommendation LLM 处理序列并通过投影头生成排名分数，避免了耗时的自回归解码，优化排序效率。与此不同，LightLM^[126]则从模型架构本身入手，设计了专为推荐任务定制的轻量级“深且窄”语言模型，并结合约束性搜索技术

直接生成开放集物品 ID，论证了针对推荐任务进行架构瘦身的可行性与高效性。为降低高昂的训练成本，DEALRec^[127]提出基于数据剪枝的 LLM 高效微调方法，通过影响分数评估样本对整体性能的贡献，结合努力分数补偿代理模型与 LLM 的能力差异，直接优化 LLM 在生成推荐结果时的适应效率与准确性。为了更好地对齐个性化排序任务，S-DPO^[128]基于多候选物品的相对偏好建模，设计多负样本排序损失函数，将推荐任务转化为对候选物品概率分布的直接排序。

为进一步增强模型性能，研究者将微调范式应用于融合多样化信息及应对特定推荐挑战。为了融合文本语义之外的宝贵信号，CoLLM^[129]通过外部协作模型提取用户-物品协同信息，将其映射至 LLM 的输入嵌入空间，结合 LoRA^[130]模块进行参数高效微调，使 LLM 在生成推荐时融合文本语义与协同信号；CALRec^[131]在训练目标层面进行创新，它通过两阶段微调框架，结合对比对齐损失与语言建模目标，将序列推荐任务建模为文本生成问题，直接生成目标物品的文本描述。USER-LLM^[132]则通过自监督预训练的用户编码器提取用户行为的潜在表征，利用交叉注意力机制动态注入 LLM，直接指导其生成个性化推荐结果。更进一步，研究者开始构建更通用的推荐基础模型，例如 RecSysLLM^[133]通过在数据、训练和推理阶段的独特设计，并结合参数高效微调，在保留 LLM 通用能力的同时深度整合推荐领域知识，旨在构建一个高效统一的推荐生成框架。

该范式也被广泛应用于特定领域和任务。例如，在序列推荐中，PALR^[134]框架通过将用户历史行为转化为自然语言提示，结合检索模块生成推荐候选集，并利用微调后的 LLaMA 模型^[135]生成推荐结果。在兴趣点（POI）推荐中，

LLM4POI^[136]提出轨迹提示方法，将下一兴趣点推荐转化为问答任务，通过微调 LLM 直接生成 POI 预测。在专业领域，LEADER^[137]框架通过设计自然语言提示模板将患者健康记录转化为 LLM 可理解的语义输入，并替换输出层生成药物概率分布，解决冷启动场景下的药物推荐问题；为了实现更精细的推荐控制，DLCRec^[138]提出基于任务分解的 LLM 推荐框架，将推荐过程分解为类型预测、类型填充与物品预测三个可独立微调的子任务，以生成多样化的推荐列表；CIER^[139]框架微调 LLM 进行领域适配，通过流水线方式首先预测用户评分并转换为评分向量，随后基于评分向量和用户-物品信息生成一致性解释。最后，在系统层面，LSC4Rec^[140]提出的设备-云协作框架，利用云端微调的 LLM 生成候选列表及初始排序，再由设备端小型模型进行实时重排，展现了 LLM 在复杂系统架构中生成推荐的应用潜力。

3.3.2 提示调优

调优范式下的提示调优是一种参数高效的调优策略，通过优化可训练的提示（而非模型主体参数）适配推荐任务。提示可以是离散的自然语言模板（硬提示）或连续向量（软提示），作为额外参数参与训练，引导模型聚焦用户历史交互中的关键特征或生成符合格式的推荐结果。

初期的研究主要探索如何利用提示将推荐任务重构为语言模型所熟悉的形式。例如，Prompt4NR^[141]将新闻推荐转化为完形填空式的掩码预测任务，通过精心设计离散、连续与混合提示模板，将用户点击预测巧妙地转换为对答案词的预测，充分挖掘了大语言模型的语义推理能力。M6-Rec^[142]将用户行为统一建模为自然语言文本，借助其提出的“选项调优”（Option Tuning）与适配器技术，实现了在多任务、开放

域场景下的高效推荐，验证了提示调优在兼顾性能与效率上的潜力。

随着研究的深入，如何设计更优的提示表示以融合多样化信息成为新的焦点。为解决离散提示在连接 ID 与文本语义上的不足并提升效率，POD^[143]提出将特定任务的离散提示蒸馏为一组连续的提示向量，为模型更灵活地生成推荐结果提供了新的思路。更进一步地，为了将传统推荐模型中的协同信号融入提示，LLaRA^[144]设计了一种创新的混合提示方法，将传统推荐模型学习的行为模式（ID 嵌入）与 LLM 的文本特征对齐，通过课程学习策略逐步注入行为知识，使 LLM 生成融合用户行为与语义的推荐结果。为了融合结构化的知识图谱信息，KP4SR^[145]提出知识提示调优，通过关系模板将结构化知识图谱转化为文本序列知识提示，将推荐任务转化为掩码预测任务，从而在提示中注入了丰富的领域知识以生成结果。

此外，提示调优也被用于引入新的训练范式或解决特定的挑战。RecGPT^[146]借鉴了 ChatGPT 的训练范式，通过构建包含模型生成推荐结果与用户反馈的个性化提示，实现对模型的提示调优，将自回归生成范式与推荐任务深度结合。UP5^[147]提出基于对抗学习的反事实公平提示（CFP）方法，通过优化可训练前缀提示消除 LLM 推荐中的用户敏感属性偏差，确保生成结果不受性别、年龄等特征影响，实现公平性感知的个性化推荐。

3.3.3 指令调优

调优范式下的指令调优策略通过将多种推荐任务（如评分预测、序列推荐、解释生成）转化为统一的自然语言指令格式，在多任务指令数据集上对 LLM 进行微调，使其具备理解和执行多样化推荐指令的能力。该范式强调通过设计覆盖

不同任务类型的指令集合（如“推荐”、“解释”、“预测”等指令模板），训练模型捕捉跨任务的通用语义理解能力，从而提升其在未见任务上的零样本泛化性能。

指令调优在推荐系统中的应用，始于构建统一的文本到文本生成范式，代表性工作 P5^[148]率先提出将评分预测、序列推荐、解释生成、直接推荐等不同任务统一封装为自然语言指令，通过个性化提示模板，使语言模型（T5^[110]）能够以单一的生成式目标进行端到端学习。在此基础上，研究者们进一步探索如何优化对齐过程，例如 InstructRec^[149]聚焦于指令数据的构建，通过精心设计的模板和 GPT-3.5 模型，生成了大规模、多样化的用户个性化指令数据，专门用于微调 LLM，使其更好地理解用户意图。TALLRec^[150]则关注调优效率，提出了一个包含通用指令微调与推荐任务微调的两阶段框架，并采用轻量级 LoRA 技术^[130]，将复杂的推荐问题简化为“Yes/No”的二元判断任务，显著提升了 LLM 与推荐任务的对齐效率。LREF^[151]框架以 LLM 为核心相关性判别模型，通过高质量数据筛选的监督微调、多链式思维调优，以及直接偏好优化去偏，针对电商搜索场景实现了精准的查询-商品相关性判别与预测。为处理用户长序列历史，LLM-TRSR^[152]采用分层与循环摘要策略压缩用户长行为序列，构建结构化提示，通过监督微调直接优化 LLM 对候选物品的二元评分能力，直接生成候选物品交互概率；

为解决推荐系统广泛依赖的离散物品 ID 与 LLM 的自然语言之间存在巨大的语义鸿沟问题，研究者们从不同角度进行了探索。一种思路是在保留 ID 的基础上增强 LLM 的 ID 理解能力。E4Srec^[153]通过指令调优的 LLaMA2-13B 模型^[154]，将 ID 嵌入投影至语义空间，冻结主干参

数并引入轻量适配器,实现可控生成式推荐,直接输出候选集内的排序结果,解决了传统 LLM 无法建模 ID 及生成越界问题。另一路线则致力于将 ID 语义化,使其与 LLM 的语言空间对齐。LC-Rec^[155]提出了一种基于残差向量量化(RQ-VAE^[77])的索引方法,将物品的文本语义编码为离散索引,并通过多任务指令微调将协作语义注入 LLM 的语义空间,实现从语言建模到推荐生成的适配。TransRec^[156]则提出多维度标识符,将 ID、标题和属性等信息融合,并设计了基于 FM-index 的约束生成机制,确保 LLM 能生成有效的、语义丰富的物品标识符,将 LLM 的语义理解与协同信号融合于推荐生成任务。

为了进一步提升模型性能,后续研究开始探索将 LLM 与外部知识或其他辅助模型进行深度融合。在融合结构化知识方面,GLRec^[157]将异质行为图谱转化为“元路径”提示,通过指令调优训练模型直接生成“是/否”的二元判断,其推荐概率通过捕捉生成特定标签的 softmax 值计算,从而将图结构语义融入生成式决策。在与传统推荐模型协同方面,Llama4Rec 框架^[158]利用 LLM 为传统模型进行数据增强,并利用传统模型来丰富 LLM 的提示,协同传统模型与指令调优的 LLM,并采用自适应聚合模块融合二者预测结果,以精炼最终推荐。为应对长序列挑战,ReLLa^[159]引入检索增强思路,通过语义检索优化指令内容,并设计检索增强指令调优,训练 LLM 在接收精简历史信息后,能更准确地作为评分函数生成逐点(pointwise)预测结果。此外,为了提升生成结果的质量与可控性,Lu 等人^[160]的研究提出了一个两阶段对齐框架,通过监督微调引入多样化推荐指令,再结合强化学习优化输出格式与指令泛化能力,引导 LLM 生成更符合特定格式要求的推荐列表。

在训练范式优化方面,SPRec^[161]提出自博弈框架,通过交替执行监督微调(SFT)与直接偏好优化(DPO),将前一轮模型预测的输出作为动态负样本,通过自适应重加权 DPO 损失函数,有效抑制 LLM 推荐中的流行度偏差与过度推荐问题,提升推荐结果的公平性与准确性。

3.3.4 提示与上下文学习

非调优范式指在推荐任务中保持大语言模型预训练参数不变,仅通过自然语言提示激活模型固有能力的方法。该范式通过设计包含任务描述、交互信息和格式约束的提示,引导 LLM 利用预训练知识生成推荐结果。其中,提示方法直接通过指令驱动模型(如零样本场景),而上下文学习方法额外引入少量输入-输出示例,通过上下文示范增强模型对任务的理解。

初期的探索主要集中于将推荐问题巧妙地重构为 LLM 所熟悉的自然语言任务。Damien Sileo 等人^[162]提出基于 GPT-2 的零样本推荐框架,通过构建用户偏好文本提示,直接利用语言模型似然估计生成候选物品相关性得分,实现仅使用非结构化文本作为训练数据的推荐。在此基础上,研究者探索了更多元的任务转化路径。PromptRec^[163]则将推荐过程转化为情感极性预测任务,通过模板化自然语言描述,引导 BERT 等模型预测用户对物品的情感倾向(如“好”或“坏”),从而生成偏好评分。

随着研究的深入,学者们开始设计更精细、结构化的提示策略,并系统性地评测 LLM 在不同推荐场景下的能力。Sanner 等人^[164]的工作比较了基于物品历史与基于自然语言偏好描述两种提示方式的有效性,证明了 LLM 在冷启动场景下处理纯语言偏好的潜力。为进一步探明 LLM 的能力边界,Dai 等人^[165]系统地研究了如何将 ChatGPT 与传统信息检索的三种排序范式对齐,

他们将逐点（point-wise）、成对（pair-wise）和列表（list-wise）排序策略重构为特定的提示模板，实验发现列表式提示在性能和成本之间取得了最佳平衡。在此基础上，NIR^[166]提出了一种三步式提示策略，通过连续的指令引导模型逐步完成用户偏好捕捉、历史代表项选择和最终排名列表生成，将复杂的推荐任务分解为一系列 LLM 可控的子任务。而 Liu 等人^[167]则将视角扩展到更广泛的推荐任务，系统性地将 ChatGPT 应用于评分预测、序列推荐、解释生成等五类场景，通过设计包含任务描述、用户行为注入和格式约束的零样本或少样本提示，全面验证了大型模型作为通用推荐引擎的泛化能力。同样，Sun 等人^[168]也通过手动设计面向特定任务的提示模板，统一调用大语言模型接口（如 ChatGPT API）来实现多种推荐任务，系统性地探索了其提升推荐性能的潜力。

为进一步提升推荐的准确性与多样性，研究者开始探索将 LLM 作为推荐流程中特定的排序或重排序模块。LLMRank^[169]将推荐任务形式化为条件排序任务，通过精心设计的提示模板，LLM 直接将用户历史交互作为条件对候选物品进行评分排序，展现了 LLM 作为推荐系统排序模型的潜力。针对排序的粒度问题，LLMRanker^[170]提出在提示中引入“高度相关”、“部分相关”等细粒度相关性标签，使模型能更精确地区分不同相关程度的文档，从而优化排序精度。在多样性方面，Carraro 等人^[171]的研究提出基于 LLM 的零样本提示重排序方法，通过设计

包含不同重排序指令的多种提示模板，促使 LLM 从候选排名中生成相关且多样化的推荐。

为了突破 LLM 自身参数化知识的局限，将模型与外部知识或传统推荐系统的优势相结合成为新的研究热点。A-LLMRec^[172]设计了一种对齐机制，将预训练协同过滤模型学到的高质量协同知识嵌入映射到 LLM 的标记空间，通过提示将用户表示与增强后的物品嵌入相结合，使 LLM 在零样本条件下也能利用协同信号进行推理。与之类似，RaRS^[173]探索了将检索增强生成（RAG）框架直接应用于推荐的方法，即在生成推荐前先从外部知识库中检索相关信息作为上下文融入提示，旨在利用外部事实知识缓解模型的“幻觉”现象并提升对新物品的推荐能力。在此基础上，CFRAG^[174]将协同过滤方法与 RAG 框架相结合，创新性地在检索阶段引入相似用户的历史行为信息，不再局限于当前用户自身历史交互，从而充分利用用户间的协同信息，显著提升了个性化文本生成的表现。

最新进展将 LLM 塑造为具备自主决策与反思能力的推荐智能体。AgentCF^[175]将用户和物品均视作拥有记忆和行为能力的智能体，通过提示驱动两者进行多轮自主交互与协作反思，从而在模拟的交互中学习并传播用户偏好，以一种全新的方式实现了协同过滤。RecPrompt^[176]提出了一种自动优化提示的框架，通过推荐器 LLM 和优化器 LLM 的闭环迭代，不断优化推荐器的提示模板，从而动态生成更符合用户兴趣的个性化新闻推荐。

表 3 推荐结果生成阶段技术路线优缺点

Table 3 Advantages and disadvantages of technical approaches in the recommendation result generation stage

技术路线	优点	缺点
调优范式（微调）	1. 微调使 LLM 能够针对具体任务深度优化，提升推荐的个性化与任务适配精度 2. 能够深度学习推荐场景特有的协同模式与用户偏好，适用于精度要求高的工业级场景	1. 计算和存储资源消耗大，训练、推理、部署成本高昂 2. 严重依赖高质量的领域标注数据，数据质量直接影响模型性能，易导致过拟合 3. 微调后的模型通常面向特定任务，向新任务或场景迁移时灵活性受限，存在知识遗忘风险
调优范式（提示调优）	1. 参数高效，仅需优化少量提示参数，极大降低	1. 性能上限受限于基础模型的能力，在复杂任

调优范式（指令调优）	了训练和存储成本，适合资源受限场景	务中表现通常弱于全参数微调
	2.灵活性高，冻结 LLM 主体参数，通过切换或组合不同提示即可适配多样化任务	2.效果对可训练提示的初始化与优化过程高度敏感，训练可能不稳定且难以调试
非调优范式（提示、上下文学习）	1.任务泛化能力强，能有效提升模型在未见推荐任务上的零样本或少样本泛化能力	1.需要设计多样化的指令集合，训练过程复杂，对数据和计算资源要求较高
	2.有助于模型在新领域或多任务场景下的快速迁移，降低了重复开发的成本	2.模型的泛化效果严重依赖指令的设计质量，设计不当可能导致在部分任务上性能下降
	1.无需参数调整，可直接利用 LLM 的固有知识，适合快速原型验证和零/少样本场景	1.推荐效果严重依赖提示工程（指令设计、示例选择）质量，性能不稳定
	2.灵活性极高，通过调整提示即可快速适应不同任务，无需额外训练	2.提示构建与示例选择过程繁琐，缺乏系统化的方法论，试错成本高
	3.不依赖大量标注数据或计算资源，适合资源有限环境，易于实现	3.受限于 LLM 的输入窗口长度，难以处理长历史行为序列或复杂的多模态信息

3.4 系统与用户交互

系统与用户交互阶段作为现代推荐系统连接用户与推荐系统的关键环节，正随着智能化和个性化需求的提升，从传统的单向信息推送逐步演化为以对话推荐系统（CRS）为代表的多轮、动态交互模式。对话推荐系统是一种通过多轮自然语言交互支持用户实现推荐相关目标的智能软件系统^[177]。其核心在于通过任务导向的对话流程，动态获取用户偏好、提供个性化推荐并解释推荐理由，同时具备对话状态管理能力以追踪对话历史和上下文。与传统推荐系统依赖静态用户行为数据的单次交互模式不同，CRS 通过实时对话捕捉用户需求的细微变化，支持多种交互模式（如文本、语音或表单），并以用户为中心优化推荐体验。

传统对话推荐系统存在静态偏好建模能力不足、自然语言处理的局限性、用户交互体验单一和冷启动与数据稀疏等问题。大语言模型凭借其强大的自然语言处理能力，能够理解复杂的语言结构和语义，生成流畅、自然的对话内容；同时，LLM 的上下文理解能力和开放域知识使其能够根据对话历史动态调整推荐策略，支持任务导向型和开放式交互模式；此外，LLM 的预训练特性使其在零样本或低资源场景下仍能表现出色。

推荐任务与对话生成任务是对话推荐系统的核心，基于其在系统架构中的整合程度，本文将基于大语言模型的对话推荐系统分为以下两类：

任务解耦型 CRS 和任务整合型 CRS。

3.4.1 任务解耦型 CRS

任务解耦型 CRS 将推荐任务与对话生成任务视为独立子任务，通常由不同的模型或模块分别处理推荐逻辑与自然语言生成，随后通过协同机制（如结果传递或语义对齐）整合两者的输出。这类系统先由推荐模块生成候选结果，再交由对话模块（常为 LLM）生成自然语言响应，或利用 LLM 辅助推荐模块优化。

在这一思路下，TG-ReDial^[178]采用分离的模块设计，将推荐与对话任务分别交由不同模型处理（BERT 与 GPT-2），通过主题线程实现向推荐场景的语义过渡，结合用户历史交互与对话上下文实现主动式多轮交互，增强了推荐系统的语义连贯性与用户引导能力。

为提升解耦式推荐模块的推理能力，后续研究转向引入外部知识图谱进行增强。VRICR^[179]聚焦于知识图谱的动态优化，它利用 BERT 理解对话上下文，在变分贝叶斯框架下重构并筛选与情境相关的知识子图，以应对原始知识图谱的不完整性。在此基础上，KECR^[180]在知识图谱推理路径上进一步深化，通过联合嵌入属性级与物品级的结构化知识，并利用互信息最大化约束对齐对话与知识图谱的语义空间，实现了基于显式推理路径的精准推荐与高质量对话生成。

随着技术发展，应用边界进一步拓展至多模态与复杂业务场景。MuseChat^[181]将多模态特征（视频、候选音乐、文本提示）与 LLM 的跨模

态推理能力结合，构建首个对话式视频配乐推荐系统，实现基于上下文细化的音乐推荐及可解释性回应，拓展了 CRS 在多媒体场景的应用边界。而在电商售前对话场景下，Liu 等人^[182]提出的 CRS 与 LLM 双向协作框架，探索了 LLM 与传统 CRS 的互补优势，通过双向增强策略（CRS 辅助 LLM/LLM 辅助 CRS），将 LLM 的语义理解能力与 CRS 的领域知识结合，优化售前对话中的用户需求引导与个性化推荐，实现多任务协同的交互式推荐流程。

3.4.2 任务整合型 CRS

任务解耦型 CRS 中推荐任务与对话生成任务解耦的架构导致模块间连接复杂，信息传递不直观，且训练效率低下。任务整合型 CRS 将推荐任务与对话生成任务深度整合为一个统一的模型架构，通常依托大语言模型的强大生成能力，通过端到端的学习框架同时完成用户偏好建模、推荐候选生成及自然语言响应的生成。这类系统将推荐逻辑嵌入对话生成过程中，利用统一的语义表示和联合优化策略，实现推荐与对话的无缝协同。

MESE^[183]率先将物品元数据直接映射至 LLM 的语义空间，通过让模型理解物品自身的文本信息来进行推荐，从而简化了系统的工程复杂性。与之不同，BARCOR^[184]在统一建模基础上引入知识图谱，通过 BART 模型^[185]实现推荐与对话生成任务的深度整合，利用知识图谱增强语义融合，在多轮交互中动态捕捉用户偏好并生成自然响应，有效提升了用户交互的主动性与精准性。在上述工作的基础上，为实现推荐与生成的更无缝整合，RecInDial^[186]在生成机制上进行了创新，它通过扩展模型词汇表并引入词汇指针机制，使 DialoGPT^[187]能够在生成过程中直接“指向”并输出物品，从而将推荐行为更彻底地统

一为一项语言生成任务。随着模型适配技术的发展，基于提示学习的统一框架成为新的研究焦点，为实现灵活的多任务统一提供了新的路径。

在统一复杂对话目标方面，UniMIND^[188]将多目标对话推荐系统（MG-CRS）中相互独立的四个任务（目标规划、主题预测、物品推荐和响应生成）全部重构为序列到序列范式，通过任务特定的提示词引导单一模型完成所有子任务，实现了对复杂对话流程的统一建模。与此并行，UniCRS^[189]则探索了在不微调 LLM 的条件下，通过设计知识增强的提示，将知识图谱中的语义信息与任务特定的可学习软提示相结合，构建面向推荐与对话双任务的统一输入模板，有效提升了推荐与应答结果的协同性与一致性。

大语言模型的出现催生了无需微调的零样本对话推荐范式。He 等人^[190]则以零样本对话推荐为切入点，通过结构化提示策略直接利用 LLM 的通用语言能力，在未微调条件下生成个性化推荐列表，突破了传统系统对预定义模板的依赖。同样基于提示策略，Spurlock 等人^[191]构建了基于 ChatGPT 的对话式推荐框架，通过迭代反馈重提示策略优化推荐列表，利用 LLM 的自然语言交互能力动态适应用户偏好，并采用提示工程缓解流行度偏差，增强推荐系统的交互性与可解释性。

此外，PECRS^[192]聚焦于参数高效的对话推荐，将自然语言对话与推荐任务统一为语言处理任务，利用 GPT-2 理解用户意图、生成自然语言回复，并通过语义匹配实现推荐，显著提升了推荐系统的人机交互能力与自然语言理解能力。而 MemoCRS^[193]则聚焦于用户偏好在多轮对话间的连续性问题，通过设计用户特定记忆与通用记忆的双重记忆机制，不仅能从冗长的历史对话中提炼并管理个性化偏好，还能利用通用知识缓解新

用户的冷启动问题，从而增强了模型对长序列交互的理解与记忆能力。

表 4 系统与用户交互阶段技术路线优缺点

Table 4 Advantages and Disadvantages of Technical Approaches in the System-User Interaction Stage

技术路线	优点	缺点
任务解耦型 CRS	1.模块化设计清晰，便于独立开发、优化与维护 2.各模块任务分工明确，系统开发与调试的复杂度相对较低	1.模块间信息传递存在损耗，易导致推荐结果与对话响应的语义不一致 2.推荐逻辑与对话生成的目标存在差异，难以实现系统级协同优化，影响交互体验的流畅性
任务整合型 CRS	1.通过端到端联合优化，实现推荐与对话的深度融合，交互体验更流畅、自然 2.充分发挥 LLM 的上下文理解与生成能力，能够有效处理复杂对话逻辑与动态偏好 3.统一模型架构降低了模块间协同的复杂性	1.单一模型需融合推荐与生成等异构任务，导致架构复杂且联合优化困难，训练与推理成本巨大 2.端到端范式加剧了 LLM 的“黑盒”问题，决策过程缺乏透明度，难以对推荐与生成过程进行有效的故障归因

3.5 推荐流程协调控制

随着大语言模型能力的不断提升和技术的快速进步，其在自然语言理解、推理和生成能力及复杂任务处理上的优势为推荐系统的智能化管理提供了新机遇。LLM 能够超越传统组件的角色，深度参与推荐流程的协调与控制，通过整合用户意图理解、推荐策略优化及外部工具调用（检索工具、排序模型），实现系统动态优化。这种主动管理能力显著提升了推荐系统的灵活性与智能化，增强了推荐过程的交互性与透明度，为用户体验和系统性能的提升奠定了基础。

3.5.1 LLM 作为协同增强模块

早期的工作中，大语言模型凭借其自然语言理解、推理和生成能力，在推荐系统中实现对传统推荐系统的增强。例如，Chat-REC^[194]通过引入 LLM（ChatGPT）作为对话接口，将用户画像及历史交互转化为提示，与传统推荐系统协同工作，实现多轮交互式推荐。在推荐流程中，LLM 基于上下文学习，对候选集进行优化排序和个性化过滤，并为推荐结果生成自然语言解释，显著提升了系统的可解释性和跨域迁移能力。

3.5.2 LLM 作为自主控制智能体

随着大语言模型在推荐系统中的深入探索，LLM 通过与外部工具和系统协同，实现了推理规划、工具调用、多轮对话、记忆管理和反思优化等能力，使其不仅作为“增强接口”，更演化为

具备自主感知、决策、行动与工具调度能力的“智能体”，推动推荐系统由“被动增强”向“主动智能”演进。

早期探索中，研究者致力于将复杂的推荐对话流程统一纳入 LLM 的管理范畴。RecLLM^[195]提出基于 LLM 的对话管理模块，将自然语言生成、偏好理解、上下文跟踪及推荐引擎调用整合为单一语言建模任务，并通过可控 LLM 用户模拟器生成合成对话数据，实现端到端对话推荐流程的协调控制。在此基础上，LLMCRS^[196]则从多任务管理的角度出发，以子任务检测、模型匹配、子任务执行与响应生成四阶段工作流为核心，动态结合专家模型并利用强化学习优化控制策略，实现多任务协同与对话交互的统一管理。

随着研究深入，智能体的设计重点从流程管理转向了对复杂认知能力的模拟，旨在提升其自主规划与用户对齐的能力。RAH^[197]框架引入了模仿人类认知过程的多智能体协调机制（感知、学习、行动、评估、反思），通过“学习-行动-评估”循环迭代优化对用户个性的对齐，并利用反思机制消解偏好冲突，显著增强了推荐的动态适应性。进一步的，InteRecAgent^[198]将 LLM 明确地定位为协调中心，通过共享候选总线上、长短期用户画像及动态演示增强的“规划优先执行”策略，高效协调查询、检索与排序等外部工具，实现了推荐流程的多阶段协同优化。为进一步深化智能体的推理能力，RecMind^[199]将 LLM 作为自

主智能体的核心，通过其提出的自我启发（Self-Inspiring）规划算法，在推理时保留并整合所有历史探索路径，以实现复杂推荐任务的分解，并精细化地协调数据库、搜索引擎等外部工具的使用。

此外，部分研究还从新颖的视角探索了智能

体的角色定位。ToolRec^[200]创新地将 LLM 塑造为“智能体用户”，通过模拟用户在多轮决策中探索偏好，动态调用面向属性的排序与检索工具，并协同传统推荐模型作为外部工具，实现了对推荐候选集的迭代式优化，为提升推荐的灵活性与用户对齐精度开辟了新路径。

表 5 推荐流程协调控制阶段技术路线优缺点

Table 5 Advantages and disadvantages of technical approaches in recommendation pipeline coordination and control stage		
技术路线	优点	缺点
LLM 作为协同增强模块	1.有效利用 LLM 的自然语言交互能力，显著提升推荐的可解释性与对话交互体验 2.借助 LLM 丰富的世界知识，可有效处理冷启动与跨域推荐等稀疏场景	1.LLM 在流程中处于从属地位，核心决策依赖传统推荐模型，缺乏自主规划与控制能力 2.架构受限，难以实现复杂的任务分解、动态工具调度和端到端闭环优化
LLM 作为自主控制智能体	1.具备规划、记忆与反思能力，能够自主调用外部工具，灵活适应动态、复杂推荐场景 2.LLM 作为流程的“大脑”，实现对推荐各环节的端到端闭环控制，智能化水平高	1.系统实现复杂度高，需要构建完善的智能体框架、工具调度机制和多模块协同 2.多轮推理、工具调用和记忆管理等机制对计算与存储资源要求较高

4 数据集与评测基准

在大语言模型推荐系统研究领域，数据集与评测基准作为核心资源，直接影响着模型的开发、评估与对比分析。高质量的公开数据集不仅为模型的训练与验证提供了多样化的应用场景，也为学术界和工业界的创新探索奠定了坚实基础。同时，科学合理的评测基准体系对于推动领域内算法性能的客观评价和方法间的公平对比具有不可替代的作用。本章将系统的梳理当前主流的公开数据集以及评测基准框架。

4.1 推荐系统数据集

数据集作为推荐系统研究的基础支撑，既是

算法设计与模型训练的前提，也是效果评估与方
法对比的重要依据。随着推荐系统技术的快速发展，近年来不断有新的数据集被提出，这些数据集不仅在规模、多样性、模态类型和应用场景等方面实现了突破，还更好地契合了大语言模型等前沿技术的研究需求。下面将对推荐系统领域具有代表性的数据集进行梳理与简要介绍，其中，以用户属性、物品标签以及用户-物品的评分/交互等信息为主的推荐系统数据集如表 6 所示，同时包含文本、图像或视频等多种模态信息的多模态数据集如表 7 所示。

表 6 传统数据集

Table 6 Traditional datasets		
数据集名称	应用场景	数据详情
BookCrossing ^[201]	图书推荐	包含源自 BookCrossing 社区的 10339 名用户对 6708 本图书的 361349 条评分数据及每本书的主题分类信息
Netflix Prize ^[202]	电影推荐	包含源自 Netflix 平台 480189 用户对 17770 部电影的 100480507 条显式评分
MovieLens ^[203]	电影推荐	ml-20m 版本包含源自 MovieLens 电影推荐系统的 138493 名用户对 27278 部电影的 2000 万条评分记录
MyAnimeList ^[204]	动漫推荐	包含源自 MyAnimeList 动漫社区的 302675 名用户对 14478 部动漫的显式评分
Goodreads ^[205]	图书推荐	包含源自 Goodreads 书评网站的 80 万用户对 156 万书籍的 2.25 亿条交互，含交互时间、阅读进度、评分及推荐等细粒度信息
Yelp ^[206]	餐饮/本地服务推荐	包含源自 Yelp 平台的 115907 名用户对 51948 个商户的 1451776 条推荐理由文本
Amazon Clothing ^[206]	电商推荐	包含源自 Amazon Clothing 平台 57947 名用户对 50240 件商品的 318422 条推荐理由文本
KuaiRec ^[207]	社交视频推荐	包含源自快手短视频平台的 1411 名用户对 3327 个视频的 4676570 条交互数据，附带用户特征、视频标签及社交网络信息
Tenrec ^[209]	视频/文章推荐	包含源自腾讯 QQ 看点短视频平台的 5022750 名用户对 3753436 个视频的 142321193 条点击交互，附带点赞、分享、关注等多类型反馈及用户画像特征
Reddit-Movie ^[190]	电影推荐	包含源自 Reddit 论坛的 634392 次对话、1669720 轮交流、36247 名用户和 51203 部电影的自然发生电影推荐对话数据

表 7 多模态数据集

Table 7 Multimodal datasets

数据集名称	应用场景	数据详情
PixelRec ^[209]	图像推荐	包含从在线视频分享网站收集的约 3000 万用户、40 万高分辨率微视频封面图像及约 2 亿次用户-图像交互数据
MicroLens ^[210]	微视频推荐	MicroLens-100K 版本包含源自腾讯短视频平台的 100000 名用户对 19738 个微视频的 719405 条评论交互，附带视频、音频、图像、文本等多模态原始数据
AMAZON RE-VIEWS 2023 ^[92]	商品推荐与检索	包含源自亚马逊电商平台超 5.7 亿条用户评论、4800 万件商品及商品元数据（含描述、特征、视频、图像等多模态字段）
NineRec ^[211]	流媒体内容推荐	Bili500K 版本包含源自哔哩哔哩平台的 500000 名用户对 138033 个短视频的 7845805 条交互数据，附带高分辨率封面图像及文本描述
EEG-SVRec ^[212]	短视频推荐	包含源自短视频平台的 30 名用户对 2636 个短视频的 3657 次交互数据（用户行为日志、EEG 和 ECG 信号、六维情感参与评分以及短视频的视觉和听觉特征）
MealRec ^[213]	餐饮推荐	基于 Allrecipes 平台的 49698 个菜品及 3794003 条用户-菜品交互，通过模拟用餐会话构建膳食-菜品关联及用户-膳食交互数据，附带营养健康评分

4.2 评测基准

评测基准在大语言模型推荐系统研究中发挥着核心作用，为模型能力的客观评估、方法创新与跨模型对比提供了统一平台。近年来，随着领域的快速发展，一系列具有代表性的基准相继涌现，涵盖了评分预测、序列推荐、生成式推荐、多语言与个性化助手等多元任务。这些基准不仅丰富了评测维度，也推动了推荐系统评测体系的标准化和科学化。下文将系统梳理现有主流评测基准，并分析其在推动本领域发展的作用与面临的挑战。

LLMRec^[214]是面向推荐任务的大语言模型评测基准框架，针对主流 LLM 在多样化推荐任务中的能力进行系统性评估。该基准通过统一的任务建模与多维度指标，全面刻画了 LLM 在不同推荐场景下的表现差异，尤其是在指令遵循性、泛化性及可解释性方面的能力边界，为后续 LLM 推荐系统方法的标准化比较与持续优化奠定了基础。

Amazon-M2^[215]推出了电商推荐领域的多语言多地区大规模购物会话数据集，包含六大语种下丰富商品属性与上百万用户会话。可在该数据集上对一系列算法进行了基准测试，能够系统评估推荐模型在多语言、冷启动与迁移学习等复杂场景下的表现，为 LLM 驱动的推荐系统研究提供了真实、挑战性强的数据基础和评测平台。

OpenP5^[216]是面向大语言模型推荐系统的开

源基准平台，专注于为生成式推荐方法的研究与评测提供统一的实验基础。平台基于主流 LLM 架构，覆盖当前主流公用数据集，强调任务、数据、索引与评测流程的标准化设计，显著提升了不同模型和方法的可复现性与可比性，有效促进了推荐领域大模型方法的系统性研究和社区协同创新。

Shopping MMLU^[217]是面向大语言模型的多任务在线购物基准，该基准以真实世界数据构建，强调任务的多样性与复杂性，能够系统性反映大模型在商品理解、知识推理及用户行为等多维度的表现，为构建通用型智能购物助手及推荐系统提供了系统性测试平台和方法学参考。

RecBench^[218]是面向大语言模型推荐能力系统评测的综合基准，致力于为 LLM 与传统推荐模型在多场景下的性能对比提供统一、标准化的评测框架。该基准兼顾准确性与推理效率，为 LLM 推荐系统的公平、深入、多维度评估与优化提供了标准化实验平台和方法论。

RecBench^[219]是为评估 LLM 个性化推荐助手能力而设计的高质量基准，基准结合知识图谱与用户行为，系统考察模型对复杂偏好、推理、多条件理解与个性化推荐的适应性，为新一代智能推荐系统的研究与评测提供了丰富数据和科学方法。

当前，大语言模型推荐系统的评测基准正朝着多任务、多场景和多模态方向演进，不断拓展评测维度与任务复杂性，常用评测基准的任务、特点和适用范围如表 8 所示。尽管 LLM 推荐评测基准在准确性、可解释性、效率等方面取得了

长足进展，但仍面临真实场景覆盖不足、推理效率低下和复杂用户意图建模等挑战。未来，构建更具代表性和可扩展性的统一基准，将是推动领域持续创新和落地应用的关键。

表 8 评测基准的任务、特点和适用范围

Table 8 The tasks, characteristics, and applicable scenarios of benchmarks

评测基准	测试任务	特点	适用范围
LLMRec ^[214]	包含五类推荐系统任务，分别为评分预测、序列推荐、直接推荐、解释生成和评论摘要，涵盖准确性导向和可解释性导向两大任务类型	LLMRec 以 LLM 为统一推荐器，覆盖多种典型推荐任务，支持零样本及有监督微调两种设置，能够系统性评估 LLM 在推荐领域的泛化能力、指令遵循能力及可解释性表现	适用于评估各类主流 LLM 在多种推荐任务上的表现，尤其适合探索 LLM 在无需大量特定领域数据的情况下对推荐系统任务的适应性和潜力
Amazon-M2 ^[215]	包含三种推荐任务，分别是下一商品推荐、跨域下一商品推荐以及下一商品标题生成	Amazon-M2 具有商品属性丰富（含文本、类别、数值等多模态特征）、规模大、覆盖多地区多语言、商品类别多样等特点，可支持推荐系统、迁移学习、文本生成等多种研究方向，能够更真实反映实际电商推荐场景中的挑战，尤其是冷启动、长尾分布和领域迁移等问题	适用于会话推荐、跨领域迁移推荐、多语言/多地区推荐、冷启动推荐、文本生成推荐、图神经网络推荐等推荐系统相关研究领域
OpenP5 ^[216]	主要支持序列推荐任务（要求模型基于用户 ID 及其历史交互生成推荐）和直接推荐任务（仅基于用户 ID 生成推荐）	OpenP5 是统一的 LLM-based 推荐系统开发、训练与评测流程，支持多种主流 LLM，内置三种基于用户-物品交互的索引方式（随机索引、顺序索引、协同索引），并提供丰富的个性化 prompt 模板，强调可扩展性与标准化评测	适用于推荐系统领域中基于 LLM 的生成式推荐方法的开发、训练与评测，尤其适合需要标准化数据处理流程、统一任务定义和多模型对比实验的学术研究场景
Shopping MMLU ^[218]	包含五种测试任务类型：多项选择、检索、排序、命名实体识别、生成	Shopping MMLU 具有任务多样性、全面性和现实性，覆盖 57 个任务，细分为购物概念理解、知识推理、用户行为对齐、多语言能力四大能力，能评估大模型在推荐场景的多方面能力，且所有任务均统一为文本生成格式，便于大模型端到端评测	适用于评估 LLM 在电商推荐、商品理解、用户行为建模及多语言场景下的通用性和多任务能力，尤其适用于需统一、多维度评测大模型作为智能购物助手的研究与应用场景
RecBench ^[218]	涵盖了两大类推荐任务，分别为点击率预测和序列推荐	RecBench 系统性地考察了多种物品表示方式（唯一标识符、文本、语义嵌入、语义标识符），覆盖了零样本和微调两种评测方案，支持多达 17 种 LLM 和多种传统推荐模型，评测既包括推荐准确性，也包括推理效率，覆盖范围广，评测维度全	适用于需要系统评价 LLM 与传统推荐系统在不同推荐任务、不同物品表示、不同数据域下性能的研究与开发场景，特别适合学术研究和新模型开发的标准化对比与复现
RecBench+ ^[219]	涵盖三类基于条件的任务（显式条件查询、隐式条件查询、错误条件查询）和两类基于用户画像的任务（兴趣导向查询、人口属性导向查询）	RecBench+ 包含多类型、不同难度、覆盖多样用户画像和需求的高质量自然语言查询，能够更真实地反映大模型推荐助手在实际交互场景下的能力要求，填补了现有数据集缺乏复杂文本查询和真实用户需求表达的空白	适用于系统性评测 LLM 在个性化推荐助手任务中的推理、多条件理解、用户画像建模等综合能力，尤其适合面向复杂、交互式推荐需求的下一代推荐系统研究与开发

5 关键挑战和未来展望

尽管大语言模型为推荐系统带来了范式革新，但其在走向规模化、高风险和复杂场景应用的道路上，仍面临一系列挑战。纵观本文前述章节对基于大语言模型推荐系统的系统梳理可以发现，该领域呈现出三条清晰的技术演进脉络：其一，从特征增强到端到端生成的范式转变，即大语言模型的作用正从辅助性的特征工程工具和语义编码器逐步演化为直接承担推荐结果生成的核

心模块；其二，从单模态文本处理到多模态语义融合的能力拓展，语言模型不仅需要处理文本特征，更需整合图像、音频等多模态信息以实现更全面的内容理解；其三，从被动推荐到主动智能体的交互升级，系统正从传统的单向推荐模式向具备多轮对话、动态规划和自主决策能力的智能体方向演进。然而，这些技术演进在实际落地过程中仍面临模型效率、知识可信性、系统公平性及数据安全等现实挑战。本章将结合当前学术界

与产业界的最新进展，系统梳理这些核心挑战，并基于上述技术演进规律展望未来发展方向。

5.1 模型效率与部署瓶颈

大语言模型卓越性能的背后是其庞大的参数规模与高昂的计算开销，这构成了其在推荐系统高并发、低延迟场景中应用的首要瓶颈。模型的训练成本、推理延迟以及对计算资源的巨大需求，限制了其在产业界的广泛部署与快速迭代^[10]。此外，现有 LLM 对输入上下文长度的限制，也使其难以直接处理推荐场景中常见的长用户行为序列与大规模候选集，可能导致关键信息的丢失^[3]。为应对此挑战，未来的研究重心将持续聚焦于模型的高效化。一方面，参数高效微调技术（如 LoRA^[130]、Adapter^[106]等）将在降低领域自适应成本方面发挥关键作用，实现对特定推荐任务的快速、低成本适配。另一方面，模型蒸馏^[94]、量化^[80]以及针对推荐任务的专用稀疏化模型架构设计^[127]，是降低在线推理延迟、实现资源友好型部署的必然路径。

5.2 知识可信性与决策可解释性

LLM 在推荐中的核心优势之一是其丰富的世界知识与生成自然语言解释的能力，然而也伴随着严峻的挑战。当前，LLM 在生成推荐理由或用户偏好分析时，时常出现“幻觉”现象，即生成看似合理但与事实相悖或无法溯源的内容，严重影响了推荐结果的可信度与用户信任^[2]。同时，LLM 固有的“黑箱”特性使其决策过程不透明，难以满足金融、医疗等高风险领域对可解释性的严格要求。未来的发展方向在于构建更为稳健的知识对齐与解释生成机制。一个关键路径是推动 LLM 与外部知识图谱的深度融合，利用知识图谱的结构化事实来约束和校准 LLM 的生成内容，提升推荐解释的事实性与一致性^[90]。此外，探索能够解释 LLM 内部神经元行为或决策逻辑的新技术，将是提升推荐系统透明度与可

靠性的重要突破口^[11]。

5.3 系统公平性与内在偏见消解

在海量语料上预训练的大语言模型，不可避免地学习并固化了数据中存在的刻板印象与社会偏见，例如对性别、种族等敏感属性的歧视，以及对热门事物或主流观点的过度偏好。当这些偏见被带入推荐系统后，不仅可能被进一步放大，更会衍生出推荐场景特有的问题。现有研究已揭示，模型在推荐结果中会表现出显著的位置偏差^[73]、流行度偏差^[169]和公平性偏差^[220]。这些问题共同导致了对弱势群体的系统性忽视、信息茧房效应加剧以及推荐多样性锐减，最终可能引发严重的伦理与法律风险。尽管学术界已开始探索多种缓解策略，例如反事实公平性提示^[147]、文本匹配建模^[221]以及对抗训练^[222]等算法，但现有的解决方案仍显零散。当前最核心的挑战在于：如何系统性地检测、评估并消解从数据到模型、再到推荐结果全链路中存在的偏见，构建一个理论完善且工程上可落地的公平性保障框架，这依然是亟需突破的核心科学与工程难题。

5.4 领域知识增强与多模态融合

通用大语言模型虽知识广博，但在金融、法律、医疗等专业垂直领域，往往存在知识深度不足、术语理解不精的问题，难以满足这些领域的复杂推荐需求。同时，现实世界中的用户偏好与物品特征通常由文本、图像、音频等多种模态信息共同构成，仅依赖文本信息会限制推荐系统的感知与理解能力^[224]。因此，未来的两大发展趋势是领域化与多模态化。一方面，构建面向特定领域的专属大语言模型将成为重要方向，通过注入高质量领域语料、知识图谱及专家规则，提升模型在专业场景下的推理与决策能力。另一方面，发展多模态融合推荐技术，研究如何高效地对齐并统一不同模态的语义表示，实现跨模态的理解与生成，将极大拓展 LLM 推荐系统的应用

边界,使其能够处理更复杂、更丰富的推荐场景。

5.5 数据安全性与隐私保护机制

推荐系统对用户个性化数据的依赖与大语言模型对海量数据的需求,共同引发了对数据安全性与用户隐私的深切忧虑^[225]。LLM 在训练过程中可能“记忆”用户敏感信息,存在被恶意攻击者提取的风险;同时,在模型服务过程中,用户数据的流转与使用也面临合规性挑战。如何在保障模型性能的同时,兼顾数据安全性与隐私保护,是当前亟待解决的核心议题,合理的保护不仅能够增强用户对于推荐系统的信任度,更是维护用户权益的关键所在。未来的研究必须将隐私保护技术作为基础能力融入 LLM 推荐系统中。当前已有部分研究探索联邦学习^[91]、差分隐私^[223]等技术在 LLM 推荐系统中的应用,但在大规模、异构数据环境下的实用性和效率仍有待提升。

结束语 大语言模型依托其海量的开放世界知识,并凭借其在语义深度理解、跨场景知识应用、内容创造性生成及复杂逻辑推断等方面的卓越能力,为推荐系统提供了新的范式与研究方向。本文全面综述了基于大语言模型的推荐系统研究进展,聚焦于 LLM 在推荐流程中参与推荐的阶段或在不同阶段中发挥的作用,系统剖析了其在特征工程与数据增强、特征编码与语义表示、推荐结果生成、系统与用户交互以及推荐流程协调控制等核心环节的融合路径与技术演进。此外,本文还系统梳理了该领域内主流的数据集与评测基准,并指出了当前研究在模型效率、知识可信性、系统公平性与隐私安全等方面面临的核心挑战。展望未来,如何有效应对上述挑战,构建更为高效、可信、公平且安全的新一代智能推荐系统,将是亟待深入探索的核心议题与重要发展方向。

参考文献

- [1] MICHALOWSKI M. How much data is generated every day in 2025[EB/OL]. (2025-07-10)[2025-08-08]. <https://spacelift.io/blog/how-much-data-is-generated-every-day>.
- [2] KA Z M, ZHAO P, ZHANG B, et al. Survey of recommender systems for large language models[J]. Computer Science, 2024, 51(11A): 1-11.(in Chinese)
卡祖铭, 赵鹏, 张波, 等. 面向大语言模型的推荐系统综述[J]. 计算机科学, 2024, 51(11A): 1-11.
- [3] LIN J H, DAI X Y, XI Y J, et al. How Can Recommender Systems Benefit from Large Language Models: A Survey[J]. ACM Transactions on Information Systems, 2025, 43(2): 1-47.
- [4] WU L K, ZHENG Z, QIU Z P, et al. A survey on large language models for recommendation[J]. World Wide Web, 2024, 27(5): 60.
- [5] LIU P, ZHANG L M, GULLA J A. Pre-train, prompt and recommendation: A comprehensive survey of language modelling paradigm adaptations in recommender systems[J]. Transactions of the Association for Computational Linguistics, 2023, 11: 1553-1571.
- [6] XU W, XIAO J, CHEN J L. Leveraging large language models to enhance personalized recommendations in e-commerce[C]// 2024 International Conference on Electrical, Communication and Computer Engineering (ICECCE). Kuala Lumpur: IEEE, 2024: 1-6.
- [7] WEI G, SHAO W, WANG Z C. Side information aggregated convolutional neural network in news recommendation[J]. Journal of Tongji University (Natural Science), 2022, 50(4): 590-600.(in Chinese)
卫刚, 邵伟, 王志成. 新闻推荐系统中的边信息融合卷积神经网络[J]. 同济大学学报(自然科学版), 2022, 50(4): 590-600.
- [8] PENHA G, HAUFF C. What does BERT

know about books, movies and music? Probing BERT for conversational recommendation[C]// Proceedings of the 14th ACM Conference on Recommender Systems. Virtual Event: ACM, 2020: 388-397.

[9] YU P Y, XU Z Q, WANG J N, et al. The application of large language models in recommendation systems[C]// International Conference on Artificial Intelligence and Machine Learning Research. SPIE, 2025: 103-112.

[10] WU G D, QIN H, HU Q X, et al. Research on large language models and personalized recommendation[J]. CAAI Transactions on Intelligent Systems, 2024, 19(6): 1351-1365. (in Chinese)

吴国栋, 秦辉, 胡全兴, 等. 大语言模型及其个性化推荐研究[J]. 智能系统学报, 2024, 19(6): 1351-1365.

[11] ZHAO Z H, FAN W Q, LI J T, et al. Recommender systems in the era of large language models (LLMs) [J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(11): 6889-6907.

[12] LIU Q, ZHAO X, WANG Y, et al. Large language model enhanced recommender systems: Taxonomy, trend, application and future[J]. arXiv:2412.13432, 2024.

[13] HUANG C K, HUANG H T, YU T, et al. A survey of foundation model-powered recommender systems: from feature-based, generative to agentic paradigms[J]. arXiv:2504.16420, 2025.

[14] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding [C]// Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Minneapolis: Association for Computational Linguistics, 2019: 4171-4186.

[15] RADFORD A, WU J, CHILD R, et al. Language Models Are Unsupervised Multitask Learners [J]. OpenAI Blog, 2019, 1(8): 9.

[16] LIU J G, ZHOU T, WANG B H. Research progress of personalized recommendation systems [J]. Progress in Natural Science, 2009, 19(1): 1-15. (in Chinese)

刘建国, 周涛, 汪秉宏. 个性化推荐系统的研究进展 [J]. 自然科学进展, 2009, 19(1): 1-15.

[17] ZHANG S, YAO L N, SUN A X, et al. Deep learning based recommender system: a survey and new perspectives [J]. ACM Computing Surveys, 2019, 52(1): 1-38.

[18] HE X N, LIAO L Z, ZHANG H W, et al. Neural collaborative filtering [C]// Proceedings of the 26th International Conference on World Wide Web. Perth: International World Wide Web Conferences Steering Committee, 2017: 173-182.

[19] DZIUGAITE G K, ROY D M. Neural network matrix factorization[J]. arXiv:1511.06443, 2015.

[20] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition [J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.

[21] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning representations by back-propagating errors [J]. Nature, 1986, 323(6088): 533-536.

[22] TANG J X, WANG K. Personalized top-n sequential recommendation via convolutional sequence embedding [C]// Proceedings of the Eleventh ACM International Conference on Web Search and Data Mining. Marina Del Rey: ACM, 2018: 565-573.

[23] HIDASI B, KARATZOGLOU A, BALTRUNAS L, et al. Session-based recommendations with recurrent neural networks [J].

arXiv:1511.06939, 2015.

- [24] WANG X, HE X N, WANG M, et al. Neural graph collaborative filtering [C]// Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval. Paris: ACM, 2019: 165-174.
- [25] SUN F, LIU J, WU J, et al. BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer [C]// Proceedings of the 28th ACM International Conference on Information and Knowledge Management. Beijing: ACM, 2019: 1441-1450.
- [26] SPARCK JONES K. A statistical interpretation of term specificity and its application in retrieval[J]. Journal of Documentation, 1972, 28(1): 11-21.
- [27] HE X, LIAO L, ZHANG H, et al. Neural collaborative filtering[C]//Proceedings of the 26th International Conference on World Wide Web. 2017: 173-182.
- [28] CHENG H T, KOC L, HARMSSEN J, et al. Wide & deep learning for recommender systems[C]//Proceedings of the 1st Workshop on Deep Learning for Recommender Systems. 2016: 7-10.
- [29] MINAEE S, MIKOLOV T, NIKZAD N, et al. Large language models: a survey [J]. arXiv:2402.06196, 2024.
- [30] DE MULDER W, BETHARD S, MOENS M F. A survey on the application of recurrent neural networks to statistical language modeling [J]. Computer Speech & Language, 2015, 30(1): 61-98.
- [31] MIN B, ROSS H, SULEM E, et al. Recent advances in natural language processing via large pre-trained language models: A survey [J]. ACM Computing Surveys, 2023, 56(2): 1-40.
- [32] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [J]. Advances in Neural Information Processing Systems, 2017, 30.
- [33] BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners [C]// Advances in Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2020: 1877-1901.
- [34] CHOWDHERY A, NARANG S, DEVLIN J, et al. Palm: Scaling Language Modeling with Pathways [J]. Journal of Machine Learning Research, 2023, 24(240): 1-113.
- [35] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models [C]// Advances in Neural Information Processing Systems 35. Cambridge: MIT Press, 2022: 24824-24837.
- [36] BORISOV V, SESSLER K, LEEMANN T, et al. Language Models Are Realistic Tabular Data Generators [J]. arXiv:2210.06280, 2022.
- [37] MYSORE S, MCCALLUM A, ZAMANI H. Large Language Model Augmented Narrative Driven Recommendations [C]// Proceedings of the 17th ACM Conference on Recommender Systems. New York: ACM, 2023: 777-783.
- [38] BOGERS T, KOOLEN M. Defining and Supporting Narrative-driven Recommendation [C]// Proceedings of the Eleventh ACM Conference on Recommender Systems. New York: ACM, 2017: 238-242.
- [39] LIU Q J, CHEN N, SAKAI T, et al. ONCE: Boosting Content-based Recommendation with Both Open- and Closed-source Large Language Models [C]// Proceedings of the 17th ACM International Conference on Web Search and Data Mining. Merida: ACM, 2024: 452-461.
- [40] WANG X, RAHMANI H A, LIU J Q, et al. Improving Conversational Recommendation Systems via Bias Analysis and Language-Model-Enhanced Data Augmentation [J]. arXiv:2310.16738, 2023.
- [41] WANG J L, LU H K, CAVERLEE J, et al. Large Language Models as Data Augmenters for

- Cold-start Item Recommendation [C]// Companion Proceedings of the ACM Web Conference 2024. Singapore: ACM, 2024: 726-729.
- [42] PENG W J, LI G Y, JIANG Y, et al. Large Language Model Based Long-tail Query Rewriting in Taobao Search [C]// Companion Proceedings of the ACM Web Conference 2024. Singapore: ACM, 2024: 20-28.
- [43] ZHANG A, CHEN Y X, SHENG L H, et al. On Generative Agents in Recommendation [C]// Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. Washington: ACM, 2024: 1807-1817.
- [44] WANG J, KARATZOGLOU A, ARAPAKIS I, et al. Large language model driven policy exploration for recommender systems[C]//Proceedings of the Eighteenth ACM International Conference on Web Search and Data Mining. New York: ACM, 2025: 107-116.
- [45] ZHENG Z, QIU Z, HU X, et al. Generative Job Recommendations With Large Language Model[J]. arXiv:2307.02157, 2023.
- [46] DU Y, LUO D, YAN R, et al. Enhancing job recommendation through LLM-based generative adversarial networks[C]//Proceedings of the AAAI Conference on Artificial Intelligence. Menlo Park: AAAI Press, 2024: 8363-8371.
- [47] GOODFELLOW I J, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[J]. Advances in Neural Information Processing Systems, 2014, 27.
- [48] ACHARYA A, SINGH B, ONOE N. LLM based generation of item-description for recommendation system[C]//Proceedings of the 17th ACM Conference on Recommender Systems. New York: ACM, 2023: 1204-1207.
- [49] TAORI R, GULRAJANI I, ZHANG T, et al. Alpaca: A strong, replicable instruction-following model[EB/OL]. (2023-03-13)[2025-08-18]. <https://crfm.stanford.edu/2023/03/13/alpaca.html>.
- [50] LI Y, MA S, WANG X, et al. EcomGPT: instruction-tuning large language models with chain-of-task tasks for e-commerce[C]//Proceedings of the AAAI Conference on Artificial Intelligence. Menlo Park: AAAI Press, 2024: 18582-18590.
- [51] MUENNIGHOFF N, WANG T, SUTAWIKA L, et al. Crosslingual generalization through multitask finetuning[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Toronto: Association for Computational Linguistics, 2023: 15991-16111.
- [52] LIU F, LIU Y, CHEN H, et al. Understanding before recommendation: semantic aspect-aware review exploitation via large language models[J]. ACM Transactions on Information Systems, 2025, 43(2): 1-26.
- [53] YIN B, XIE J, QIN Y, et al. Heterogeneous knowledge fusion: a novel approach for personalized recommendation via LLM[C]//Proceedings of the 17th ACM Conference on Recommender Systems. New York: ACM, 2023: 599-601.
- [54] XI Y J, LIU W W, LIN J H, et al. Towards open-world recommendation with knowledge augmentation from large language models [C]// Proceedings of the 18th ACM Conference on Recommender Systems. New York: ACM, 2024: 12-22.
- [55] TIAN C X, HU B B, GAN C, et al. ReLand: integrating large language models' insights into industrial recommenders via a controllable reasoning pool [C]// Proceedings of the 18th ACM Conference on Recommender Systems. New York: ACM, 2024: 63-73.
- [56] DODDAPANENI S, SAYANA K, JASH A, et al. User embedding model for personalized language prompting [J]. arXiv:2401.04858, 2024.

-
- [57] LYU H J, JIANG S, ZENG H Q, et al. LLM-rec: personalized recommendation via prompting large language models [J]. arXiv:2307.15780, 2023.
- [58] REN X B, WEI W, XIA L H, et al. Representation learning with large language models for recommendation [C]// Proceedings of the ACM Web Conference 2024. New York: ACM, 2024: 3464-3475.
- [59] WANG X F, CUI J, SUZUKI Y, et al. RDRec: rationale distillation for LLM-based recommendation [J]. arXiv:2405.10587, 2024.
- [60] TORBATI G H, TIGUNOVA A, YATES A, et al. Recommendations by concise user profiles from review text [J]. arXiv:2311.01314, 2023.
- [61] WEI W, REN X B, TANG J B, et al. LLMRec: large language models with graph augmentation for recommendation [C]// Proceedings of the 17th ACM International Conference on Web Search and Data Mining. New York: ACM, 2024: 806-815.
- [62] WANG Y, CHU Z X, OUYANG X, et al. Enhancing recommender systems with large language model reasoning graphs [J]. arXiv:2308.10835, 2024.
- [63] SHEN X T, ZHANG R, ZHAO X Y, et al. PMG: personalized multimodal generation with large language models [C]// Proceedings of the ACM Web Conference 2024. Singapore: ACM, 2024: 3833-3843.
- [64] WANG Y H, WANG Y C, FU Z C, et al. LLM4MSR: An LLM-enhanced paradigm for multi-scenario recommendation[C]// Proceedings of the 33rd ACM International Conference on Information and Knowledge Management. Boise: ACM, 2024: 2472-2481.
- [65] YANG S H, MA W Z, SUN P J, et al. Sequential recommendation with latent relations based on large language model[C]// Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. Washington: ACM, 2024: 335-344.
- [66] WU C H, WU F Z, QI T, et al. Empowering news recommendation with pre-trained language models[C]// Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. Virtual Event: ACM, 2021: 1652-1656.
- [67] WU C H, WU F Z, GE S Y, et al. Neural news recommendation with multi-head self-attention[C]// Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. Hong Kong: Association for Computational Linguistics, 2019: 6389-6394.
- [68] QIU Z P, WU X, GAO J Y, et al. U-BERT: Pre-training user representations for improved recommendation[C]// Proceedings of the AAAI Conference on Artificial Intelligence. Virtual Event: AAAI Press, 2021: 4320-4327.
- [69] ZHANG Q, LI J J, JIA Q L, et al. UNBERT: User-News Matching BERT for news recommendation[C]// Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence. 2021: 3356-3362.
- [70] MUHAMED A, KEIVANLOO I, PERERA S, et al. CTR-BERT: Cost-effective knowledge distillation for billion-parameter teacher models[C]// NeurIPS Efficient Natural Language and Speech Processing Workshop. 2021.
- [71] LIU Q, ZHU J, DAI Q, et al. Boosting deep CTR prediction with a plug-and-play pre-trainer for news recommendation[C]// Proceedings of the 29th International Conference on Computational Linguistics. 2022: 2823-2833.

- [72] DING H, MA Y, DEORAS A, et al. Zero-shot recommender systems[J]. arXiv:2105.08318, 2021.
- [73] HOU Y, MU S, ZHAO W X, et al. Towards universal sequence representation learning for recommender systems[C]// Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2022: 585-593.
- [74] HOU Y, HE Z, MCAULEY J, et al. Learning vector-quantized item representation for transferable sequential recommenders [C]// Proceedings of the ACM Web Conference 2023. New York: ACM, 2023: 1162-1171.
- [75] RAJPUT S, MEHTA N, SINGH A, et al. Recommender systems with generative retrieval [J]. Advances in Neural Information Processing Systems, 2023, 36: 10299-10315.
- [76] NI J, ABREGO G H, CONSTANT N, et al. Sentence-T5: scalable sentence encoders from pre-trained text-to-text models [J]. arXiv:2108.08877, 2021.
- [77] LEE D, KIM C, KIM S, et al. Autoregressive image generation using residual quantization [C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society, 2022: 11523-11532.
- [78] SINGH A, VU T, MEHTA N, et al. Better generalization with semantic IDs: a case study in ranking for recommendations [C]// Proceedings of the 18th ACM Conference on Recommender Systems. New York: ACM, 2024: 1039-1044.
- [79] JIN B W, ZENG H S, WANG G Y, et al. Language models as semantic indexers [J]. arXiv:2310.07815, 2023.
- [80] ZHU J M, JIN M Q, LIU Q J, et al. CoST: contrastive quantization based semantic tokenization for generative recommendation [C]// Proceedings of the 18th ACM Conference on Recommender Systems. New York: ACM, 2024: 969-974.
- [81] LI R Y, DENG W H, CHENG Y, et al. Exploring the upper limits of text-based collaborative filtering using large language models: discoveries and insights [J]. arXiv:2305.11700, 2023.
- [82] PENG W J, XU D R, XU T, et al. Are GPT embeddings useful for ads and recommendation? [C]// International Conference on Knowledge Science, Engineering and Management. Cham: Springer Nature Switzerland, 2023: 151-162.
- [83] HARTE J, ZORGDRAGER W, LOURIDAS P, et al. Leveraging large language models for sequential recommendation [C]// Proceedings of the 17th ACM Conference on Recommender Systems. New York: ACM, 2023: 1096-1102.
- [84] HE J D, XU B W, YANG Z, et al. PTM4Tag: sharpening tag recommendation of Stack Overflow posts with pre-trained models [C]// Proceedings of the 30th IEEE/ACM International Conference on Program Comprehension. Virtual: IEEE, 2022: 1-11.
- [85] LI X Y, CHEN B, HOU L, et al. CTRL: connect collaborative and language model for CTR prediction [J]. ACM Transactions on Recommender Systems, 2023.
- [86] WANG D, YAN S G, XIA Y Q, et al. Learning supplementary NLP features for CTR prediction in sponsored search [C]// Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. Washington: ACM, 2022: 4010-4020.
- [87] ZHANG X Y, MALKOV Y, FLOREZ O, et al. TwHIN-BERT: a socially-enriched pre-trained language model for multilingual tweet representations at Twitter [C]// Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. Long Beach: ACM, 2023: 5597-5607.
- [88] JIANG J, FERRARA E. Social-LLM: mod-

-
- eling user behavior at scale using language models and social network data [J]. arXiv:2401.00893, 2024.
- [89] QIU Z C, TAO Y, PAN S R, et al. Knowledge graphs and pre-trained language models enhanced representation learning for conversational recommender systems [J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2024, 36(4): 6107-6121.
- [90] CHEN H, XIE R F, CUI X Y, et al. LKPNR: LLM and KG for personalized news recommendation framework [J]. arXiv:2308.12028, 2023.
- [91] GUO L, LU Z A, YU J L, et al. Prompt-enhanced federated content representation learning for cross-domain recommendation [C]// *Proceedings of the ACM Web Conference 2024*. New York: ACM, 2024: 3139-3149.
- [92] HOU Y P, LI J C, HE Z K, et al. Bridging language and items for retrieval and recommendation [J]. arXiv:2403.03952, 2024.
- [93] ZHANG C, WU S W, ZHANG H X, et al. NoteLLM: a retrievable large language model for note recommendation [C]// *Companion Proceedings of the ACM Web Conference 2024*. New York: ACM, 2024: 170-179.
- [94] WANG Y L, TIAN C X, HU B B, et al. Can small language models be good reasoners for sequential recommendation [C]// *Proceedings of the ACM Web Conference 2024*. New York: ACM, 2024: 3876-3887.
- [95] ZHANG Y, BAO K Q, YAN M, et al. Text-like encoding of collaborative information in large language models for recommendation [J]. arXiv:2406.03210, 2024.
- [96] FU Z C, LI X Y, WU C H, et al. A unified framework for multi-domain ctr prediction via large language models [J]. *ACM Transactions on Information Systems*, 2025, 43(5): 1-33.
- [97] WU C H, WU F Z, QI T, et al. Mm-rec: Visiolinguistic model empowered multimodal news recommendation [C]// *Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval*. New York: ACM, 2022: 2560-2564.
- [98] LU J S, BATRA D, PARIKH D, et al. Vilbert: Pretraining task-agnostic visiolinguistic representations for vision-and-language tasks [J]. *Advances in Neural Information Processing Systems*, 2019, 32.
- [99] WANG J, YUAN F J, CHENG M Y, et al. Transrec: Learning transferable recommendation from mixture-of-modality feedback [C]// *Asia-Pacific Web (APWeb) and Web-Age Information Management (WAIM) Joint International Conference on Web and Big Data*. Singapore: Springer Nature Singapore, 2024: 193-208.
- [100] YUAN Z, YUAN F J, SONG Y, et al. Where to go next for recommender systems? id-vs. modality-based recommender models revisited [C]// *Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval*. New York: ACM, 2023: 2639-2649.
- [101] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: transformers for image recognition at scale [C]// *9th International Conference on Learning Representations*. Vienna: ICLR, 2021.
- [102] WANG J P, ZENG Z Y, WANG Y X, et al. Missrec: Pre-training and transferring multi-modal interest-aware sequence representation for recommendation [C]// *Proceedings of the 31st ACM International Conference on Multimedia*. New York: ACM, 2023: 6548-6557.
- [103] LI Y H, DU H W, NI Y X, et al. Multi-modality is all you need for transferable recommender systems [C]// *2024 IEEE 40th International Conference on Data Engineering (ICDE)*. IEEE,

2024: 5008-5021.

- [104] LIU Y H, OTT M, GOYAL N, et al. RoBERTa: A robustly optimized BERT pretraining approach [J]. arXiv:1907.11692, 2019.
- [105] FU J C, YUAN F J, SONG Y, et al. Exploring adapter-based transfer learning for recommender systems: Empirical studies and practical insights [C]// Proceedings of the 17th ACM International Conference on Web Search and Data Mining. New York: ACM, 2024: 208-217.
- [106] HOULSBY N, GIURGIU A, JASTRZEBSKI S, et al. Parameter-efficient transfer learning for NLP [C]// Proceedings of the 36th International Conference on Machine Learning. Long Beach: PMLR, 2019: 2790-2799.
- [107] ZHAI J Y, MAI Z F, WANG C D, et al. Multimodal quantitative language for generative recommendation [J]. arXiv:2504.05314, 2025.
- [108] HEGSELMANN S, BUENDIA A, LANG H, et al. TabLLM: Few-shot classification of tabular data with large language models [C]// Proceedings of the 26th International Conference on Artificial Intelligence and Statistics. Cambridge: PMLR, 2023: 5549-5581.
- [109] LI X Y, ZHANG Y F, MALTHOUSE E C. PBNR: Prompt-based news recommender system [J]. arXiv:2304.07862, 2023.
- [110] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer [J]. Journal of Machine Learning Research, 2020, 21(140): 1-67.
- [111] PETROV A V, MACDONALD C. Generative sequential recommendation with GPTRec [J]. arXiv:2306.11114, 2023.
- [112] JI J, LI Z, XU S, et al. GenRec: Large language model for generative recommendation [C]// European Conference on Information Retrieval. Cham: Springer Nature Switzerland, 2024: 494-502.
- [113] LI J, WANG M, LI J, et al. Text is all you need: learning language representations for sequential recommendation [C]// Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York: ACM, 2023: 1258-1267.
- [114] LI J M, ZHANG W T, WANG T, et al. GPT4Rec: a generative framework for personalized recommendation and user interests interpretation [J]. arXiv:2304.03879, 2023.
- [115] TANG Z L, HUAN Z X, LI Z H, et al. One model for all: large language models are domain-agnostic recommendation systems [J]. ACM Transactions on Information Systems, 2025, 43(5): 1-27.
- [116] HUA W Y, XU S Y, GE Y Q, et al. How to index item IDs for recommendation foundation models [C]// Proceedings of the Annual International ACM SIGIR Conference on Research and Development in Information Retrieval in the Asia Pacific Region. New York: ACM, 2023: 195-204.
- [117] TAN J T, XU S Y, HUA W Y, et al. ID-GenRec: LLM-RecSys alignment with textual ID learning [C]// Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2024: 355-364.
- [118] ZHU Y C, WU L, GUO Q, et al. Collaborative large language model for recommender systems [C]// Proceedings of the ACM Web Conference 2024. New York: ACM, 2024: 3162-3172.
- [119] QU H H, FAN W Q, ZHAO Z H, et al. TokenRec: learning to tokenize ID for LLM-based generative recommendation [J]. arXiv:2406.10450, 2024.
- [120] BAO K Q, ZHANG J Z, WANG W J, et al. A bi-step grounding paradigm for large language models in recommendation systems [J]. ACM Transactions on Recommender Systems, 2025, 3(4):

1-27.

- [121] WANG W J, LIN X Y, FENG F L, et al. Generative recommendation: towards next-generation recommender paradigm [J]. arXiv:2304.03516, 2023.
- [122] YUE Z R, RABHI S, MOREIRA G D S P, et al. LlamaRec: two-stage recommendation using large language models for ranking [J]. arXiv:2311.02089, 2023.
- [123] DETTMERS T, PAGNONI A, HOLTZMAN A, et al. QLoRA: Efficient finetuning of quantized LLMs[C]//Advances in Neural Information Processing Systems. Cambridge: MIT Press, 2023: 10088-10115.
- [124] CUI G Q, HU S D, DING N, et al. Prototypical verbalizer for prompt-based few-shot tuning[J]. arXiv:2203.09770, 2022.
- [125] WANG H B, LIU X R, FAN W Q, et al. Rethinking large language model architectures for sequential recommendations[J]. arXiv:2402.09543, 2024.
- [126] MEI K, ZHANG Y F. LightLM: a light-weight deep and narrow language model for generative recommendation[J]. arXiv:2310.17488, 2023.
- [127] LIN X Y, WANG W J, LI Y Q, et al. Data-efficient Fine-tuning for LLM-based Recommendation[C]//Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2024: 365-374.
- [128] CHEN Y X, TAN J F, ZHANG A, et al. On softmax direct preference optimization for recommendation[C]//Advances in Neural Information Processing Systems. Cambridge: MIT Press, 2024: 27463-27489.
- [129] ZHANG Y, FENG F L, ZHANG J Z, et al. CoLLM: integrating collaborative embeddings into large language models for recommendation[J]. IEEE Transactions on Knowledge and Data Engineering, 2025, 37(5): 2329-2340.
- [130] HU E J, SHEN Y L, WALLIS P, et al. LoRA: Low-rank adaptation of large language models[J]. arXiv:2106.09685, 2021.
- [131] LI Y Y, ZHAI X, ALZANTOT M, et al. CALRec: contrastive alignment of generative LLMs for sequential recommendation[C]//Proceedings of the 18th ACM Conference on Recommender Systems. Bari: ACM, 2024: 422-432.
- [132] NING L, LIU L Y, WU J X, et al. User-llm: Efficient llm contextualization with user embeddings[C]//Companion Proceedings of the ACM on Web Conference 2025. Sydney: ACM, 2025: 1219-1223.
- [133] CHU Z X, HAO H Y, OUYANG X, et al. Leveraging large language models for pre-trained recommender systems[J]. arXiv:2308.10837, 2023.
- [134] YANG F, CHEN Z, JIANG Z Y, et al. Palr: Personalization aware llms for recommendation[J]. arXiv:2305.07622, 2023.
- [135] TOUVRON H, LAVRIL T, IZACARD G, et al. LLaMA: open and efficient foundation language models[J]. arXiv:2302.13971, 2023.
- [136] LI P B, DE RIJKE M, XUE H, et al. Large language models for next point-of-interest recommendation[C]//Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. Washington: ACM, 2024: 1463-1472.
- [137] LIU Q D, WU X, ZHAO X Y, et al. Large language model distilling medication recommendation model[J]. arXiv:2402.02803, 2024.
- [138] CHEN J J, GAO C M, YUAN S, et al. DLCRec: A Novel Approach for Managing Diversity in LLM-Based Recommender Systems[C]//Proceedings of the Eighteenth ACM International Conference on Web Search and Data Min-

ing. New York: ACM, 2025: 857-865.

[139] LIU S J, DING R X, LU W H, et al. Coherency Improved Explainable Recommendation via Large Language Model[C]//Proceedings of the AAAI Conference on Artificial Intelligence. Menlo Park: AAAI Press, 2025: 12201-12209.

[140] LV Z Q, ZHAN T Y, WANG W J, et al. Collaboration of Large Language Models and Small Recommendation Models for Device-Cloud Recommendation [J]. arXiv:2501.05647, 2025.

[141] ZHANG Z Z, WANG B. Prompt Learning for News Recommendation [C]// Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2023: 227-237.

[142] CUI Z Y, MA J X, ZHOU C, et al. M6-Rec: Generative Pretrained Language Models Are Open-Ended Recommender Systems [J]. arXiv:2205.08084, 2022.

[143] LI L, ZHANG Y F, CHEN L. Prompt Distillation for Efficient LLM-Based Recommendation [C]// Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. New York: ACM, 2023: 1348-1357.

[144] LIAO J Y, LI S H, YANG Z Y, et al. LLaRA: Aligning Large Language Models with Sequential Recommenders [J]. arXiv:2310.10422, 2023.

[145] ZHAI J Y, ZHENG X W, WANG C D, et al. Knowledge prompt-tuning for sequential recommendation [C]// Proceedings of the 31st ACM International Conference on Multimedia. Ottawa: ACM, 2023: 6451-6461.

[146] ZHANG Y B, YU W H, ZHANG E H, et al. RecGPT: Generative Personalized Prompts for Sequential Recommendation via ChatGPT Training Paradigm [J]. arXiv:2404.08675, 2024.

[147] HUA W Y, GE Y Q, XU S Y, et al. UP5: Unbiased Foundation Model for Fairness-Aware

Recommendation [J]. arXiv:2305.12090, 2023.

[148] GENG S J, LIU S C, FU Z H, et al. Recommendation as Language Processing (RLP): A Unified Pretrain, Personalized Prompt & Predict Paradigm (P5) [C]// Proceedings of the 16th ACM Conference on Recommender Systems. New York: ACM, 2022: 299-315.

[149] ZHANG J J, XIE R B, HOU Y P, et al. Recommendation as Instruction Following: A Large Language Model Empowered Recommendation Approach [J]. ACM Transactions on Information Systems, 2025, 43(5): 1-37.

[150] BAO K Q, ZHANG J Z, ZHANG Y, et al. TALLRec: An Effective and Efficient Tuning Framework to Align Large Language Model with Recommendation [C]// Proceedings of the 17th ACM Conference on Recommender Systems. New York: ACM, 2023: 1007-1014.

[151] TANG T, TIAN Z X, ZHU Z Y, et al. LREF: A Novel LLM-based Relevance Framework for E-commerce Search[C]//Companion Proceedings of the ACM on Web Conference 2025. New York: ACM, 2025: 468-475.

[152] ZHENG Z, CHAO W S, QIU Z P, et al. Harnessing large language models for text-rich sequential recommendation[C]//Proceedings of the ACM Web Conference 2024. Singapore: ACM, 2024: 3207-3216.

[153] LI X H, CHEN C, ZHAO X Y, et al. E4SRec: An elegant effective efficient extensible solution of large language models for sequential recommendation [J]. arXiv:2312.02443, 2023.

[154] TOUVRON H, MARTIN L, STONE K, et al. Llama 2: open foundation and fine-tuned chat models [J]. arXiv:2307.09288, 2023.

[155] ZHENG B W, HOU Y P, LU H Y, et al. Adapting large language models by integrating collaborative semantics for recommendation [C]// 2024

-
- IEEE 40th International Conference on Data Engineering. IEEE, 2024: 1435-1448.
- [156] LIN X Y, WANG W J, LI Y Q, et al. Bridging items and language: a transition paradigm for large language model-based recommendation [C]// Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York: ACM, 2024: 1816-1826.
- [157] WU L K, QIU Z P, ZHENG Z, et al. Exploring large language model for graph data understanding in online job recommendations [C]// Proceedings of the AAAI Conference on Artificial Intelligence. AAAI, 2024, 38(8): 9178-9186.
- [158] LUO S C, YAO Y X, HE B W, et al. Integrating large language models into recommendation via mutual augmentation and adaptive aggregation [J]. arXiv:2401.13870, 2024.
- [159] LIN J H, SHAN R, ZHU C X, et al. Rella: retrieval-enhanced large language models for lifelong sequential behavior comprehension in recommendation [C]// Proceedings of the ACM Web Conference 2024. New York: ACM, 2024: 3497-3508.
- [160] LU W S, LIAN J X, ZHANG W, et al. Aligning large language models for controllable recommendations [J]. arXiv:2403.05063, 2024.
- [161] GAO C M, CHEN R J, YUAN S, et al. SPRec: self-play to debias LLM-based recommendation [C]// Proceedings of the ACM on Web Conference 2025. Sydney: ACM, 2025: 5075-5084.
- [162] SILEO D, VOSSEN W, RAYMAEKERS R. Zero-shot recommendation as language modeling [C]// European Conference on Information Retrieval. Cham: Springer International Publishing, 2022: 223-230.
- [163] WU X S, ZHOU H C, SHI Y C, et al. Could small language models serve as recommenders? towards data-centric cold-start recommendation [C]// Proceedings of the ACM Web Conference 2024. New York: ACM, 2024: 3566-3575.
- [164] SANNER S, BALOG K, RADLINSKI F, et al. Large language models are competitive near cold-start recommenders for language-and item-based preferences [C]// Proceedings of the 17th ACM Conference on Recommender Systems. New York: ACM, 2023: 890-896.
- [165] DAI S, SHAO N, ZHAO H, et al. Uncovering ChatGPT's capabilities in recommender systems [C]// Proceedings of the 17th ACM Conference on Recommender Systems. New York: ACM, 2023: 1126-1132.
- [166] WANG L, LIM E P. Zero-shot next-item recommendation using large pretrained language models [J]. arXiv:2304.03153, 2023.
- [167] LIU J, LIU C, ZHOU P, et al. Is ChatGPT a good recommender? a preliminary study [J]. arXiv:2304.10149, 2023.
- [168] SUN W, YAN L, MA X, et al. Is ChatGPT good at search? investigating large language models as re-ranking agents [J]. arXiv:2304.09542, 2023.
- [169] HOU Y, ZHANG J, LIN Z, et al. Large language models are zero-shot rankers for recommender systems [C]// European Conference on Information Retrieval. Cham: Springer Nature Switzerland, 2024: 364-381.
- [170] ZHUANG H, QIN Z, HUI K, et al. Beyond yes and no: improving zero-shot pointwise LLM rankers via scoring fine-grained relevance labels [C]// Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics. Mexico City: Association for Computational Linguistics, 2024.
- [171] CARRARO D, BRIDGE D. Enhancing recommendation diversity by re-ranking with large language models [J]. ACM Transactions on Recommender Systems, 2024.
- [172] KIM S, KANG H, CHOI S, et al. Large

- language models meet collaborative filtering: an efficient all-round LLM-based recommender system [C]// Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York: ACM, 2024: 1395-1406.
- [173] DI PALMA D. Retrieval-augmented recommender system: enhancing recommender systems with large language models [C]// Proceedings of the 17th ACM Conference on Recommender Systems. New York: ACM, 2023: 1369-1373.
- [174] SHI T, XU J, ZHANG X, et al. Retrieval augmented generation with collaborative filtering for personalized text generation [C]// Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2025: 1294-1304.
- [175] ZHANG J J, HOU Y P, XIE R B, et al. AgentCF: collaborative learning with autonomous language agents for recommender systems [C]// Proceedings of the ACM Web Conference 2024. New York: ACM, 2024: 3679-3689.
- [176] LIU D R, YANG B M, DU H H, et al. RecPrompt: a self-tuning prompting framework for news recommendation using large language models [C]// Proceedings of the 33rd ACM International Conference on Information and Knowledge Management. Boise: ACM, 2024: 3902-3906.
- [177] JANNACH D, MANZOOR A, CAI W, et al. A survey on conversational recommender systems [J]. ACM Computing Surveys, 2021, 54(5): 1-36.
- [178] ZHOU K, ZHOU Y H, ZHAO W X, et al. Towards topic-guided conversational recommender system [J]. arXiv:2010.04125, 2020.
- [179] ZHANG X Y, XIN X, LI D D, et al. Variational reasoning over incomplete knowledge graphs for conversational recommendation [C]// Proceedings of the Sixteenth ACM International Conference on Web Search and Data Mining. Singapore: ACM, 2023: 231-239.
- [180] REN X H, CHEN T, NGUYEN Q V H, et al. Explicit knowledge graph reasoning for conversational recommendation [J]. ACM Transactions on Intelligent Systems and Technology, 2024, 15(4): 1-21.
- [181] DONG Z K, LIU X L, CHEN B, et al. Musechat: A conversational music recommendation system for videos [C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle: IEEE, 2024: 12775-12785.
- [182] LIU Y X, ZHANG W N, CHEN Y F, et al. Conversational recommender system and large language model are made for each other in E-commerce pre-sales dialogue [J]. arXiv:2310.14626, 2023.
- [183] YANG B W, HAN C, LI Y, et al. Improving conversational recommendation systems' quality with context-aware item meta information [C]// Findings of the Association for Computational Linguistics: NAACL 2022. Seattle: Association for Computational Linguistics, 2022: 38-48.
- [184] WANG T C, SU S Y, CHEN Y N. Barcor: Towards a unified framework for conversational recommendation systems [J]. arXiv:2203.14257, 2022.
- [185] LEWIS M, LIU Y H, GOYAL N, et al. BART: denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension [C]// Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2020: 7871-7880.
- [186] WANG L Z, HU H, SHA L, et al. RecInDial: A unified framework for conversational recommendation with pretrained language models [J]. arXiv:2110.07477, 2021.

-
- [187] ZHANG Y Z, SUN S Q, GALLEY M, et al. DialoGPT: Large-scale generative pre-training for conversational response generation[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics: System Demonstrations. 2020: 270-278.
- [188] DENG Y, ZHANG W X, XU W W, et al. A unified multi-task learning framework for multi-goal conversational recommender systems [J]. *ACM Transactions on Information Systems*, 2023, 41(3): 1-25.
- [189] WANG X L, ZHOU K, WEN J R, et al. Towards unified conversational recommender systems via knowledge-enhanced prompt learning [C]//Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. Washington: ACM, 2022: 1929-1937.
- [190] HE Z K, XIE Z H, JHA R, et al. Large language models as zero-shot conversational recommenders [C]// Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. New York: ACM, 2023: 720-730.
- [191] SPURLOCK K D, ACUN C, SAKA E, et al. ChatGPT for conversational recommendation: refining recommendations by reprompting with feedback [J]. arXiv:2401.03605, 2024.
- [192] RAVAUT M, ZHANG H, XU L, et al. Parameter-efficient conversational recommender system as a language processing task [J]. arXiv:2401.14194, 2024.
- [193] XI Y, LIU W, LIN J, et al. MemoCRS: Memory-enhanced Sequential Conversational Recommender Systems with Large Language Models [C]// Proceedings of the 33rd ACM International Conference on Information and Knowledge Management. New York: ACM, 2024: 2585-2595.
- [194] GAO Y, SHENG T, XIANG Y, et al. Chat-rec: Towards interactive and explainable llms-augmented recommender system [J]. arXiv:2303.14524, 2023.
- [195] FRIEDMAN L, AHUJA S, ALLEN D, et al. Leveraging large language models in conversational recommender systems [J]. arXiv:2305.07961, 2023.
- [196] FENG Y, LIU S, XUE Z, et al. A large language model enhanced conversational recommender system [J]. arXiv:2308.06212, 2023.
- [197] SHU Y, GU H, ZHANG P, et al. RAH! RecSys-Assistant-Human: A human-centered recommendation framework with LLM agents [J]. arXiv:2308.09904, 2023.
- [198] HUANG X, LIAN J, LEI Y, et al. Recommender AI agent: integrating large language models for interactive recommendations [J]. *ACM Transactions on Information Systems*, 2025, 43(4): 1-33.
- [199] WANG Y, JIANG Z, CHEN Z, et al. RecMind: large language model powered agent for recommendation [J]. arXiv:2308.14296, 2023.
- [200] ZHAO Y, WU J, WANG X, et al. Let me do it for you: towards LLM empowered recommendation via tool learning [C]// Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. Washington: ACM, 2024: 1796-1806.
- [201] ZIEGLER C N, MCNEE S M, KONSTAN J A, et al. Improving recommendation lists through topic diversification [C]// Proceedings of the 14th International Conference on World Wide Web. New York: ACM, 2005: 22-32.
- [202] BENNETT J, LANNING S. The Netflix Prize [C]// Proceedings of KDD Cup 2007. San Jose: ACM, 2007.
- [203] HARPER F M, KONSTAN J A. The MovieLens datasets: history and context [J]. *ACM Transactions on Interactive Intelligent Systems*, 2015, 5(4): 1-19.
- [204] COOPERUNION. Anime Recommendations

- Database [EB/OL]. (2016-12-21) [2025-08-18]. <https://www.kaggle.com/datasets/CooperUnion/anime-recommendations-database>.
- [205] WAN M, MCAULEY J. Item recommendation on monotonic behavior chains [C] // Proceedings of the 12th ACM Conference on Recommender Systems. Vancouver: ACM, 2018: 86-94.
- [206] NI J, LI J, MCAULEY J. Justifying recommendations using distantly-labeled reviews and fine-grained aspects [C] // Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. Hong Kong: ACL, 2019: 188-197.
- [207] GAO C, LI S, LEI W, et al. KuaiRec: A fully-observed dataset and insights for evaluating recommender systems [C] // Proceedings of the 31st ACM International Conference on Information & Knowledge Management. Atlanta: ACM, 2022: 540-550.
- [208] YUAN G, YUAN F, LI Y, et al. Tenrec: A large-scale multipurpose benchmark dataset for recommender systems [J]. *Advances in Neural Information Processing Systems*, 2022, 35: 11480-11493.
- [209] CHENG Y, PAN Y, ZHANG J, et al. An image dataset for benchmarking recommender systems with raw pixels [C] // Proceedings of the 2024 SIAM International Conference on Data Mining. Alexandria: SIAM, 2024: 418-426.
- [210] NI Y X, CHENG Y, LIU X Y, et al. A content-driven micro-video recommendation dataset at scale [J]. *arXiv:2309.15379*, 2023.
- [211] ZHANG J Q, CHENG Y, NI Y X, et al. NineRec: a benchmark dataset suite for evaluating transferable recommendation [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024.
- [212] ZHANG S R, HE Z Y, YE Z Y, et al. EEG-SVRec: an EEG dataset with user multidimensional affective engagement labels in short video recommendation [C] // Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. Washington: ACM, 2024: 698-708.
- [213] LI M, LI L, TAO X H, et al. MealRec+: a meal recommendation dataset with meal-course affiliation for personalization and healthiness [C] // Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. Washington: ACM, 2024: 564-574.
- [214] LIU J L, LIU C, ZHOU P L, et al. LLMRec: benchmarking large language models on recommendation task [J]. *arXiv:2308.12241*, 2023.
- [215] JIN W, MAO H T, LI Z, et al. Amazon-M2: a multilingual multi-locale shopping session dataset for recommendation and text generation [C] // *Advances in Neural Information Processing Systems*. Cambridge: MIT Press, 2023: 8006-8026.
- [216] XU S Y, HUA W Y, ZHANG Y F. OpenP5: an open-source platform for developing, training, and evaluating LLM-based recommender systems [C] // Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2024: 386-394.
- [217] JIN Y L, LI Z, ZHANG C W, et al. Shopping MMLU: a massive multi-task online shopping benchmark for large language models [C] // *Advances in Neural Information Processing Systems* 37. Cambridge: MIT Press, 2024: 18062-18089.
- [218] LIU Q J, ZHU J M, FAN L, et al. Benchmarking LLMs in recommendation tasks: a comparative evaluation with conventional recommenders [J]. *arXiv:2503.05493*, 2025.
- [219] HUANG J N, WANG S J, NING L B, et al.

Towards next-generation recommender systems: a benchmark for personalized recommendation assistant with LLMs [J]. arXiv:2503.09382, 2025.

[220] SHEN T S, LI J R, BOUADJENEK M R, et al. Towards understanding and mitigating unintended biases in language model-driven conversational recommendation [J]. Information Processing & Management, 2023, 60(1): 103139.

[221] LIU Z H, MEI S, XIONG C Y, et al. Text matching improves sequential recommendation by reducing popularity biases [C] // Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. New York: ACM, 2023: 1534-1544.

[222] TANG J H, DU X Y, HE X N, et al. Adversarial training towards robust multimedia recommender system [J]. IEEE Transactions on Knowledge and Data Engineering, 2019, 32(5): 855-867.

[223] CARRANZA A G, FARAHANI R, PONOMAREVA N, et al. Synthetic query generation for privacy-preserving deep retrieval systems using differentially private language models [J]. arXiv:2305.05973, 2023.

[224] LIU Q, HU J, XIAO Y, et al. Multimodal recommender systems: A survey[J]. ACM Computing Surveys, 2024, 57(2): 1-17.

[225] OGUNSEYI T B, AVOUSSOUKPO C B, JIANG Y. A systematic review of privacy techniques in recommendation systems[J]. International Journal of Information Security, 2023, 22(6): 1651-1664.

史鸿旭，出生于 2002 年，硕士，主要研究方向为大语言模型、推荐系统。

刘艺，出生于 1990 年，博士，副研究员，中国科协青年人才托举工程入选者，主要研究方向为智能数据工程。

刘坤，出生于 1982 年，博士，副研究员，主要研究方向为大数据和人工智能。



SHI Hongxu, born in 2002, postgraduate. His main research interests include large language models and recommendation systems.



LIU Kun, born in 1982, Ph.D, associate professor. His main research interests include big data and artificial intelligence.