

面向推荐系统的用户兴趣建模综述

吕学强, 王夏雨, 马登豪⁺

北京信息科技大学 网络文化与数字传播北京市重点实验室, 北京 100192

+ 通信作者 E-mail: madenghao@bistu.edu.cn

摘要: 聚焦用户兴趣建模任务, 对点击意图识别和兴趣构建方法进行归纳分析, 并探讨该领域现存挑战。用户兴趣建模包括点击意图识别和兴趣构建两个级联阶段。根据是否对用户点击行为涉及特征给予差异化关注, 将点击意图识别方法归纳为个性化和非个性化两类; 根据对用户点击意图序列处理方式的不同, 将兴趣构建方法划分为聚集式和生成式两类, 为该领域提供清晰的研究思路。在 ml-20m 和 Amazon_all_beauty 数据集上进行实验, 采用 Recall、Precision、MRR 和 NDCG 作为评价指标, 验证各类兴趣构建方法的优势与不足。用户兴趣建模能够依据行为序列及其上下文信息构建兴趣表示, 帮助模型学习用户行为之间的隐含关系进而实现个性化推荐服务。但是该任务仍面临一些挑战, 例如个性化点击意图识别方法未充分探索一元点击意图之间的潜在关联性, 兴趣构建阶段需要深刻认知兴趣多样性从而捕捉不同粒度的用户兴趣等。

关键词: 推荐系统; 兴趣建模; 用户点击意图

文献标志码: A **中图分类号:** TP393 **doi:** 10.3778/j.issn.1002-8331.2501-0190

Survey of User Interest Modeling for Recommendation Systems

LYU Xueqiang, WANG Xiayu, MA Denghao⁺

Beijing Key Laboratory of Internet Culture and Digital Dissemination Research, Beijing Information Science and Technology University, Beijing 100192, China

Abstract: Focusing on the task of user interest modeling, this paper summarizes and analyzes the methods of click intention identification and interest construction, and discusses the existing challenges in this field. User interest modeling includes two cascade stages: click intention recognition and interest construction. According to whether or not differential attention is paid to the features involved in user click behavior, click intention recognition methods are classified into two categories: personalized and non-personalized. According to the different processing methods of user click intention sequence, the interest construction method is divided into two categories: aggregation and generation, which provides clear research ideas for this field. Experiments are carried out on ml-20m and Amazon_all_beauty datasets, and Recall, Precision, MRR and NDCG are used as evaluation indicators to verify the advantages and disadvantages of various interest construction methods. User interest modeling can construct interest representation according to behavior sequence and its context information, help the model learn the implicit relationship between user behaviors, and then realize personalized recommendation service. However, this task still faces some challenges, such as personalized click intention recognition method does not fully explore the potential correlation between unary click intentions, interest construction phase needs a deep understanding of interest diversity in order to capture different granularity of user interests and so on.

Key words: recommendation systems; interest modeling; user click intention

推荐系统作为高效的信息过滤系统, 旨在帮助用户从海量数据中快速找到感兴趣的内容, 改善用户体验, 同时提高商业流程效率与平台效益^[1]。然而, 随着科技

的飞速发展和生活质量的持续提升, 用户需求日益呈现出高度个性化的趋势, 使推荐平台难以精准推荐符合用户需求的项目^[2]。为应对这一难题, 众多学者深入探索

基金项目: 国家自然科学基金(62171043, 62202061); 北京市自然科学基金(4232025)。

作者简介: 吕学强(1970—), 男, 博士, 教授, CCF 高级会员, 研究方向为自然语言处理、多媒体信息处理; 王夏雨(2000—), 男, 硕士研究生, 研究方向为推荐系统; 马登豪(1989—), 男, 博士, 助理研究员, CCF 专业会员, 研究方向为搜索与推荐、大模型应用。

收稿日期: 2025-01-13 **修回日期:** 2025-05-06 **文章编号:** 1002-8331(2025)21-0015-15

用户兴趣建模任务,并证实其可以有效帮助推荐系统预测用户的个性化需求^[3-4]。兴趣建模任务旨在深入分析用户行为序列,通过识别用户的点击意图,挖掘其深层次兴趣偏好,搭建起连接用户与推荐项目之间的桥梁。

近年来,关于推荐系统的综述研究主要从三个方向展开。首先,部分综述类研究对推荐系统在各应用领域的发展进行归纳梳理。例如,文献[5-7]分别针对在线教育、医学及服装推荐领域的推荐方法进行系统梳理并探讨存在的问题。其次,基于某项技术归纳整理推荐系统的发展。例如,文献[8]对基于图神经网络的会话推荐方法进行梳理;文献[9-11]聚焦基于知识图谱的推荐算法,系统梳理该方向技术演进脉络;文献[12]探讨推荐系统中将注意力机制与神经网络相结合的相关成果。最后,围绕推荐系统常见问题的解决办法进行概述。例如,文献[13]针对解决推荐系统可解释性问题的研究成果进行概述。

然而,用户兴趣建模作为实现个性化推荐的关键环节,尚未有综述性文章对其进行归纳梳理,在一定程度上限制了该领域的深入发展。据此,本文从点击意图识别和兴趣构建两个阶段出发,系统归纳并整理相关研究中用到的用户兴趣建模方法:在点击意图识别阶段,基于三类点击定义对当前非个性化点击意图识别方法进行概述,还对比介绍了更为灵活的个性化点击意图识别方法;在兴趣构建阶段,以新的视角将当前研究分为聚集式和生成式两类,系统整理了使用注意力机制和聚类技术、序列推荐任务中常用的循环神经网络(recurrent neural network, RNN)和 Transformer 及其变体,以及基于大语言模型构建用户兴趣的相关研究,并剖析各类方法的实现过程与不足。这一分类角度不仅与现有研究技术路线高度契合,还揭示各个方法之间的本质差异,如静态兴趣表征和动态兴趣演化的不同建模方法,为技术融合与创新提供帮助,相较于传统分类方法的宽泛归纳,本文聚焦用户兴趣建模的实现过程,填补了该任务下系统性综述的空白。

最后,结合该领域当前面临的挑战展望未来发展方向,旨在为推荐系统领域中的用户兴趣建模任务提供研究思路。

1 用户兴趣建模

用户兴趣建模是个性化推荐流程中的关键环节,通过分析用户行为序列捕捉用户个性化需求,帮助模型筛选贴合用户偏好的推荐内容。用户行为序列是指用户随着时间的推移与项目交互而产生的一系列行为,其中蕴含着用户的潜在偏好,即用户兴趣^[14]。如图1所示,用户兴趣建模包含点击意图识别与兴趣构建两个级联阶段。其中,点击意图识别阶段通过分析用户行为序列,推断背后驱动点击行为发生的用户意图,即点击意图。

然后,兴趣构建阶段基于点击意图序列深入挖掘用户的隐藏兴趣,将该兴趣表示输入给上层推荐打分模型,使其能够排序并筛选出最符合用户当前需求的项目。




图1 兴趣建模阶段

Fig.1 Stage of interest modeling

点击意图识别阶段的核心任务是,揭示驱动用户执行点击行为的动机,即用户在点击时所关注的特征属性。根据用户对不同项目是否关注相同的特征属性,将点击意图识别方法分为非个性化与个性化两类。其中,非个性化识别方法侧重于点击行为的一致性,认为用户对所有项目的点击行为均是基于相同的曝光属性,在交互过程中平等对待项目的所有特征。个性化识别方法则更为灵活,依据用户多样的需求和偏好对项目不同特征给予差异化的关注。

兴趣构建阶段的核心任务,是在获得用户点击意图的基础上分析行为之间的潜在联系以此构建用户兴趣。根据对行为序列的处理方式不同,将当前已有的兴趣构建方法归类为聚集式和生成式两类。聚集式方法细分为基于注意力和基于聚类的方法来构建用户兴趣。例如,模型DIN(deep interest network)^[15]计算用户历史行为与目标项目的注意力得分,再通过加权聚合构建用户兴趣。生成式方法则侧重用户行为之间的时序依赖关系,序列推荐任务广泛使用RNN(recurrent neural network)和 Transformer 捕捉用户兴趣的动态演化^[16]。例如,文献[17]中模型SASRec(self-attentive sequential recommendation)通过Transformer中堆叠的自注意力模块学习行为序列中项目之间的依赖关系,从序列角度挖掘用户兴趣演变过程,构建动态的用户兴趣表示。本文第2章和第3章结合已有研究概述点击意图识别和兴趣构建阶段,并分析各类方法的特点与不足。

2 点击意图识别方法

点击意图识别通过分析用户的点击行为序列并捕捉点击时用户关注的项目特征属性进而推断其背后的点击意图。根据点击行为发生时用户对项目是否持有

一致的关注点,将点击意图识别方法划分为非个性化与个性化两类。后文先对点击定义进行介绍,然后基于两类点击意图识别方法对已有研究进行归纳,最后总结对比两类方法。

2.1 点击定义

点击行为能够反映用户的个性化需求。用户每次点击涉及的特征属性包括但不限于项目类别、价格区间以及主题风格等,这些细粒度的特征信息在构建用户兴趣时发挥着关键作用。当前在用户兴趣建模领域通常采用以下三类点击定义:

(1)基于ID的点击定义:仅通过被点击项目的ID编号表示点击行为。

(2)一般点击定义<ID,项目特征>:这种定义除被点击项目的ID外,还附加交互项目的特征属性,例如价格、类别、品牌等,提供更丰富的语义信息。

(3)深度点击定义<ID,项目特征,上下文特征>:这是一种更为综合的点击定义,通过引入上下文特征深入捕捉点击行为发生时的情景信息,以及与用户行为相关的描述信息,例如时间、地点、行为类型等,从而为用户兴趣建模提供更全面的数据支持。

三种点击定义的特点与不足如表1所示。

表1 点击定义对比
Table 1 Comparison of click definition

点击分类	特点	存在的不足
基于ID的点击定义	点击行为只记录了被点击项目的ID编号,数据的收集和存储相对简单,易于实现且数据处理简单	1.提供信息有限,难以结合其他特征深入分析用户行为,用户点击意图不明确 2.面临数据稀疏问题
一般点击定义<ID,项目特征>	1.引入项目附加信息,赋予点击行为更丰富的语义表示 2.能够更准确地理解用户需求	1.数据复杂性增加 2.涉及隐私问题,项目附加信息可能包含敏感内容,需要谨慎处理
深度点击定义<ID,项目特征,上下文特征>	1.综合考虑ID编号、项目特征信息和上下文环境信息,全面分析用户行为 2.丰富的数据维度支持模型分析更复杂的用户行为,从多维度识别点击意图	1.数据处理难度大且技术要求高,而且全面的数据收集和分析需投入更高成本 2.隐私问题突出,深度点击定义涉及更多的用户个人信息和行为数据

2.2 非个性化识别方法

非个性化识别方法主张用户对所有项目的点击行为均建立在同一组曝光属性之上,即用户在点击时平等地对待项目的特征属性,不会因为用户的个性化需求而偏向或忽视某一方面。接下来围绕点击意图识别任务,按照第2.1节提到的点击定义类型对已有研究中的非个性化识别方法进行概述。

(1)基于用户和项目ID识别用户点击意图。例如,文献[18]中行为序列由用户点击项目ID组成,通过项目ID嵌入识别用户点击意图。文献[19]中会话的项目和目标项目均由项目ID表示,识别点击意图的过程中将输入项嵌入的线性组合作为会话嵌入,保证会话序列和项目序列位于相同的表示空间。

(2)在描述点击行为时结合项目特征丰富点击维度。例如,文献[15,20-22]加入项目的类别特征丰富点击的语义,将基于ID的表示和基于类别的表示进行拼接之后识别用户的点击意图,然后送入兴趣构建模块。文献[23]在加入点击项目类别的基础上,还引入商家信息丰富点击表示。文献[24]从特征级的角度进行显式特征挖掘,除了引入项目类别、品牌信息以外,还对与项目相关的非结构化文本信息进行word2vec获得语义表示。文献[4]引入项目更细致的特征信息,比如颜色、尺寸等特征,在更细粒度的层次上分离并识别出用户对项目各个维度的点击意图。

(3)一些研究在识别过程中引入点击事件发生的具体时间、地理位置以及行为模式等上下文信息。例如,文献[14,25-32]在点击意图识别阶段结合交互行为的时空环境,在用户点击行为的基础上融合被点击项目特征和上下文特征来识别用户点击意图。文献[33]在识别点击意图的过程中除了结合点击项目的ID和项目类别信息,还考虑被点击项目在展示页面上所处位置周围的其他曝光项目,在识别点击意图时赋予点击行为更丰富且特殊的含义。文献[34]通过项目品牌、类别、评分、曝光位置等数据建模点击意图。文献[35]针对酒店推荐领域将酒店的所有曝光内容都用来识别点击意图,例如价格、距离、评分等。文献[36-38]将用户的行为类型、时间和空间特征统称为情景特征,在用户行为序列的基础上结合情景特征挖掘用户更深层次的点击意图。另外,一些研究结合用户不同交互行为类别识别点击意图。文献[39]根据不同点击类型构建多个反馈序列作为输入,结合项目特征和上下文特征识别点击意图。文献[40]将点击行为划分为不同类型的交互,例如浏览、添加购物车、收藏和购买,与项目以及时间组合为三元组的形式识别点击意图。

2.3 个性化识别方法

个性化识别方法更加灵活,依据不同用户的偏好对项目特征给予差异化关注,从多维度审视项目的曝光属性。值得注意的是,个性化识别方法承认每个用户的偏好各不相同,即使多个用户点击相同的项目也可能持有不同的点击意图。

2023年,文献[41]声明首次提出一个基于规则的方法从曝光内容中识别用户点击意图,依据用户的具体需求对项目的曝光属性给予个性化关注,丰富用户点击意图表示,提供更加个性化的服务或推荐从而带来更好的

用户体验。且该研究通过丰富的实验验证了准确识别点击意图能有效提升推荐系统的离线评估指标(AUC、NDCG、MAP等)和线上业务指标(CTR、CTCVR)等。尽管该方法能够从用户独特的需求出发识别点击意图,符合个性化推荐核心要求,但该研究还存在改进空间,将在本文第5章进行介绍。

2.4 小结

综上所述,非个性化识别方法平等地处理点击定义中的特征属性字段,展现出其简洁且易于实现的优势,在当前兴趣建模领域被广泛应用,但没有结合用户个性化需求对项目特征加以区分。个性化识别方法的实现则相对复杂,需要从细粒度层面考虑用户需求选择较为重要的特征属性,目前还在研究的初步阶段。两类方法的对比如表2所示。

表2 点击意图识别方法
Table 2 Click intention identification methods

方法	文献	特点	存在的不足
非个性化方法	文献[4, 15, 18-40]	1. 简单易实现,整体计算效率相对较高	1. 准确性有限,忽视了用户之间的差异性
		2. 可解释性强	2. 缺乏个性化,无法根据用户的个人需求选择合适的项目特征,识别出的用户意图不够具有针对性
个性化方法	文献[41]	1. 准确度较高,识别个性化点击意图,在兴趣构建阶段能够更准确地建模用户兴趣	1. 整体计算效率相对较低,需结合预训练模型提升线上计算速度
		2. 在细粒度层面考虑用户行为、偏好等信息,提供更具个性化的服务	2. 原理相对复杂,需要大量用户数据 3. 面对新用户或缺乏历史数据的用户时,数据稀疏影响严重

3 基于点击意图序列的兴趣构建方法

兴趣构建阶段基于用户点击意图序列,学习用户行为之间的隐藏关系挖掘用户兴趣。在实际场景中,用户兴趣偏好是动态变化的,且存在长期兴趣、短期兴趣等多种形式^[42-43],兴趣构建方法能够基于用户点击意图挖掘隐藏的用户兴趣,帮助推荐模型进行个性化推荐。

本章依据对用户行为序列处理方式的不同,将当前已有的兴趣构建方法归类为聚集式和生成式两类,如图2所示。聚集式兴趣构建方法细分为基于注意力机制和基于聚类两类,这部分内容在3.1节展开说明。对于生成式方法则更关注行为序列之间的依赖关系以及兴趣演化过程,序列推荐模型在这方面表现出优异性能且被广泛使用^[16],本文将生成式兴趣构建方法细分为基于RNN、基于Transformer和基于大模型三类,将在3.2节展开介绍。




图2 兴趣构建方法
Fig.2 Interest construction methods

3.1 聚集式方法

聚集式兴趣构建方法主要沿两个维度展开:一是通过计算用户行为的权重,利用加权方式构建用户兴趣,如图3(a)所示;二是从聚类视角出发,依据特定相关性标准将用户行为分组至不同簇中,兼顾用户的多样化兴趣,再聚集成为最终的用户兴趣,如图3(b)所示。据此,本文将聚集式兴趣构建方法划分为基于注意力和基于聚类两类。接下来,本节基于已有研究概述这两类方法的实现过程,并分析每类方法现存的不足。




图3 聚集式方法
Fig.3 Aggregation methods

3.1.1 基于注意力机制的方法

基于注意力机制的方法通过评估用户历史行为中项目的重要性,以加权聚合的方式构建用户兴趣,确保权重较高的项目在用户兴趣中占据主导地位。

(1)相关研究概述

最具代表性的是文献[15]中的目标注意力机制(target attention, TA),计算用户行为和目标项目的注意力得分,通过加权聚合建模用户兴趣。文献[31]同样采用目标注意力机制学习交互项目和目标项目之间的相关性。文献[44-45]通过注意力激活单元关注和目标项目相关的历史行为数据,并引入情境特征来学习用户兴趣表示。文献[46]提出两种级别的注意力机制改进协同过滤模型,具体来说,特征级别的注意力机制用于从多媒体数据中抽取有价值的特征信息,项目级别的注意力机制用于选择具有代表性的点击并通过加权构建用

户兴趣。文献[1]为每个项目分配个性化权重,设计两种不同的注意力模型结构,通过将特征向量拼接或点积学习权重参数。文献[41]从多个视角评估点击的权重,即点击和当前查询之间的相关性、点击和整个历史行为序列的一致性、点击和目标项目之间的相关性。此外,特定场景信息也会影响用户兴趣,当用户进入两个主题不同的场景时,例如温泉和滑雪场,用户表现出的兴趣显著不同,用户在温泉场景中的兴趣偏向于休闲类型,而在滑雪场景中的兴趣偏向于户外冒险。据此,文献[36]构建兴趣投影网络消除行为序列中与当前访问场景无关的信息来过滤噪声,筛选用户在当前场景下特定的行为。

用户兴趣的形成是一个复杂的过程,受到长短期兴趣的共同影响^[42]。长期兴趣反映用户的一般偏好和稳定需求,而短期兴趣则体现用户最新偏好和实时需求。一些研究采用聚集式兴趣构建方法挖掘长短期兴趣对最终用户兴趣的综合影响。例如,文献[18]提出一种新颖的短期优先注意力能够关注到近期用户行为中短期兴趣,具体来说,根据目标项目、最后点击项目以及会话中所有项目的嵌入计算会话中项目的注意力系数,通过目标项目与用户长短期兴趣之间的相关性构建用户最终兴趣。一些研究采用分层注意力网络建模用户和项目的交互。文献[47]提出层次注意力网络,第一个注意力层学习用户长期偏好,第二个注意力层通过耦合用户长期和短期偏好构建最终用户兴趣。文献[48]利用注意力机制聚合多模态表示以及项目描述信息从用户行为中提炼长期兴趣,通过分析实时上下文识别细粒度的即时兴趣。文献[21]同样设计两层注意力模块通过目标注意力机制为每个项目赋予不同权重,再根据项目属性分组以生成每个属性级特征表示构建的用户兴趣。

随着时间的推移,推荐系统不可避免地遭遇用户交互数据爆炸性增长的问题,这一趋势下用户行为序列长度不断延伸,导致基于长序列的用户兴趣建模任务充满挑战。文献[49]通过注意力机制筛选更能代表用户兴趣的行为,通过平均池化或最大池化的方法聚合筛选后的行为构建用户兴趣。文献[29]从数据角度出发,使用注意力机制从整个历史行为序列中检索关键的用户行为输入到深度模型中。

(2)分析不足

该类方法旨在评估用户行为重要程度并通过加权聚合构建用户兴趣。但是在挖掘用户兴趣的动态性和多样性存在局限:该类方法忽视行为序列中动态的依赖关系,而是通过筛选最具代表性的行为并将这些离散的行为进行聚集,但本质上是构建静态的历史兴趣,不能将其认定为用户的最新兴趣,无法准确预测用户在“下一时刻”的需求;用户兴趣往往是多元且复杂的,而这类方法对用户兴趣的理解较单一且无法全面概括用户的

多重兴趣。

3.1.2 基于聚类的方法

基于聚类的方法旨在基于不同角度划分用户行为,刻画用户在多个领域的兴趣偏好,以此构建用户的多重兴趣。

(1)相关研究概述

文献[50]在逻辑回归的基础上引入聚类的思想对全量样本进行分片,在每个分片内部通过逻辑回归聚集项目特征建模用户兴趣。文献[25]利用哈希签名对整个用户行为序列进行聚类,同一个哈希签名下的点击被认为属于同一分类,直接对整个序列中聚集与目标项的哈希签名相同的行为构建用户兴趣。文献[51]使用项目类别特征聚类点击行为,通过两个搜索单元扩展点击找到更多相似的项目,以此增强当前兴趣表示。文献[3]从概念池中激活用户喜欢的概念原型(conceptual prototype),并将用户行为序列中的项目聚集到对应的高级概念中,构建用户的多重兴趣。文献[4]通过解耦表征学习(disentangled representation learning)从宏观和微观两个层次学习和表示用户兴趣,宏观层面上推理和用户意图相关的高级概念并聚类用户行为,而微观层面则关注于在这些高级兴趣内部进一步细化用户的偏好。此外,胶囊网络^[52]利用特征胶囊构建部分与整体之间的关系,捕获行为之间的重要空间层次结构,通过动态路由机制在胶囊的不同层次之间传递用户行为序列信息,构建不同行为的重要性以及相关性^[53-54],建模用户的多重兴趣表示。文献[55]使用胶囊网络对历史点击进行聚类,认为来自同一个兴趣胶囊的项目密切相关并代表特定的用户兴趣。

(2)分析不足

该类方法大多基于静态视角对用户行为进行划分,简单地聚合交互信息构建用户的兴趣表示,将每个用户行为视为独立的个体,忽视了用户兴趣随时间、环境等因素变化的动态信息,无法准确表达用户灵活多变的兴趣;当前在聚类得到的用户兴趣质量评估方面存在局限性,不恰当的聚类视角可能会导致用户行为被严格划分为多个簇,使得构建出的用户兴趣过于碎片化;基于聚类的兴趣构建方法在处理噪声和异常数据上的表现不佳。

3.2 生成式方法

相较于聚集式方法,生成式方法则关注用户行为序列的顺序依赖关系,充分考虑用户行为之间的相互影响和演变过程,以此构建动态用户兴趣。序列推荐任务中模型RNN和Transformer被广泛应用^[16],如图4所示。并且,近年来大语言模型(large language models, LLMs)在推荐系统领域受到极大关注,其生成式算法基于文本特征的深层次表示结合外部知识建立用户与项目之间的联系,构建高质量用户兴趣^[56]。接下来,本节基于已

有研究概述以上方法的实现过程,并分析每类方法存在的不足。




图4 生成式方法

Fig.4 Generation methods

3.2.1 基于RNN的方法

RNN能够保留先前时间步的信息,这种记忆能力能够捕捉用户行为之间的时序依赖关系。基于RNN的序列模型还包括GRU(gate recurrent unit)^[57]和LSTM(long short-term memory)^[58]等变体模型,增加门控单元进一步增强RNN处理序列信息的能力。

(1) 相关研究概述

文献[57]通过RNN捕获会话级别时序信息,构建会话级别用户兴趣。文献[59-60]通过RNN从用户和项目的交互数据中学习用户兴趣的演化过程。文献[61]以GRU为基础提出一种带有注意力机制的混合编码器,利用GRU捕获行为序列中的长期依赖关系构建基于会话的用户兴趣。文献[20]通过GRU提取用户行为背后的兴趣状态并学习行为之间的依赖关系,建模兴趣演化过程。文献[62]基于RNN模型在视频推荐的统一框架中考虑视频语义嵌入,并挖掘用户随时间变化的动态兴趣。文献[23]应用Bi-LSTM捕捉会话内上下文演化过程和会话之间的关系,利用局部激活单元聚合与目标项相关的会话兴趣。文献[63]提出基于堆叠RNN上下文感知序列推荐方法,建模行为序列中上下文的动态信息表示用户兴趣。文献[64]提出一种基于RNN的多路径知识图谱推荐算法,充分利用路径之间的关联建模用户的兴趣偏好。文献[65]将相邻序列融入RNN,提出K-plet循环神经网络建模序列中的全局和局部关系。模型采用Bi-GRU捕捉行为相关性建模用户兴趣的演变过程^[26],并将最后一个隐藏状态作为最终兴趣。文献[27]设计分层结构通过双层GRU提取用户兴趣。文献[14]设计ATGRU构建用户兴趣,首先使用Bi-GRU从用户历史行为序列中捕获序列关系,再结合目标注意力机制建模用户兴趣。文献[32]设计基于会话的时间感知门控循环单元ST-GRU,得到会话内的兴趣状态集合,考虑不同会话兴趣之间的依赖性,通过Bi-GRU建模最终用户兴趣。

(2) 分析不足

基于RNN的兴趣构建方法无法有效去除用户行为序列中的噪声,用户行为中可能包括用户偶然点击或不

相关项目,干扰用户真实兴趣的构建;这类方法难以识别用户的多重兴趣,导致兴趣表示单一且不能全面概括用户偏好;这类方法强调项目之间的局部顺序依赖,在实际应用中的用户行为不仅受相邻项目的影响,还可能涉及更广泛、更复杂的上下文关系。基于前两点不足,可以通过结合聚集式兴趣构建方法来改进,即引入目标注意力机制聚焦关键行为来减少噪声干扰,或者通过聚类用户行为得到不同的兴趣簇来构建用户的多重兴趣表示。

3.2.2 基于Transformer的方法

比起RNN模型,Transformer的优势在于其自注意力机制能够保证每个时刻求得的隐向量均包含整个序列的信息。与第3.1.1小节聚集式方法中的注意力机制不同,生成式方法涉及到的自注意力机制从全局上下文角度出发,学习用户行为之间的时序依赖关系^[66],构建动态的用户兴趣表示。

(1) 相关研究概述

文献[67]提出了一种多粒度Transformer模型建模联合级别的点击关系,学习交互序列中的多级顺序行为模式以此构建用户兴趣。文献[68]探讨用户行为序列中的隐含层次结构,并提出一种基于时空上下文聚合的分层Transformer模型,全局注意力层捕获序列的时空上下文,每个子序列内执行的局部注意力层增强子序列表示。文献[69]利用多头自我注意力机制从目标会话中提取与目标相关的兴趣表示,并采用分割和池化产生会话兴趣和目标兴趣。文献[28, 37, 39]通过Transformer堆叠的多头自注意力模块捕获序列中行为之间的相关性构建用户兴趣。文献[70]将用户的历史行为序列视为自然语言处理中的单词序列,使用基于双向自注意力的方法建模用户兴趣。为了从多种类型的交互行为中学习动态的用户兴趣,文献[40]在构建用户兴趣时针对点击行为的不同类型(例如浏览、购买和收藏)提出一种新的时间序列框架,考虑用户和项目之间不同的交互模式构建用户兴趣。文献[71]结合自注意力机制和图神经网络捕捉用户和项目的细粒度关系,提高兴趣构建的准确性。文献[72]将目标注意力机制扩展到目标模式注意力机制捕捉模式间的相关性。文献[24]分别基于商品级序列和特征级序列学习商品转换模式和特征转换模式构建用户兴趣。文献[66]提出一种Transformer变体,引入轻量级的自注意力机制建模用户的潜在兴趣。文献[19]通过Transformer中的位置编码技术捕获顺序关系,利用多头自注意力模块学习会话中项目间相关性构建用户兴趣。文献[16, 73]将视角转向在时域和频域中构建混合注意力模块,关注不同频谱上的特征并选择特定的频率分量作为时域和频域中自注意力层的输入特征,在构建用户兴趣时能够同时关注低频和高频序列信息。

(2)分析不足

基于Transformer的方法在构建用户兴趣时缺乏可解释性,难以深入揭示兴趣偏好形成的内在机制。此外,尽管生成式兴趣构建方法能够从序列角度有效捕捉行为之间的时序关联,但在过滤噪声、筛选重要用户行为、构建多重兴趣表示等场景下,仍需结合聚集式方法中的注意力机制和聚类技术更全面地构建用户兴趣。

3.2.3 基于大语言模型的方法

近年来,大语言模型在推荐系统中的应用成为研究热点^[56,74]。在用户兴趣建模任务中,基于大语言模型的生成式方法通过将用户行为序列和上下文信息转化为自然语言提示,借助LLMs的语义理解、知识推理和生成能力,构建动态、多粒度的用户兴趣表示,为兴趣建模提供了新范式。下面从相关研究概述和分析不足两个方面展开介绍。

(1)相关研究概述

文献[75]提出一种生成式推荐框架(generative recommenders, GRs),通过将用户行为与异构特征统一编码为时序序列,并利用改进的Transformer架构HSTU(hierarchical sequential transduction units)动态捕捉用户兴趣演化过程。文献[76]提出一种分层大语言模型框架HLLM(hierarchical large language models),通过Item LLM和User LLM两级架构,分别建模物品特征与用户行为序列,实现用户兴趣的动态捕捉。文献[77]提出通用推荐提示框架,将任务描述、用户行为序列和输出格式指令结合,通过ChatGPT生成用户兴趣的语义化表示。文献[74]针对电影推荐场景提出时序感知提示方法,强调用户近期交互行为的时序依赖关系,增强LLMs对兴趣演化模式的捕捉能力。文献[78]提出滑动窗口策略,缓解长上下文限制问题,将候选项目分批次输入LLMs进行局部排序,再通过多轮聚合和平均池化得到全局兴趣表示。在对话推荐场景,文献[79]验证ChatGPT通过多轮交互动态修正用户兴趣的能力,其生成的解释性文本可辅助构建可解释的兴趣表示。文献[80]提出基于LLMs的用户画像增强方法,从用户历史行为中提取关键词与商品特征进行语义匹配,提升冷启动场景下的兴趣建模效果。文献[81]设计多智能体框架,由LLMs模拟用户的交互过程扩展训练数据,捕捉多样化用户兴趣。一部分研究基于大模型的微调方式构建用户兴趣。文献[82]基于Alpaca指令数据预训练后,通过用户历史行为与反馈数据的对比学习微调LLMs,使其生成符合用户偏好的结构化兴趣表示。文献[83]设计多任务指令模板,对T5模型进行跨任务联合训练,增强模型对用户兴趣多样性和动态性的建模能力。文献[84]提出两阶段对齐方法,先生成语义化的兴趣描述,再通过嵌入相似度加权映射至具体商品ID,平衡语义相关性与实际商品分布。文献[85]对齐传统推

荐模型中的ID嵌入与LLMs的文本表示空间,融合协同过滤信号与语义特征构建混合兴趣表示。文献[86]提出基于LLMs的生成式检索框架,将用户兴趣转化为自然语言查询,通过语义检索扩充候选集。

此外,一些研究聚焦于利用LLMs解决用户兴趣建模任务中的特定难题。文献[87]提出LLM-CF框架,在离线阶段让LLMs学习协同过滤信息并生成思维链推理,在线阶段利用检索的上下文示例学习相关特征来增强推荐模型,提升推荐性能。文献[88]设计出结合LLMs与协同过滤的方法,通过训练LLMs理解用户偏好和物品特征关系来生成文本信息,协同过滤利用这些信息更准确地捕捉用户兴趣。文献[89]利用精心设计的提示策略,将用户浏览、购买记录等转化为文本输入LLMs,挖掘用户潜在兴趣,为推荐系统提供精确的兴趣信息。文献[90]将LLMs作为数据增强器,针对冷启动物品推荐难题,采用成对比较提示法推断用户偏好,生成的增强训练信号融入下游推荐模型,提升冷启动推荐效果。文献[91]提出借助LLMs获取语义嵌入,处理长尾物品和用户问题,强化用户偏好表示。文献[92]通过检索用户与物品交互信息融入LLMs提示,分析用户偏好模式,利用强化学习精准把握用户兴趣。文献[93]将用户画像和历史交互转为提示让LLMs学习用户兴趣偏好,实现多轮推荐并解释推荐原因。文献[94]利用LLMs为推荐结果生成解释,理解推荐模型决策过程,根据用户行为和物品特征生成解释文本。文献[95]应对序列推荐中用户行为的个体差异问题,为不同用户序列生成定制权重,捕捉用户动态兴趣变化。文献[96]通过分析用户不同阶段的行为数据,转化为文本输入LLMs,理解用户兴趣的发展变化,提供符合用户当前兴趣状态的推荐。文献[97]提出ReLLa模型,利用检索模块获取历史信息,结合LLMs语言理解能力捕捉用户长期兴趣和行为模式。文献[98]在电商推荐系统中,将用户浏览和购买记录转化为文本供LLMs挖掘潜在兴趣,生成个性化推荐列表。文献[99]针对下一个兴趣点推荐任务,把用户的历史轨迹数据转化为文本输入LLMs预测用户下一个可能感兴趣的地点。

(2)分析不足

尽管基于大模型的生成式方法在用户兴趣建模领域展现出巨大潜力,但仍存在诸多挑战。主要体现在以下四个方面:①在数据适配问题上,大语言模型依赖的文本和图像数据与用户兴趣建模所需的用户行为数据在结构和性质上有着根本差异;②在可控性与稳定性上,LLMs输出难契合推荐任务需求,可能生成格式不符或虚构内容,并且LLMs在复杂场景下推理延迟高,制约实际应用;③数据偏差与隐私风险也不容忽视,预训练语料流行度偏差影响推荐结果趋同,且用户信息转化为自然语言存在隐私泄露风险;④在动态兴趣建模方

表3 兴趣构建方法对比
Table 3 Comparison of interest construction methods

方法分类	文献	特点	存在的不足
聚集式方法	基于注意力机制: 文献[1, 15, 18, 21, 29, 31, 36, 41-42, 44-49]	1. 可解释性强	1. 没有考虑行为之间的时序依赖关系, 忽略动态信息, 无法建模兴趣演变过程 2. 面临冷启动、数据稀疏问题
	基于聚类: 文献[3-4, 25, 50-55]	2. 注意力和聚类提供多个视角看待用户行为, 从不同维度构建兴趣 3. 具有较强的可扩展性和灵活性, 根据数据特性设计不同模型结构	
生成式方法	基于 RNN: 文献[14, 20, 23, 26-27, 32, 57-65]	1. 能够从丰富的动态行为数据中构建准确的用户兴趣, 从而预测用户“下一时刻”的需求	1. 增加计算代价, 模型处理数据耗时增加
	基于 Transformer: 文献[16, 19, 24, 28, 37, 39-40, 66-73]	2. 能够建模用户行为的序列信息以及捕获用户兴趣的演变, 从而应对兴趣漂移等问题	2. 数据依赖性较强, 如果序列之间的噪声过多, 兴趣建模的效果会受到明显影响
	基于大模型: 文献[74-99]		3. 面临冷启动、数据稀疏问题

面,现有方法难以捕捉用户兴趣的实时变化。要借助大模型实现真正意义上的个性化推荐服务,未来需在生成算法的可控性、计算效率、偏差消除和动态兴趣建模等方面持续研究,推动 LLMs 与用户兴趣建模任务的深度融合。

3.3 小结

综上所述,聚集式方法侧重于从历史行为数据中提取构建用户兴趣所需的静态信息,而忽视了兴趣随时间的演化过程,主要通过加权、聚类等方法实现。这种方法在捕捉用户长期、稳定的兴趣时表现良好,但在处理用户兴趣的实时性和动态性方面存在局限。对于生成式方法,通过学习用户行为之间的依赖关系捕捉用户兴趣的动态信息,更适合预测用户在下一时刻的需求走向,其中,基于大模型的生成式算法能够凭借语义理解和知识推理能力,构建高质量的用户兴趣表示。两类兴趣构建方法的侧重点不同,综合对比如表 3 所示。

4 实验

基于聚集式与生成式两类建模方法,旨在深入分析不同用户兴趣建模策略对候选项目排序质量的影响,以便为个性化推荐系统提供可靠的兴趣建模方法选择依据。在 4.1 节介绍实验的准备工作,包括数据集、相关评价指标以及实验参数的设置;第 4.2 和 4.3 节分别验证聚集式和生成式兴趣构建方法的有效性。

4.1 准备工作

在数据处理过程中,遵循文献[17]中的常见做法,将选取的数据集中所有数字评级转换为隐式反馈。然后,按用户对交互记录进行分组,并根据时间戳进行排序,为每个用户构建行为序列。在排序阶段将测试集中的每个真实项目和用户未与之交互的 99 个随机抽样的负样本配对一起进行排名。

4.1.1 数据集介绍

在 ml-20m 和 Amazon_all_beauty 数据集上进行实验,数据处理统计信息如表 4 所示。数据集 ml-20m 中 ratings.

dat 包含 20 000 263 条数据,记录用户对观看的电影的评分情况,对于 Amazon2018 数据集本文使用 Amazon_all_beauty 类别的仅评分版本,包含用户对美妆项目的评分情况,将以上两个数据集中数字评级转换为隐式反馈,将评分为 4 分和 5 分的样本标记为正样本,其余评分样本标记为负样本。按用户对交互记录进行分组,并根据时间戳进行排序,从而构建每个用户的交互序列。为了保证所有建模方法的一致性,对所有模型的输入特征仅使用用户 ID 以及项目 ID,没有引入额外的特征信息,以此突出聚集式和生成式方法在构建用户兴趣时的本质区别。

表4 数据集统计信息
Table 4 Dataset statistics information

数据集	用户数	项目数	交互数	稀疏性/%
ml-20m	138 494	26 745	20 000 263	99.46
Amazon all beauty	324 039	32 587	371 345	99.99

4.1.2 评价指标介绍

选取 Recall、Precision、MRR 和 NDCG 四个常用评价指标评估各个模型的排序性能,采用 Top-K 排序结果进行统计和分析。在排序阶段将真实项目与用户未与之交互的 99 个随机抽样的负样本配对,根据项目的排名计算所有指标并报告平均分数。所有评价指标值越高代表性能越好。

(1)Precision: 评估推荐列表中用户真正感兴趣项目的比例,指预测正确的正样本数占模型判定为正样本的数量的比例。

(2)Recall: 衡量模型预测正确的正样本个数占真正的正样本数量的比例。Recall 关注的是模型能否识别出用户所有可能感兴趣的内容。

(3)MRR(mean reciprocal rank): 通过计算相关项目在推荐列表中的平均倒数排名并取平均值来评估系统的排序能力。MRR 值越高,表明模型更擅长将真正相关的项目放在推荐结果的顶部,即衡量第一个真实交互项目是否置于推荐结果的明显位置。

(4)NDCG(normalized discounted cumulative gain):衡量推荐系统排序性能的关键指标,不仅考虑推荐结果的排名位置,还考虑每个结果相对于查询或用户需求的相关性或重要性,并通过相应的权重来体现这一点,鼓励模型将更重要或相关的内容优先展示。

4.1.3 参数介绍

使用 Adam 优化器并以 0.001 的学习率优化所有模型,训练过程采用留一法进行交叉验证,隐向量维度固定为 64, batch_size 设置为 2 048, epoch 设置为 20。基线模型的其他超参数根据原始论文的建议进行了细节调整。部分基线模型基于流行的开源推荐算法库 RecBole^[100]实现。

4.2 聚集式方法实验

本节从第 3.1 节聚集式建模方法中选取经典模型进行对比,其中模型 SHAN、STAMP、NAIS、HGN 和 DIN 采用基于注意力机制的兴趣构建方法,模型 SINE 和 MacridVAE 采用基于聚类兴趣构建方法。

4.2.1 模型介绍

SHAN^[47]通过两个分层注意力网络捕获用户和项目之间的非线性交互,计算不同用户对其历史行为产生的权重得分。

SINE^[3]借助聚类识别的概念提取用户的多重兴趣,具备对项目进行聚类并以端到端方式推断用户稀疏兴趣集的能力。

MacridVAE^[4]对用户行为在宏观维度解纠缠推断用户的不同偏好。

STAMP^[18]提出短期注意力网络捕捉用户最新兴趣,同时建模一般兴趣。

NAIS^[1]设计两种不同的注意力模型结构构建用户兴趣,即 NAIS-prob 和 NAIS-concat。

HGN^[49]采用分层结构学习项目的组级表示。

DIN^[15]利用目标注意力激活相关的用户行为,通过

加权构建用户兴趣。

4.2.2 实验结果分析

表 5 列出了选取的模型在两个数据集上的实验结果,每个数据集同一指标下的最优结果已用粗体标出。

模型 MacridVAE 在 Amazon_all_beauty 数据集上展现出卓越的排序性能,这得益于在宏观与微观两个层面实施解纠缠策略以学习用户兴趣。具体而言,该模型通过推断与用户意图紧密相关的高级概念(如购买衬衫或手机)实现宏观层面解纠缠,同时精确地捕捉用户针对这些不同概念的个性化偏好。此外,模型 SINE 同样考虑用户兴趣的多样性推断与用户兴趣相关联的高级概念,将行为序列中的项目与相应偏好进行聚类,构建用户多重兴趣表示。相较于建模单一的用户兴趣,这种基于聚类的兴趣构建方法能够更全面地反映用户多重偏好。

模型 STAMP、SHAN 和 HGN 在两个不同的数据集上相较于 NAIS 和 DIN 模型均展现出更为出色的表现。尽管这五个模型构建用户兴趣时均通过注意力机制为用户行为分配权重,但模型 STAMP、SHAN 和 HGN 在建模过程中不仅考虑序列的全局信息以反映用户的长期偏好,还通过注意力机制聚焦用户近期行为,即兼顾用户的短期兴趣。这一策略验证了同时捕获用户的一般兴趣和最新兴趣对于兴趣建模的有效性,且这种综合考虑用户长短期兴趣的方法在兴趣建模领域获得了高度评价。在构建兴趣表示时,模型 SHAN 和 HGN 均采用分层结构,通过层级注意力和层级门控单元分别学习行为权重,融合用户的长短期偏好以构建最终的用户兴趣。此外,STAMP 模型在 ml-20m 展现出较好的排序能力。其优势不仅在于能够同时建模用户的长短期兴趣,还强调会话中最后一次点击的重要性,通过短期注意力机制学习用户的当前兴趣,并综合目标项目、最后点击的项目以及会话中所有项目的综合嵌入来构建最终的用户兴趣表示。

表 5 聚集式方法实验结果
Table 5 Experimental results of aggregation methods

数据集	模型	NDCG@10	MRR@10	Recall@10	Precision@10
ml-20m	SHAN	0.707 1	0.637 2	0.925 0	0.092 5
	SINE	0.659 0	0.575 4	0.921 1	0.092 1
	STAMP	0.709 2	0.639 2	0.928 0	0.092 8
	NAIS-prob	0.270 1	0.219 1	0.431 1	0.043 1
	NAIS-concat	0.279 5	0.227 8	0.447 0	0.044 7
	HGN	0.659 6	0.577 4	0.917 3	0.091 7
	DIN	0.568 6	0.461 5	0.921 5	0.092 2
	MacridVAE	0.650 0	0.568 9	0.902 6	0.090 3
Amazon_all_beauty	SHAN	0.569 0	0.539 1	0.663 8	0.066 4
	SINE	0.568 0	0.535 5	0.671 0	0.067 1
	STAMP	0.584 2	0.541 5	0.717 9	0.071 8
	NAIS-prob	0.510 5	0.474 8	0.620 5	0.062 0
	NAIS-concat	0.486 8	0.449 3	0.605 2	0.060 5
	HGN	0.590 1	0.551 7	0.710 6	0.071 1
	DIN	0.455 9	0.317 5	0.710 9	0.072 0
	MacridVAE	0.620 1	0.581 3	0.745 9	0.074 6

进一步分析实验结果,发现模型DIN和NAIS的表现相对欠佳。DIN模型的目标注意力机制能够聚焦用户行为与候选项目之间的相关性,然而缺乏对用户长短期兴趣的构建,在处理复杂且规模庞大的数据集时仅依赖目标注意力机制难以全面且捕捉用户的多维度兴趣。另一方面,虽然NAIS模型在处理全量数据或稀疏数据的场景时,有限的用户与项目之间的交互信息导致输入向量无法可靠地从数据中学习,NAIS模型的注意力结构难以有效发挥作用。这些模型尝试探索不同结构的注意力机制,但在实际应用中如何有效结合用户的长短期兴趣,以及如何在数据稀疏或复杂数据的场景下保持模型的性能,仍是需要进一步解决的问题。

4.3 生成式方法实验

本节从3.2节生成式建模方法中选取经典模型进行对比分析,其中模型SASRec、BERT4Rec、CORE、LightSANs、FEARec和FDSA采用基于Transformer的兴趣构建方法,模型GRU4Rec和NARM采用基于RNN的兴趣构建方法。值得一提的是,基于Transformer的模型大部分是对自注意力机制的应用和改进,以此来充分学习用户行为序列之间的复杂关系。

4.3.1 模型介绍

GRU4Rec^[57]基于GRU的深度学习模型,用于会话级顺序推荐。

SASRec^[17]基于Transformer模型,通过多头自注意力机制捕获行为之间依赖关系构建用户兴趣。

BERT4Rec^[70]引入双向自注意力网络,从左右上下文中捕获每个项目的上下文信息,从用户行为序列中构建用户兴趣。

CORE^[19]利用Transformer中的自注意力模块学习会话中项目的相关性。

LightSANs^[66]用于序列推荐的Transformer变体,利用位置编码捕获项目之间的顺序依赖关系。

NARM^[61]基于GRU建模用户的顺序行为并捕获会话级用户兴趣。

FEARec^[16]一种新颖的用于顺序推荐的频率增强混合注意力网络,在时域和频域上构建混合注意力。

FDSA^[24]分别对商品级和特征级序列应用自注意力机制构建用户兴趣。

4.3.2 实验结果分析

表6列出了选取的模型在两个数据集上的实验结果,每个数据集同一指标下的最优结果已用粗体标出。

总体来看,模型BERT4Rec、SASRec、LightSANs、FEARec以及FDSA,相较于模型GRU4Rec和NARM,展现出显著的性能优势。这一结果验证自注意力机制在兴趣建模领域的卓越能力,直接捕获任意距离依赖关系的能力确保每个时间步的隐向量均包含整个序列的信息,能够更精准地建模用户兴趣演变过程。具体而言,LightSANs模型引入低阶分解的自注意力机制,通过将用户历史交互项目映射至固定数量的潜在兴趣向量中,有效避免了模型在无明显目标下学习项目间相关性的弊端,从而构建更具代表性的用户兴趣。FEARec模型性能的提升揭示兴趣建模在时域和频域的研究对于提高模型捕获用户兴趣的能力有一定帮助,使得在构建兴趣时能够同时关注低频和高频信息。BERT4Rec模型在大规模数据集ml-20m中展现出优异的排序性能,建模用户兴趣时通过学习正向与逆向的上下文关系能够更深入剖析用户行为序列。以上实验结果验证从不同维度对自注意力机制的改进对于构建用户兴趣具有显著帮助。

在基于RNN的方法中,NARM模型在两个数据集上的表现均优于GRU4Rec模型。因为NARM模型不仅通过GRU建模用户行为之间的顺序依赖关系捕捉会话中的核心兴趣,还引入项目级别的注意力机制赋予模型能够聚焦于会话中关键的用户行为的能力,正如3.2.2

表6 生成式方法实验结果
Table 6 Experimental results of generation methods

数据集	模型	NDCG@10	MRR@10	Recall@10	Precision@10
ml-20m	SASRec	0.788 3	0.732 7	0.960 0	0.096 0
	BERT4Rec	0.827 4	0.780 6	0.970 8	0.097 1
	GRU4Rec	0.743 3	0.679 4	0.941 9	0.094 2
	CORE	0.574 3	0.476 1	0.886 2	0.088 6
	LightSANs	0.788 9	0.734 4	0.957 2	0.095 7
	NARM	0.750 1	0.687 6	0.943 9	0.094 4
	FEARec	0.755 5	0.695 1	0.943 2	0.094 3
	FDSA	0.771 4	0.713 9	0.949 7	0.095 0
Amazon_all_beauty	SASRec	0.613 6	0.579 6	0.722 0	0.072 2
	BERT4Rec	0.445 0	0.413 1	0.543 4	0.054 3
	GRU4Rec	0.571 6	0.528 7	0.706 0	0.070 6
	CORE	0.434 9	0.414 0	0.502 7	0.050 3
	LightSANs	0.623 3	0.591 3	0.725 6	0.072 6
	NARM	0.573 3	0.534 3	0.696 4	0.069 6
	FEARec	0.610 1	0.578 6	0.710 6	0.071 1
	FDSA	0.609 4	0.576 2	0.715 3	0.071 5

小节中的分析,生成式方法在一些场景下仍需结合聚集式方法从而更全面地构建用户兴趣。

5 总结与展望

本文聚焦用户兴趣建模任务,围绕点击意图识别与兴趣构建两个阶段展开,对现有方法进行归纳、剖析与整理。以全新的分类视角,将已有点击意图识别方法归纳为非个性化和个性化两类,将兴趣构建方法归纳为聚集式与生成式两类,概述相关研究并分析现存不足。最后,结合两阶段当前面临的挑战展望未来发展方向,本文旨在为读者提供一条清晰的研究脉络,为该领域的创新与实践提供帮助。

尽管当前兴趣建模任务已取得显著进展,但仍面临一些挑战值得深入探讨:

(1)点击意图识别挑战。当前点击意图识别阶段面临三大核心挑战:冷启动挑战、点击意图多样性挑战、线上耗时增加等问题。首先,该领域冷启动问题尤为突出,当处理新用户或新项目时,因缺乏充足的交互数据导致难以精准捕捉用户点击意图。其次,点击意图识别的多样性源于多模态数据的融合。虽然图片和视频提供的视觉内容能够直观且生动地传递信息,文本以其详尽的语义内容帮助用户深度理解,但是,如何精准识别用户在不同数据形式背后的真实点击意图,成为该领域亟待解决的关键挑战之一,需要准确构建并表征不同形式数据之间的内在联系,跨越多维度融合用户行为数据来深度洞察用户意图。此外,点击意图识别过程涉及曝光内容的语义理解、点击概率的精确评估以及多源信息的有效融合,不仅增加了系统的计算负担,还可能导致系统响应时间延长和线上打分模型耗时增加的问题。

本文2.3节中提到的点击意图个性化识别方法目前还在研究初步阶段,如何灵活根据用户的偏好需求对项目的不同特征给予差异化的关注,同样是后续应考虑的关键问题。尽管文献[41]在该方法上做了初次尝试,能够捕捉并分析用户点击行为背后所蕴含的个性化需求,但仍存在改进空间。该研究采用基于规则的简单方法建模点击意图,在一元点击意图建模的准确性上仍有提升空间,未充分探索一元点击意图之间的潜在关联性与相互影响,限制了模型全面解析并理解复杂用户行为的能力。此外,正如点击意图面临的多样性挑战,该方法未考虑点击意图的形式多样性,用户点击意图可能以多种方式展现,这包括但不限于项目的文本描述、图片以及视频中的隐含信息等。未充分利用这些多模态数据,限制了模型捕捉用户真实意图的广度和深度。

(2)兴趣多样性挑战。首先,对于同一用户来说,兴趣多样性体现在该用户的兴趣由多个相互作用的隐藏兴趣共同构成^[15]。本文在3.1节概述基于聚类的兴趣构建方法,并在4.2节验证这些方法能够有效提升模型性

能。但面对序列推荐任务时,在兴趣多样性的基础上捕捉兴趣间的时序信息和动态变化尤为关键。聚集式方法受限于处理长期依赖建模能力,而且仅仅聚焦于通过聚类得到的多重兴趣,忽略了兴趣之间的传递与演变关系,使得兴趣多样性局限在静态表示层面,难以全面反映用户兴趣的演化性和时空性。

其次,对于不同用户来说,兴趣多样性揭示了用户群体间兴趣偏好的高度异质性。不同用户基于其独特的背景、经历和需求,展现出多样化的兴趣偏好且跨度广泛。兴趣多样性挑战对应多样化推荐领域中的个体多样性和整体多样性^[101],在构建同一用户的多重兴趣的同时也要深刻认识到不同用户之间兴趣的差异。此外,用户多样化的兴趣常跨越多个领域,如何有效捕捉这些兴趣并实现跨领域的推荐是未来值得研究的一个方向。在知识图谱领域相关研究基于其网络结构实现实体关系的低维映射,并在图谱中通过多跳传播捕捉用户偏好^[9],以此探索实体间的层次关系为跨域推荐提供了技术支持与理论支撑。

(3)结合大语言模型挑战。基于大模型的方法在语义理解与内容生成方面的突破性进展为兴趣建模任务带来新的发展机遇,但也伴随着诸多挑战,主要体现在以下四个方面:

①数据转化与适配挑战。当前,推荐系统领域大语言模型依赖的文本和图像数据,与用户兴趣建模所需的用户行为数据在结构和性质上有着根本差异^[56]。一部分研究^[77,89,96,98]将用户浏览、购买记录重构为文本信息供LLMs处理,通过设计不同提示策略、框架和方法,以自然语言形式表达用户的多样化需求和潜在偏好,从而构建用户兴趣。文献[102]提出GPT4Rec框架致力于将LLMs的语义理解能力用于处理推荐系统的多粒度交互特征。

②在可控性与稳定性方面,LLMs开放性的生成机制与推荐系统的精准需求存在冲突。一些场景下,LLMs可能生成虚构内容导致事实性错误,难以满足推荐任务场景的需求。文献[103]通过强化学习优化指令提高推荐结果的稳定性,但训练成本较高且难以覆盖所有场景。此外,LLMs推理延迟高是普遍问题,尽管模型压缩和蒸馏技术可缓解LLMs推理速度的制约^[104],但会一定程度上牺牲生成结果的多样性。文献[75]尝试采用M-FALCON算法,在训练和推理阶段分别实现算力复用与微批次处理提升推理速度。

③数据偏差问题与隐私风险也不容忽视。LLMs预训练语料中的流行度偏差会影响推荐结果,以此为基础来挖掘用户兴趣可能导致推荐结果趋同。同时,将用户行为转化为自然语言存在隐私泄露风险,例如,文献[80]提出基于LLMs的用户画像增强方法,需要更可靠的隐私保护机制来保障用户信息安全。

④在捕捉用户实时兴趣演化方面。大部分研究依

赖静态提示或固定指令分析用户行为序列,无法做到实时捕捉动态的用户兴趣。文献[105]尝试通过多智能体模拟用户动态行为,提升捕捉用户兴趣实时变化的能力。

综上,该领域未来的研究应聚焦于开发跨模态特征的有效映射策略;设计基于LLMs的轻量化兴趣构建模型,保证推理效率同时提升推荐结果的稳定性和可靠性;建立保护机制,降低数据偏差与隐私泄露问题带来的风险;从点击意图识别和兴趣构建两阶段现存挑战出发,增强捕捉用户兴趣动态变化的能力,解析更深层次的用户兴趣。本文研究旨在推动LLMs在推荐系统领域的广泛应用与发展,提供更加个性化、多样化的推荐服务。

参考文献:

- [1] HE X N, HE Z K, SONG J K, et al. NAIS: neural attentive item similarity model for recommendation[J]. IEEE Transactions on Knowledge and Data Engineering, 2018, 30(12): 2354-2366.
- [2] TANG J X, WANG K. Personalized top-N sequential recommendation via convolutional sequence embedding[C]//Proceedings of the Eleventh ACM International Conference on Web Search and Data Mining. New York: ACM, 2018: 565-573.
- [3] TAN Q Y, ZHANG J W, YAO J C, et al. Sparse-interest network for sequential recommendation[C]//Proceedings of the 14th ACM International Conference on Web Search and Data Mining. New York: ACM, 2021: 598-606.
- [4] MA J X, ZHOU C, CUI P, et al. Learning disentangled representations for recommendation[C]//Advances in Neural Information Processing Systems, 2019: 5712-5723.
- [5] 余鹏, 刘星雨, 程颖, 等. 在线课程推荐系统综述[J]. 计算机工程与应用, 2023, 59(22): 1-14.
YU P, LIU X Y, CHENG H, et al. Survey of online course recommendation system[J]. Computer Engineering and Applications, 2023, 59(22): 1-14.
- [6] 吴性丽, 张皓月, 廖虎昌. 面向在线问诊平台的医生推荐方法及应用研究综述[J]. 计算机科学, 2025, 52(5): 109-121.
WU X L, ZHANG H Y, LIAO H C. Review of doctor recommendation methods and applications for consultation platforms[J]. Computer Science, 2025, 52(5): 109-121.
- [7] 吕福荣, 师云龙, 景晓宁, 等. 服装推荐系统的关键技术研究进展[J]. 现代纺织技术, 2024, 32(12): 134-144.
LÜ F R, SHI Y L, JING X N, et al. Research progress on key technologies of clothing recommendation systems[J]. Advanced Textile Technology, 2024, 32(12): 134-144.
- [8] 张雄涛, 祝娜, 郭玉慧. 基于图神经网络的会话推荐方法综述[J]. 数据分析与知识发现, 2024, 8(2): 1-16.
ZHANG X T, ZHU N, GUO Y H. A survey on session-based recommendation methods with graph neural network [J]. Data Analysis and Knowledge Discovery, 2024, 8(2): 1-16.
- [9] 朱冬亮, 文奕, 万子琛. 基于知识图谱的推荐系统研究综述[J]. 数据分析与知识发现, 2021, 5(12): 1-13.
ZHU D L, WEN Y, WAN Z C. Review of recommendation systems based on knowledge graph[J]. Data Analysis and Knowledge Discovery, 2021, 5(12): 1-13.
- [10] 张明星, 张骁雄, 刘姗姗, 等. 利用知识图谱的推荐系统研究综述[J]. 计算机工程与应用, 2023, 59(4): 30-42.
ZHANG M X, ZHANG X X, LIU S S, et al. Review of recommendation systems using knowledge graph[J]. Computer Engineering and Applications, 2023, 59(4): 30-42.
- [11] 王慧欣, 童向荣. 融合知识图谱的推荐系统研究进展[J]. 浙江大学学报(工学版), 2023, 57(8): 1527-1540.
WANG H X, TONG X R. Research progress of recommendation system based on knowledge graph[J]. Journal of Zhejiang University (Engineering Science), 2023, 57(8): 1527-1540.
- [12] 高广尚. 推荐系统中神经网络结合注意力机制研究综述[J]. 计算机工程与应用, 2024, 60(10): 47-60.
GAO G S. Review of research on neural network combined with attention mechanism in recommendation system[J]. Computer Engineering and Applications, 2024, 60(10): 47-60.
- [13] 高广尚. 可解释推荐模型中的可解释性方法研究综述[J]. 数据分析与知识发现, 2024, 8(S1): 6-19.
GAO G S. A survey of interpretable methods in interpretable recommendation model[J]. Data Analysis and Knowledge Discovery, 2024, 8(S1): 6-19.
- [14] ZHANG L, LIU F A, WU H C, et al. CFF: combining interactive features and user interest features for click-through rate prediction[J]. The Journal of Supercomputing, 2024, 80(3): 3282-3309.
- [15] ZHOU G R, ZHU X Q, SONG C R, et al. Deep interest network for click-through rate prediction[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. New York: ACM, 2018: 1059-1068.
- [16] DU X Y, YUAN H H, ZHAO P P, et al. Frequency enhanced hybrid attention network for sequential recommendation [C]//Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2023: 78-88.
- [17] KANG W C, MCAULEY J. Self-attentive sequential recommendation[C]//Proceedings of the 2018 IEEE International Conference on Data Mining. Piscataway: IEEE, 2018: 197-206.
- [18] LIU Q, ZENG Y F, MOKHOSI R, et al. STAMP: short-term attention/memory priority model for session-based recommendation[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. New York: ACM, 2018: 1831-1839.
- [19] HOU Y P, HU B B, ZHANG Z Q, et al. CORE: simple and effective session-based recommendation within consistent representation space[C]//Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2022: 1796-1801.
- [20] ZHOU G R, MOU N, FAN Y, et al. Deep interest evolution network for click-through rate prediction[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2019: 5941-5948.
- [21] XU W N, HE H X, TAN M S, et al. Deep interest with hierarchical attention network for click-through rate prediction [C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information

- Retrieval. New York: ACM, 2020: 1905-1908.
- [22] NIU C, HUANG W, YANG Y J. Multi-granularity interest learning for click-through rate prediction[C]//Proceedings of the 2023 IEEE International Conference on Systems, Man, and Cybernetics. Piscataway: IEEE, 2024: 1970-1977.
- [23] FENG Y F, LV F Y, SHEN W C, et al. Deep session interest network for click-through rate prediction[J]. arXiv:1905.06482, 2019.
- [24] ZHANG T T, ZHAO P P, LIU Y C, et al. Feature-level deeper self-attention network for sequential recommendation[C]//Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence, 2019: 4320-4326.
- [25] CAO Y, ZHOU X J, FENG J Q, et al. Sampling is all you need on modeling long-term user behaviors for CTR prediction[C]//Proceedings of the 31st ACM International Conference on Information & Knowledge Management. New York: ACM, 2022: 2974-2983.
- [26] ZHOU R J, JIN Z M, WAN J, et al. Evolutionary interest representation network for click-through rate prediction[C]//Proceedings of the 2023 IEEE International Conference on Web Services. Piscataway: IEEE, 2023: 535-544.
- [27] XU E, YU Z W, GUO B, et al. Core interest network for click-through rate prediction[J]. ACM Transactions on Knowledge Discovery from Data, 2021, 15(2): 1-16.
- [28] XIAO Z B, YANG L W, JIANG W, et al. Deep multi-interest network for click-through rate prediction[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. New York: ACM, 2020: 2265-2268.
- [29] QIN J R, ZHANG W N, WU X, et al. User behavior retrieval for click-through rate prediction[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2020: 2347-2356.
- [30] CHEN Q W, ZHAO H, LI W, et al. Behavior sequence transformer for e-commerce recommendation in Alibaba[C]//Proceedings of the 1st International Workshop on Deep Learning Practice for High-Dimensional Sparse Data. New York: ACM, 2019: 1-4.
- [31] LYU Z, DONG Y, HUO C F, et al. Deep match to rank model for personalized click-through rate prediction[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2020: 156-163.
- [32] ZHANG C X, QIU L Q, JING C X, et al. TIAE-DSIN: a time interval aware deep session interest network for click-through rate prediction[J]. Expert Systems with Applications, 2024, 249: 123531.
- [33] HOU X Y, WANG Z, LIU Q, et al. Deep context interest network for click-through rate prediction[C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. New York: ACM, 2023: 3948-3952.
- [34] XIE Y Q, ZHOU P L, KIM S. Decoupled side information fusion for sequential recommendation[C]//Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2022: 1611-1621.
- [35] MA D H, PEI H B, BAO P, et al. Deep click interest network for reranking hotels[J]. Engineering Applications of Artificial Intelligence, 2024, 130: 107675.
- [36] CHEN P L, WEN H, ZHANG J, et al. cold-start based multi-scenario ranking model for click-through rate prediction[C]//Proceedings of the 1st International Conference on Database Systems for Advanced Applications. Cham: Springer, 2023: 64-79.
- [37] ZHANG X, WANG Z M, DU B, et al. Deep session heterogeneity-aware network for click through rate prediction[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(12): 7927-7939.
- [38] XUE S, HE C Q, HUA Z X, et al. Interactive attention-based capsule network for click-through rate prediction[J]. IEEE Access, 2024, 12: 170335-170345.
- [39] XIE R B, LING C, WANG Y L, et al. Deep feedback network for recommendation[C]//Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence, 2020: 2519-2525.
- [40] XIA L H, HUANG C, XU Y, et al. Multi-behavior sequential recommendation with temporal graph transformer[J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35(6): 6099-6112.
- [41] MA D H, SUN J J, CHEN Y G, et al. Two-stage interest calibration network for reranking hotels[C]//Proceedings of the International Conference on Database Systems for Advanced Applications. Cham: Springer, 2023: 325-335.
- [42] 仲兆满, 管燕, 胡云, 等. 基于背景和内容的微博用户兴趣挖掘[J]. 软件学报, 2017, 28(2): 278-291.
- [42] ZHONG Z M, GUAN Y, HU Y, et al. Mining user interests on microblog based on profile and content[J]. Journal of Software, 2017, 28(2): 278-291.
- [43] 张玉洁, 董政, 孟祥武. 个性化广告推荐系统及其应用研究[J]. 计算机学报, 2021, 44(3): 531-563.
- [43] ZHANG Y J, DONG Z, MENG X W. Research on personalized advertising recommendation systems and their applications[J]. Chinese Journal of Computers, 2021, 44(3): 531-563.
- [44] YU M T, LIU T T, YIN J, et al. Deep interest context network for click-through rate[J]. Applied Sciences, 2022, 12(19): 9531.
- [45] YU M T, LIU T T, YIN J. Deep filter context network for click-through rate prediction[J]. Journal of Theoretical and Applied Electronic Commerce Research, 2023, 18(3): 1446-1462.
- [46] CHEN J Y, ZHANG H W, HE X N, et al. Attentive collaborative filtering: multimedia recommendation with item- and component-level attention[C]//Proceedings of the 40th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2017: 335-344.
- [47] YING H C, ZHUANG F Z, ZHANG F Z, et al. Sequential recommender system based on hierarchical attention networks[C]//Proceedings of the International Joint Conference on Artificial Intelligence, 2018: 3926-3932.
- [48] XUE T, LIN Z, ZHANG Z, et al. Large scale hierarchical user interest modeling for click-through rate prediction[C]//

- Proceedings of the Recommender Systems Challenge 2024, 2024: 53-57.
- [49] MA C, KANG P, LIU X. Hierarchical gating networks for sequential recommendation[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. New York: ACM, 2019: 825-833.
- [50] GAI K, ZHU X Q, LI H, et al. Learning piece-wise linear models from large scale data for ad click prediction[J]. arXiv:1704.05194, 2017.
- [51] PI Q, ZHOU G R, ZHANG Y J, et al. Search-based user interest modeling with lifelong sequential behavior data for click-through rate prediction[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. New York: ACM, 2020: 2685-2692.
- [52] SABOUR S, FROSST N, HINTON G E. Dynamic routing between capsules[C]//Advances in Neural Information Processing Systems, 2017: 3856-3866.
- [53] YANG S, LEE F F, MIAO R, et al. RS-CapsNet: an advanced capsule network[J]. IEEE Access, 2020, 8: 85007-85018.
- [54] KWABENA PATRICK M, FELIX ADEKOYA A, ABRA MIGHTY A, et al. Capsule networks—a survey[J]. Journal of King Saud University-Computer and Information Sciences, 2022, 34(1): 1295-1310.
- [55] LI C, LIU Z Y, WU M M, et al. Multi-interest network with dynamic routing for recommendation at Tmall[C]//Proceedings of the 28th ACM International Conference on Information and Knowledge Management. New York: ACM, 2019: 2615-2623.
- [56] ZHAO Z H, FAN W Q, LI J T, et al. Recommender systems in the era of large language models (LLMs)[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(11): 6889-6907.
- [57] HIDASI B, KARATZOGLOU A, BALTRUNAS L, et al. Session-based recommendations with recurrent neural networks[J]. arXiv:1511.06939, 2015.
- [58] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [59] DAI H J, WANG Y C, TRIVEDI R, et al. Recurrent coevolutionary latent feature processes for continuous-time recommendation[C]//Proceedings of the 1st Workshop on Deep Learning for Recommender Systems. New York: ACM, 2016: 29-34.
- [60] TAN Y K, XU X X, LIU Y. Improved recurrent neural networks for session-based recommendations[C]//Proceedings of the 1st Workshop on Deep Learning for Recommender Systems. New York: ACM, 2016: 17-22.
- [61] LI J, REN P J, CHEN Z M, et al. Neural attentive session-based recommendation[C]//Proceedings of the 2017 ACM on Conference on Information and Knowledge Management. New York: ACM, 2017: 1419-1428.
- [62] GAO J Y, ZHANG T Z, XU C S. A unified personalized video recommendation via dynamic recurrent neural networks[C]//Proceedings of the 25th ACM International Conference on Multimedia. New York: ACM, 2017: 127-135.
- [63] RAKKAPPAN L, RAJAN V. Context-aware sequential recommendations with stacked recurrent neural networks[C]//Proceedings of the World Wide Web Conference. New York: ACM, 2019: 3172-3178.
- [64] ZHAO N, LONG Z, WANG J, et al. AGRE: a knowledge graph recommendation algorithm based on multiple paths embeddings RNN encoder[J]. Knowledge-Based Systems, 2023, 259: 110078.
- [65] LIN X, NIU S Z, WANG Y Q, et al. K-plet recurrent neural networks for sequential recommendation[C]//Proceedings of the 41st International ACM SIGIR Conference on Research & Development in Information Retrieval. New York: ACM, 2018: 1057-1060.
- [66] FAN X Y, LIU Z, LIAN J X, et al. Lighter and better: low-rank decomposed self-attention networks for next-item recommendation[C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2021: 1733-1737.
- [67] ZHANG Y H, YANG B, MAO R Z, et al. MGT: multi-Granularity Transformer leveraging multi-level relation for sequential recommendation[J]. Expert Systems with Applications, 2024, 238: 121808.
- [68] XIE J Y, CHEN Z Z. Hierarchical transformer with spatio-temporal context aggregation for next point-of-interest recommendation[J]. ACM Transactions on Information Systems, 2024, 42(2): 1-30.
- [69] ZHONG H J, MA J C, DUAN X B, et al. Deep target session interest network for click-through rate prediction[C]//Proceedings of the 2024 International Joint Conference on Neural Networks. Piscataway: IEEE, 2024: 1-8.
- [70] SUN F, LIU J, WU J, et al. BERT4Rec: sequential recommendation with bidirectional encoder representations from transformer[C]//Proceedings of the 28th ACM International Conference on Information and Knowledge Management. New York: ACM, 2019: 1441-1450.
- [71] LI Z K, CUI Z Y, WU S, et al. Fi-GNN: modeling feature interactions via graph neural networks for CTR prediction[C]//Proceedings of the 28th ACM International Conference on Information and Knowledge Management. New York: ACM, 2019: 539-548.
- [72] ZHANG H Y, PAN J W, LIU D P, et al. Deep pattern network for click-through rate prediction[C]//Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2024: 1189-1199.
- [73] ZHOU K, YU H, ZHAO W X, et al. Filter-enhanced MLP is all you need for sequential recommendation[C]//Proceedings of the ACM Web Conference 2022. New York: ACM, 2022: 2388-2399.
- [74] HOU Y P, ZHANG J J, LIN Z H, et al. Large language models are zero-shot rankers for recommender systems[C]//Advances in Information Retrieval. Cham: Springer, 2024: 364-381.
- [75] ZHAI J Q, LIAO L, LIU X, et al. Actions speak louder than words: trillion-parameter sequential transducers for generative recommendations[J]. arXiv:2402.17152, 2024.

- [76] CHEN J Y, CHI L, PENG B Y, et al. HLLM: enhancing sequential recommendations via hierarchical large language models for item and user modeling[J]. arXiv:2409.12740, 2024.
- [77] LIU J L, LIU C, ZHOU P L, et al. Is ChatGPT a good recommender? a preliminary study[J]. arXiv:2304.10149, 2023.
- [78] SUN W W, YAN L Y, MA X Y, et al. Is ChatGPT good at search? investigating large language models as re-ranking agents[J]. arXiv:2304.09542, 2023.
- [79] HE Z K, XIE Z H, JHA R, et al. Large language models as zero-shot conversational recommenders[C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. New York: ACM, 2023: 720-730.
- [80] LIU Q J, CHEN N, SAKAI T, et al. ONCE: boosting content-based recommendation with both open- and closed-source large language models[J]. arXiv:2305.06566, 2023.
- [81] ZHANG A, CHEN Y X, SHENG L H, et al. On generative agents in recommendation[J]. arXiv:2310.10108, 2023.
- [82] BAO K Q, ZHANG J Z, ZHANG Y, et al. TALLRec: an effective and efficient tuning framework to align large language model with recommendation[J]. arXiv:2305.00447, 2023.
- [83] ZHANG J J, XIE R B, HOU Y P, et al. Recommendation as instruction following: a large language model empowered recommendation approach[J]. arXiv:2305.07001, 2023.
- [84] LIN X, WANG W, LI Y, et al. A multi-facet paradigm to bridge large language model and recommendation[J]. arXiv: 2310.06491, 2023.
- [85] ZHANG Y, FENG F L, ZHANG J Z, et al. CoLLM: integrating collaborative embeddings into large language models for recommendation[J]. arXiv:2310.19488, 2023.
- [86] WANG W J, LIN X Y, FENG F L, et al. Generative recommendation: towards next-generation recommender paradigm [J]. arXiv:2304.03516, 2023.
- [87] SUN Z X, SI Z H, ZANG X X, et al. Large language models enhanced collaborative filtering[C]//Proceedings of the 33rd ACM International Conference on Information and Knowledge Management. New York: ACM, 2024: 2178-2188.
- [88] KIM S, KANG H, CHOI S, et al. Large language models meet collaborative filtering: an efficient all-round LLM-based recommender system[C]//Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York: ACM, 2024: 1395-1406.
- [89] WANG J L, LU H K, LIU Y F, et al. LLMs for user interest exploration in large-scale recommendation systems[C]//Proceedings of the 18th ACM Conference on Recommender Systems. New York: ACM, 2024: 872-877.
- [90] WANG J L, LU H K, CAVERLEE J, et al. Large language models as data augmenters for cold-start item recommendation[C]//Proceedings of the ACM Web Conference 2024. New York: ACM, 2024: 726-729.
- [91] LIU Q, WU X, ZHAO X, et al. Large language models enhanced sequential recommendation for long-tail user and item[J]. arXiv:2405.20646, 2024.
- [92] WU J D, CHANG C C, YU T, et al. CoRAL: collaborative retrieval-augmented large language models improve long-tail recommendation[C]//Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York: ACM, 2024: 3391-3401.
- [93] GAO Y F, SHENG T, XIANG Y L, et al. Chat-REC: towards interactive and explainable LLMs-augmented recommender system[J]. arXiv:2303.14524, 2023.
- [94] LEI Y X, LIAN J X, YAO J, et al. RecExplainer: aligning large language models for explaining recommendation models[C]//Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York: ACM, 2024: 1530-1541.
- [95] KONG X Y, WU J C, ZHANG A, et al. Customizing language models with instance-wise LoRA for sequential recommendation[J]. Advances in Neural Information Processing Systems, 2025: 113072-113095.
- [96] KONSTANTINA C, ALBERTO L, CJ A, et al. Large language models for user interest journeys[J]. arXiv:2305.15498, 2023.
- [97] LIN J H, SHAN R, ZHU C X, et al. ReLLa: retrieval-enhanced large language models for lifelong sequential behavior comprehension in recommendation[C]//Proceedings of the ACM Web Conference 2024. New York: ACM, 2024: 3497-3508.
- [98] XU W, XIAO J, CHEN J L. Leveraging large language models to enhance personalized recommendations in E-commerce[C]//Proceedings of the 2024 International Conference on Electrical, Communication and Computer Engineering. Piscataway: IEEE, 2025: 1-6.
- [99] LI P B, DE RIJKE M, XUE H, et al. Large language models for next point-of-interest recommendation[C]//Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2024: 1463-1472.
- [100] ZHAO W X, MU S L, HOU Y P, et al. RecBole: towards a unified, comprehensive and efficient framework for recommendation algorithms[C]//Proceedings of the 30th ACM International Conference on Information & Knowledge Management. New York: ACM, 2021: 4653-4664.
- [101] 姜书浩, 张立毅, 周娜. 个性化推荐系统中的多样性综述 [J]. 软件工程与应用, 2019, 8(3): 172-178.
- JIANG S H, ZHANG L Y, ZHOU N. A survey of diversity in personalized recommendation systems[J]. Software Engineering and Applications, 2019, 8(3): 172-178.
- [102] LI J M, ZHANG W T, WANG T, et al. GPT4Rec: a generative framework for personalized recommendation and user interests interpretation[J]. arXiv:2304.03879, 2023.
- [103] LU W S, LIAN J X, ZHANG W, et al. Aligning large language models for controllable recommendations[J]. arXiv: 2403.05063, 2024.
- [104] LI L, ZHANG Y F, CHEN L, et al. Prompt distillation for efficient LLM-based recommendation[C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. New York: ACM, 2023: 1348-1357.
- [105] ZHANG J Z, BAO K Q, WANG W J, et al. Prospect personalized recommendation on large language model-based agent platform[J]. arXiv:2402.18240, 2024.