

北京交通大学

本科毕业论文（设计）

基于深度学习的风电机组故障诊断系统设计与实现

Design and Implementation of Wind Turbine Fault
Diagnosis System Based on Deep Learning

学 院： 软件学院

专 业： 软件工程

学生姓名：

学 号：

指导教师：

北京交通大学

2024 年 6 月

学士论文版权使用授权书

本学士论文作者完全了解北京交通大学有关保留、使用学士论文的规定。特授权北京交通大学可以将学士论文的全部或部分内容编入有关数据库进行检索，提供阅览服务，并采用影印、缩印或扫描等复制手段保存、汇编以供查阅和借阅。

（保密的学位论文在解密后适用本授权说明）

学位论文作者签名：

指导教师签名：

签字日期： 2024 年 6 月 10 日

签字日期： 2024 年 6 月 10 日

学士论文诚信声明

本人声明所呈交的毕业论文（设计），题目基于深度学习的风电机组故障诊断系统设计与实现是本人在指导教师的指导下，独立进行研究工作所取得的成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

本人签名：_____ 日期：_____ 2024-6-10

中文摘要

随着新能源理念不断发展，清洁能源愈发受到瞩目。风能以其可再生、对环境友好等特性，成为需求量最高的新能源之一。然而，由于风场大多建于环境恶劣地区，工作人员驻扎产生的人力成本和故障发生后产生的维修成本非常高昂。因此，如何远程监控风电机组的运行状态，及时获取风机故障信息，从而降低维修成本成为一个重要课题。

为此，本文设计并实现了一套基于深度学习的风电机组故障诊断系统。根据需求分析结果，本系统划分为状态监测、故障诊断、健康评估三个主要模块，各模块功能如下：

（1）状态监测模块：实现对所有入网风机的运行状态监测和运行数据统计功能。统计风电机组的运行数据并在地图上标记显示，同时以图表形式展示近 24 小时内的风机运行状态，方便风场管理员及时、直观的获取到每个风机的运行状态。

（2）故障诊断模块：实现对故障风机的故障类型诊断功能。对于已发生故障的风机，系统提供对风电机组常见的六大故障类型（变桨系统故障、液压系统故障、偏航系统故障、测风系统故障、储能系统故障、变流器故障）进行诊断的功能。同时，系统提供故障处理流程追踪功能，通过设置高效的故障处理流程，跟踪已发生故障的处理进程。

（3）健康评估模块：实现对风电机组的健康程度进行量化的功能。结合风电机组的运维构型，根据健康评价体系计算风电机组各部件的健康分数，对于健康等级为“一般”和“异常”的部件或系统应及时检修，预防故障的发生。

在故障诊断模块中，本文采用压缩激励-卷积神经网络（Squeeze and Excitation-Convolutional Neural Networks, SENet-CNN），以提高故障诊断的准确率。该算法在卷积神经网络（Convolutional Neural Networks, CNN）的基础上加入压缩激励网络（Squeeze-and-Excitation Networks, SENet），实现自动调整多通道特征的训练权重，解决了由于网络训练过程中注意力分散导致的准确率低的问题。在实际数据集进行的实验表明，加入注意力机制后本文采用的 SENet-CNN 算法准确率由未加入前的 92.2%提升至 93.4%。同时，本文还将 SENet-CNN 算法同 AlexNet、VGG-16 算法进行了对比，实验结果表明 SENet-CNN 算法在准确率和训练耗时方面都明显优于其它算法。

在本系统的支持下，一方面，在故障发生前，风场管理员由状态监测和健康评估功能获取风机运行状态和部件损耗情况，及时检修问题风机，预防故障发生；另一方面，在故障发生后，维修人员由故障诊断功能确定故障类型并进行处理，提高故障维修效率。

目前，风电机组故障诊断系统已经建成并投入使用。截至目前已经接入了兰州风场、西安风场、呼和浩特风场等多个风场，入网风机达 880 个，系统运行状态良好。

关键词：风电机组；故障诊断；神经网络；注意力机制

ABSTRACT

With the continuous development of new energy concepts, clean energy is increasingly attracting attention. Wind energy has become one of the new energy sources with the highest demand due to its renewable and environmentally friendly characteristics. However, because most wind farms are built in harsh environments, the labor costs incurred by staff stationing and maintenance costs incurred after failures are very high. Therefore, how to remotely monitor the operating status of wind turbines, timely obtain fan fault information, and reduce maintenance costs has become an important issue.

Therefore, this paper designs and implements a deep learning-based fault diagnosis system for wind turbines. According to the results of demand analysis, the system is divided into three main modules: condition monitoring, fault diagnosis and health assessment. The functions of each module are as follows:

(1) Status monitoring module: realize the function of running status monitoring and running data statistics of all fans in the network. Statistical wind turbine operation data and marked on the map display, at the same time in the form of a chart to show the nearly 24 hours of fan operation status, convenient staff timely and intuitive access to the operating status of each fan.

(2) Fault diagnosis module: To diagnose the fault type of the faulty fan. For the faulty fan, the system provides diagnostic functions for six common fault types of wind turbines (variable pitch system fault, hydraulic system fault, yaw system fault, wind measurement system fault, energy storage system fault, converter fault). In addition, the system provides the troubleshooting process tracing function. You can set an efficient troubleshooting process to track the troubleshooting process that has occurred.

(3) Health assessment module: to achieve the function of quantifying the health degree of wind turbines. Based on the operation and maintenance configuration of the wind turbine, the health scores of each component of the wind turbine are calculated according to the health evaluation system. The components or systems with health grades of "general" and "abnormal" should be repaired in time to prevent the occurrence of faults.

In the fault diagnosis module, this paper adopts the attention-convolutional Neural network model (SENet-CNN, Squeeze and texture-convolutional neural Networks, SENet-CNN) to improve the accuracy of fault diagnosis. The algorithm is based on Convolutional

Neural Networks (CNN) by adding the Squeeze and Excitation mechanism (SE) to automatically adjust the training weights of multi-channel features. The problem of low accuracy caused by distraction in network training is solved. Experiments on actual data sets show that the accuracy of SE-CNN algorithm is improved from 92.2% to 93.4% of CNN after adding the attention mechanism. At the same time, this paper also compares the SE-CNN algorithm with AlexNet and VGG-16 algorithms, and the experimental results show that the SE-CNN algorithm is obviously better than other algorithms in terms of accuracy and training time.

With the support of this system, on the one hand, before the fault occurs, the wind farm manager can obtain the operating status and component loss of the fan by the status monitoring and health evaluation function, and repair the faulty fan in time to prevent the fault; on the other hand, after the fault occurs, the maintenance personnel can determine the fault type and deal with it by the fault diagnosis function, so as to improve the fault maintenance efficiency.

At present, the fault diagnosis system of wind turbine has been built and put into use. Up to now, it has been connected to Lanzhou wind farm, Xi 'an wind farm, Hohhot wind farm and other wind farms, and 880 fans have been connected to the network, and the system is running well.

KEYWORDS: Wind Turbine; Fault Diagnosis; Neural Network; Attention Mechanism

目 录

中文摘要.....	I
ABSTRACT	II
1 引言.....	1
1.1 项目背景及意义	1
1.2 研究现状分析	3
1.2.1 系统研发现状	3
1.2.2 技术研发现状	3
1.3 论文的主要工作	5
1.4 论文内容与组织结构	6
2 关键技术与理念.....	7
2.1 PHM 技术	7
2.2 MQTT 协议.....	7
2.3 Kafka 消息订阅发布系统	8
2.4 Redis 缓存机制	8
2.5 微服务架构	9
2.6 TDengine 时序数据库	9
2.7 SENet 注意力机制.....	9
2.8 本章小结	10
3 故障诊断系统需求分析.....	11
3.1 系统需求整体概述	11
3.2 系统功能性需求分析	11
3.2.1 状态监测	12
3.2.2 故障诊断	13
3.2.3 健康评估	14
3.3 系统非功能性需求分析	15
3.4 本章小结	15
4 故障诊断系统概要设计.....	16
4.1 系统整体架构设计	16
4.2 系统功能模块设计	17
4.3 系统核心流程设计	18
4.4 数据存储设计	19
4.4.1 概念模型设计	20
4.4.2 逻辑模型设计	20
4.4.3 物理模型设计	21
4.5 本章小结	26

5 故障诊断算法设计	27
5.1 数据集介绍	27
5.2 数据预处理	29
5.3 基于 CNN 的故障诊断算法设计	30
5.4 基于 SENet-CNN 的故障诊断技术	32
5.5 本章小结	34
6 故障诊断系统详细设计	35
6.1 状态监测模块设计	35
6.1.1 地图监测	36
6.1.2 风机监测	38
6.1.3 系统监测	40
6.1.4 部件监测	41
6.2 故障诊断模块设计	43
6.2.1 故障诊断	44
6.2.2 故障处理	46
6.2.3 故障分析	50
6.3 健康评估模块设计	52
6.3.1 健康状态评估	53
6.3.2 健康评估管理	55
6.4 数据统计模块设计	57
6.5 基础配置模块设计	58
6.6 本章小结	60
7 系统测试与验证	61
7.1 测试环境	61
7.2 功能性测试	61
7.3 非功能性测试	67
7.3.1 并发性测试	67
7.3.2 安全性测试	68
7.3.3 易用性测试	69
7.4 本章小结	69
8 总结与展望	70
8.1 全文总结	70
8.2 系统展望	71
参考文献	72
致 谢	74

1 引言

近年来，随着世界各国的不断发展，能源短缺以及衍生的生态环境污染问题日益凸显。与此同时，人们逐步认识到风能作为一种可再生的清洁能源在当今的能源市场中有着巨大的发展潜力。随着国家对新能源的需求量逐渐增大，我国风电产业也迅速崛起。然而，由于风机所处地理环境恶劣，故障频发，一旦发生故障所需要的维护成本高昂，因此实现对风机部件的故障检测，对风机进行状态监控，减少因风机频繁故障造成的损失便显得尤为重要。

本文为解决以上问题，设计并实现了一套风电机组故障诊断系统。系统旨在搭建一套基于深度学习的风电机组故障诊断平台，实现对风机的多角度、全方位的运行监测，有效保证风电机组故障检测的准确性和及时性。同时，根据已获取到的风电机组的运行数据对风电机组的运行状态进行监控并实时展示，设置合理的评估准则对各关键部件进行健康评估，保障风力发电机组的安全高效运行。

本章将介绍本项目意义及背景，然后介绍相关技术和系统的研发现状，分析本文需要解决的问题，最后将介绍全文的组织架构。

1.1 项目背景及意义

随着风力发电行业的崛起，监控风电系统的健康状况成为行业研究的热门问题。在实际运行场景中，风电机组的健康状态影响着整个发电系统的运作。同时，由于风机所处的自然环境大多恶劣，各部件的损坏情况时常发生，一旦出现故障，需要的维护成本可高达总费用的 35%^[1-3]。因此，为了保证风电机组可以安全高效运行，需要在风电机组出现故障时，利用已有的知识库和技术手段对风电机组的故障情况进行准确诊断并给出有效措施^[4]。

然而随着风电机组故障诊断技术在工业界更加广泛而深入的应用，目前也面临着如下的几个问题：

（1）数据体量庞大

在数据采集过程中，需要采集风电机组各部位处于运行状态时的运行数据，由此产生的数据量十分庞大。由于数据体量庞大，处理难度高，系统运算的工作压力很大，难以进行数据统计分析从而掌握风电机组的运行状态^[5]。

为了获取风电机组运行过程中的数据，需要在风力发电机传动链、轮毂、塔筒等关键部件布置传感器，即利用传感器接入的方式，采集设备的各参量，并通过 SCADA（Supervisory Control And Data Acquisition, SCADA）系统收集数据，实现数据的传输与

存储。

（2）故障特征提取难度高

风电机组产生的数据规模大、维度高，且在实际运行过程中，风电机组会受到各种不确定因素（如风速、风向等天气因素）导致受力状态改变，由此产生大量噪声和无效数据。由于风电机组监测数据的复杂度高，在进行故障特征提取时难以保证数据的有效性和完整性，从而影响故障诊断模型的精度^[6]。

（3）机组健康程度难以量化

风电机组的健康评估工作在实际工作环境中非常重要，合理的健康评估准则一方面可以帮助维修人员掌握风电机组整体的健康状态，为检修工作提供指导；另一方面可以对风电机组的关键部件进行寿命分析，提前进行部件故障排查或更换，进一步降低由于部件故障产生的维修成本。

目前，风电机组健康评估工作通常由检修人员上报部件故障或异常的形式来进行估计，由于没有统一的评价标准，各系统在发生故障时反馈的维度及数据格式多样，因此难以对风电机组的健康程度进行量化^[7]。

针对第一个问题，本项目将通过服务器集群部署和时序数据库接入来存储海量的运行数据，并将数据处理分析后的结果接入关系型数据库，以此来提高数据访问速度，同时以统计图表的形式将分析结果进行可视化，使得风场管理员可直观看到各个风机的运行状态。

针对第二个问题，本项目将设计合理的卷积神经网络，并通过和其他深度学习网络进行对比分析来进一步优化故障诊断技术，实现自动故障特征提取，提高故障诊断模型的精度。

针对第三个问题，本项目将构建一个评估准则，将风电机组各个系统的数据纳入其中，采用量化评分的方式对机组的健康程度进行准确分析并进行等级划分，通过健康分数来指导部件更换，降低维护成本。

综上所述，本项目首先通过数据大屏的方式实现风电机组状态监测，以统计图表的形式展现风电机组的实时运行状态同时在中国地图上显示风电机组的实时位置，做到直观展现风电机组的运行状况；然后基于深度学习技术实现风电机组故障诊断，优化故障处理流程，做到在故障发生后能够有效处理故障；最后设置一套合理的健康评估体系，对风电机组的健康状态进行量化并进行等级划分，对于得分低或者健康等级为“一般”或者“异常”的风机及时进行检修，做到掌握风电机组运行状态，在故障发生前能够有效预判，降低故障损失。

1.2 研究现状分析

随着风力发电技术的不断发展，风电机组的需求量在不断提高。然而，由于风场所处的地理环境普遍比较恶劣，部件故障及人力维护的成本较高，远程监控风电机组的运行状态、及时发现运行故障并进行妥善维修成为工业界普遍研究的热点问题。

1.2.1 系统研发现状

如今越来越多的风力发电公司意识到风电机组故障检测的重要性，通过搭建在线状态监测系统掌握风电机组的健康状态，从而降低维护成本已成为业内共识。

福建国电风力发电有限公司搭建了风电机组在线状态监测与数据分析系统，包含叶片缺陷检测、塔筒监测、无线自组网以及数据分析平台四部分，实现在线实时监测风电机组运行^[8]，该系统通过无人机拍照实现数据采集，存储数据量较大，且在确认故障类型后并未通过系统实现故障处理流程，故障处理仍在线下监管，智能化程度较低。中广核风电有限公司开发了智能风电机组叶片故障监测系统，系统包含故障查询、检测、管理以及统计分析功能，对故障出现的处理流程清晰，但功能单一，无法对风电机组的状态进行监控，对风电机组的整体健康状态也难以把握^[9]。国网冀北电力有限公司设计了基于嵌入式技术的风电场监控系统，实现风电机组数据智能采集、运行状态的监控以及对风电机组的故障诊断功能，但系统响应速度较慢，平均在 10s 左右，处理数据的能力较差^[10]。

结合以上系统的研发现状，本系统将充分考虑风电机组在实际环境中的运行需要，对风电机组的运行状态进行监控并实现可视化；对故障情况进行准确检测并优化处理流程，实现线上工单监控；对风电机组的整体以及关键部件进行寿命分析和健康度量化，使得相关人员充分掌握风电机组的健康状况；同时，本系统还将对故障情况进行分析统计，优化数据存储结构，提高数据处理能力，搭建高性能、多功能的风电机组故障诊断系统。

1.2.2 技术研发现状

目前，国内外众多高校、研究院以及能源电力公司均针对风电机组故障诊断技术展开了深入研究。目前关于风电机组故障诊断的方法主要分为三大类：基于物理模型的建模仿真技术、基于信号特征的数字信号处理技术以及基于数据驱动的机器学习技术^[11]。

基于物理模型的建模仿真技术主要是通过模拟风电机组的物理过程和工作状态来诊断和分析可能出现的故障。来自华北电力大学的伍云浩等人建立数字孪生模型，通过

利用仿真与监测数据的残差值进行故障诊断^[12]。然而，这种基于物理模型的建模仿真技术往往需要大量的实验数据和理论支持，计算复杂度高且对领域知识依赖性强，对非专业人士来说较为困难。

基于信号特征的数字信号处理技术通过数字信号分析来提取故障特征。对于单一故障类型的信号可通过降噪和滤波处理后增强所需的故障特征，对于复合故障类型的耦合信号可通过经验模态分解等信号分解方法提取单个故障特征^[13]。李鹏飞等人结合 EMD（Empirical Mode Decomposition, EMD）和 Hilbert 谱提出将采集到的轴承振动信号进行小波分解，形成可有效应用于故障诊断过程中的局部 Hilbert 边际谱，经证明，该方法提取轴承的故障振动信号的性能明显优于传统方法^[14]。王普等人提出基于局域均值分解和多尺度熵能量的滚动轴承复合故障特征提取方法。试验结果显示该方法比单一方法提高了故障诊断率^[15]。总的来说，基于信号特征的数字信号处理技术的稳定性高、可靠性强，适用于各种复杂系统的故障检测和诊断。然而，数字信号处理技术对于复杂故障模式的诊断通常需要大量的标定数据，且对于有些故障特征可能难以通过信号处理技术准确提取，对算法参数调节和优化的要求更高。

另外还有基于数据驱动的机器学习技术，该技术目前可分为两大类，分别是浅层学习和深度学习。

浅层学习指的是基于传统机器学习方法构建的模型，通常包括少量的层（例如一到两层）和相对简单的特征表示。这些方法包括决策树、支持向量机、逻辑回归、朴素贝叶斯等。Li 等人提出了一种基于反向传播神经网络（Back Propagation Neural Network, BPNN）的滚动轴承故障诊断的多尺度局部特征学习方法，利用 BPNN 从不同尺度的信号中局部学习不同的特征，从而提高故障诊断的准确性^[16]。Xu 等人提出了一种基于交叉变异混沌粒子群优化支持向量机的混合域故障诊断断技术，利用改进的混沌粒子群优化支持向量机，提高故障分类诊断的效率^[17]。孙海蓉等人针对数据集不平衡，故障数据偏少的问题，采用过采样技术（Synthetic Minority Oversampling Technique, SMOTE）算法，合成故障数据样本，同时结合随机森林算法进行风电机组故障诊断^[18]。Carroll J 等人分别使用支持向量机、逻辑回归和人工神经网络三种机器学习算法对风力发电机组齿轮箱故障及剩余使用寿命进行预测^[19]。然而，浅层学习由于网络结构较为简单，容易产生过拟合的现象，且浅层学习需要人为提取特征，在处理大规模数据和复杂特征的任务时并不具有优势。

深度学习在处理大规模数据时通常效果更好，且深度学习可自动学习数据特征，因此深度学习在风电机组故障诊断中也已有了广泛的应用。颜毅斌等人改进了原始的生成对抗网络（Generative Adversarial Network, GAN），构建深度卷积生成对抗网络，改进后的模型在风电机组主轴承的故障诊断过程中表现出较高的准确度^[20]。He 等人提出了 NSGAIL-CNN 算法来实现网络结构的自适应搜索，提高了故障诊断网络结构模型的构建

速度，从而提高了诊断的准确性和效率^[21]。Ye 等人提出使用自适应核稀疏网络，从一维振动信号中提取多尺度故障特征，从而显著提高分类器的故障诊断性能，与浅层神经网络与其他典型的深度神经网络相比，该网络具有更好的识别性能^[22]。Rezamand M 等人提出了一种单输入广义回归神经网络集成算法、主成分分析和基于小波的概率密度方法的混合故障检测系统。该方法提出的故障检测策略可准确检测早期叶片故障，并提高系统可用性^[23]。

基于数据驱动的机器学习技术与前两种技术相比能够更好的捕捉非线性关系，对大规模数据的处理和分析具有优势，可以实现自动化的模型训练和优化过程，减少了人工干预和专业知识的依赖，提高了故障检测的效率。

针对现有的故障诊断技术存在的准确率低、故障特征丢失等问题，本文提出一种基于深度学习的故障诊断技术，在卷积神经网络的基础上加入注意力机制，实现自动调整多通道输入权重，充分学习各故障特征，解决由于故障数据维度多而导致的网络注意力分散、准确率低的问题。

1.3 论文的主要工作

本文立足于风电机组的实际运行场景，设计并实现一套风电机组故障诊断系统。

首先调研了市场上同类型系统的开发现状，确定了本系统的业务流程，同时调研了目前主流的故障诊断技术，明确了本项目使用的故障诊断技术需要解决的问题。

然后对系统进行了功能性和非功能性需求分析。在需求分析中，明确了状态监测、故障诊断、健康评估三大功能性需求和系统并发性、安全性、易用性等非功能性需求，并给出具体的量化指标。

接着依据需求分析的结果对系统进行了概要设计，主要包括系统整体架构设计、系统功能模块设计、系统核心流程设计和数据存储设计。使用 PowerDesigner 工具构建概念模型、逻辑模型和物理模型，明确系统中数据的存储结构。

然后介绍设计系统所使用的算法，本文选择在卷积神经网络的基础上加入压缩激励网络，以此来实现自动故障特征提取，充分学习故障特征，同时，压缩激励网络可以调整多通道的输入权重，使得网络训练过程中注意力集中在权重较高的通道。本文详细介绍了在搭建本算法模型中的实验流程和与其他网络的对比结果，以验证本模型在解决故障诊断问题上的有效性。

最后进行系统的详细设计，通过类图和时序图说明状态监测模块、故障诊断模块、健康评估模块实现的逻辑，展示各模块的实现效果，并对系统进行功能性和非功能性的系统测试验收。

1.4 论文内容与组织结构

本文研究了基于深度学习的风电机组故障诊断系统的需求分析、技术选型、概要设计、详细设计、算法设计、测试验收和全文的工作总结及未来展望。全文共分为八章，其结构为：

本章为引言，首先阐述了风电机组故障诊断项目的背景及意义，然后分别进行了相关技术和系统的调研分析，最后介绍了本文的主要工作，并对论文内容和论文组织结构做了简要的叙述。

第二章是关键技术理念，主要介绍了故障预测与健康管理技术、MQTT 协议、Kafka 消息订阅发布系统、Redis 缓存机制、微服务架构、TDengine 数据库以及压缩激励网络的工作原理。

第三章是风电机组故障诊断系统需求分析，先对系统的整体需求进行简要叙述，然后从系统的功能性需求和非功能性需求两方面入手进行分析。

第四章是风电机组故障诊断系统概要设计，首先介绍了系统的整体架构设计，并根据前文的需求分析将系统功能模块分为状态监测、故障诊断和健康评估三大模块。然后介绍了系统的核心流程，最后通过概念模型、逻辑模型和物理模型对系统的数据存储进行设计。

第五章是风电机组故障诊断系统的算法设计，详细介绍了网络的搭建过程与加入注意力机制的流程。

第六章是风电机组故障诊断系统的详细设计，对状态监测模块、故障诊断模块和健康评估模块进行了详细设计与具体实现。

第七章是风电机组故障诊断系统的功能性测试和非功能性测试，并进行验收。具体将运用软件测试中的相关理论和方法进行测试，并进行系统缺陷与不足的修复。

第八章是全文的总结与对未来研究的展望，对该项目的研究成果进行归纳与总结，并对该项目未来的工作方向与优化方向进行叙述。

2 关键技术与理念

本章将着重于叙述在风电机组故障诊断系统中主要运用的关键技术及理念，以及系统实现所需要的开源框架与工具，为后续系统的具体设计打好基础。

2.1 PHM 技术

故障预测与健康管理（Prognostic and Health Management, PHM）技术是一种广泛应用于工业系统维护中的关键技术。它是一种预测性维护方法，通过预测设备状态，按需对设备进行维护，相比于事后维护，它所需要的维护成本大大降低^[24]。

PHM 技术主要有三大功能：智能化诊断、预测性维护以及辅助式维修。它的优点在于可以通过各种技术手段评估部件的健康程度及寿命价值，制定合理且有效的解决方案。在发生故障前及早进行维修或更换，尽可能大的减少由于故障发生后产生的各类人力和物力成本，在故障发生后及时对故障类型进行诊断，从而达到辅助维修，优化维修流程的效果。

本系统将使用 PHM 技术，覆盖风电设备全生命周期的故障预测和主动维修，建立“预警-推送-检修-反馈-优化”的处理闭环，提升运维水平，实现风电机场的能效优化和集成管理，支撑规模化发展。

2.2 MQTT 协议

MQTT^[25]（Message Queuing Telemetry Transport, MQTT）协议是 IBM 于 1999 年发布的标准化发布/订阅推送协议。MQTT 可在长网络延迟和低带宽网络条件下准确发送数据。在网络环境差，约束条件较多的实际环境中，使用 MQTT 协议具有易部署、轻量级等优点，是很理想的通信协议^[26]。

当有大量的运行数据需存储在服务器端时，设备会向服务器频繁发出请求，这很有可能导致 MQTT 服务器宕机，为了提高服务器的响应速度和处理能力，往往通过部署服务器集群的形式来实现 MQTT 服务器的负载均衡^[27]。

在本项目中，风机设备上采集来的数据将通过风电场环网传回地面中心，数据将传输至 MQTT 服务器，服务器通过集群的方式来处理大量的数据接入。获取到数据后，将进行数据分析并存储至数据库，由此提高系统的响应速度。

2.3 Kafka 消息订阅发布系统

Kafka 是一种高吞吐量的消息引擎系统，它可以通过集群的方式存储消息记录，实现消息队列持久化，消息订阅者通过访问消息队列获取系统请求，提高数据交互的效率，在大型系统中，使用消息队列技术可以大大简化消息传递流程，对比图如图 2-1 所示，可以看到，接入消息传递系统后数据交互流程变得更加简洁。




图 2-1 使用消息传递系统前后数据交互方式

本系统使用 Kafka 系统进行数据传输。具体来说，Kafka 客户端会向服务器发送身份验证请求，该请求包含客户端的用户名和密码。服务器将使用预共享密钥来验证这些凭据，并向客户端发送加密令牌，该令牌用于在后续的通信中对消息进行加密和解密。

在安全通道建立之后，Kafka 客户端可以使用 SSL/TLS 等方式进行数据传输加密，以确保消息的机密性、完整性和可靠性。同时，Kafka 还提供了访问控制列表等功能，以进一步增强数据传输的安全性。

因此，Kafka 能够在身份验证、消息传输和访问控制等方面提供全面的安全保障，从而保证双方的数据传输安全。

2.4 Redis 缓存机制

Redis 是一种高性能的非关系型数据库，它可以解决传统关系型数据库在处理大量数据时的性能瓶颈问题，提高系统的响应速度和灵活性。Redis 具有以下优点：

（1）读写速度快：与传统数据库通过访问磁盘来读取数据不同，Redis 通过访问内存来获取数据，这就大大提升了读写速度。经统计，Redis 在 1s 内可进行十万次以上读操作。

（2）存储数据类型多：Redis 支持多种数据类型存储，包括字符串（String）、集合（Set）、有序集合（ZSet）等，可以满足在不同场景下的数据存储要求。

（3）支持数据持久化：虽然 Redis 的数据读写操作在内存上进行，但是可以将数据

存储在磁盘上，实现数据持久化。当系统出现无法预判的崩溃的情况时，可以通过 Redis 进行数据恢复，保证数据的完整性。

（4）支持集群操作：Redis 的集群操作主要包括两部分：集群部署和主从同步。Redis 可根据一个主实例创建多个从实例，当主实例出现问题时，从实例可接管数据。同时，也可以通过 Redis 实例集群部署来降低数据访问压力。

2.5 微服务架构

微服务架构的核心思想是根据系统的业务逻辑，将系统拆分为若干个服务，每个服务都可以独立运行。微服务架构有以下特点：

（1）服务治理：每个微服务都需要进行服务注册，注册成功后便可在服务注册中心获取到服务信息。

（2）服务调用：通过接口形式调用成功注册的微服务功能。

（3）服务网关：网关为所有的请求提供了统一的入口，是用户请求正式进入微服务之前的拦截层，主要包含请求过滤与转发、服务熔断、路由判断等功能。方便对服务请求和响应做统一管理。

2.6 TDengine 时序数据库

风电机组的运行数据是具备时间戳和明显结构化特征的时序数据，且数据量非常大。TDengine 数据库可以高效写入、查询数十亿数据源中的数据。同时，TDengine 数据库还可以和其他数据库如关系型数据库进行协同工作，优化数据存储结构。

在进行数据接入时，系统将从 MQTT 服务器获取实时数据，原始数据写入时序数据库 TDengine，关系数据库 MySQL 用于存储原始数据分析结果数据、业务系统数据等相对少量的数据，为系统应用提供数据支持。服务采用集群部署的模式，避免单点故障导致整个数据模块服务中断的情况发生。

2.7 SENet 注意力机制

SENet（Squeeze-and-Excitation Networks，SENet）全称为压缩激励网络，是一种通道注意力机制，它可以充分利用通道之间的关系，更为全面的学习数据特征。注意力机制是指对输入的多特征数据赋予不同的权重，在模型学习的过程中对重要特征进行关键学习。SENet 可以自动学习特征的重要程度，减少网络对无关特征的学习，将注意力集中于权重较高的数据中，提高诊断模型的准确率。

在实际应用过程中，SENet 往往是通过 SE 模块和其他网络（如 ResNet、AlexNet 等卷积神经网络）相结合的方式来实现，由于 SE 模块的计算更为轻量级且结构简单，因此可广泛结合其他网络，从而提高网络性能。

SE 模块的运行机制主要包括三个步骤，工作原理如图 2-2 所示。

（1）**Squeeze**：根据空间维度进行特征压缩

首先通过全局平均池化操作将每个通道的数据压缩成一个具备全局感受野的平均值，这样可以屏蔽通道内的分布信息，更好的学习通道之间的相关性。

（2）**Excitation**：生成每个数据特征的训练权重

Excitation 操作主要是用来度量通道间的相关性，提取数据特征。经过压缩后的特征向量需经过一个全连接层和一个 ReLU 激活函数，再通过一个全连接层和一个 Sigmoid 激活函数，经过如上操作后，每个通道的权重都在 0-1 范围内，这个权重向量的值可以视为每个通道的重要程度。

（3）**Reweight**：根据参数权重在原始特征维度上进行重新标定

最后，将每个通道的权重通过与对应通道参数值相乘的形式加入到原始数据矩阵中，实现对输入数据的注意力调整。




图 2-2 SE 模块的运行机制

2.8 本章小结

本章主要介绍了本系统开发过程中涉及到的理论基础和技术基础，包括系统核心理念 PHM 技术、数据交互过程中使用到的 MQTT 协议和 Kafka 消息传递系统、用于提高系统响应速度的 Redis 缓存机制、存储海量时序数据的 TDengine 数据库，最后介绍了用于自动提取故障特征的注意力机制。

3 故障诊断系统需求分析

本章将对风电机组故障诊断系统进行需求分析，首先对整个系统进行需求的整体概述，接着从功能性需求和非功能性需求两个角度对故障诊断系统的需求进行详细分析。

3.1 系统需求整体概述

当前风电领域处于发展热潮，但是国内风电由于缺乏对其的整体状态监控与有效运维管理，在应用过程中逐步暴露出不足，过高的运维成本直接导致上网电价的居高不下，影响了风电系统的推广速度。设备运维成本高昂是阻碍风电系统发展的最大难关，对于海上风电来说，后期运营维护费用占到总成本的一半以上。目前国内风电运维仍然以传统运维方式为主，每个风场都派驻大量维保人员，由此带来大量的人力成本和维保成本。因此亟需通过技术手段，实现风机系统的远程监控与运维保障。

针对当前风电系统的发展痛点，可以分析出系统搭建的最终目标为通过线上系统监控的形式，掌握风电机组的运行状态，结合健康评估方法，提前制定维保策略，当风机出现故障时可准确判断故障类型并结合系统知识库进行故障处理，优化故障处理流程，提高故障维修效率。

通过分析，本系统的整体需求可分为功能型需求和非功能性需求。其中系统的主要功能性需求包括三部分，分别是状态监测、故障诊断以及健康评估，其需求如下：

（1）状态监测：根据风电机组的运行数据，从不同的统计维度，对所有入网的风机进行可视化，可视化的方式包括统计图表展示和地图位置展示，方便风场管理员能够清晰准确的监控到当前入网风机的运行状况

（2）故障诊断：根据深度学习算法模型对部件的故障情况进行诊断，将诊断结果以列表形式进行展示；同时设置合理且严谨的故障处理流程，方便维修人员及时获取维修工单、风场管理员能够线上跟踪故障处理流程。

（3）健康评估：根据制定的健康评估准则，结合专家判断，划分故障部件的故障等级以及严重程度，从而评估风电机组的整体健康状态以及关键部件的剩余寿命，使得维修人员对风电机组的健康状况进行准确预估。

3.2 系统功能性需求分析

本节将通过用例图，对状态监测、故障诊断以及健康评估这三大系统的功能性需求进行分析。

3.2.1 状态监测

状态监测主要是根据风电机组的运行数据进行统计分析并进行可视化展示。系统将根据风电机组的运行数据，从不同的统计维度，对所有入网风机进行可视化，方便管理员清晰准确的监控到当前入网风机的运行状况。

状态监测功能主要分为四个子功能：地图监测、风机监测、系统监测以及部件监测。需求用例图如图 3-1 所示。

（1）地图监测

在地图监测功能中，系统将展示所有入网的风电机组实时运行状态、实时位置在中国地图上，支持不同区域入网机组实时穿透展示，通过风场图标形式可区分出风电机组数据传输装置是否在线和移动状态，支持风机索引聚焦展示。

（2）风电机组监测

在风电机组监测功能中，系统将展示风电机组的基本信息、关键参数的状态等信息，并提供针对机场、机型、机号等规则的筛选功能。

（3）系统监测

在系统监测功能中，系统将展示风电机组各个子系统关键单元的状态以及资产目录等信息，并提供关键单元的二维图展示功能。

（4）部件监测

在部件监测功能中，系统将展示机组各个子部件关键的状态数据以及故障数据，并实现 3D 模型图网页嵌套。




图 3-1 状态监测模块用例图

3.2.2 故障诊断

故障诊断是本系统的核心功能，结合故障数据和算法模型对故障类型进行判断并通过可视化前端界面对机组故障类型数据进行分析、对故障处理进度进行追踪。需求用例图如图 3-2 所示。

本功能主要包括故障诊断、故障处理和故障分析三个子功能，分别介绍如下：

（1）故障诊断

系统可根据实时检测到的风电机组故障数据，调用已训练好的深度学习模型，快速准确的对机组故障进行判断并及时给出预警。故障信息将回传至前端页面以供维修人员进行查看，同时，预警期间采集的状态参数以曲线形式展示，从故障机型、故障零件、故障位置、故障原因等多个角度进行分析，形成机组故障履历库。

（2）故障处理

当故障发生时，系统需要提供完善的故障处理流程，包含故障处理单、处置方案库以及故障词条管理。在故障发生后，系统将自动派发检修工单，且支持自主设置检修流程以方便管理。系统还将提供处置方案知识库、故障词条库管理等功能，以供检修人员参考。

（3）故障分析

故障分析主要指根据故障记录数据库中的数据，结合用户选择的筛选条件（如重要程度、处理进度、故障类型等维度）进行统计分析，并以统计图或故障分析报告的形式展现统计结果。




图 3-2 故障诊断模块用例图

3.2.3 健康评估

健康评估功能也是风电机组故障诊断系统的核心功能之一，系统通过建立合理的健康评估体系，对风电机组的整体健康状态进行量化，方便管理员及时掌握风电机组的健康状况，预防故障的发生，用例图见图 3-3。

健康评估功能主要分为两个子功能，分别为健康状态监测、评估报告管理以及管理健康评估模型。

（1）健康状态监测

在健康状态监测功能中，系统可根据人为设置的健康评估准则，通过对风电机组在处于运行状态时产生的故障类型和严重程度进行合理评估，量化风电机组的整体健康状态，得出健康分数。同时，在进行整体健康评分时也应应对关键部件的健康状态及使用寿命进行合理评估，使得管理员充分掌握风机的运行情况，预防故障发生。

（2）评估报告管理

有数据权限的用户可查看并生成指定机组的评估报告信息，用户可以在线查看风电机组的健康报告，包括健康得分、故障部位、健康等级、风电机组的机型、机号等信息，同时还可对评估报告进行下载操作，以供用户在本地进行查看。

（3）健康评估模型管理

为了保证健康分数的合理性，管理员可添加多个健康评估模型，在进行机组健康评分时，选用合理的模型进行量化，有对应权限的用户可以对评估指标及健康等级进行管理。




图 3-3 健康评估功能用例图

3.3 系统非功能性需求分析

本小节将以系统中实际的业务流程和功能性需求目标为依托，对系统的非功能性需求进行详细阐述，如表 3-1 所示。本系统的非功能性需求主要分为三个方面，分别为并发性、安全性和易用性。并发性是指系统需要具备能够承载大量用户同时访问的能力，量化指标为系统响应时间、访问成功率以及吞吐量；安全性是指系统需要具备一定的隐私保护机制和抵抗外来攻击的能力，这里提出的量化指标为隐私保护以及权限控制；易用性是指系统需要尽可能做到美观、简洁，以提升用户的使用体验，易用性可以通过易操作性、易学习性、是否有用户错误提示、界面是否美观来进行衡量。

表 3-1 系统非功能性需求分析

需求点	量化指标	说明
并发性	系统响应时间	并发数在 1000 以内时，不低于 100ms
		并发数在 2000 以内时，不低于 1s
	访问成功率	并发数在 3000 以内时，不低于 5s
		100%
安全性	吞吐量	并发数在 100 及以上时，不低于 50/sec
	隐私保护	对于用户信息、故障信息等重要信息需具备一定的隐私保护机制
	权限控制	不同权限的用户不可越权操作
易用性	易操作性	界面简单易操作
	易学习性	对初次使用的用户提供引导
	用户错误提示	对用户的错误操作进行提示与纠正
	用户界面美观	界面设计合理美观

3.4 本章小结

本章首先对风电机组故障诊断系统进行了整体概述，划分三大系统主要模块，分别为：状态监测、故障诊断以及健康评估，然后确定系统的非功能性需求，并给出了细化指标，保证系统能够顺利开发与应用。

4 故障诊断系统概要设计

在前文对风电机组故障诊断系统进行需求分析的基础上，本章首先将对系统的整体架构进行设计。其次根据系统架构和前文的需求分析结果，通过划分为状态监测、故障诊断和健康评估三大模块，进一步细化系统的功能模块。然后描绘系统的核心流程。最后使用概念、逻辑和物理模型对系统的具体数据存储结构和字段进行设计。

4.1 系统整体架构设计




图 4-1 系统整体架构图

风电机组故障诊断系统的整体架构设计如图 4-1 所示。结合前文需求分析的结果，可以将系统的架构划分为访问层、应用层、支撑层、数据层和设施层五大层。

访问层是系统的使用人员，本系统的使用对象主要有两类人群：维修人员和风场管理员。维修人员可通过本系统掌握风电机组的故障情况，并使用系统提供的知识库进行故障处理，维修流程也可通过系统进行追踪查看；风场管理员可通过本系统掌握风电机组的运行状态，进行风机管理。

应用层是系统的核心业务部分。在风机运行时，系统管理员可以在网页端监测风机的运行状态，在故障发生时，系统会根据故障数据判断故障类型，维修人员可通过关联处置方案库的形式进行故障处理，在故障发生后，系统会根据故障类型/故障部位进行故障统计分析，同时根据系统设定的健康评估准则自动生成健康评估报告，以供相关人员掌握风电机组的健康状态，及时检查或维修机组部件，预防故障的发生。

支撑层是系统的底层核心支撑部分。它围绕数据处理和应用支撑的需求，提供统一的用户管理、权限管理；提供数据的采集、处理、管理和服务等功能；满足项目对数据应用和处理方面的技术需求，支撑层的工具大多采用一些现有的或者开源的产品进行实施，保证系统的成熟性和稳定性。

数据层是系统的数据来源部分。风机设备上采集来的数据将通过风电场环网传回至地面中心，数据传输至 MQTT 服务器，服务器通过集群的方式来处理大量的数据接入，在获取到实时数据后，原始数据将存入时序数据库，而数据分析后的结果和用户数据将存入关系型数据库，以提高系统的响应速度和灵活性。

设施层是支撑应用运行的基础设施，包括计算资源、存储资源、安全设备等等，为本项目的应用提供运行环境。

4.2 系统功能模块设计

根据上一章系统功能性需求分析的结果，再结合上一小节中系统整体架构设计，综合分析后，将系统功能模块设计分为状态监测、故障诊断、健康评估三大部分，另外为了使得整个系统更加完整，还加入了数据统计和基础配置两个辅助功能，功能模块结构图如图 4-2 所示。下面是对五个功能模块的详细分析和说明。

（1）状态监测模块

状态监测模块的主要功能是通过数据可视化将数据分析结果直观展现给管理人员，辅助其掌握对入网风机的运行状态。在该模块中，入网风电机组的实时运行状态和实时位置将反映在地图中，同时系统会提供故障统计、报警分析等统计结果，以供管理人员参考。同时，除了地图监测外，本模块还将提供风机监测、系统监测以及部件监测功能，各功能将从不同的维度出发提供机组运行的详细信息。

（2）故障诊断模块

故障诊断模块是本系统的核心功能，根据采集到的风机故障数据调用深度学习算法确定故障类型，辅助检修人员进行维修。在故障发生后，维修人员可根据系统提供的处置方案库和已发生的故障进行关联，同时系统将派发工单以此来追踪故障维修进度，维修完成后，系统将更新处置方案库，在下次故障发生时，通过参考处置方案库中的成功方法提高故障处理的成功率。最后，在故障期间采集的状态参数也将以曲线形式展示，

从故障机型、故障零件、故障位置、故障原因等多个维度进行分析，方便维修人员掌握更为全面、直观的故障信息，更好的理解故障产生原因。

（3）健康评估模块

健康评估模块的主要功能是根据系统设置的评价准则对风电机组整体以及关键部件的健康程度进行量化。在健康评估的过程中，需要根据风电机组的整体结构图，由下往上依次对各个部件产生的故障进行健康等级判定，并根据评估体系中的计算方法最终得出整体的健康分数。根据量化出的健康分数，维修人员可据此对风电机组的健康状况进行准确预估，并对分数较低的部件进行检修，从而大大降低维修成本。

（4）数据统计模块

数据统计模块的主要功能是对机组运行过程中发生的故障进行多维度统计，定制化统计规则并支持统计结果报送。

（5）基础配置模块

基础配置模块的主要功能是对入网风场的基本信息进行管理，比如部件字典、机种机型等，同时管理员可通过此功能对故障处理流程进行审批，比如转办、挂起或者业务。




图 4-2 系统功能模块结构图

4.3 系统核心流程设计

用户登录系统后，根据系统的功能模块划分，下一步系统的核心流程可分为状态监测、故障诊断和故障统计三种，如图 4-3 所示。

第一个流程是状态监测，前端页面将展示所有入网风电机组的实时运行状态，用户

可查看机组基本信息、状态数据、故障数据等。

第二个流程是故障诊断，这也是系统的核心路径。维修人员可根据系统提供的算法模型进行故障诊断确认故障类型。在综合专家判断和调用算法模型得出的结果后，若已知故障如何解决，可直接进行处置报送，若未知故障如何解决，则可查找系统中提供的处置方案库，通过关联处置方案库中的解决方法进行处置报送。在通过审核后，可直接进行故障维修，反之则需要重新选择故障处理方法。对于成功解决的故障且未被记录的处理方法，需对处置方案库进行更新，以供他人参考。

第三个流程是健康评估。在这个流程中需要获取待评估机组的故障信息，比如故障部件、严重程度，维修成本等，然后根据系统设置的健康评估准则对其进行健康度量化。




图 4-3 系统核心流程图

4.4 数据存储设计

本节使用概念、逻辑和物理模型对本系统的数据存储设计进行叙述，模型的绘制使用 PowerDesigner 建模绘制软件。最终在物理模型的设计基础上，同时结合风电机组故障诊断的实际情况，搭建了数据存储结构。

4.4.1 概念模型设计

在设计概念模型时，需要梳理出系统所涉及到的实体和实体间关系，涉及到的实体有 10 个，分别为风电机组、风场、机组类型、风电机组运行状态、故障记录、诊断记录、工单、处置方案库、用户以及用户角色。一个风场可以配备多个风电机组，每个风电机组属于不同的机组类型。在风电机组发生故障后会在故障记录表中进行记录，用户通过故障诊断算法根据记录的故障信息生成诊断记录，得到诊断结果后与处置方案库进行关联进行故障处理，同时派发工单对故障进行追踪。同时，用户共分为两类角色，分别是维修人员和风场管理人员，两者具有不同的系统操作权限。

使用 PowerDesigner 绘制了概念模型，如图 4-4 所示为绘制的系统概念模型。




图 4-4 数据存储概念模型示意图

4.4.2 逻辑模型设计

在概念模型的基础上，继续完善系统内实体和实体之间的关系，并给实体增添字段属性。风电机组表记录了风电机组的基本信息，包括所属风场、机组类型等，每个风电机组都有一张运行状态表与之对应，记录风电机组当前是否处于故障状态、是否正常运行

行等信息。当风机产生故障时会在机组的故障记录表中插入数据，记录产生的故障信息，包括故障描述、故障图片等，同时作为故障诊断的依据，在诊断记录中会记录故障信息及诊断处理结果、诊断报告存放的位置等。在故障诊断完成后，需根据系统提供的处置方案库对产生的故障和拟定的解决方案形成关联，搭建诊断-方案关联表。在进行故障处理时，发起的维修人员需要派发工单，来记录故障处理流程，以供审批人员进行审核。

逻辑模型示意图如图 4-5 所示。




图 4-5 数据存储逻辑模型示意图

4.4.3 物理模型设计

使用前一小节建立的逻辑模型，PowerDesigner 可以自动生成对应的物理模型，物理模型示意图如图 4-6 所示。

与逻辑模型不同，物理模型是对真实数据库的描述，在物理模型中，将针对每一张

表给出详细设计，包括实体间关系、表与表属性之间的联系以及字段属性等。本系统核心业务主要涉及的总共有 12 张表，涵盖了风电机组的状态监测、故障诊断、故障处理的整体流程。




图 4-6 数据存储物理模型示意图

表 4-1 是风场表的结构。该表用于存放入网风场的详细信息，包括风场编号、风场名称、当前风场中故障风机的数量以及风场的在线状态。

表 4-2 是风电机组表的结构。该表用于存储风电机组的基本信息，包括其所属的风场，机组的类型以及健康得分情况等等。

表 4-3 是机组类型表。该表用于存储风电机组的不同类型，风电机组的类型分为 WT 1500-D82、WT 1500-D88、WT 1650-D77、WT 1650-D82、WT 1650-D88、WT 1650-D93、WT 2000-D103、WT 2000-D110、WT 2500-D103、WT 2500-D110、WT 5000-D128、3.0M 122、3.2M 114、3.4M 104、MM82、MM92、MM100 共 17 种型号。

表 4-1 wind_field 表设计

序号	字段名	类型	属性	描述
1	field_id	int	PRIMARY KEY	风场编号
2	field_name	varchar(10)	-	风场名称
3	fault_number	int	-	故障风机数量
4	online_state	int	-	风场在线状态 (0: 不在线/1: 在线)

表 4-2 wind_turbine 表设计

序号	字段名	类型	属性	描述
1	turbine_id	int	PRIMARY KEY	机组编号
2	turbine_type	int	FOREIGN KEY	机组类型
3	field_id	int	FOREIGN KEY	风场编号
4	turbine_name	varchar(10)	-	机组名称
5	health_score	float	-	健康得分

表 4-3 turbine_type 表设计

序号	字段名	类型	属性	描述
1	turbine_type	int	PRIMARY KEY	机组类型编号
2	type_name	varchar(50)	-	机组类型全称
3	turbine_code	varchar(10)	-	机组类型编码 (WT 1500-D82、3.0M 122、MM82 等)

表 4-4 是风电机组运行状态表。该表用于存储风电机组在运行时是否产生故障以及产生的故障次数。

表 4-5 是故障记录表。该表用于记录风电机组产生的故障信息，在发生故障时，故障记录表将存放对应的故障信息，为故障诊断提供依据。

表 4-6 是诊断记录表。该表用于记录诊断风电机组故障过程的信息，比如诊断人工号、诊断时间、诊断结果、诊断报告存放的路径、对应的故障以及风电机组相关信息等。

表 4-4 running_state 表设计

序号	字段名	类型	属性	描述
1	state_id	int	PRIMARY KEY	状态表编号
2	turbine_id	int	FOREIGN KEY	机组编号

续表 4-4 running_state 表设计

3	fault_state	int	-	故障状态
4	fault_number	int	-	故障次数
5	last_fault	datetime	-	上次故障时间
6	record_time	datetime	-	记录时间

表 4-5 fault_record 表设计

序号	字段名	类型	属性	描述
1	fault_id	int	PRIMARY KEY	故障编号
2	turbine_id	int	FOREIGN KEY	机组编号
3	fault_description	varchar(255)	-	故障描述
4	fault_image	long binary	-	故障图片
5	process_state	int	-	处理状态

表 4-6 diagnostic_record 表设计

表名: diagnostic_record				
序号	字段名	类型	属性	描述
1	diagnostic_id	int	PRIMARY KEY	诊断编号
2	user_id	int	FOREIGN KEY	用户工号
3	fault_id	int	FOREIGN KEY	故障编号
4	fault_field_name	varchar(10)	-	故障风场名称
5	fault_turbine_id	int	-	故障风机编号
6	diagnostic_result	varchar(255)	-	故障类型
7	process_state	int	-	处理进程 (0: 未处理/1: 处理中 /2: 处理完成)
8	report_url	varchar(255)	-	报告路径
9	diagnostic_time	datetime	-	诊断时间

表 4-7 是处置方案表。该表用于记录风电机组产生故障时可应用的处置方案。

表 4-8 是诊断-方案关联表。该表用于记录诊断记录和处置方案的关联关系，在故障发生后，维修人员可以将诊断记录和处置方案库中的解决方案进行关联，辅助维修进程。

表 4-9 是工单表。在确定解决方案后，发起人将派发工单，以追踪故障处理进程。工单表中存储了发起人工号、下一阶段进行故障处理的操作人员编号、目前故障处理的状态以及进度描述信息。

表 4-7 process_method 表设计

序号	字段名	类型	属性	描述
1	method_id	int	PRIMARY KEY	处置方案编号
2	fault_location	int	-	故障部位
3	fault_reason	varchar(255)	-	故障原因
4	process_scheme	varchar(255)	-	处理方案

表 4-8 diagnostic_process_relationship 表设计

表名: diagnostic_process_relationship

序号	字段名	类型	属性	描述
1	diagnostic_id	int	FOREIGN KEY	诊断编号
2	method_id	int	FOREIGN KEY	方案编号
3	process_completion	int	-	完成进度
4	refresh	int	-	是否更新方案库 (0: 不更新/1: 更新)
5	final_method	varchar(255)	-	最终解决方案

表 4-9 work_order 表设计

序号	字段名	类型	属性	描述
1	order_id	int	PRIMARY KEY	工单编号
2	diagnostic_id	int	FOREIGN KEY	诊断编号
3	user_id	int	FOREIGN KEY	发起人工号
4	operation_id	int	-	操作人编号
5	process_status	int	-	进度状态
6	process_description	varchar(255)	-	进度描述

表 4-10 至表 4-12 是用户表、角色表以及用户和角色相关联的关系表。在本系统中共有两类角色：系统管理员和维修人员，每类用户对应的操作权限不同。

表 4-10 user 表设计

序号	字段名	类型	属性	描述
1	user_id	int	PRIMARY KEY	用户工号
2	user_role	int	-	用户角色
3	user_password	varchar(255)	-	用户密码

续表 4-10 user 表设计

4	user_name	varchar(255)	-	用户名
5	user_phone	varchar(255)	-	用户电话
6	user_email	varchar(255)	-	用户邮箱

表 4-11 role 表设计

序号	字段名	类型	属性	描述
1	role_id	int	PRIMARY KEY	角色编号
2	role_description	varchar(255)	-	角色描述
3	role_name	varchar(255)	-	角色名称

表 4-12 用户角色表设计

序号	字段名	类型	属性	描述
1	user_id	int	FOREIGN KEY	用户工号
2	role_id	int	FOREIGN KEY	角色编号

4.5 本章小结

本章对风电机组故障诊断系统进行了概要设计，首先叙述了风电机组故障诊断系统的整体架构，并对系统的功能模块进行了划分，然后分析并叙述了系统的核心流程，最后也叙述了数据存储的设计，构建出了数据存储的概念模型、逻辑模型和物理模型。

5 故障诊断算法设计

本章将介绍本系统在进行故障诊断时所使用的深度学习算法的具体实现细节，首先将介绍卷积神经网络（Convolutional Neural Network, CNN）的搭建流程，然后介绍如何实现压缩激励网络和卷积神经网络的结合（Squeeze and Excitation-Convolutional Neural Network, SENet-CNN），最后通过不同算法的对比实验验证算法的有效性。

5.1 数据集介绍

本算法实验所使用的数据集为来自郑州风场的运行数据，该风场配置的 SCADA 系统每隔几秒就会进行一次传感器数据采集，所形成的数据集具有 21 个状态参数，分别为：风速、湍流强度、机舱角度、转子速度、发电机转速、叶片角度_1、叶片角度_2、叶片角度_3、功率大小、功率因数、环境温度、发电机温度、总体温度、液压油温度、液压压力、轴承温度、空气压力、液压、空气角度、风速参考、湿度，本数据集中各状态参数的属性如表 5-1 所示。

表 5-1 数据集属性表

状态参数	英文名称	最大值	最小值	平均值	方差
风速	wind_speed	1.89	0.000043	0.6531	0.0636
湍流强度	turbulence_intensity	13.59	0	0.1238	0.0209
机舱角度	nacelle_direction	359.99	0.004395	203.1081	2456.6577
转子速度	rotor_speed	1.04	0	0.7420	0.0830
发电机转速	generator_speed	1.01	0.0004	0.7201	0.0781
叶片角度_1	blade_angle_1	82.59	-2.8246	6.2256	465.5223
叶片角度_2	blade_angle_2	82.19	-2.8395	6.1804	465.2940
叶片角度_3	blade_angle_3	82.0	-2.8570	6.1375	461.3882
功率大小	power	1.05	-0.013	0.5070	0.1398
功率因数	cosphi	0.99	-0.8290	0.6695	0.1847
环境温度	temp_environment	40.91	10	19.6549	12.6688
发电机温度	generator_temp	200.0	15.3238	75.2981	747.7054
总体温度	break_temperature	76.98	17.7138	39.1056	44.2048
液压油温度	temp_hydraulic_oil	52.0	20	35.7426	9.3444
轴承温度	bearing_temp	53.81	20	40.8868	33.3125
液压压力	hydraulic_pressure	242.44	-3	220.7499	3131.3151

续表 5-1 数据集状态属性表

气体压力	gear_pressure	3.50	-0.1001	2.1967	0.1779
空气角度	wind_direction	359.96	0.0140	204.5909	2595.9146
风速参考	wind_speed_refer	1.63	0.0171	0.6766	0.0601
气压	Airpressure	1028.0	996.955	1011.7001	15.0781
湿度	Humidity	97.35	3.2876	67.694	342.3984

本系统提供的故障诊断算法将依据此数据集中的状态属性诊断风电机组最为常见的六大故障，分别为：变桨系统故障、液压系统故障、偏航系统故障、测风系统故障、储能系统故障以及变流器故障，在数据集中，每个故障类型都有着对应的标签（1-6），无故障时对应的分类标签为 0，故障类型与编号对应表如表 5-2 所示。

表 5-2 数据集故障类型对应表

故障位置	故障标签
正常无故障	0
变桨系统	1
液压系统	2
偏航系统	3
测风系统	4
储能系统	5
变流器	6

因此，本实验需要通过具有 21 个状态参数的 104430 个样本数据处理七分类问题，样本示例如表 5-3 所示，该样本对应的故障类型为变桨系统故障。

表 5-3 变桨系统故障样本示例

数据集属性	属性值	数据集属性	属性值
风速($\text{m} \cdot \text{s}^{-1}$)	0.8991	发电机温度($^{\circ}\text{C}$)	35.6696
湍流强度	0.1165	总体温度($^{\circ}\text{C}$)	32
机舱角度($^{\circ}$)	208.371	液压油温度($^{\circ}\text{C}$)	35.3392
转子速度($\text{r} \cdot \text{s}^{-1}$)	0.48403	轴承温度($^{\circ}\text{C}$)	39
发电机转速($\text{r} \cdot \text{s}^{-1}$)	0.4696	液压压力(/bar)	235.1731
叶片角度_1($^{\circ}$)	27.9352	气体压力(/kPa)	2.9
叶片角度_2($^{\circ}$)	27.9188	空气角度($^{\circ}$)	208.1212
叶片角度_3($^{\circ}$)	27.9293	风速参考($\text{m} \cdot \text{s}^{-1}$)	1.053
功率大小(/dB)	-0.0004	气压(hPa)	1009.65
功率因数(/dB)	-0.0020	湿度(/%rh)	75.1394
环境温度($^{\circ}\text{C}$)	20.2157	故障标签	1

5.2 数据预处理

首先，清洗数据集中的异常值与空值，防止由于数据集异常导致算法出现误差，同时，由于各特征属性的量纲不同，为了消除不同量级之间的差异，需要对数据进行标准化^[28]。

然后对各故障类型进行统计，发现各类型对应的样本数量存在着明显偏差，即数据集存在不平衡现象，这可能会使得算法模型在训练集和测试集上的表现出现较大差异，故障类型统计图如图 5-1 所示。为了解决此问题，采用 SMOTE 过采样技术合成少数类。SMOTE 过采样技术的基本思想是通过分析数据集中少数类样本的特点来合成少数类样本，使各分类样本的数量达到均衡。经过统计图可以看出，发生故障次数最多的为测风系统故障，总计达 26780 次，因此将对其他所有类别进行过采样，处理后的故障类型统计图如图 5-2 所示，可以看到，经过处理后的数据集中各类型样本数量一致。




图 5-1 故障类型统计图（处理前）




图 5-2 故障类型统计图（处理后）

最后，按照 8:2 的比例划分训练集和测试集，分别进行模型的训练和测试。

5.3 基于 CNN 的故障诊断算法设计

在深度学习中，解决分类问题常用的一种方法是卷积神经网络模型（Convolutional Neural Networks, CNN）。本文首先尝试使用卷积神经网络来解决此多分类问题。

在搭建卷积神经网络的过程中，为了得到适合解决本问题的最优网络结构，需要通过对比实验的形式来确定神经网络的超参数，如网络层数、神经元个数等。若网络结构过于简单，即网络层数和神经元个数较少，则会导致神经网络无法全面学习特征信息，使得分类准确率较低，但若网络结构过于复杂，则又会出现训练耗时长且过拟合的问题，因此，需要对比不同层数和神经元个数的训练效果，确定最优网络结构。

为了控制变量，保证实验的准确性，首先将神经元的个数设置为 16，然后将隐藏层个数设置为 3、4、5、6、7，经过对比实验得出不同隐藏层对应的网络训练准确率和训练时长数据如表 5-4 所示，可以看到，隐藏层的层数设置为 5 最为适宜。

表 5-4 隐藏层层数对比数据

隐藏层层数	3	4	5	6	7
训练准确率	90.2%	90.8%	92.7%	91%	89.7%
训练时长	206s	301s	305s	505s	684s

然后，控制隐藏层的层数为 5 层不变，改变神经元的个数为 16、32、64、128、256，得到对应的训练准确率和训练时长数据表 5-5 所示。

表 5-5 神经元个数对比数据

神经元个数	16	32	64	128	256
训练准确率	90.5%	91.6%	92.2%	91.1%	89.2%
训练时长	210s	278s	365s	605s	728s

通过上述对比实验可以看出本网络结构应采用 5 层隐藏层，64 个神经元的网络结构，此时训练准确率最高且耗费的训练时间也在可接受的范围内，符合实际需求。

在确定了网络的结构之后此外，还应确定网络训练过程的优化器以及激活函数。在神经网络中常使用的优化器有随机梯度下降优化器（Stochastic Gradient Descent, SGD）、自适应梯度下降优化器（Adaptive Gradient, AdaGrad）、均方根传播优化器（Root Mean Square Propagation, RMSprop）以及适应性矩估计优化器（Adaptive Moment Estimation, Adam），在网络训练过程中，不同优化器使得损失函数最小化的方式不同，进而影响模型准确率和网络训练时长。激活函数的选择也同样重要，不合适的激活函数可能会在训练过程中产生梯度消失的问题，影响训练准确率。

不同优化器和激活函数的对比图如图 5-3 和图 5-4 所示。




图 5-3 不同优化器效果对比图




图 5-4 不同激活函数对比数据

由图 5-3 可以看出，Adam 优化器的训练耗时少且准确率高，因此选用 Adam 优化器。由图 5-4 可以看出 Sigmoid 函数的训练准确率低，训练耗时长，这可能是由于 Sigmoid 激活函数中具有幂运算或产生了梯度消失的问题，但 ReLU 和 Tanh 函数相较于 Sigmoid 函数训练时长大幅降低，且训练准确率大幅提升，Tanh 激活函数的准确率更高，因此最终选择 Tanh 作为本网络的激活函数。

通过上述分析，整理得到如图 5-5 所示的网络结构。输入样本尺寸为 60×21 ，每个类别对应的样本数目为 26780 个，每个样本有 21 个状态参数，每个状态参数有 60 个值，然后经过 5 个隐藏层，隐藏层的神经元个数为 64 个，接着经过全局最大池化层降低网络参数量，缩短网络训练时间，最后连接全连接层，输出对应的故障标签值（0-6）。网络激活函数选用 Tanh，优化器选择 Adam 优化器，损失函数选用交叉熵损失函数。




图 5-5 卷积神经网络结构

搭建上述网络结构后，进行模型训练，共训练了 100 轮，模型收敛后达到的准确率为 92.2%，模型训练时间为 310 秒，图 5-6(a)为模型训练过程中损失函数的收敛曲线图，图 5-6(b)为准确率的收敛曲线图。




图 5-6 基于卷积神经网络的故障诊断模型训练结果图

5.4 基于 SENet-CNN 的故障诊断技术

为了在 CNN 基础上进一步提高分类的准确性，本小节将对构建的神经网络进行改进，在卷积层和池化层之间加入 SE 模块，实现通道重要性调整^[29]。调整后的网络模型共包括 1 个输入层、4 个卷积层、2 个 SE 模块层、2 个池化层、2 个全连接层、一个输出层，总计 12 层。调整后的网络结构图如图 5-7 所示。




图 5-7 重新调整后的网络结构图

重新对模型进行训练，得到的模型训练过程损失值和准确率的变化图像如图 5-8 所示，图 5-8(a)为模型训练过程中损失函数的收敛曲线图，图 5-8(b)为准确率的收敛曲线图。可以看到和调整前的神经网络相比，加入了 SE 模块后的网络模型在本数据集上的表现更好，准确率收敛于 93.4%，比调整前上升了 1.2%，训练时间为 318 秒，同时可以看到调整后的网络模型在测试集上的损失值也较为稳定，整体网络性能更好。




图 5-8 基于卷积神经网络的故障诊断模型训练结果图

为了验证模型的性能，在实验过程中还对比了 AlexNet^[30]、VGG-16^[31]两种常用的分类算法模型，对比数据如表 5-6 所示。可以看到在四种模型的对比下，VGG-16 和 AlexNet 的准确率低且训练时长明显高于其他模型，而本文提出的 SENet-CNN 模型准确率最高且训练时长也在可接受的范围内，并未由于加入 SE 模块后参数量增多而导致模型训练时间明显变长。由此验证了此算法的有效性。

表 5-6 不同算法模型性能对比表

模型名称	准确率	训练时长
SENet-CNN	93.4%	318s
CNN	92.2%	310s
AlexNet	91.8%	378s
VGG-16	89.8%	782s

5.5 本章小结

本章详细介绍了在风电机组故障诊断系统中使用到的算法，首先介绍了在故障诊断算法中所使用到的数据集以及数据处理流程，然后介绍了本实验所采用的注意力机制的工作原理和卷积神经网络的搭建流程，最后验证了算法的有效性。

6 故障诊断系统详细设计

本章将在前一章概要设计的基础上，结合具体的业务需要和具体业务流程，分别针对状态监测模块、故障诊断模块、健康评估模块介绍实现的类图与时序图，完善和细化系统每个功能模块的具体实现方案，并对实现效果进行展示。

6.1 状态监测模块设计

该模块主要实现从不同的维度对风电机组的运行和故障状态进行统计的功能。包括地图监测、风机监测、系统监测以及部件监测四部分。业务流程图如图 6-1 所示。




图 6-1 状态监测模块业务流程图

在状态监测模块，系统将经过数据处理分析后的结果进行数据统计并调用地图接口，将数据统计后的结果显示在地图中，如各风场的在线风机数量、故障风机分析。同时，经过整理分析后的风机数据将以列表的形式呈现在风机监测界面，点击详情便可查看风机的详细状态，在部件监测模块中，系统会根据风电机组的部件类型（如测风系统、变桨系统、储能系统等）进行详情整理和列表呈现，对于关键部件，前端则会使用 3D 模型网页嵌套来直观展示系统详情。

6.1.1 地图监测

该部分实现目的为展现风电机组的数据分析结果以图表及地图标识的方式，主要包括在线监测、故障统计、获取机组信息、动态检索、报警趋势功能，类图如图 6-2 所示。

StateMonitorController 类负责接收前端请求。**IStateMonitorService** 类负责地图检测页面的查询功能，分为属性动态检索和全部查询功能。**IPhmStateStatisticsService** 类负责在线监测和报警趋势的数据获取功能，获取离线、在线、故障趋势图数据以及过去一周的报警数量。**TurbineStatusService** 类负责获取车辆数量信息以及机组报警雷达图的数据。




图 6-2 地图监测类图

下面以 IphmStateStatisticsService 服务中的在线监测和报警分析功能为例介绍统计图数据获取流程。时序图如图 6-3 所示。

在线监测功能中需要获取三类数据，分别是在线、离线以及故障风电机组的数量。首先，StateMonitorController 类接收前端请求，需要获取以上三类数据，为了获取故障风机统计数据，controller 类调用 PhmDstateStatisticsImpl 类中的 getFailureStatisticsData 方法，该方法用于获取以风电机组数量为单位的指定时间内的故障数量，在该方法中调用了 ILdpGzDataService 类中的 getFailureCountWithLocomotiveByTimeRang 方法，该方法通过对应的 Impl 类实现，并通过 mapper 操作数据库获取风电机组的故障数量，最后以 TurbineFailureDto 实体类型返回 list 数据，获取在线风机统计数据同理。

报警分析功能中需要获取在某一时间段内某机型的故障数量，该功能通过 getAlarmRadarData 方法实现。StateMonitorController 类接收前端请求后，调用 Impl 类中的 getAlarmRadarData 方法，该方法调用 PhmStateStatisticsMapper 类中的 getAlarmRadarData 方法进行数据库操作，返回在一段时间间隔中某机型的故障数量和部件名称，以键值对集合的形式返回给前端进行绘图显示。




图 6-3 地图监测时序图

地图监测实现效果如图 6-4 所示，展示所有入网的风电机组实时运行状态、实时位置在中国地图上，支持不同区域入网机组实时穿透展示，通过风场图标形式可区分出风电机组数据传输装置是否在线和移动状态，支持风机索引聚焦展示。



图 6-4 地图监测实现效果

6.1.2 风机监测

该模块主要实现对风电机组的监测，展示机组基本信息、健康评分、风电模型、关键参数的状态，并提供针对机场、机型、机号等规则筛选功能，类图如图 6-5 所示。




图 6-5 风机监测类图

本功能模块主要涉及 9 个类，其中 TurbineMonitorController 类接收前端请求，当用户进入风机监测界面中时，Controller 类调用 ITurbineMonitorService 类中的方法 getMaintainList 来获取风电机组的详细数据，如机型、机号、所属风场信息并将结果返回至 Controller 类。当用户点击列表中的详情按钮时，需要再次触发 Controller 类中的 getBasicInfoDetailPage 方法，获取机车的基本信息。ITurbineMonitorService 类中的方法都需要通过对应的 Impl 类来实现，Impl 类需要调用其他的接口类来实现，其中 ILdpDataService 类和 ILdpGzDataService 类分别用来获取指定机组的最新数据以及在最近一段时间内收到的故障数据，ITurbineStatusService 类和 ITurbineFailureItemService 分别用来获取机组状态数据和机组故障数据，时序图如图 6-6 所示。




图 6-6 风机监测功能时序图

风机监测实现效果如图 6-7 和图 6-8 所示，展示机组基本信息、健康评分、风电模型、关键参数的状态，并提供针对机场、机型、机号等规则筛选功能。




图 6-7 监测风机列表实现效果




图 6-8 风机监测详情页实现效果

6.1.3 系统监测

该功能模块用于展示风电机组各个子系统关键单元的状态以及资产目录信息，将关键单元以二维图形式展示，并提供针对机场、机型、机号等规则筛选功能。

图 6-9 为本模块的类图。当前端请求访问系统监测页面时，Controller 类接收到请求会调用 ISystemMonitorService 接口中的同名方法并由 Impl 类实现，Impl 类调用 ITurbineMonitorService 类中的方法，返回监测数量列表，包括监测系统数量、监测系统正常/异常数量，同时调用 ITurbineStatusService 类中方法，获取机组编号、机型等信息，返回值为 Page 类，实现分页查询。




图 6-9 系统监测模块类图

系统监测功能模块实现效果如图 6-10 和 6-11 所示，展示风电机组各个子系统关键单元的状态以及资产目录信息，将关键单元以二维图形式展示，并提供针对机场、机型、机号等规则筛选功能。

状态监测 / 系统监测

选择风场

选择机型

选择状态

选择机号

查询

序号	机号	状态	机型	风场	监测基线	正常数	异常数	操作
1	1001	在线	HXD2	西安风场	8	8	0	详情
2	1002	离线	HXD2	呼和浩特风场	8	8	0	详情
3	1003	在线	HXD2	呼和浩特风场	8	8	0	详情
4	1004	在线	HXD2	呼和浩特风场	8	7	1	详情
5	1005	在线	HXD2	呼和浩特风场	8	8	0	详情
6	1006	在线	HXD2	西安风场	8	8	0	详情
7	1007	在线	HXD2	西安风场	8	7	1	详情
8	1008	在线	HXD2	西安风场	8	8	0	详情
9	1009	在线	HXD2	西安风场	8	8	0	详情
10	1010	在线	HXD2	西安风场	8	8	0	详情
11	1011	在线	HXD2	西安风场	8	8	0	详情
12	1012	在线	HXD2	西安风场	8	8	0	详情
13	1013	在线	HXD2	西安风场	8	8	0	详情
14	1014	离线	HXD2	西安风场	8	8	0	详情

1

2

3

4

5

6

...

69

图 6-10 系统监测列表实现效果

详情

基本信息

机号 1001

状态 在线

机型 HXD2

风场 西安风场

监测基线 2271

正常数 2271

异常数 0

系统状态监测

测风系统

变桨系统

变频器

传动系统

液压系统

发电机冷却系统

安全链系统

偏航系统

正常

系统位置代号

产品型号

设计图号

检修维护说明书号

目录编码

供应商制造商

设计图执行版本

检修维护说明书执行版本

产品序列号

生产日期

设计图版本号

设计图执行版本

图 6-11 系统监测详情页实现效果

6.1.4 部件监测

部件监测的实现逻辑与系统监测相似，这里不再赘述。图 6-12 至 6-14 是部件监测

功能的实现效果。其中，图 6-14 为故障监控，在这里实现了 3D 模型的网页嵌套，导入关键部件的 3D 模型，用户可看到部件细节。

状态监测 / 部件监测

A1风场	HXD2	选择状态	1497	选择监测系统	查询				
序号	机号	状态	机型	风场	监测系统	监测部件	正常数	异常数	操作
1	1497	离线	HXD2	呼和浩特风场	测风系统	8	8	0	详情
2	1497	离线	HXD2	呼和浩特风场	变桨系统	6	6	0	详情
3	1497	离线	HXD2	呼和浩特风场	变流器	6	6	0	详情
4	1497	离线	HXD2	呼和浩特风场	传动系统	3	3	0	详情
5	1497	离线	HXD2	呼和浩特风场	液压系统	9	9	0	详情
6	1497	离线	HXD2	呼和浩特风场	发电机/冷却系统	6	6	0	详情
7	1497	离线	HXD2	呼和浩特风场	安全链系统	7	7	0	详情
8	1497	离线	HXD2	呼和浩特风场	偏航系统	4	4	0	详情
9	1497	离线	HXD2	呼和浩特风场	控制及通讯系统（采：控制及通讯）	4	4	0	详情
10	1497	离线	HXD2	呼和浩特风场	安全监测检测装置	2	2	0	详情
11	1497	离线	HXD2	呼和浩特风场	监控及电气信号	3	3	0	详情
12	1497	离线	HXD2	呼和浩特风场	其它	3	3	0	详情

图 6-12 部件监测列表实现效果

详情

监测风场

监测区域

监测机型

状态

监测机号

监测系统

监测部件

监测元件

监测时间

查询

基本信息

机号 1497

机型 HXD2

风场 呼和浩特风场

监测系统 测风系统

部件信息

系统位置代号

目录编码

产品型号

供应商/制造商

产品序列号

生产日期

设计图号

设计图执行版本

设计规范号

设计规范执行版本

检修维护说明书号

检修维护说明书执行版本

图 6-13 部件监测详情页实现效果




图 6-14 部件监测故障监控实现效果

6.2 故障诊断模块设计

该模块主要负责风电机组的故障管理功能。包括风电机组故障诊断、故障处理、故障分析的功能，业务流程如图 6-15 所示。




图 6-15 故障诊断模块业务流程图

在故障诊断模块中，首先会调用已训练好的算法模型来确定故障类型，确定了故障的具体类型后风场管理员可查看风场的故障列表，并进行故障统计分析生成统计图或故障分析报告。同时，在确定故障类型后，还应依据系统提供的故障处理流程进行故障处理。首先利用系统提供的处置方案库将诊断出的故障类型和解决方案进行关联，关联后系统将派发工单并指定下一流程操作人进行处置报送，审核通过后便可进行故障维修，

若审核不通过则说明处置方案库的解决方案有效性差或与故障类型的对应关系不匹配，需要对处置方案库进行更新。同时管理员还可查看维修过程中的操作日志，方便进行故障追踪和错误追责等。

下面将分别介绍各部分的详细设计方案。

6.2.1 故障诊断

该部分将经过故障诊断算法分类后的故障数据进行展示，类图如图 6-16 所示。该部分主要涉及 6 个类。FailureInfoController 类主要负责接收前端请求，FailureInfoVo 类为故障信息表的实体类，包括机组型号、机组编号、故障类型、故障开始及结束时间，审批状态等信息，IFailureInfoService 接口接收 FailureInfoVo 实例，响应前端请求，并交由 FailureInfoServiceImpl 类进行实现，其中主要包括两个方法，用于获取故障信息。FailureInfoMapper 类配合 FailureInfoMapper.xml，完成对数据库的查询操作。FailureInfoLogsVo 类用于保存故障信息操作日志，包括操作人、操作类型、操作标题等。




图 6-16 故障诊断类图

下面介绍故障诊断的处理流程，时序图如图 6-17 所示。FailureInfoController 类接收前端请求，当前端调用该类的 page 方法发出查看故障列表的请求时，Controller 调用 IFailureInfoImpl 中的 failureInfoPage 方法，Impl 类调用 FailureInfoMapper 类中的 getInfoPage 方法，由 mapper 操作数据库，并将故障列表返回至 Controller，由 Controller

发送至前端，在界面上进行展示。此时若有新故障记录需要插入，前端则调用 Controller 类中的 create 方法将请求发送至后端，Controller 调用 FailureInfoLogsImpl 类中的 failureInfoPage 方法进行数据插入，再调用 Mapper 类操作数据库完成记录添加。同时，若需要对某条故障记录进行查询，则可通过 Controller 类调用 Impl 类中的 failureInfoPage 方法，获取到 page<FailureInfo>对象后由 Controller 类发送至前端进行页面回显。




图 6-17 故障诊断功能时序图

故障诊断功能实现效果如图 6-18 至 6-20 所示，在故障诊断功能中可以查看所有故障记录并生成报告。



图 6-18 故障诊断功能实现效果——故障诊断列表

请输入关键字进行搜索

Q

	报告名	报告类型	操作
>	1 变桨系统故障	诊断报告	下载 删除
>	2 传动系统故障	诊断报告	下载 删除
>	3 液压系统故障	诊断报告	下载 删除
>	4 通讯故障	诊断报告	下载 删除

图 6-19 故障诊断功能实现效果——诊断报告列表

A 危险系数	诊断结果 危险系数高 用时 20秒 算法模板 线性回归
详细信息 发电机失磁。该故障发生后，会降低系统电压和定子电压，升高定子电流	建议方案 检查轴承表明和密封性确认是否发生故障,发现请及时修补

图 6-20 故障诊断功能实现效果——诊断报告详情

6.2.2 故障处理

该部分类图如图 6-21 所示。




图 6-21 故障处理功能类图

本功能共涉及 10 个类，共有两个控制类。其中 FailureInfoController 类接收前端请求进行故障处置报送以及关联处置方案库，IFailureInfoService 接口类负责查询故障信息，IFailureInfoLogsService 接口类负责管理处置方案库的管理功能，IFailureDisposalSchemeFailureInfoService 接口类负责关联故障信息和处置方案库、若需要对处置方案库进行更新则需要通过 iFailureDisposalSchemeService 删除原有方案库，并实现方案更新。IDisposalSubmissionService 接口类负责管理处置报送的相关信息。

DisposalSubmissionController 类为处置报送的控制器，当前端发送需要进行故障处置报送的请求时，控制器会通过 IDisposalSubmissionService 接口类实现处置报送分页查询、插入、更新等操作。

下面以关联处置方案库为例介绍故障处理流程，功能流程图如图 6-22 所示。




图 6-22 关联处置方案功能流程图

在关联故障信息和处置方案库前，首先需要查询故障信息，返回 `failureInfo` 对象，然后根据故障的具体类型通过处置报送接口判断对象是否为空，若为空，则说明处置报送未成功，不可进入关联流程，若成功则可进入下一阶段。

在下一阶段开始前，需要根据数据库查询是否该条故障记录是否已和处置方案库进行关联，若关联则通过 `Mapper` 接口删除本条关联记录，避免重复插入关联记录，然后判断是否更新处置方案库，是否更新方案库需要根据函数传入对象的属性值 `type` 来决定，若 `type` 值为 0 则需进行更新，通过数据库对处置方案库进行新增、删除或编辑操作，并新增处置方案库操作日志，若 `type` 值为 1 则不需要进行更新，将此故障信息和对应的处置方案库进行关联，并将关联记录插入至对应数据库中，至此，关联操作结束。

故障处理功能实现效果如图 6-23 至 6-28 所示，部分涉密数据已做处理。




图 6-23 故障处理功能实现——派发工单



图 6-24 故障处理功能实现效果——工单详情



图 6-25 故障处理功能实现效果——工单操作日志




图 6-26 故障处理功能实现效果——处置方案库



图 6-27 故障处理功能实现效果——故障操作记录



图 6-28 故障处理功能实现效果——故障辅助分析

6.2.3 故障分析

该部分从不同统计维度进行风电机组故障统计分析，用户可自主选择统计维度，并结合系统的筛选功能直观看到某机组的故障分布特点，本功能可提供故障处置数量统计图、故障类型分布图、故障状态分布图、系统故障排名等统计图。

本功能类图如图 6-29 所示。




图 6-29 故障分析功能类图

本功能共涉及 11 个类。FailureAnalyseController 类主要负责接收前端请求，FailureAnalyseServiceImpl 类负责接收前请求并实现故障统计分析，Controller 类会调用 Mapper 类实现数据库操作，TurbineModelMapper 类负责接收机组型号列表、TurbineAdministrationMapper 类负责接收风场列表、FailureInfoMapper 类负责查询故障信息表。此外，还涉及到五个实体类，TurbineModel 类为机组机型实体类，TurbineAdministration 类为风电机场实体类，FailureStatusDistributionVo 类为故障状态分布图实体类，包括故障类型、处置状态属性，FailureAnalyseVo 类为故障统计分析查询条件，FailureDistributionVo 为故障类型分布图实体类，包括系统划分的故障类型。

下面以绘制故障类型分布图为例介绍故障分析流程，时序图如图 6-30 所示。FailureAnalyseController 类接收前端请求，当前端调用该类的 typeDistribution 方法发出绘制故障类型分布图的请求时，Controller 类调用 FailureAnalyseService 接口中的同名方法 pointsScheme，并由 FailureAnalyseImpl 类实现，在实现过程中，首先需要调用 dateUpdate 方法修改时间格式，然后通过 failureInfoMapper 类操作数据库，统计各故障类型的数量，以键值对的形式返回至 Controller，Controller 将统计数据传回至前端进行图表绘制。




图 6-30 故障统计功能时序图

图 6-31 至 6-32 为故障统计功能的实现效果图。




图 6-31 故障分析功能实现效果



图 6-32 故障分析功能实现效果

6.3 健康评估模块设计

在健康评估模块中，需要统计风电机组部件故障情况，结合评估准则进行健康评分。评分结果和报告可下载和查看，来指导风电机组的部件维修，业务流程如图 6-33 所示。




图 6-33 健康评估模块业务流程图

6.3.1 健康状态评估

在健康评估模块中，需要根据风电机组的故障情况对风电机组整体以及关键部件的健康程度进行量化，以供工作人员对风机健康状态进行合理评估及预判。

本系统采用的健康评估算法步骤如下：

（1）搭建风电机组运维构型，根据部件重要程度确定部件健康总分。

首先基于运维构型，填写被评估主体，分为整机级、系统级、部件级和零部件级，并确定健康评分的总分，每个父部件的健康总分等于下属各子部件的健康得分总和，图 6-34 为风电机组运维构型图。

其中，本系统设定的整机级健康总分为 500 分，按照子系统的重要程度和故障频率结合专家判断设定每个子系统的健康总分，所有子系统的健康总分相加应等于整机级健康总分。以此类推，结合实际情况和专家判断设定底层各系统的健康总分。




图 6-34 风电机组运维构型图

（2） 筛查每个部件的故障，结合专家判断，判断故障等级以及需要扣除的分数

检查每个系统的故障，假设出现故障 E_1 ，则根据故障的严重程度将 E_1 值设为 1.2、1、0.8，若不存在故障 E_1 ，则将 E_1 的值设为 0，并在总分中扣除 D_1 分。各部件的健康得分计算公式见式(6-1)所示，即用总分数减去由于系统故障损失的分数。其中 S 表示该部件的健康总分， E_i 表示第 i 个故障发生的严重系数， D_i 表示发生故障所扣除的分数。

$$S' = \max\{S - \sum E_i * D_i, 0\} / S \quad (1 \leq i \leq n)$$

(式 6-1)

（3） 从下到上，依次对每个父部件进行健康评分，最终得出整机级健康总分

风电机组总体的健康度评分通过计算各个子系统的健康得分得到，计算公式如式(6-2)。其中 S_i 表示系统 i 在原始总分数中占据的分数， S'_i 表示系统 i 的得分， N 为风电机组的健康评分总分。

$$S_0 = \sum S'_i * (S_i / N) \quad (1 \leq i \leq n)$$

(式 6-2)

（4） 根据风电机组健康得分划分健康等级

计算完成后，根据健康得分范围划分健康等级，得分与等级对应表如表 6-1 所示。对于健康等级为“一般”和“异常”的风电机组，应该及时进行检修，预防故障的发生。

表 6-1 健康得分与等级对应表

健康得分	健康等级
85-100	健康
70-85	良好
60-70	一般
60 以下	异常

6.3.2 健康评估管理

健康评估管理模块分析类图如图 6-35 所示。此功能共涉及 16 个类，其中共有 4 个 Controller 类。HealthScoreController 类负责操作健康评分数据，具体操作为分页查询、根据 ID 查询、插入数据、更新数据，上述操作通过调用 HealthScoreServiceImpl 类和 IHealthScoreService 接口中的同名方法，并结合 HealthScoreMapper 类对数据库进行操作来实现。HealthComputationalFormulaTemplateController 类负责管理健康评估计算公式，HealthReportTurbineController 类负责管理整车级健康评估报告，HealthReportSystemController 类负责管理系统级健康评估报告，HealthRecordController 类负责管理健康评分记录。




图 6-35 健康评估管理模块类图

健康评估模块实现效果如图 6-36 至 6-40 所示。



图 6-36 健康评估模块实现效果——配置公式




图 6-37 健康评估模块实现效果——健康状态列表




图 6-38 健康评估模块实现效果——健康状态详情




图 6-39 健康评估模块实现效果——生成健康评估报告

健康评估 / 健康评估模型

机种	请选择机种	机型	请选择机型	查询	重置
更新日期	机种	机型	公式数量	操作	
2023-06-20 14:33:23	发电1	HXD2C	4	配置公式	
2023-07-11 13:45:07	发电2	HXD2	25	配置公式	
	发电1	HXD3D	0	配置公式	
	发电1	HXD3C	0	配置公式	
	发电1	ZT	0	配置公式	
	发电1	GX	0	配置公式	
	发电1	TEST02	0	配置公式	
	发电2	TEST003	0	配置公式	
	发电2	CHA2C1	0	配置公式	
	测试风机	测动	0	配置公式	
共 36 条				10条/页	< 1 2 3 4 >
				前往 1 页	

图 6-40 健康评估模块实现效果——管理健康评估模型

6.4 数据统计模块设计

本模块主要是对风电机组运行过程中发生的故障进行多种类型的统计，定制化统计规则，支持统计结果报送。进入一般性统计页面，录入查询条件，点击查询按钮即可得到统计结果，实现效果如图 6-41 所示。



数据统计 / 统计库

统计库

统计范围

统计时间

开始日期

至

结束日期

请输入风机的编号

查询

重置

创建时间	统计类型	机号	统计时间	创建用户	操作
2023-07-06 11:23:09	一般性统计	/	2023-06-21 00:00:00 ~ 2023-07-06 00:00:00	sys_admin	详情
2023-06-30 16:43:04	RAMS分析	1476	2023-06-01 00:00:00 ~ 2023-06-30 00:00:00	test002	详情 删除
2023-06-30 15:30:59	一般性统计		2023-06-01 00:00:00 ~ 2023-06-30 15:07:49	test002	详情
2023-06-30 15:30:55	一般性统计		2023-06-01 00:00:00 ~ 2023-06-30 15:07:49	test002	详情
2023-06-30 15:29:22	一般性统计		2023-06-01 00:00:00 ~ 2023-06-30 15:07:49	test002	详情
2023-06-30 15:25:28	一般性统计		2023-06-01 00:00:00 ~ 2023-06-30 15:07:49	test002	详情 删除
2023-06-30 15:09:23	一般性统计		2023-06-01 00:00:00 ~ 2023-06-30 15:07:49	test002	详情 删除
2023-06-30 15:09:03	一般性统计		2023-06-01 00:00:00 ~ 2023-06-30 15:07:49	test002	详情 删除
2023-06-30 15:08:13	一般性统计		2022-11-01 00:00:00 ~ 2023-06-30 15:07:49	test002	详情 删除
2023-06-30 14:45:32	一般性统计	1256	2023-06-25 00:00:00 ~ 2023-06-30 14:45:11	test002	详情 删除

共 60 条

10条/页

1 2 3 4 5 6

 前往 1 页

图 6-42 数据统计功能实现效果

选择某条记录，点击详情按钮，可查看记录明细，实现效果如图 6-43 所示。




图 6-43 数据统计功能实现效果

6.5 基础配置模块设计

本模块主要是对系统对象进行管理，包括风机管理、风场管理、用户管理等。

进入风机管理页面，展示风机列表，点击查看按钮，可以查看风机详情，可以编辑修改风机详情，还可以删除记录，实现效果如图 6-44 所示。

风场选择风场 机型选择机型 状态选择状态 搜索字段请输入机号查询 查询 重置

+ 新增

序号	风场	机型	机号	风机状态	创建人	创建时间	操作
1	测试风场	测试风机A	aaaa	离线	sys_admin	2023-07-06 11:39:12	查看 编辑 删除
2	B1风场	HXD2	8989	离线	test002	2023-06-25 14:21:13	查看 编辑 删除
3	B1风场	HXD2	8787	离线	test002	2023-06-25 14:19:10	查看 编辑 删除
4	测试风场	测试风机A	001X	离线	sys_admin	2023-06-20 13:53:37	查看 编辑 删除
5	测试风场	测试风机B	7070	离线	test002	2023-06-14 09:28:35	查看 编辑 删除
6	测试风场	测试风机A	6565	离线	test002	2023-06-13 19:21:01	查看 编辑 删除
7	测试风场	测试风机A	ccc2	离线	sys_admin	2023-06-13 19:15:13	查看 编辑 删除
8	测试风场	机辅002	1838517	离线	sys_admin	2023-06-13 15:03:15	查看 编辑 删除
9	测试风场	测试风机A	6464	离线	test002	2023-06-13 09:26:15	查看 编辑 删除
10	测试风场	测试风机A	6262	离线	test002	2023-06-12 17:32:06	查看 编辑 删除

图 6-44 风机管理

点击风场信息菜单，进入风场列表页面；点击新增按钮，可以新增一个风场信息选择一条记录；点击编辑按钮，可以修改风场信息，实现效果如图 6-45 所示。

关键字请输入风场查询 查询 + 新增

序号	风场名称	经度	纬度	分机数量	创建时间	操作
1	> 测试风场			11	2023-06-08 13:39:28	编辑 删除
3	> B1风场			22	2023-04-12 13:47:38	编辑 删除
5	> 青磁风场			0	2023-04-12 13:47:37	编辑 删除
8	> 昆湖风场			34	2023-04-12 13:47:36	编辑 删除
11	> 南宁风场			0	2023-04-12 13:47:35	编辑 删除
14	> 呼和浩特风场			134	2023-04-12 13:47:34	编辑 删除
18	> 乌鲁木齐风场			0	2023-04-12 13:47:33	编辑 删除
22	> 兰州风场			196	2023-04-12 13:47:32	编辑 删除
26	> 济南风场			0	2023-04-12 13:47:31	编辑 删除
30	> 西安风场			192	2023-04-12 13:47:30	编辑 删除

图 6-45 风场管理

进入用户管理界面，超级管理员可查看所有用户的信息，设置用户的权限，如图 6-46 至图 6-47 所示。

系统设置 / 用户管理 / 用户

分类名称

在职状态请选择在职状态 角色请选择角色 搜索字段手机号、姓名 查询 重置

+ 新增

手机号	用户名	姓名	所属组织	职务	工号	操作
18300000000	zcTest	test01	硬件组	员工	00001	编辑 重置密码 风机权限 删除
13700000000	admin	测试用户2_0	系统组			编辑 重置密码 风机权限 删除
13800000001	testuser1	测试用户1	架构组			编辑 重置密码 风机权限 删除
15000000000	sys_admin	系统管理员	运维组			编辑 重置密码 风机权限 删除
15000000001	sys_admin1	系统管理员_1	系统组			编辑 重置密码 风机权限 删除
18968666662	test002	test002	架构组			编辑 重置密码 风机权限 删除
13800000005	testuser5	测试用户5	运维组			编辑 重置密码 风机权限 删除

全部

中车研究院

技术研究部

智能产品室

硬件组

架构组

系统组

运维组

图 6-46 用户管理

编辑

* 用户名

zcTest

* 真实姓名

zcTest

年龄

25

性别

男

* 电话号码

18300000000

* 邮箱

123456789@qq.com

* 所属机构

示例机构

职位

员工

工号

00001

所属角色

cszzzz

选择

* 状态

启用

保存

取消

风机权限

手机号: 18300000000 姓名: zcTest 角色: cszzzz

风机权限:

☒ A1风场

☐ A2风场

☐ A3风场

☐ 哈尔滨风场

☐ 上海风场

☐ 南昌风场

☐ 成都风场

☐ 太原风场

☐ 郑州风场

☐ 武汉风场

☐ 西安风场

☐ 济南风场

☐ 兰州风场

☐ 乌鲁木齐风场

☐ 呼和浩特风场

☐ 南宁风场

☐ 昆明风场

☐ 青岛风场

☐ B1风场

☐ 测试风场

全选

反选

保存

取消

图(a) 编辑用户信息

图(b) 设置用户权限

图 6-47 用户权限管理

6.6 本章小结

本章根据系统概要设计，对系统的设计做了进一步的完善，首先结合业务流程图、类图、时序图对状态监测、故障诊断和健康评估三大功能模块的具体设计与代码执行逻辑进行了详细的叙述，最后，对本系统中五大功能模块的实现效果进行了展示。

60

7 系统测试与验证

为了保证风电机组故障检测系统开发完毕后符合需求分析时的预期且运行稳定，本章对系统分别进行功能性测试和非功能性测试。

7.1 测试环境

系统功能型测试主要是用于验证系统设定的功能目标能否正常实现，能否根据设定的处理流程给出正确的响应结果。本次测试具体的测试环境如表 7-1 所示。

表 7-1 系统测试环境

服务	测试环境		
硬件详情	Intel(R) Core(TM) i7-9750H CPU @ 2.60GHz 2.59 GHz		
数据库服务	MySQL: 8.0.34	TDengine: 3.0.5	Redis: 5.0.6
浏览器	Microsoft Edge、Google Chrome		
操作系统	Windows10		

7.2 功能性测试

本次功能性测试将分别针对需求分析中状态监测、故障诊断以及健康评估三大模块展开测试，测试将采用黑盒测试的方法，忽略系统内部的代码实现逻辑，通过比较预期结果与实验结果，判断测试是否通过。

表 7-2 为状态监测模块中地图监测功能的测试用例，该用例主要用来测试在进行条件筛选后各统计数据能否根据筛选条件正常显示。

表 7-2 地图监测条件筛选测试用例

用例编号	ZTJC_DT	用例名称	地图监测
测试日期	2024-3-28	优先级	高
测试目的	能否通过条件筛选实现统计图和地图模块展示		
测试准备	用户进入系统		
测试流程	1. 点击导航栏“状态监测-地图监测” 2. 在在线监测模块上方下拉框中选择对应的时间间隔筛选数据 3. 在故障统计模块上方下拉框中选择对应的时间间隔筛选数据 4. 在机型报警分析模块上方下拉框中选择对应的时间间隔筛选数据		

续表 7-2 地图监测条件筛选测试用例

测试流程	5. 在报警趋势模块上方下拉框中选择对应的时间间隔筛选数据 6. 在发电量模块上方下拉框中选择对应的时间间隔筛选数据，点击查询 7. 在地图监测上方模块下拉框中选择风场、机型、机组号信息，点击查询按钮
预期结果	1. 地图监测页面各个模块均正常显示相应的统计图，默认显示近 24 小时的统计数据 2. 在线监测模块显示对应时间间隔内的统计数据 3. 故障统计模块显示对应时间间隔内的统计数据 4. 机型报警分析模块显示对应时间间隔内的统计数据 5. 报警趋势模块显示对应时间间隔内的统计数据 6. 发电量监测模块显示对应时间间隔内的统计数据 7. 地图监测模块显示对应条件的风场图标，鼠标移近可看到筛选风场的相关信息
实际结果	测试结果符合预期，测试用例通过

表 7-3 为状态监测模块中风机监测功能的测试用例，该用例主要用来测试风机监测清单数据能否正常显示和查询。

表 7-3 风机清单查看测试用例

用例编号	ZTJC_FJ	用例名称	风机监测
测试日期	2024-03-28	优先级	高
测试目的	风机监测清单能否正常显示		
测试准备	用户进入系统		
测试流程	1. 用户点击“状态监测-风机监测” 2. 用户选择某一个风机，点击详情按钮 3. 用户选择不同的风电机组系统 4. 用户输入风场、机型、状态、机号信息，点击查询按钮		
预期结果	1. 界面展示所有入网风机的详细信息，包括机号、状态、机型、所属风场、各类数据显示正常 2. 跳转至详情界面，显示此风电机组的健康评分、系统工作图以及工况示意图 3. 页面显示经条件筛选后的风机清单，数据显示正常，符合筛选条件		
实际结果	测试结果符合预期，测试用例通过		

表 7-4 为状态监测模块中系统监测功能的测试用例，该用例主要用来测试系统监测清单数据能否正常显示和查询。

表 7-4 系统监测测试用例

用例编号	ZTJC_XT	用例名称	系统监测
测试日期	2024-03-28	优先级	高
测试目的	风机监测清单能否正常显示		
测试准备	用户进入系统		
测试流程	1. 用户点击“状态监测-系统监测” 2. 用户选择某一个风机，点击详情按钮 3. 用户输入风场、机型、状态、机号信息，点击查询按钮		
预期结果	1. 界面展示所有入网风机的详细信息，包括机号、状态、机型、所属风场、监测系统数、正常数、异常数，各类数据显示正常 2. 跳转至详情界面，显示此风电机组的基本信息 3. 选择不同的系统后，页面显示该系统的细节二维图、工作状态以及工作信息，数据显示无误 4. 页面显示经条件筛选后的风机清单，数据显示正常，符合筛选条件		
实际结果	测试结果符合预期，测试用例通过		

表 7-5 为状态监测模块中部件监测功能的测试用例，该用例主要用来测试部件监测清单数据能否正常显示和查询，网页嵌套 3D 模型是否成功。

表 7-5 部件监测测试用例

用例编号	ZTJC_BJ	用例名称	部件监测
测试日期	2024-03-28	优先级	高
测试目的	部件监测清单能否正常显示		
测试准备	用户进入系统		
测试流程	1. 用户点击“状态监测-系统监测” 2. 用户选择某一个风机记录，点击详情按钮 3. 在故障数据监控区滑动鼠标滚轮，观察模型状态 4. 用户输入风场、机型、状态、机号信息，点击查询按钮		
预期结果	1. 界面展示所有入网风机的详细信息，包括机号、状态、机型、所属风场、监测部件数、正常数、异常数，各类数据显示正常		

续表 7-5 部件监测测试用例

预期结果	2. 跳转至详情界面，显示此风电机组的基本信息 3. 模型随着鼠标滚轮的移动实现放大缩小，模型显示、缩放正常 4. 页面显示经条件筛选后的风机清单，数据显示正常，符合筛选条件
实际结果	测试结果符合预期，测试用例通过

表 7-6 为故障诊断功能的测试用例，该用例主要用来测试故障记录清单数据能否正常显示和查询，故障诊断报告能否正常生成并下载。

表 7-6 故障诊断测试用例

用例编号	GZZD	用例名称	故障诊断
测试日期	2024-03-29	优先级	中
测试目的	故障监测清单能否正常显示，报告能否正常显示并下载		
测试准备	用户进入系统		
测试流程	1. 用户点击“故障中心-故障诊断” 2. 选择一条故障诊断记录，点击删除 3. 选择一条故障诊断记录，点击下载		
预期结果	1. 界面展示所有入网风机的故障总数、故障类型数以及故障位置数，显示故障清单，数据显示无误 2. 此条故障诊断记录删除，页面清单更新 3. 跳转至诊断报告列表页，自动定位至此条诊断信息对应的报告记录项 4. 点击报告名左侧的下拉框，在线显示诊断信息，所有数据显示无误 5. 下载诊断报告文件，命名为“诊断报告_车号.pdf”，文件内容与系统内容显示一致		
实际结果	测试结果符合预期，测试用例通过		

表 7-7 为故障诊断模块中故障分析功能的测试用例，该用例主要用来测试能否根据用户筛选条件或者某条故障记录生成故障统计图。

表 7-7 故障分析测试用例

用例编号	GZZD_GZFX	用例名称	故障分析
测试日期	2024-03-30	优先级	中
测试目的	能否根据查询条件生成故障统计图		

续表 7-7 故障分析测试用例

测试准备	用户进入系统
测试流程	1. 用户点击“故障中心-故障分析” 2. 选择筛选条件和报告内容 3. 点击查询按钮 4. 点击导出报告按钮
预期结果	1. 界面显示根据筛选条件生成的各类统计图 2. 鼠标靠近统计图看到对应的统计数据，统计数据正常无误 3. 自动下载故障分析报告，命名为“故障统计分析_日期.pdf”，点开PDF文件后统计图与页面显示一致
实际结果	测试结果符合预期，测试用例通过

表 7-8 为故障诊断模块中故障处理功能的测试用例，该用例主要用来测试故障处理流程能否正常进行。

表 7-8 故障处理测试用例

用例编号	GZZD_GZCL	用例名称	故障处理
测试日期	2024-03-29	优先级	高
测试目的	系统能否正常派发工单		
测试准备	用户进入系统		
测试流程	1. 用户点击“故障中心-故障处理-派发工单” 2. 用户选择某一个故障记录，点击下拉按钮 3. 用户选择关联的处置方案库编号 4. 输入故障辅助分析处理意见，点击上传 5. 用户点击操作日志按钮 6. 点击某条操作记录		
预期结果	1. 界面展示所有派发的工单信息，包括工单号、故障模块、故障名称、故障开始日期、负责人以及负责工程师 2. 显示工单详情信息以及故障处理进度，工单号、故障名称、负责人等消息不可编辑 3. 用户可在知识库选项卡中选择对应的处置方案库编号，点击后可查看对应处置方案的详情信息 4. 用户可在知识库选项卡中选择对应的处置方案库编号，点击后可查看对应处置方案的详情信息		

续表 7-8 故障处理测试用例

预期结果	5. 若为超级管理员，则可进入故障操作记录页面，对操作记录进行删除或修改操作，否则显示无权限编辑的警告 6. 跳转至操作日志界面，显示此工单对应的操作人、操作时间、操作类型等信息，信息显示无误
实际结果	测试结果符合预期，测试用例通过

表 7-9 为健康评估模块中健康评估报告管理功能的测试用例，该用例主要用来测试健康评估报告能否正常生成并下载，数据显示是否正确。

表 7-9 健康评估报告管理测试用例

用例编号	JKPG1	用例名称	健康评估报告管理
测试日期	2024-03-31	优先级	中
测试目的	能否生成健康评估报告		
测试准备	用户进入系统		
测试流程	1. 用户点击“健康评估” 2. 选择一条健康记录点击查看按钮 3. 点击预览按钮 4. 点击导出报告按钮		
预期结果	1. 界面显示入网风机的健康状况概览情况，以页面卡片形式展示入网风机的总数、健康状态风机数量、良好状态风机数量、一般状态风机数量以及异常状态风机数量，展示健康状况列表，包括机号、风场、机型、健康等级以及指标总分等属性值，数据显示无误，点击可查看详情 2. 跳转至健康评估报告页面，显示此风机的基本信息以及工作结构图 3. 显示健康评估报告的预览文件，文件信息数据与页面显示一致，页面排版正常 4. 自动下载健康评估报告，命名为“健康评估_日期.pdf”，点开 PDF 文件后与预览文件、在线页面显示内容一致		
实际结果	测试结果符合预期，测试用例通过		

表 7-10 为健康评估模块中健康评估模型管理功能的测试用例，该用例主要用来测试健康评估模型能否正常配置并更新。

表 7-10 健康评估模型管理测试用例

用例编号	JKPG2	用例名称	健康评估模型管理
测试日期	2024-03-31	优先级	中
测试目的	能否管理健康评估模型		
测试准备	用户进入系统		
测试流程	1. 用户点击“健康评估-健康评估模型” 2. 选中第一个健康评估模型并点击配置公式按钮 3. 点击编辑公式，修改 A1 对应的权重为 0.1，A2 对应的权重为 0.2 4. 点击编辑等级，修改健康得分对应的等级		
预期结果	1. 进入公式配置界面 2. 系统更新模型公式，并刷新前端界面 3. 系统更新模型得分等级，并刷新前端界面		
实际结果	测试结果符合预期，测试用例通过		

7.3 非功能性测试

非功能性测试的目标主要是用来保证系统在满足功能性需求的基础上，也能满足系统易用性、安全性等非功能性需求。本系统的非功能性测试主要分为三部分：性能测试、安全性测试以及易用性测试。

7.3.1 并发性测试

系统非功能性测试主要是测试系统的易用性、可靠性、安全性、可移植性要求等，在本次非功能性测试中，将性能测试作为测试的重点内容，使用 JMeter 测试工具，衡量系统性能是否达到需求目标。

JMeter 是一个用来执行软件测试行为并测试软件性能的开源软件，它可以用于模拟服务器所承受的重负载，以测试其强度或分析不同负载类型下的应用的整体性能。

首先将使用 JMeter 进行系统并发测试，测试目的是验证在多个用户同时访问的情况下，系统能否在短时间内给出正确响应。这里里使用 JMeter 建立了一个线程组。通过设置时长为 1 秒，线程数为 1000，来模拟 1000 个用户并发访问故障诊断页面的情况，结果如图 7-1 所示，可以看到页面的平均响应时间为 74ms，访问成功率为 100%，结果

符合预期，测试通过。

Label	# 样本	平均值	中位数	90% 百分位	95% 百分位	99% 百分位	最小值	最大值	异常 %	吞吐量	接收 KB/sec
pred	1000	74	47	171	230	304	4	431	0.00%	710.2/sec	2167.44
总体	1000	74	47	171	230	304	4	431	0.00%	710.2/sec	2167.44

图 7-1 并发量为 1000 的测试情况

在测试过程中，还分别进行了并发量为 100、500、2000、2500 的测试，将具体的测试数据进行整理分析后得到表 7-11。可以看到，本系统在同时访问数达到 2500 时仍可以正常响应且响应速度也在可接受的范围内，通过了并发性测试。

表 7-11 并发测试

并发数	响应时间	吞吐量	访问成功率
100	9ms	100.4/sec	100%
500	13ms	386.7/sec	100%
1000	74ms	710.2/sec	100%
2000	117ms	919.1/sec	100%
2500	2141ms	649.7/sec	100%

测试结果表明，系统响应时间和成功率均符合要求，并发性测试通过。

7.3.2 安全性测试

本次安全性测试主要用来验证本系统是否实现不同登录角色的权限控制。安全性测试用例如表 7-12 所示，可以看到系统通过对不同系统用户设置权限和登录验证机制可以有效对用户数据进行隐私保护，通过安全性测试。

表 7-12 安全性测试用例

测试内容	测试步骤	期望结果	实际结果	是否通过测试
用户权限	分别使用系统管理员和维修人员两种登录身份进入系统	两种角色进入的界面不同，当点击不属于角色权限外的页面时，系统提示错误	两种角色可进入的页面不同，在进入非法页面时，系统提示“权限不匹配”	是
登录验证	用户跳过登录界面，直接通过网址访问特定的功能界面	系统自动返回至登录界面，提示用户登录后才可进入系统	系统跳转至登录界面，用户收到错误信息“登录后才可访问”	是

7.3.3 易用性测试

易用性测试无硬性衡量指标，主要是根据用户反馈判断系统界面是否美观、应用逻辑是否合理，对于初次使用系统的用户是否简单易上手等。

本次测试的测试人群为公司内部人员，通过以系统使用感受为主题的问卷进行调查，根据反馈，在测试的 84 名人员中，全部测试人员均反映系统界面美观、逻辑合理、操作简单、提示合理、符合产品逻辑。由此判断系统通过了易用性测试。

7.4 本章小结

本章分别对系统进行了功能性测试和非功能性测试，通过对每个功能模块编写详细的测试用例，对系统功能进行黑盒测试。最后对系统的并发性、安全性和易用性进行了非功能性测试。测试的结果表明，系统的整体功能表现通过测试。

8 总结与展望

随着国家对新能源的需求越来越高，风力发电以其清洁、可再生的优质特性受到大力提倡。然而由于风电机组所处的自然环境恶劣，故障维修所需的人力物力成本高昂，本文依托于企业的真实项目，设计并实现了基于深度学习的风电机组故障诊断系统。本章节将对全文进行总结，同时发现系统不足，提出未来的改进方案。

8.1 全文总结

本文的主要工作内容总结如下：

（1）项目背景分析与技术调研

介绍了风电机组故障诊断系统产生的背景，分析了在实现风电机组线上监控过程中遇到的难点，调研了此课题的技术研发现状和系统研发现状，确定项目需要解决的问题。

（2）风电机组故障诊断系统需求分析

这一部分在进行市场调研的基础上，对系统的功能性需求做了整体概述，确定了本系统的主要功能模块：状态监测、故障诊断和健康评估，对主要模块进行了详尽的用例描述。同时对非功能性需求进行了分析。

（3）风电机组故障诊断系统概要设计

这一部分在需求分析的基础上，对系统进行了概要设计，首先进行了系统整体架构设计。然后进行系统功能模块设计，确定系统功能结构图。之后进行了系统核心流程设计，通过流程图的形式进行了系统功能流程分析。最后进行了数据存储设计，借助 PowerDesigner 工具设计概念、逻辑、物理模型并给出具体的表结构。

（4）风电机组故障诊断系统算法设计

这一部分主要介绍系统进行故障诊断的算法设计，详细介绍了卷积神经网络的搭建流程和优化过程，最终确定使用 SENet-CNN 模型作为本系统中采用的故障诊断模型，并通过多种算法模型对比得出本算法在解决故障诊断问题中的优越性。

（5）风电机组故障诊断系统详细设计

这一部分在概要设计的基础上，进一步完善了系统的设计，首先通过系统核心 workflows 对系统主要模块的工作流程进行了分析，然后结合类图和时序图说明每个模块的实现逻辑，对每个功能模块都进行了详细的分析。

（6）风电机组故障诊断系统测试验证

这一部分在详细设计的基础上，以需求分析为基础，进行功能与非功能性测试。

总体而言，系统的设计与实现过程顺利，系统搭建效果符合预期要求。

8.2 系统展望

随着能源需求的不断变化，在系统上线后，需要根据用户需求对系统体系结构和实现逻辑进行调整，这是不可避免的。

在已开发完成的系统中，以下部分还有着优化空间：

（1）在状态监测方面，目前是根据时间维度统计各数据量，且统计图筛选条件局限于日期项。未来可以提供更多维度的统计数据，实现多角度、全方位的线上监测。

（2）在健康评估方面，目前是根据数值分析来确定健康评分，仍存在需要专家判断的部分，日后可设计机器学习的相关方法实现自动健康评分，进一步降低评分过程中的主观因素。

综上所述，目前系统的主要展望方向是希望能够实现风电机组的全方面监控、全流程故障处理和全自动健康量化，使得本系统具备更加出色的功能和更好的用户体验。

参考文献

- [1] 张传远.基于 DBN 网络的风电机组故障检测研究[J].风力发电,2023(5):21-24.
- [2] 钱小毅,张宇献.基于动态特征矩阵的 k 近邻风电机组故障检测方法[J].仪器仪表学报,2019,40(6):202-212.
- [3] 龙寰,杨婷,徐劲辉,顾伟.基于数据驱动的风电机组状态监测与故障诊断技术综述[J].电力系统自动化,2023,47(23):55-69.
- [4] 马康原,李忠虎,王金明,杨立清,芦建文.基于 XGBoost 模型的风电机组故障检测[J].内蒙古科技大学学报,2023,42(4):349-353.
- [5] 卢莉莉.大数据技术在风电机组状态监测中的应用[J].中文科技期刊数据库（全文版）工程技术,2023(10):21-23.
- [6] 呼木吉乐图.基于动态载荷的风电机组故障诊断技术[J].机械制造,2023,61(7):76-83.
- [7] 朱乾鏊,刘德昌,王超.和谐电力机车健康评估研究[J].技术与市场,2023,30(4):40-44.
- [8] 郑启山,朱少红,陈长红,常海青,晏锡忠,魏晨曦.风电机组在线状态监测与数据分析系统设计[J].电脑知识与技术,2024,20(1):36-40.
- [9] 董礼,苏宝定,张振宇,张焱,刘方涛.智能风电机组叶片故障监测系统设计与实现[J].电工技术,2021(20):75-78+91.
- [10] 张雁忠,刁嘉,翟化欣,胡晓虎,杨俊丰.基于嵌入式技术的风电场智慧监控系统[J].微型电脑应用,2023,39(10):91-94.
- [11] 孟良,苏元浩,许同乐,孔晓佳,兰孝生,李云凤.并行卷积神经网络的风电机组故障诊断方法[J].太阳能学报,2023,44(5):449-456.
- [12] 伍云浩,滕伟,王罗,彭迪康,武鑫,柳亦兵.数字孪生驱动的风电机组变桨系统故障诊断[J].风机技术,2023,65(2):63-69.
- [13] 杨岗,徐五一,邓琴,卫昱乾,李芾.基于振动信号的滚动轴承复合故障诊断研究综述[J].西华大学学报（自然科学版）,2024,43(1):48-69.
- [14] 李鹏飞,闫佳,左蓬,苏伟.基于 EMD 和 Hilbert 谱的风电机组滚动轴承故障诊断方法研究[J].微型电脑应用,2024,40(1):36-40.
- [15] 王普,李天垚,高学金,高慧慧.基于 LMD 和 MSEE 的滚动轴承复合故障特征提取方法[J].轴承,2019(3):63-69.
- [16] Li J ,Yao X ,Wang X , et al. Multiscale local features learning based on BP neural network for rolling bearing intelligent fault diagnosis [J]. Measurement, 2020, 153 107419-107419.
- [17] Xu T, Ji J, Kong X, et al. Bearing fault diagnosis in the mixed domain based on crossover-mutation chaotic particle swarm[J]. Complexity, 2021,1-13.
- [18] 孙海蓉,曹瑶佳,张雨晴.基于 WKFCM-SMOTE 和随机森林的风电机组故障诊断[J].山东电力技术,2022,49(3):65-70.
- [19] Carroll J, Koukoura S, McDonald A, et al. Wind turbine gearbox failure and remaining useful life

- prediction using machine learning techniques[J]. Wind Energy, 2019, 22(3): 360-375.
- [20] 颜毅斌,陈清化,吉天平,李晟方.基于改进生成对抗网络的风电机组主轴承故障诊断研究[J]. 机电工程技术,2024,53(2):103-106.
- [21] Chen H ,Daochuan G ,Minghan Y , et al. A data-driven adaptive fault diagnosis methodology for nuclear power systems based on NSGAI-CNN [J]. Annals of Nuclear Energy, 2021, 159.
- [22] Ye Z, Yu J. AKSNet: A novel convolutional neural network with adaptive kernel width and sparse regularization for machinery fault diagnosis[J]. Journal of Manufacturing Systems, 2021, 59: 467-480.
- [23] Rezamand M, Kordestani M, Carriveau R, et al. A new hybrid fault detection method for wind turbine blades using recursive PCA and wavelet-based PDF[J]. IEEE Sensors journal, 2019, 20(4): 2023-2033.
- [24] 杨鸿泰.基于 PHM 技术的铁路客车转向架故障预测系统[J].智能城市,2024,10(1):27-29.
- [25] Soni D, Makwana A. A survey on MQTT: a protocol of internet of things (IoT)[C]//International conference on telecommunication, power analysis and computing techniques (ICTPACT-2017). 2017, 20: 173-177.
- [26] 熊风光,陈霖,韩慧妍,张元,庞敏,焦世超.基于 MQTT 协议的轻量化文本信息分发技术研究[J]. 计算机技术与发展,2024,34(2):90-97.
- [27] 李嘉钰.MQTT 服务器动态负载均衡的研究与应用[J].软件工程与应用,2020,9(4):262-271.
- [28] 辛鹏,杨剡勋,文孝强.基于改进 SE-CNN 的风电机组故障诊断方法研究[J].吉林化工学院学报,2023,40(1):34-40.
- [29] 杨志勇,王俊杰,金磊.基于 SE-CNN 的人体摔倒检测方法[J].计算机工程,2022,48(6):270-277.
- [30] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [31] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. CoRR, 2014, abs/1409.1556.

致 谢

首先感谢我的论文指导老师邸晓飞老师，感谢您不厌其烦的指导和付出，感谢您在服务外包大赛中一点一滴的教导，在保研、实习阶段为我提供的宝贵建议，在您身上学习到的精益求精的学术态度也将成为我人生中的宝贵财富，在此向您表示衷心的感谢！

此外，我还要特别感谢永远支持鼓励、永远无私帮助我、永远在为我考虑的我的姐姐，在未来全新的人生阶段里，我要祝你永远永远都幸福！感谢我永远的底气我的老爸老妈，你们的爱让我在很多低谷时刻都能够重新感到幸福！感谢永远不吝啬对我的夸奖，在每个关键时刻都向前推我一把，我大学生活中的小太阳、永远的好朋友阿俊同学！

祝自己在未来的人生中可以随性而为！幸福快乐！学有所得！